




Diffusion Improves Graph Learning

NeurIPS 2019

汇报人：庞媛媛

2024/03/24

目 录



背景



理论



实验



总结

CNN

固定数量的邻域节点排序，与相同数量的卷积核参数相乘求和。

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

图片

4		

Convolved
Feature

卷积得到的特征

Step1: 构建邻域。


找到固定数量的邻居节点。

对找到的邻居节点进行排序。



Step2: 对邻域的点与卷积核参数做内积。

GNN

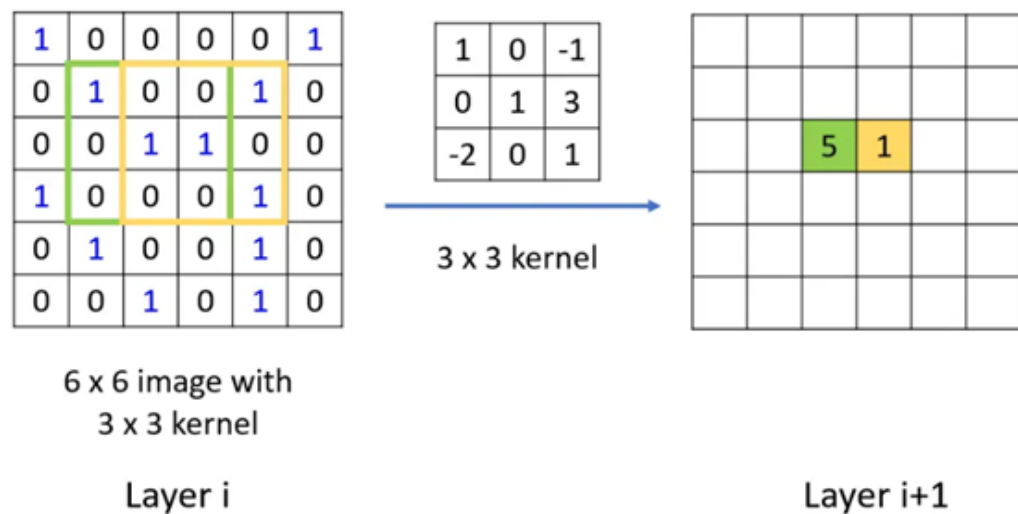
借助神经网络的能力如深度特征抽取等来处理图结构的数据，直观结构：




为什么需要？




欧氏空间卷积&非欧氏空间卷积



对于欧氏空间的图结构，通过卷积核滑动整个图区域。

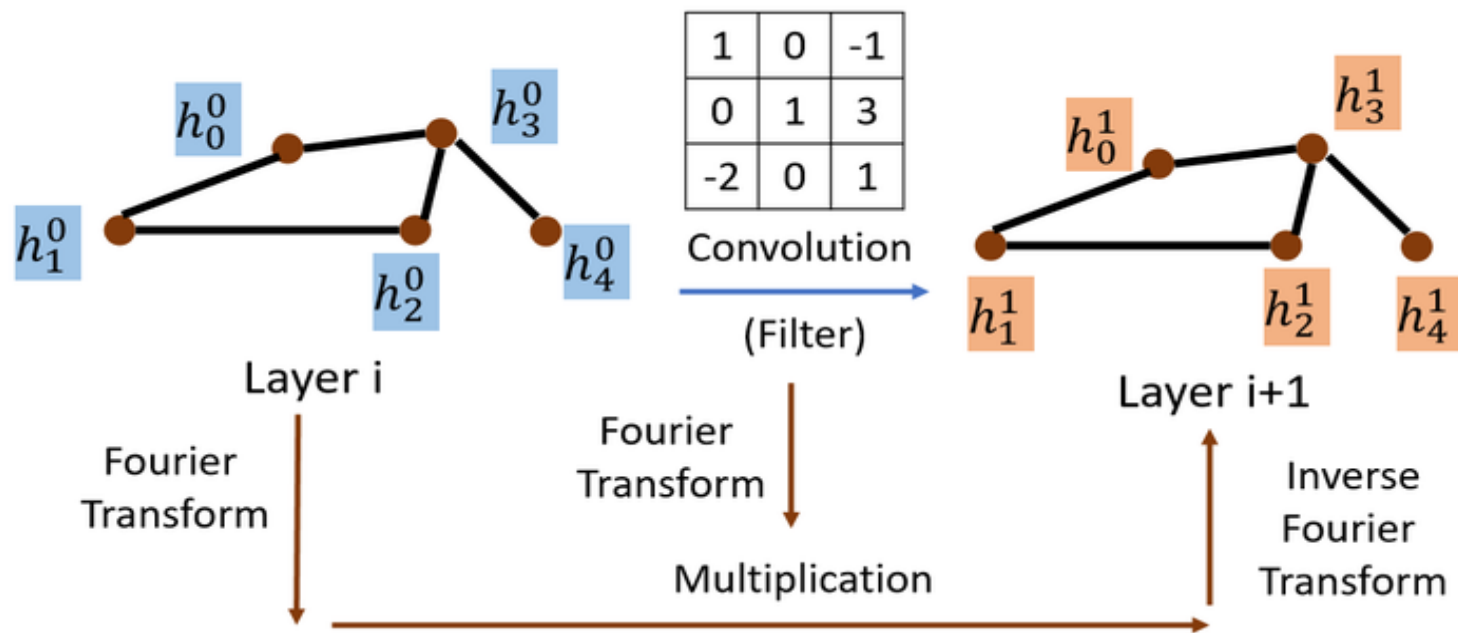


对于非欧氏空间的图结构，无法找到固定大小的卷积核滑动整个图区域。



GCN

方案一：谱域GCN（图卷积运算~从图信号中去除噪声）



- **基本思路：**先将空域输入信号和空域卷积核通过图傅里叶变换转换到谱域，然后在谱域中相乘，再通过反傅里叶变换转换回空域。
- **经典谱域GCN：**SCNN、ChebNet、GCN
- **缺点：**不适用于有向图；假定图结构是固定的；复杂度问题

➤ 图傅里叶变换：

拉普拉斯特征向量~基函数，拉普拉斯矩阵的特征值 ~ “频率”

① 图上的信号： $x = [x_1, x_2, \dots, x_n]^T \in \mathbb{R}^n$

② 空间域→谱域： $\hat{x} = U^T x \in \mathbb{R}^n$


③ 谱域→空间域： $x = U \hat{x}$

$$L = U \Lambda U^{-1} = U \begin{bmatrix} \lambda_1 & & \\ & \dots & \\ & & \lambda_n \end{bmatrix} U^{-1}, U = (\vec{u}_1, \vec{u}_2, \dots, \vec{u}_n)$$

GCN

方案二：空域GCN（参考CNN对每个节点的邻居节点加权求和）

- 问题：图结构不存在固定的邻域结构
- 每一个节点的邻域大小不同且是变化的
 - 同一领域内的节点不存在顺序性



(a)

(a) 2D Convolution: 每个像素是一个节点，红色节点的像素值与邻居节点的像素值加权平均。节点的邻居是有序的，且大小相同且固定。



(b)

(b) Graph Convolution: 取红色节点及其邻域的节点特征的平均值。与图像数据不同，节点的邻域是无序的，大小不同且是可变的。

GCN

方案二：空域GCN

➤ 解决思路：①使用随机游走的方法，根据被选中的概率期望大小选择固定数量的邻居节点。


②根据节点被选择的概率期望对邻域排序。

Step1: $P=D^{-1}S$ (P : 图上的随机游走转移矩阵; S : 相似度矩阵 (类似邻接矩阵); D : 度矩阵)

Step2: 归一化 P 作为转移矩阵

Step3: 定义多步的转移期望 $Q^{(0)} = I, Q^{(1)} = I + P, \dots, Q^{(k)} = \sum_{i=0}^k P^i$ 。

每一项 $Q_{ij}^{(k)}$ 表示 k 步内，节点 i 出发到节点 j 的期望访问数。



Step4: 根据期望大小选择邻域

$\pi_i^{(k)}(c)$ 表示 k 步内由节点 i 出发的访问期望数第 c 大的节点，则选择的邻域顺序: $Q_{i\pi_i^{(k)}(1)} > Q_{i\pi_i^{(k)}(2)} > \dots > Q_{i\pi_i^{(k)}(N)}$


Step5: 做1D卷积 $Conv_1(\mathbf{x}) = \begin{bmatrix} x_{\pi_1^{(k)}(1)} & \dots & x_{\pi_1^{(k)}(p)} \\ x_{\pi_2^{(k)}(1)} & \dots & x_{\pi_2^{(k)}(p)} \\ \vdots & \ddots & \vdots \\ x_{\pi_N^{(k)}(1)} & \dots & x_{\pi_N^{(k)}(p)} \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_p \end{bmatrix}$

GCN

2个术语

Aggregate: 用当前层的某节点邻居状态特征更新下一层该节点的状态特征。

Readout: 把所有节点的状态特征集合起来代表整个图的状态特征。




GCN


2个术语

Aggregate: 用当前层的某节点邻居状态特征更新下一层该节点的状态特征。

Readout: 把所有节点的状态特征集合起来代表整个图的状态特征。




NN4G—经典空域GCN



方法：直接将节点的邻域信息相加来进行图卷积

$$\text{Aggregate: } \mathbf{h}_v^{(k)} = f \left(\mathbf{W}^{(k)T} \mathbf{x}_v + \sum_{i=1}^{k-1} \sum_{u \in N(v)} \Theta^{(k)T} \mathbf{h}_u^{(k-1)} \right)$$

$$\text{矩阵形式 } \mathbf{H}^{(k)} = f(\mathbf{XW}^{(k)} + \sum_{i=1}^{k-1} \mathbf{AH}^{(k-1)}\Theta^{(k)})$$



Readout: 通过对每一层的所有节点信息的取平均获得每一层图的representation，并对每一层的信息通过求和平均的方式进行整个图的representation更新，即：

$$\mathbf{h}_G = \text{sum/mean/sum}(\mathbf{h}_1^{(K)}, \mathbf{h}_2^{(K)}, \dots, \mathbf{h}_n^{(K)})$$

GDC

GCN通常通过直接（一跳）邻居进行信息传递，捕获信息受限。

➤ 问题：如何克服？转向更具表现力的邻居

➤ 解决思路：空域GCN能在更深的层中利用高阶信息但将每层的信息限制在一跳邻域

频域GCN能捕捉更复杂的图属性但表现经常劣于MPNN（消息传递神经网络，当时的图卷积网络）

结合优势→受光谱启发的执行消息传递的新技术，聚合更大邻域的信息



图扩散卷积GDC



通过稀疏化广义的图扩散
生成的新图构建的




Page Rank: 利用网页简单的超链接来计算网页的分值，从而给网页进行排名的一种算法。

思想：估计悠闲的上网者分布在各个网页上的概率。顶点之间是随机游走的

模型：互联网~有向图，网页~节点

$$P(A) = P(C) + \frac{P(B)}{2}$$



Personalized PageRank: 顶点之间偏向于一组起始顶点（个性化）

Heart kernel: 局部扩散方法，相比PPR将更大的权重放在了距离种子节点（扩散起点）较近的节点

广义的图扩散

通过扩散矩阵定义广义图扩散: $\mathbf{S} = \sum_{k=0}^{\infty} \theta_k \mathbf{T}^k$

无向图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$, $N = |\mathcal{V}|$ 表示节点数, $\mathbf{A} \in \mathbb{R}^{N \times N}$ 表示邻接矩阵, \mathbf{D} 度矩阵。

➤ 广义过渡矩阵 \mathbf{T} :

随机游走过渡矩阵 $\mathbf{T}_{\text{rw}} = \mathbf{A}\mathbf{D}^{-1}$: \mathbf{A} 中添加 (加权) 自循环来调整随机游走, 即懒惰随机游走

$$\mathbf{T}_{\text{sym}} = (\mathbf{w}_{\text{loop}} \mathbf{I}_N + \mathbf{D})^{-1/2} (\mathbf{w}_{\text{loop}} \mathbf{I}_N + \mathbf{A}) (\mathbf{w}_{\text{loop}} \mathbf{I}_N + \mathbf{D})^{-1/2}$$

对称过渡矩阵 $\mathbf{T}_{\text{sym}} = \mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2}$

➤ 加权系数 θ_k :


PPR $\mathbf{T} = \mathbf{T}_{\text{rw}}$, $\theta_k^{\text{PPR}} = \alpha(1 - \alpha)^k$ 远距传输概率 $\alpha \in (0, 1)$

heart kernel $\mathbf{T} = \mathbf{T}_{\text{rw}}$, $\theta_k^{\text{HK}} = e^{-t} \frac{t^k}{k!}$ 扩散时间为 t

Kipf & Welling 提出的近似图卷积, 当 $\theta_1 = 1$ and $\theta_k = 0$ for $k \neq 1$ 使用 $\mathbf{T} = \tilde{\mathbf{T}}_{\text{sym}}$ with $\mathbf{w}_{\text{loop}} = 1$

其他方法: 将优化稀疏类似于 θ_k 的方法作为其训练过程的一部分, 但表现差于上述简单系数。

图扩散卷积




本质上：GDC是用广义图扩散矩阵 S 的稀疏化版本 \tilde{S} 交换普通邻接矩阵 A

Graph diffusion Density defines edges Sparsify edges

- Step1: 开始时所有注意力放在节点 v 上，对原始图进行扩散，不断将一些注意力传递给邻居，将注意力分散开。
- Step2: 一段时间后，扩散后的密度定义了起始节点 v 的边。
- Step3: 通过对每个节点这样做，得到了一个矩阵 S ，它定义了一个新的连续加权图（稠密）。
- Step4: 移除所有权值较小的边。对每个节点这样做一次，得到一个新的稀疏的加权图和稀疏矩阵 \tilde{S} 。

图扩散卷积



几点思考：

- 图扩散平滑图上的邻域~图像的高斯滤波器去噪
- 稀疏化：前提“四/六度分离”导致的局部化；top-k或阈值
- 局限：基于同类假设，即“物以类聚”。扩展到异亲关系（即“异性相吸”）表现不佳。

GDC四步骤：

1. 计算过渡矩阵 T : T_{rw} / T_{sym}
2. 广义图扩散矩阵 S : $S = \sum_{k=0}^{\infty} \theta_k T^k$
3. 截断小值稀疏化得到稀疏矩阵 \tilde{S}
4. 计算过渡矩阵 $T_{\tilde{S}}$

实验设置、数据集、模型

➤ 过渡矩阵：带自循环的对称过渡矩阵 $\tilde{T}_{\text{sym}} = (I_N + D)^{-\frac{1}{2}}(I_N + A)(I_N + D)^{-\frac{1}{2}}$

列随机游走过渡矩阵 $T_{rw}^{\tilde{S}} = \tilde{S}D_{\tilde{S}}^{-1}$

加权系数：heart kernel和 PPR

扩散矩阵 S ：使用阈值或 top-k 进行稀疏化

➤ 6个数据集：引用图 CITESEER、CORA 和 PUBMED，共同作者图 COAUTHOR CS，
共同购买图 AMAZON COMPUTERS 和 AMAZON PHOTO

➤ 9个模型：

有监督的模型：图卷积网络（GCN）、图注意网络（GAT）、跳跃知识网络（JK）、图同构网络（GIN）、ARMA

无监督的模型：degree corrected随机块模型（DCSBM）、谱聚类、DeepWalk、Deep Graph Infomax（DGI）

实验结果

➤ 半监督的节点分类




Figure 3: Node classification accuracy of GNNs with and without GDC. GDC consistently improves accuracy across models and datasets. It is able to fix models whose accuracy otherwise breaks down.

有 GDC 和没有 GDC 的 GNN 的节点分类准确率。在不同的模型和数据集上，GDC 都能持续提高准确率。它还能修复那些精度不佳的模型。

➤ 无监督的聚类




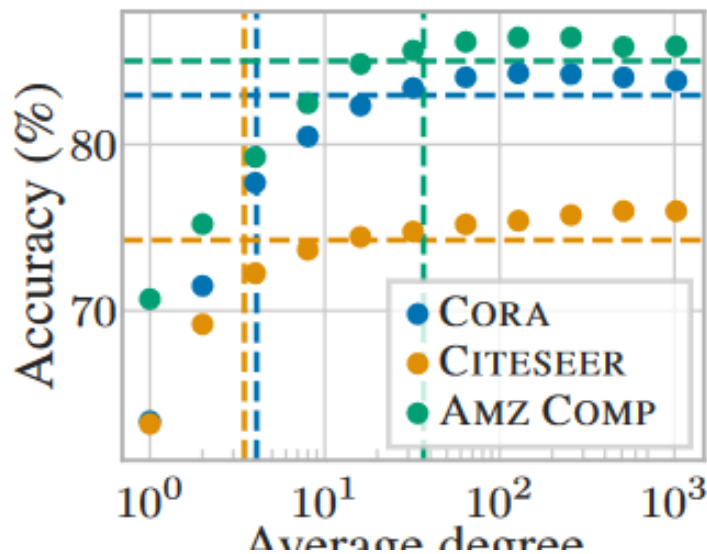
Figure 4: Clustering accuracy with and without GDC. GDC consistently improves the accuracy across a diverse set of models and datasets.

使用和不使用 GDC 时的聚类精度。在不同的模型和数据集中，GDC 始终能提高准确率。

5个问题

Q1: GDC 是否会增加图密度?


- GDC需要大致相同的平均度才能超越原始图的性能，与数据集及其平均度无关。
- 存在最佳稀疏度
- 稀疏化有利于计算，提高预测性能。



GCN+GDC 精确度（使用 PPR 和 top-k）

Q2: 如何选择过渡矩阵 T ?


- T_{rw} 性能更差
- 自循环没有明显影响



使用 T_{sym} 和 T_{rw} 对 GCN+GDC 精度的差异（使用 PPR 和 top-k，百分点）

Q3: 标签率对 GDC 有何影响?

- 标签率越稀疏，GDC 的改进幅度越大。



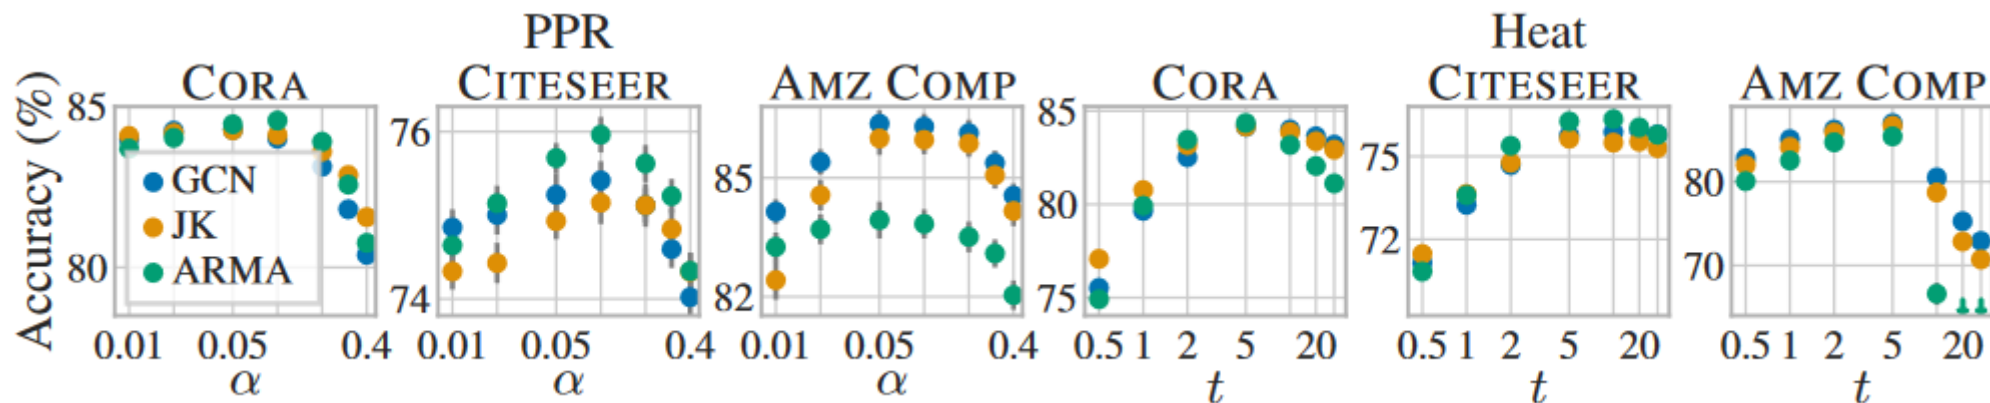
不同标签率下 Cora 的准确率



5个问题

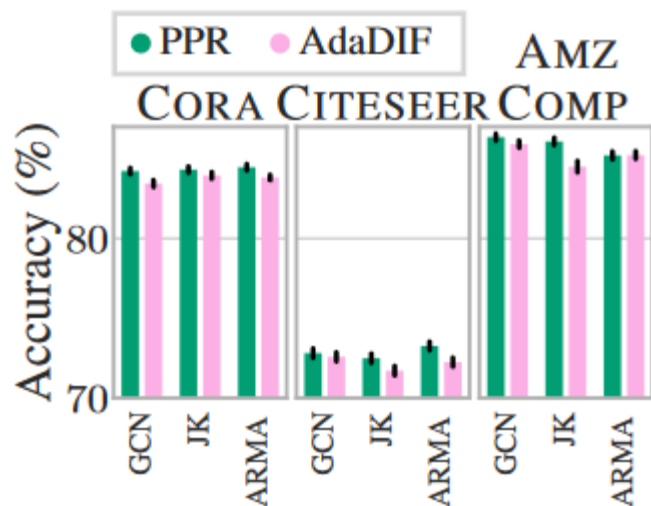
Q4: 如何选择系数 θ_k ?

➤ 最佳超参数在很小范围内，不同数据集和模型的最佳值一致。



使用 GDC 并改变 PPR(α)和 $heart\ kernel(t)$ 的超参数所达到的精度

➤ 学习类似系数的模型中获取的 θ_k ，即使手工调整正则化，训练后也比不上原系数。




使用 PPR 定义的系数 θ_k 和 AdaDIF 学习的系数 θ_k 的 GDC 精度

5个问题

Q5: 哪些节点受益于 GDC?

➤ 距离较远的节点往往从 GDC 中获益更多



根据与训练集的距离（跳数），添加 GDC 后 GCN 精度的提高（百分点）

优点及扩展

- 提出基于稀疏广义图扩散的图扩散卷积（GDC）方法。
- GDC 是 GNN 中消息传递的一种更强大的空间局部扩展，够增强任何基于图的模型。
- 广泛而严谨的实验表明，GDC 在有监督和无监督任务中都能持续提高各种模型的准确性。
- 扩展包括：其他扩散系数 θ_k ，如 Fouss 等人[22]提出的方法所给出的扩散系数，以及更先进的随机游走和不是由过渡矩阵幂定义的算子。

谢 谢！