

# Next track point prediction using a flexible strategy of subgraph learning on road networks

使用灵活的道路网络子图学习策略预测下一个轨迹点

期刊: IJGIS (International Journal of Geographical Information Science)

code data: <https://doi.org/10.6084/m9.figshare.22785503>

❑ **背景:** 轨迹预测研究模式“轨迹表达→轨迹预测”，现有的轨迹表达按空间载体分3类①基于轨迹坐标（经纬度）②基于空间网格③基于匹配道路。①②忽略了路网对车辆轨迹的约束③准确将轨迹匹配到道路是难点“不确定地理上下文问题”

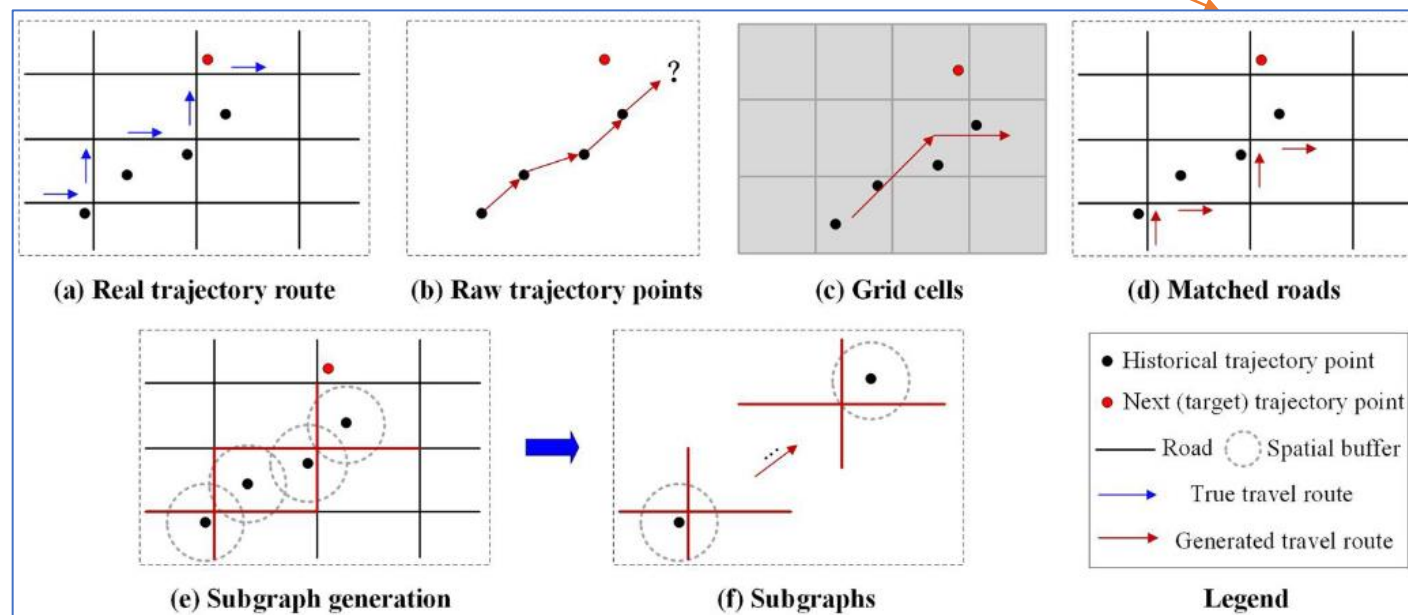
❑ **挑战:** 不确定的地理环境问题（空间不确定性、时间不确定性）+地图匹配问题

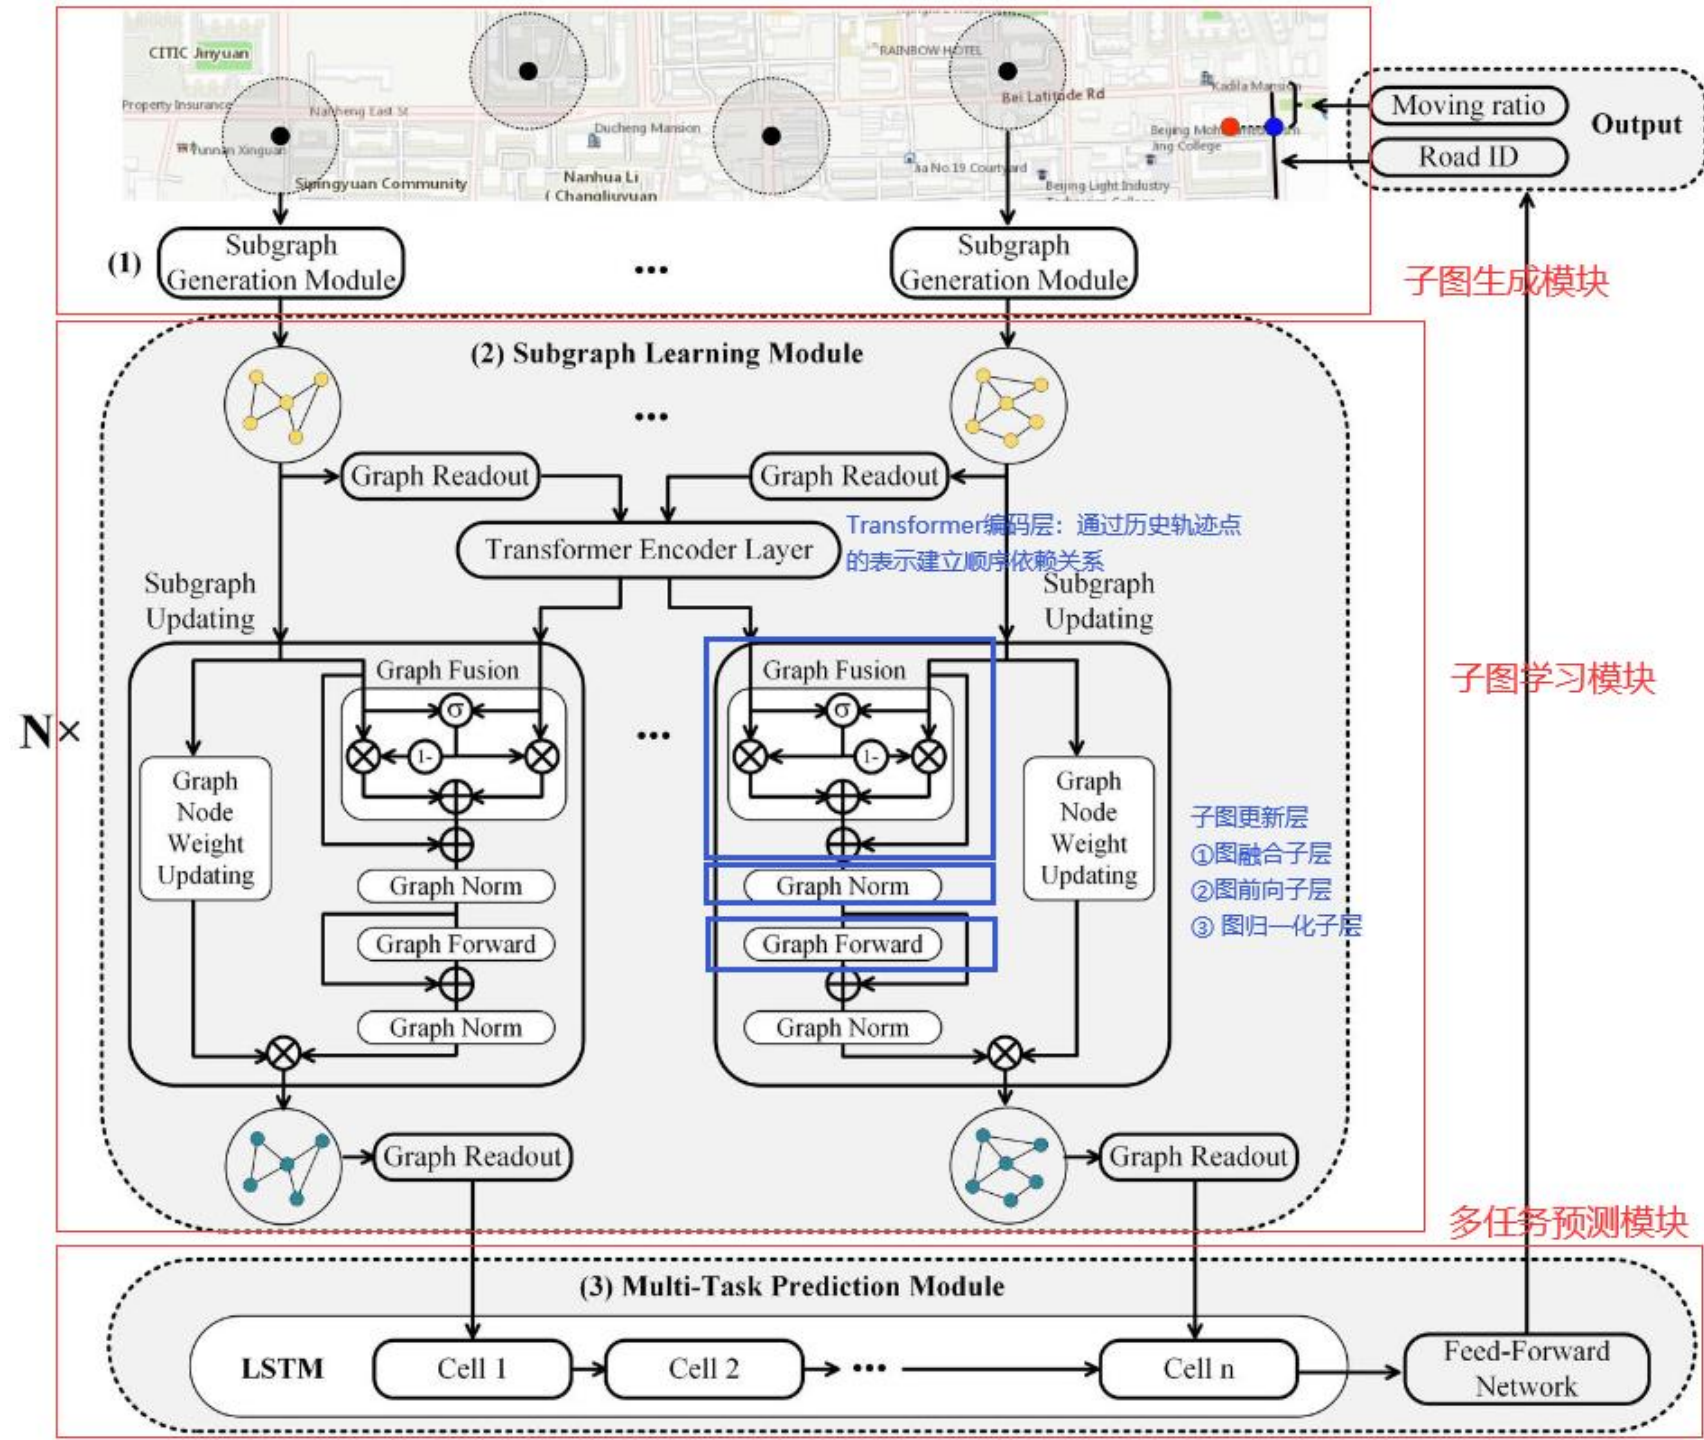
❑ **方法:** 灵活子图学习策略SLM预测车辆的下一个轨迹点

■ 子图生成模块: 在历史轨迹点周围创建空间缓冲区，提取历史轨迹点周围道路的拓扑上下文信息

■ 子图学习模块: 才能够生成的子图中学习空间和时间特征

■ 预测模块: 时空特征预测道路ID和响应的移动比率（0-1 起点-终点）





## 子图生成模块

已知：道路网络 $G = (V, E)$ 和一个轨迹点 $p$ ,

Step1: 提取 $G$ 中分布在距离 $p$   $\omega$ 米以内的 $s$ 个路段作为子图 $G_p$ 的节点（见图 1f）。 $\omega$ 超参数，表示轨迹点的感受野。

子图的节点 $V_p = \{v_1, v_2, \dots, v_s\}$ ，子图的边 $E_p$ 。

Step2: 每个路段表示为 $d$ 维的路段嵌入，则子图 $G_p$ 中相应的路段嵌入 $D_p = \{D_{v_1}, D_{v_2}, \dots, D_{v_s}\}$

Step3: 利用子图 $G_p = (V_p, E_p, D_p)$ 中的固有信息代表轨迹点 $p$

Step4: 考虑距离衰减效应，用指数函数模拟每个子图节点对轨迹点 $p$ 的影响

$$g_p = \sum_{v_i \in V_p} w_{v_i} * \frac{D_{v_i}}{\sum_{v_i \in V_p} w_{v_i}}$$
$$w_{v_i} = \exp\left(-\frac{\text{dist}(v_i, p)}{\varphi}\right)$$

Step5: 对于原始历史轨迹 $t = \{p_1, p_2, \dots, p_{|t|}\}$ ，轨迹表示为 $g_t = \{g_1, g_2, \dots, g_{|t|}\}$

子图生成模块的输出为 $(G_t, g_t) = \{(G_1, g_1), (G_2, g_2), \dots, (G_{|t|}, g_{|t|})\}$ ，一个轨迹点 $p_t$ 对应一个子图 $G_t$ 和轨迹表示 $g_t$ .

□ Transformer编码层：历史轨迹点的表示 $g_t$ 建立顺序依赖关系模型

$$z_t^{(l)} = \text{TransformerEncoder} \left( h_t^{(l-1)} \right)$$

$$h_t^{(0)} = g_t$$

✓ 输入：所有历史轨迹点的表示 $g_t$

✓ 输出：考虑到顺序依赖关系的更新表示 $z_t^{(l)}$

□ 子图更新层：学习轨迹的局部空间特征，考虑每个子图中路段的连通性。“图节点嵌入更新+图节点权重更新”

■ 图融合子层：采用门控融合机制整合每个轨迹点的更新表示 $z_i^{(l)}$ 及其对应的局部子图特征 $f_i^{(l-1)}$

$$\rho_i^{(l)} = \sigma \left( \ddot{z}_i^{(l)} W_z + f_i^{(l-1)} W_f + \tau \right)$$

$$Z_i^{(l)} = \ddot{z}_i^{(l)} \rho_i^{(l)} + f_i^{(l-1)} (1 - \rho_i^{(l)})$$

$f_i^0$ 是路段嵌入 $D_i$ ， $\ddot{z}_i^{(l)}$ 重复 $z_i^{(l)}$   $|V_i|$ 次以确保 $\ddot{z}_i^{(l)}$ 和 $f_i^{(l-1)}$ 尺寸相同， $W_z, W_f \in \mathbb{R}^{d \times d}$ ,  $\tau$ 是可学习参数， $\sigma$ sigmoid 激活函数。

✓ 输入：Transformer 编码层学习到的轨迹点  $p_i$  的表示 $z_i^{(l)}$ 和局部子图特征 $f_i^{(l-1)}$

✓ 输出：通过全局特征和局部特征融合更新的子图特征 $Z_i^{(l)}$

■ 图前向子层：采用GAT模型，提取的相邻道路拓扑信息（即子图结构）用于图节点嵌入、权重更新。

$$\dot{f} = GFD(G, f)$$

$$w_i^{(l)} = \sigma \left( GFD \left( G_i, h_i^{(l-1)} \right) \right)$$

其中， $G$ 表示图结构， $f$ 表示该图中相应的节点特征， $\dot{f}$ 表示考虑空间图结构后更新的节点特征。

■ 图归一化子层：增强模型训练的稳定性和收敛性

$$\dot{f}_i^{(l)} = GN \left( f_i^{(l-1)} + Z_i^{(l)} \right)$$

$$f_i^{(l)} = GN \left( \dot{f}_i^{(l)} + GFD(G_i, \dot{f}_i^{(l)}) \right)$$

## 多任务预测模块

利用子图学习模块的输出，采用LSTM对轨迹序列建模

$$h_i^{(N)} = w_i^{(N)} f_i^{(N)}$$

$$\Gamma = LSTM(h_1^{(N)}, h_2^{(N)}, \dots, h_{|t|}^{(N)})$$

$$\widehat{P}_{rid} = \Gamma W_r + \tau_r$$

$$\widehat{mr} = \sigma(\Gamma W_m + \tau_m)$$

✓ 输入：子图学习后更新的轨迹表示（节点权重、节点嵌入）

✓ 输出：下一个轨迹点位于每条道路上的概率分布（ $\widehat{P}_{rid}$ ）以及相应的移动比率（ $\widehat{mr}$ ）。

交叉熵 $L_{ce}$ 和均方损失 $L_{mse}$ 分别作为路段 ID 和移动比率预测任务的损失函数

$$Loss = L_{ce}(\widehat{P}_{rid}, P_{rid}) + \lambda L_{mse}(\widehat{mr}, mr)$$

$$L_{ce}(\hat{y}_i y_i) = -\frac{1}{n} \sum_i^n [(1 - y_i) \log(1 - \hat{y}_i) + y_i \log \hat{y}_i]$$

$$L_{mse}(\hat{y}_i y_i) = \frac{1}{n} \sum_i^n (y_i - \hat{y}_i)^2$$

## 实验

### □ 评估指标

L2距离、路网距离、预测路段ID准确性

$$L2_{dis} = \frac{\sum_{i=1}^{I_p} L2_{dist}(\hat{\vec{p}}_i, \vec{p}_i)}{I_p}$$

$$rn_{dis} = \frac{\sum_{i=1}^{I_p} rn_{dist}(\hat{\vec{p}}_i, \vec{p}_i)}{I_p}$$

$$acc = \frac{\sum_{i=1}^{I_p} 1(\widehat{rid}_i = rid_i)}{I_p}$$

### □ Baseline

道路表示法: DW、node2Vec、GAE

轨迹表示法: t2vec、T3S、Toast