Spatio-Temporal Meta-Graph Learning for Traffic Forecasting

AAAI Conference on Artificial Intelligence 2023

2024/5/25

I 摘要

当前流量预测的主要问题？

- 交通流的时空异质性——交通状况因道路（高速、立交）和时间（非高峰、高峰）而异
- 非平稳性问题——事故或拥堵等未知因素

■ 本文提出一种基于时空数据的元图学习机制

- 提出了一种用于时空图学习的元图学习器，以明确解决时空异质性
- 提出一个通用的元图卷积循环网络MegaCRN，能适应从正常到非平稳的交通状况

II 方法

■ 问题定义：多步交通预测问题

$$[X_{t-(\alpha-1)}, \ldots, X_t] \xrightarrow[\theta]{\mathbb{F}(\cdot)} [X_{t+1}, \ldots, X_{t+\beta}]$$

$X \in R^{N*C}$，N代表空间单元的数量，C代表信息通道数，本文C=1，表示速度

■ 图卷积循环单元(Graph Convolutional Recurrent Unit)

$$H = \sigma(X \star_{\mathcal{G}} \Theta) = \sigma(\sum_{k=0} \tilde{\mathcal{P}}^k X\, W_k)$$

$$\begin{cases} u_t = sigmoid([X_t,\ H_{t-1}] \star_{\mathcal{G}} \Theta_u + b_u) \\ r_t = sigmoid([X_t,\ H_{t-1}] \star_{\mathcal{G}} \Theta_r + b_r) \\ C_t = tanh([X_t,\ (r_t \odot H_{t-1})] \star_{\mathcal{G}} \Theta_C + b_C) \\ H_t = u_t \odot H_{t-1} + (1 - u_t) \odot C_t \end{cases}$$

- $X \in R^{N*c}, H \in R^{N*h}$表示输入和输出，$u, r, C$分别表示更新门、重置门和候选状态
- 将图卷积操作注入到**GRU**中，由此衍生的**GCRU**可以同时捕获由**输入图拓扑表示的空间依赖性**和以**顺序方式表示的时间依赖性**

□ GRU门控循环单元

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

- 与LSTM相同，有效抑制梯度消失或爆炸
- 效果优于传统RNN且计算复杂度比LSTM小

II 方法

■ 图结构学习(Graph Structure Learning)

$$H = \sigma(X \star_{\mathcal{G}} \Theta) = \sigma(\sum_{k=0}^{K} \tilde{\mathcal{P}}^k X W_k)$$

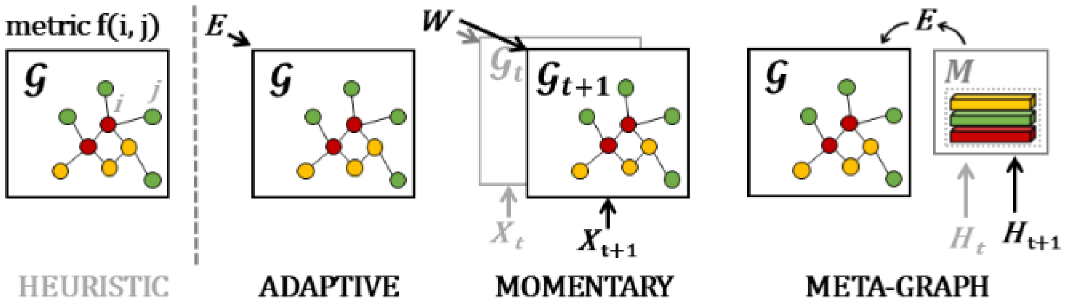

Figure 1: Progression of Graph Structure Learning for Spatio-Temporal Modeling

● 除了X输入之外，GCRU还需要对图G的拓扑进行辅助输入$P \in R^{N*N}$

□ 图结构学习中的图矩阵通常由某些度量(距离、余弦相似度)定义，度量的选择是任意的

□ 本文中提到的三种方法：自适应(Adaptive)、瞬时图(Momentary)和元图(Meta-Graph)

■ 自适应

- 当前大多数深度学习方法基于共享参数模型（不同节点对应同一卷积），每条道路的具体情况不一样，无法捕捉细粒度数据模式
- 现存方法根据距离或相似度预先定义一个图来捕捉空间相关性，不能完善地表示空间依赖

$$\tilde{\mathcal{P}} = softmax(relu(E\, E^{\top}))$$

- 通过随机游走将嵌入的可训练节点的矩阵积的非负部分归一化得到
- **问题：自适应图仅依赖参数化节点嵌入矩阵E——不随时间变化**
- 来源：Adaptive graph convolutional recurrent network for traffic forecasting.2020

■ 瞬时图

- 之前的图结构一旦定义即固定，而实际上交通数据每时每刻都在变化，图结构也在变化
- 以往模型所有数据均共享同一个权重矩阵，作者基于当前时刻的输入设置权重，不同输入数据具有的不同图结构信息可以体现出来

$$\tilde{\mathcal{P}}_t = softmax(relu((H_t * W)\,(H_t * W)^{\top}))$$

- 通过将输入特征经过可学习参数映射到嵌入空间
- **问题：瞬时图实际上是输入条件图，对输入信号较为敏感**
- 来源：Spatio-temporal graph structure learning for traffic forecasting.2020

II 方法

- □ 元节点库(Meta-Node Rank)：$\emptyset \in R^{\emptyset * d}$,$\emptyset$代表存储项的个数，d代表每项的维度

■ 元图学习模块(Meta-Graph Learner)

$$Q_t^{(i)} = H_t^{(i)} * W_Q + b_Q$$

H_t^i表示H_t中的第i个节点向量，将输入隐藏状态映射为局部查询向量Q

$$\begin{cases} a_j^{(i)} = \dfrac{\exp\left(Q_t^{(i)} * \Phi^{\top}[j]\right)}{\sum_{j=1}^{\phi} \exp\left(Q_t^{(i)} * \Phi^{\top}[j]\right)} \\ M_t^{(i)} = \sum_{j=1}^{\phi} a_j^{(i)} * \Phi[j] \end{cases}$$

表示记忆读取操作，将第i个节点的查询链接于元节点库中的每个元素进行匹配计算权重a,用于衡量相似性

$$H_t' = [H_t, M_t] \in \mathbb{R}^{N \times (h+d)}$$

将输出结果与H拼接

$$\begin{cases} E' = NN_H(\Phi) \\ \tilde{\mathcal{P}}' = softmax(relu(E' \, E'^{\top})) \end{cases}$$

使用超网络(Hyper-Network)

P代表所学习的元图

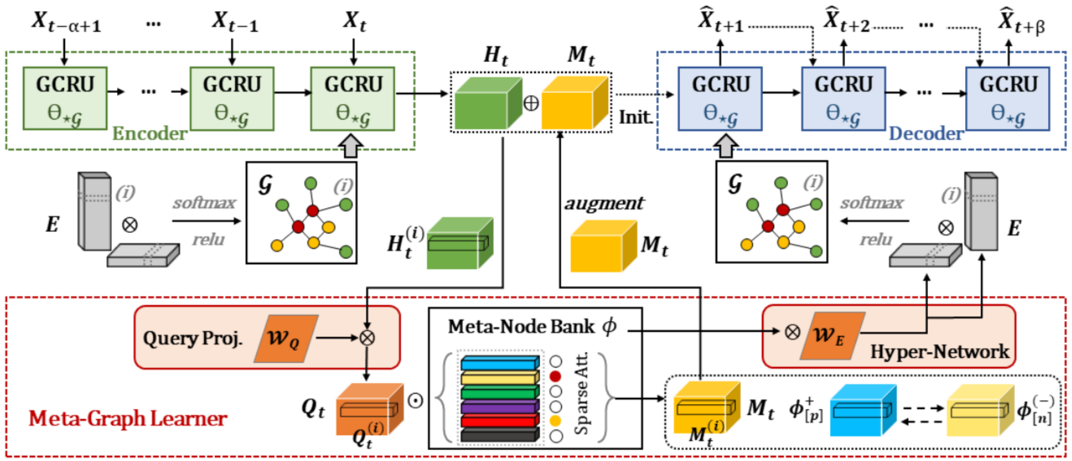

Figure 2: Framework of Meta-Graph Convolutional Recurrent Network (MegaCRN)

- □ **超网络基本思想：用小网络为大网络生成参数**
- □ 保存权重矩阵->找到mapping函数使得[z1,z2,z3…zn]mapping [W1,W2,…Wn]，节省空间

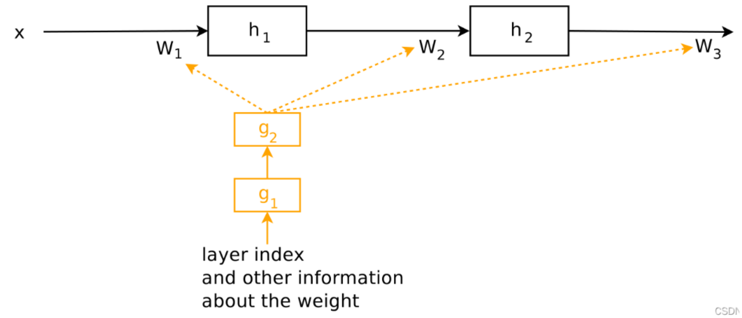

II 方法

■ 元图卷积循环网络(Meta-Graph Convolutional Recurrent Network)MegaCRN

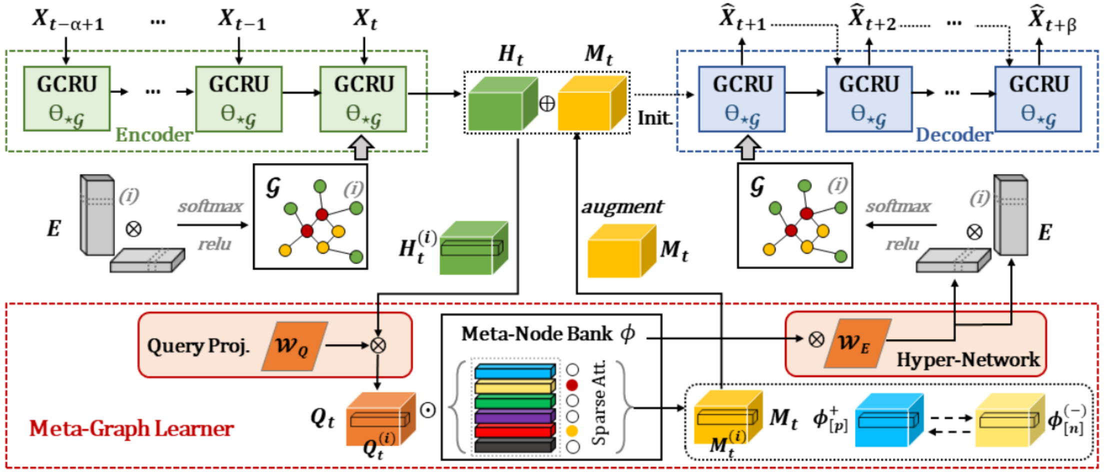

Figure 2: Framework of Meta-Graph Convolutional Recurrent Network (MegaCRN)

- 文章对整体模型进行介绍，MegaCRN在元节点库中学习节点级的交通模式原型，根据观察到的情况自适应地更新辅助图

□ 为增强对不同道路上不同场景的区分能力，使用两个约束调节记忆参数：对比损失与一致性损失

ø[p]为最相似的原型节点，作为正样本；ø[n]为第二相似原型，为负样本。从而让元节点库中的原型尽可能不同

$$\mathcal{L}_1 = \sum_t^T \sum_i^N \max\{||Q_t^{(i)} - \Phi[p]||^2 - ||Q_t^{(i)} - \Phi[n]||^2 + \lambda, 0\}$$

$$\mathcal{L}_2 = \sum_t^T \sum_i^N ||Q_t^{(i)} - \Phi[p]||^2$$

$$\mathcal{L}_{task} = \sum_t^T \sum_\rho^\beta |\hat{X}_{t+\rho} - X_{t+\rho}| + \kappa_1 \mathcal{L}_1 + \kappa_2 \mathcal{L}_2$$

将上述两个约束进行加权求和并加入到目标函数中构成损失函数

III 实验

■ 数据集

Table 1: Summary of Datasets

Dataset	METR-LA	PEMS-BAY	EXPY-TKY
Start Time	2012/3/1	2017/1/1	2021/10/1
End Time	2012/6/30	2017/5/31	2021/12/31
Time Interval	5 minutes	5 minutes	10 minutes
#Timesteps	34,272	52,116	13,248
#Spatial Units	207 sensors	325 sensors	1,843 road links

- 两个标准基准数据集：METR-LA和PEMS-BAY
- 其中70%用于训练，10%用于验证，20%用于测试
- 此外，作者发表了一篇新的数据集EXPY-TKY，该数据集收集了3个月(2021/10 ~ 2021/12)期间，以东京市内1843条高速公路为对象，每隔10分钟收集交通速度信息和相应交通事故信息的交通数据集。文章使用前两个月(作为训练和验证数据集，最后一个月作为训练和验证数据集)

expy-tky_202110.csv

```
timestamp,linkid,speed
2021-10-01 00:00:00,83585420,62.5825
2021-10-01 00:00:00,83585485,43.1356
2021-10-01 00:00:00,83585609,73.4477
2021-10-01 00:00:00,83585658,62.3942
2021-10-01 00:00:00,83585806,69.9304
2021-10-01 00:00:00,83585863,51.0601
2021-10-01 00:00:00,83585888,43.7822
2021-10-01 00:00:00,83586020,61.7853
2021-10-01 00:00:00,83586069,70.5938
2021-10-01 00:00:00,83586126,48.9400
2021-10-01 00:00:00,83586135,88.6200
2021-10-01 00:00:00,83586355,95.7553
2021-10-01 00:00:00,83586485,91.2022
2021-10-01 00:00:00,83586502,94.5769
2021-10-01 00:00:00,83586663,95.2061
```

	link_id	roadname	start_lon	start_lat
0	83585420	首都高速湾岸線	139.61914279513888	35.387905815972225
1	83585485	首都高速湾岸線	139.62179036458335	35.385592447916665
2	83585609	首都高速湾岸線	139.61992838541667	35.40112413194444
3	83585658	首都高速湾岸線	139.61868489583333	35.39909939236111
4	83585806	首都高速湾岸線	139.62001085069446	35.40148654513889
5	83585863	首都高速湾岸線	139.618203125	35.39909939236111
6	83585888	首都高速湾岸線	139.61754774305555	35.39813368055555

■ 实验结果

预测步长

METR-LA	15min / horizon 3			30min / horizon 6			60min / horizon 12		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
HA(Li et al. 2018)	4.16	7.80	13.00%	4.16	7.80	13.00%	4.16	7.80	13.00%
STGCN(Yu, Yin, and Zhu 2018)	2.88	5.74	7.62%	3.47	7.24	9.57%	4.59	9.40	12.70%
DCRNN(Li et al. 2018)	2.77	5.38	7.30%	3.15	6.45	8.80%	3.60	7.59	10.50%
GW-Net(Wu et al. 2019)	2.69	5.15	6.90%	3.07	6.22	8.37%	3.53	7.37	10.01%
STTN(Xu et al. 2020)	2.79	5.48	7.19%	3.16	6.50	8.53%	3.60	7.60	10.16%
GMAN(Zheng et al. 2020)⋆	2.80	5.55	7.41%	3.12	6.49	8.73%	3.44	7.35	10.07%
MTGNN(Wu et al. 2020)	2.69	5.18	6.86%	3.05	6.17	8.19%	3.49	7.23	9.87%
StemGNN(Cao et al. 2020)†	2.56	5.06	6.46%	3.01	6.03	8.23%	3.43	7.23	9.85%
AGCRN(Bai et al. 2020)	2.86	5.55	7.55%	3.25	6.57	8.99%	3.68	7.56	10.46%
CCRNN(Ye et al. 2021)	2.85	5.54	7.50%	3.24	6.54	8.90%	3.73	7.65	10.59%
GTS(Shang, Chen, and Bi 2021)⋆	2.65	5.20	6.80%	3.05	6.22	8.28%	3.47	7.29	9.83%
PM-MemNet(Lee et al. 2022)	2.65	5.29	7.01%	3.03	6.29	8.42%	3.46	7.29	9.97%
MegaCRN (Ours)	**2.52**	**4.94**	**6.44%**	**2.93**	**6.06**	**7.96%**	**3.38**	**7.23**	**9.72%**

PEMS-BAY	15min / horizon 3			30min / horizon 6			60min / horizon 12		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
HA(Li et al. 2018)	2.88	5.59	6.80%	2.88	5.59	6.80%	2.88	5.59	6.80%
STGCN(Yu, Yin, and Zhu 2018)	1.36	2.96	2.90%	1.81	4.27	4.17%	2.49	5.69	5.79%
DCRNN(Li et al. 2018)	1.38	2.95	2.90%	1.74	3.97	3.90%	2.07	4.74	4.90%
GW-Net(Wu et al. 2019)	1.30	2.74	2.73%	1.63	3.70	3.67%	1.95	4.52	4.63%
STTN(Xu et al. 2020)	1.36	2.87	2.89%	1.67	3.79	3.78%	1.95	4.50	4.58%
GMAN(Zheng et al. 2020)⋆	1.35	2.90	2.87%	1.65	3.82	3.74%	1.92	4.49	4.52%
MTGNN(Wu et al. 2020)	1.32	2.79	2.77%	1.65	3.74	3.69%	1.94	4.49	4.53%
StemGNN(Cao et al. 2020)†	1.23	2.48	2.63%	N/A from (Cao et al. 2020)			N/A from (Cao et al. 2020)		
AGCRN(Bai et al. 2020)	1.36	2.88	2.93%	1.69	3.87	3.86%	1.98	4.59	4.63%
CCRNN(Ye et al. 2021)	1.38	2.90	2.90%	1.74	3.87	3.90%	2.07	4.65	4.87%
GTS(Shang, Chen, and Bi 2021)⋆	1.34	2.84	2.83%	1.67	3.83	3.79%	1.98	4.56	4.59%
PM-MemNet(Lee et al. 2022)⋆	1.34	2.82	2.81%	1.65	3.76	3.71%	1.95	4.49	4.54%
MegaCRN (Ours)	**1.28**	**2.72**	**2.67%**	**1.60**	**3.68**	**3.57%**	**1.88**	**4.42**	**4.41%**

EXPY-TKY	10min / horizon 1			30min / horizon 3			60min / horizon 6		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
HA(Li et al. 2018)	7.63	11.96	31.26%	7.63	11.96	31.25%	7.63	11.96	31.24%
STGCN(Yu, Yin, and Zhu 2018)	6.09	9.60	24.84%	6.91	10.99	30.24%	8.41	12.70	32.90%
DCRNN(Li et al. 2018)	6.04	9.44	25.54%	6.85	10.87	31.02%	7.45	11.86	34.61%
GW-Net(Wu et al. 2019)	5.91	9.30	25.22%	6.59	10.54	29.78%	6.89	11.07	31.71%
STTN(Xu et al. 2020)	5.90	9.27	25.67%	6.53	10.40	29.82%	6.99	11.23	32.52%
GMAN(Zheng et al. 2020)	6.09	9.49	26.52%	6.64	10.55	30.19%	7.05	11.28	32.91%
MTGNN(Wu et al. 2020)	5.86	9.26	24.80%	6.49	10.44	29.23%	**6.81**	**11.01**	31.39%
StemGNN(Cao et al. 2020)†	6.08	9.46	25.87%	6.85	10.80	31.25%	7.46	11.88	35.31%
AGCRN(Bai et al. 2020)	5.99	9.38	25.71%	6.64	10.63	29.81%	6.99	11.29	32.13%
CCRNN(Ye et al. 2021)	5.90	9.29	24.53%	6.68	10.77	29.93%	7.11	11.56	32.56%
GTS(Shang, Chen, and Bi 2021)	-	-	-	-	-	-	-	-	-
PM-MemNet(Lee et al. 2022)	5.94	9.25	25.10%	6.52	10.42	29.00%	6.87	11.14	31.22%
MegaCRN (Ours)	**5.81**	**9.20**	**24.49%**	**6.44**	**10.33**	**28.92%**	6.83	11.04	**31.02%**

III 实验

■ 消融实验

● 对比：自适应图、瞬时图、记忆网络

Table 3: Ablation Test across All Horizons

Ablation	METR-LA	PEMS-BAY	EXPY-TKY
	MAE / RMSE	MAE / RMSE	MAE / RMSE
Adaptive	3.01 / 6.25	1.61 / 3.73	6.79 / 10.76
Momentary	2.96 / 6.16	1.62 / 3.75	6.68 / 10.59
Memory	2.97 / 6.21	1.60 / 3.70	6.55 / 10.48
MegaCRN	**2.89 / 6.02**	**1.54 / 3.59**	**6.44 / 10.35**

1. **Adaptive GCRN**：只保留GCRN编码解码器，让编码解码器共享一个自适应图
2. **Memory GCRN**：不使用超网络Hyper-Network，只使用元节点库
3. **Momentary GCRN**：不使用元节点库，直接从输入条件图获得

■ 效率研究

通过与基线模型进行比较来评估所提出模型的效率

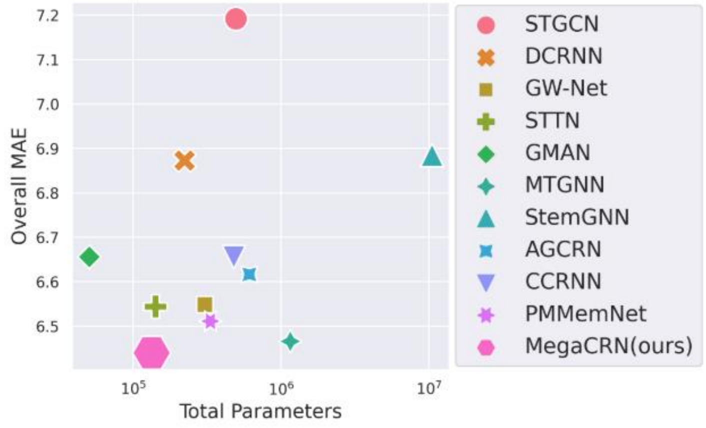

Figure 3: Efficiency Evaluation

- MegaGRN模型具有第二少的参数，但总体MAE最小对于像EXPY-TKY这样的大规模数据集，所提出模型可能非常节省内存
- 一些模型，特别是基于Transoformer的模型，由于在大张量上进行点积运算，因此非常消耗内存/时间
- 综上所述，所提出模型可以在保持相对效率的同时达到最先进的精度

III 实验

定性分析

- 文章通过在低维空间中使用t-SNE可视化来定性地评估节点嵌入的质量

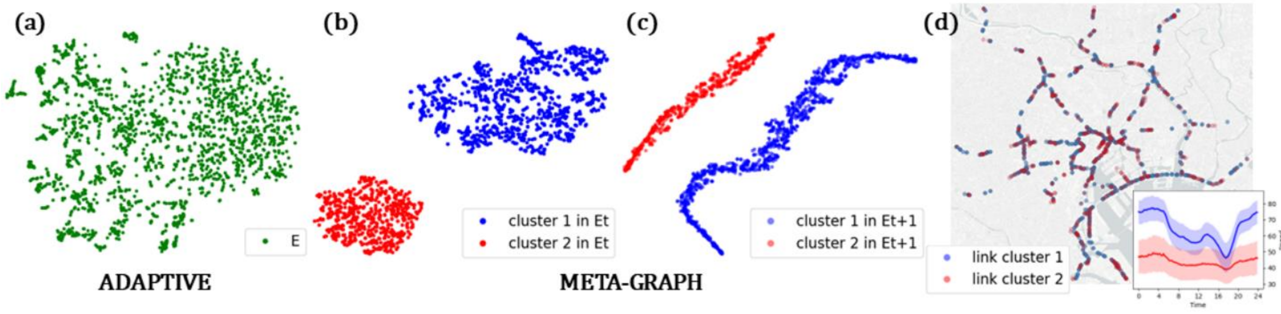

Figure 4: Spatio-Temporal Disentangling Effect of Meta-Graph Learning

- 与(a)自适应图相比，元图可以**自动学习聚类节点**
- (b)(c)从t时刻到t+1，这种聚类效应仍然存在，且形状发生了变化，证明了文章所提出的方法具有**时空解纠缠能力**和**时间适应性**
- (d)日平均时间序列图中，集群1(蓝色)的道路具有强烈的高峰时间模式；集群2(红色)的平均速度较低，但变化大，特点是在立交/收费站附近由大量的速度变化。验证了元图学习器具有区分时空异质性的能力

- **模型相比baseline可以更好地捕捉波动，适应更复杂的情况，包括高峰时间和交通事故**
- (b)对元节点库的查询在正常情况下和事件情况下不同
- (c)(d)在发生事故后节点1的影响显著下降，(节点越大表示加权出度越大)，验证了MegaCRN的适应性

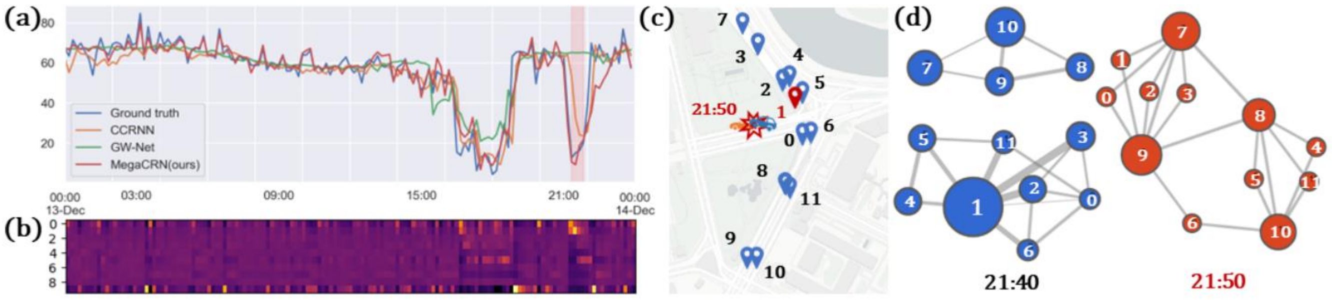

Figure 5: Incident Awareness of MegaCRN

IV 结论

- 本文提出了元图卷积循环网络**MegaCRN**以及一种新的时空图结构学习(元图)机制用于交通预测
  - 在三个数据集上，所提出的模型在很大程度上都优于最先进的模型
  - 通过一系列可视化，展示了不同模式解决时空异质性的能力，以及对突发事故的适应性：

IV 结论

■ 后续工作

Unifying Lane-Level Traffic Prediction from a Graph Structural Perspective: Benchmark and Baseline

Shuhao Li, *Student Member, IEEE*, Yue Cui, Jingyi Xu, Libin Li, Lingkai Meng, Weidong Yang, Fan Zhang, and Xiaofang Zhou, *Fellow, IEEE*

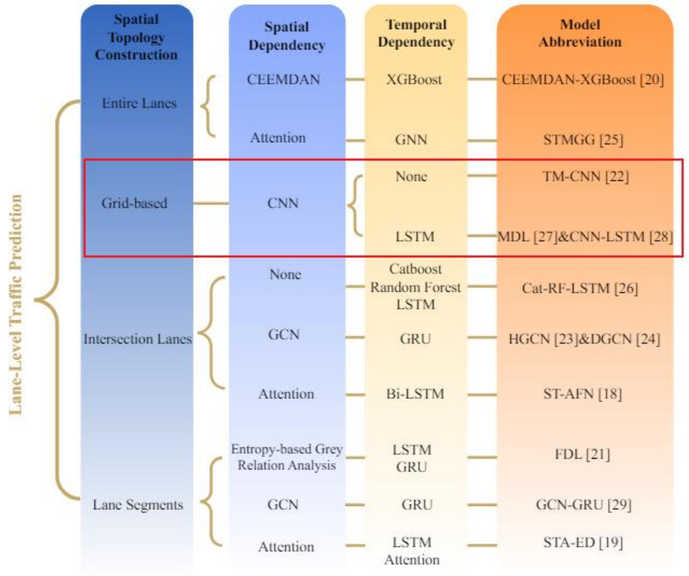

- 分析车道级别交通预测问题
- 涉及到基于网格模式的车道的模型

Published as a conference paper at ICLR 2024

GEOLLM: EXTRACTING GEOSPATIAL KNOWLEDGE FROM LARGE LANGUAGE MODELS

Rohin Manvi[†*] **Samar Khanna**[†] **Gengchen Mai**[‡]
Marshall Burke[†] **David Lobell**[†] **Stefano Ermon**[†]

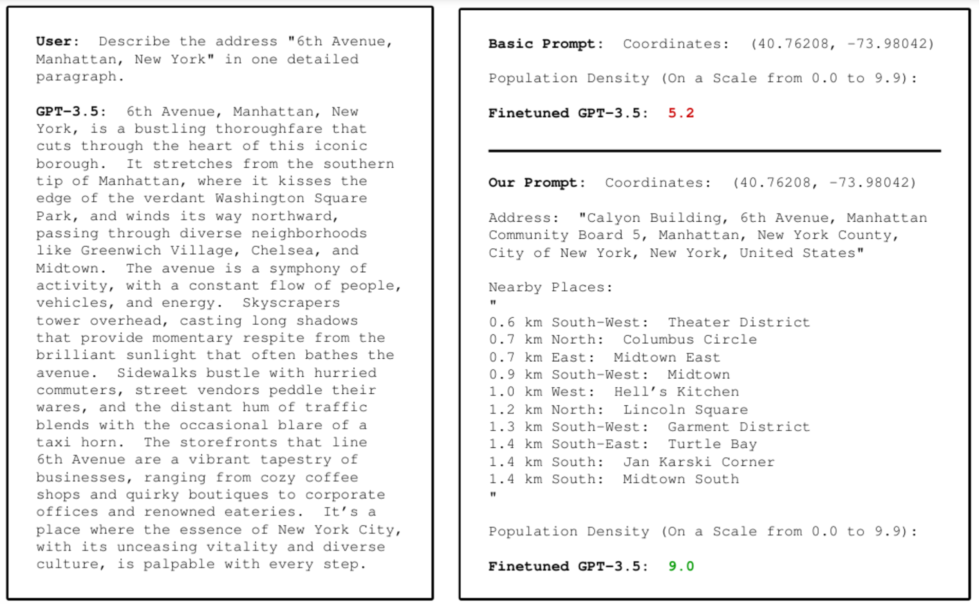

(a) GPT-3.5 describing an address. (b) Prompting with coordinates vs our strategy.

- 利用**LLM**中的地理空间知识进行预测的可能性
- 从**LLM**中提取空间信息，用于衡量人口密度和经济活动等地理空间任务

谢 谢！