



北京工业大学

BEIJING UNIVERSITY OF TECHNOLOGY

Deep Spatio-temporal Adaptive 3D Convolutional Neural Networks for Traffic Flow Prediction

汇报人：闫林枝

CONTENT_

01 背景_

02 方法_

03 实验_

04 结论_

P

ART ONE

背景

01

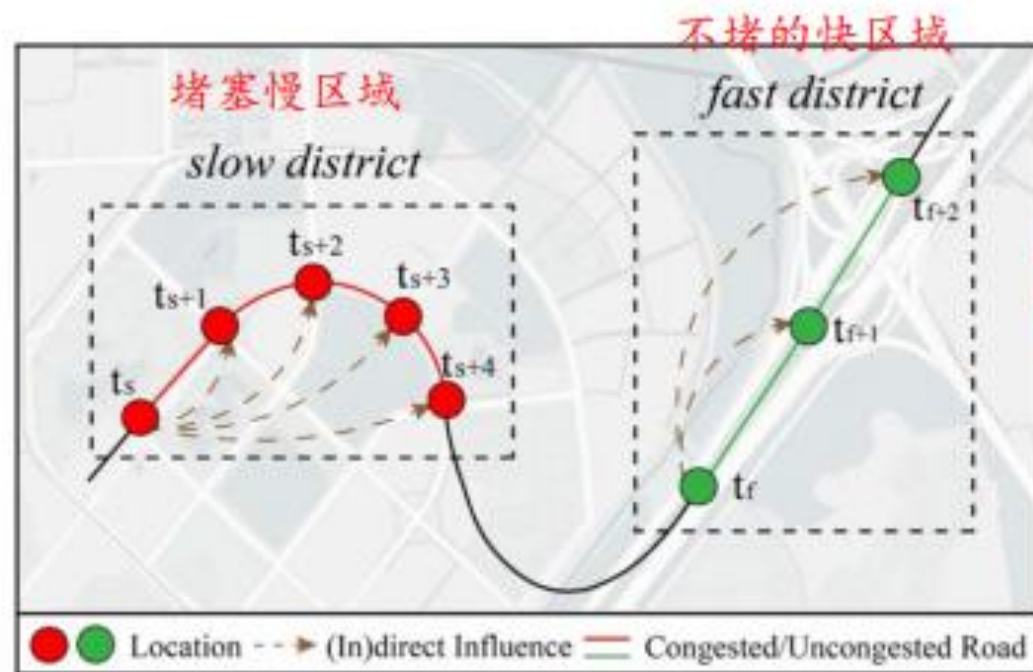
研究意义

- 交通拥堵成为世界各国城市建设和管理面临的重大挑战
- 交通流量预测可以通过分析历史交通GPS数据，预测未来的交通信息，对于解决城市拥堵、道路建设和交通管理问题具有重要意义

定义

时空相关性：每个区域对下一个时间点的区域有直接影响，
对后续时间点的区域有间接影响


对附近区域交通
影响大，对远区
域的未来交通流
影响较小，影响
时间长



(a) Spatiotemporal Correlations

定义

时空灵活性：固定时间的历史数据的参考价值和可信度会灵活变化，所以输入不能平等对待



不同时间不同区域高峰时段不同，节假日和周末交通流量也会有很大的变化

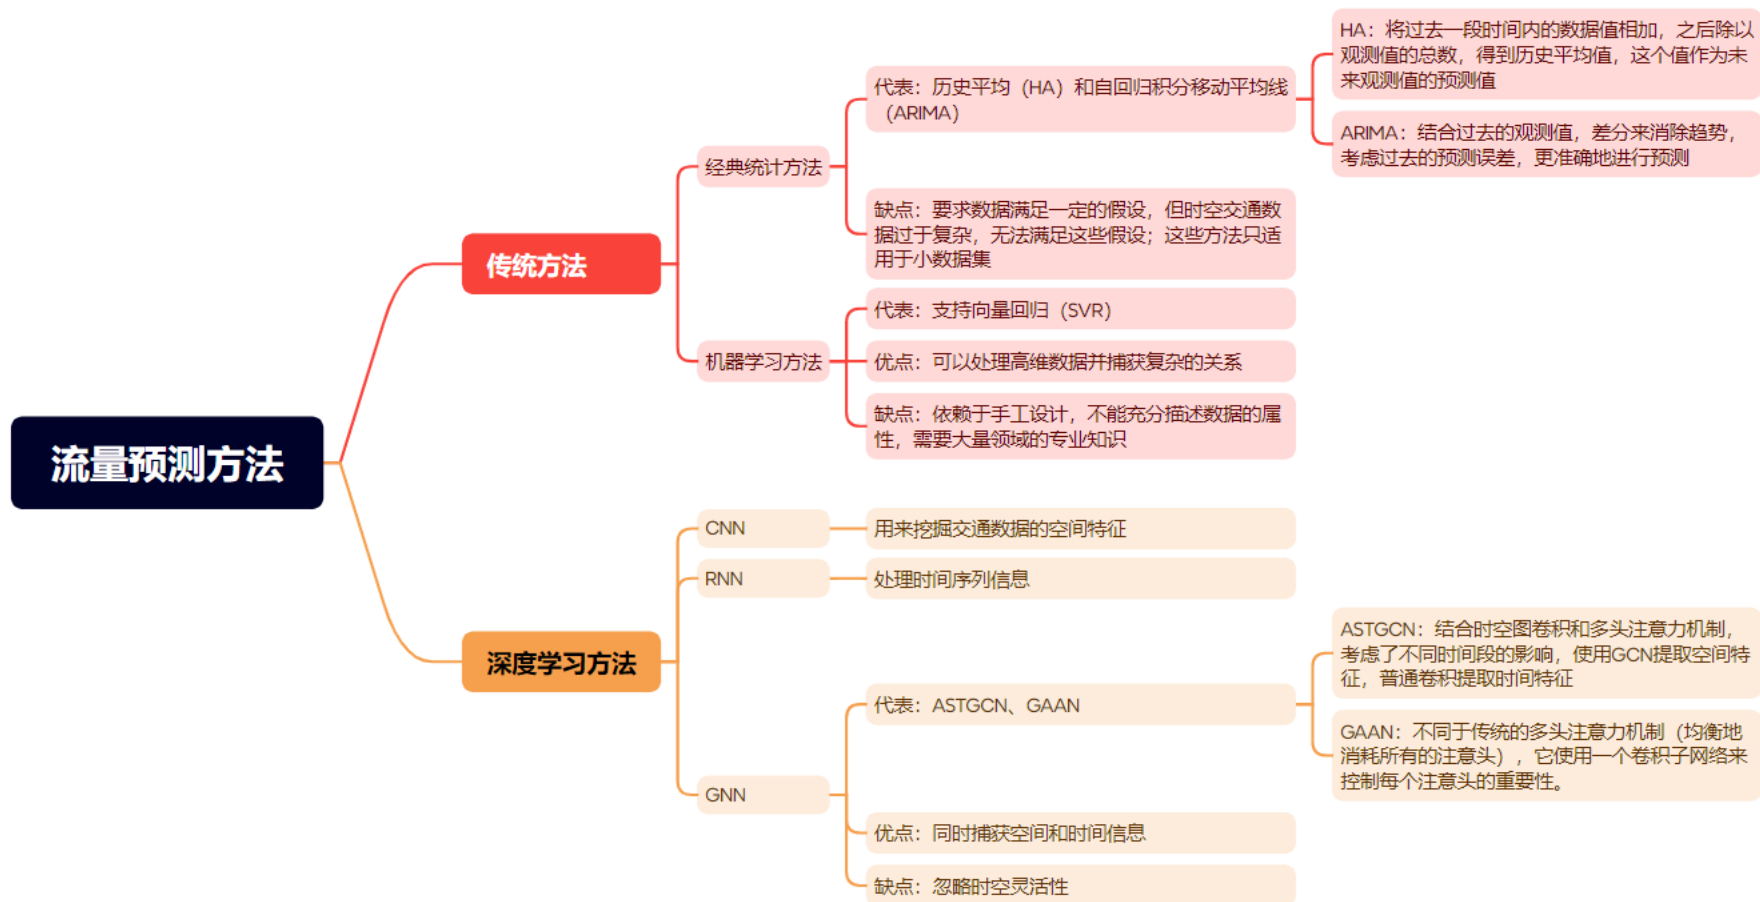
固定时间的历史数据的参考价值和可信度会灵活变化

(b) Spatiotemporal Flexibility

定义

■ **时空复杂性**：交通流会受到交通事故、天气、大型活动等复杂因素的影响

过往研究方法



缺点: 忽略时空灵活性

Definition

■ 城市区域: $M \times N$, (i, j)

流量流入和流量流出:

$$X_t(0, i, j) = \left| (s, e) \in \mathbb{P} : (x_e, y_e) \in r_{ij} \wedge \tau_e \in t \right|, \quad \text{进入该区域}$$
$$X_t(1, i, j) = \left| (s, e) \in \mathbb{P} : (x_s, y_s) \in r_{ij} \wedge \tau_s \in t \right|, \quad \text{离开该区域}$$

历史流量状态: 历史交通状态的整个时间段可以划分为不重叠的时间段

交通流量预测: 基于连续的历史流量观测数据和在T时间间隔内的外部因素预测T+1时间每个区域的进出流量

P

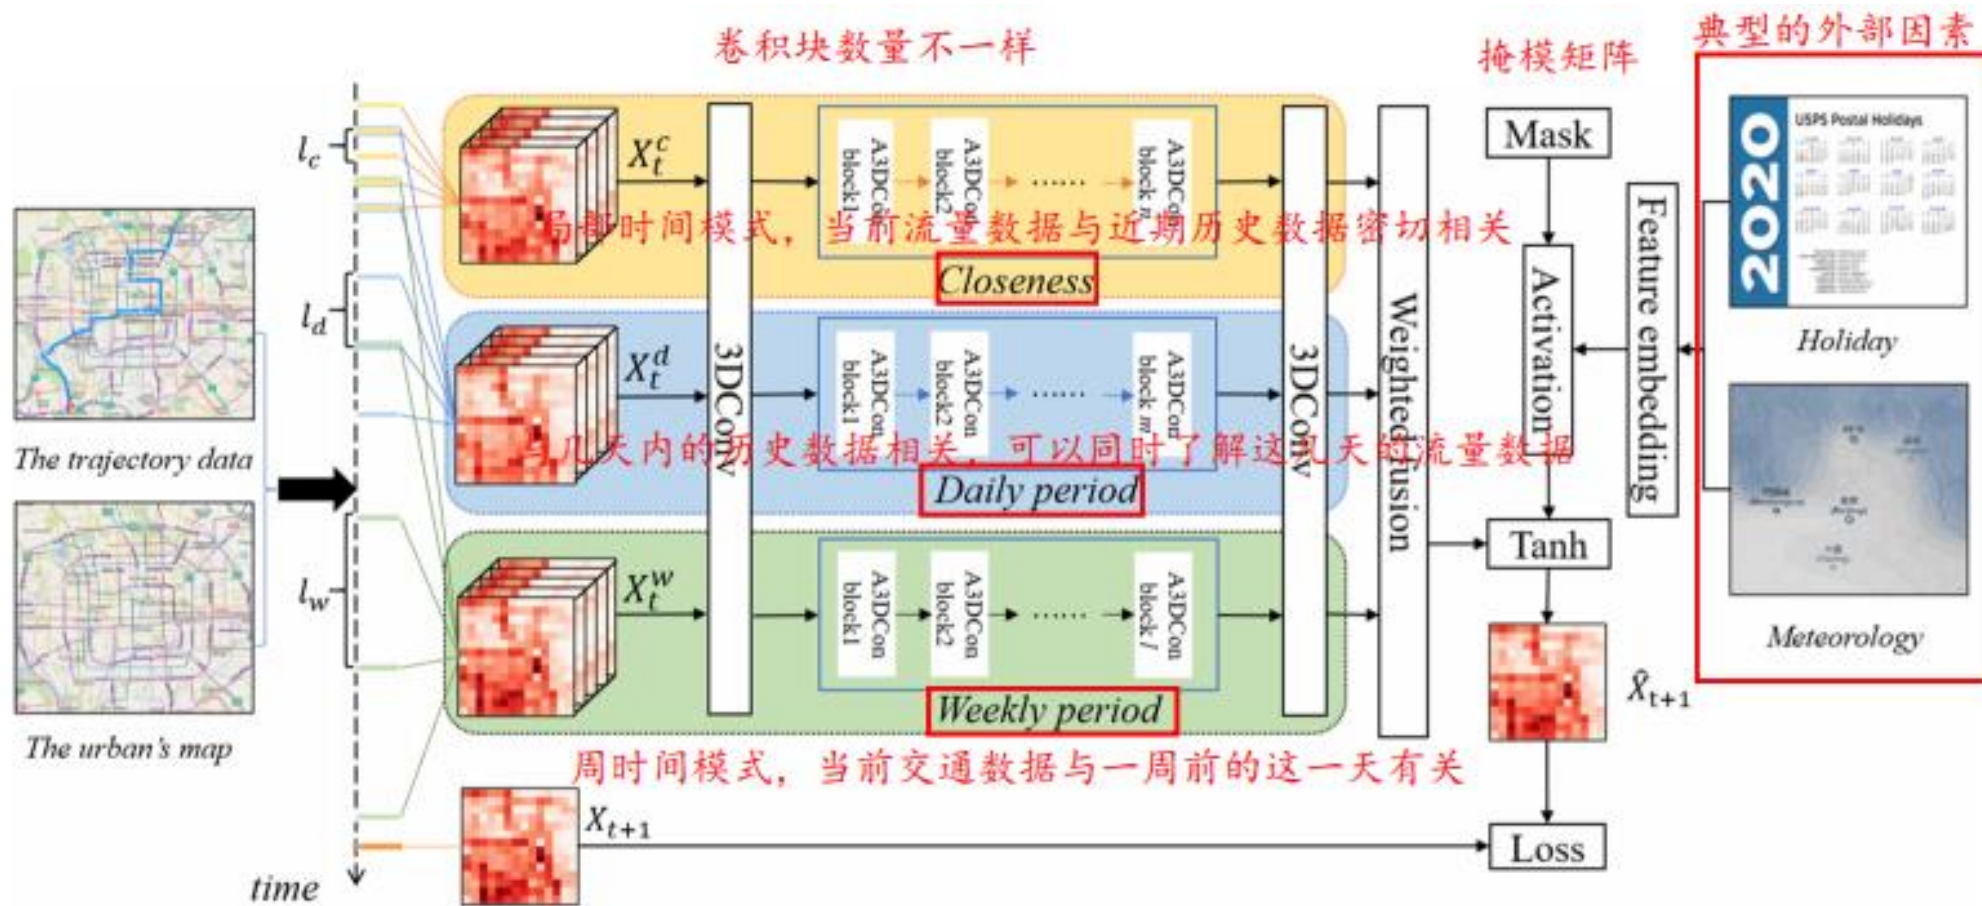
ART THREE

方法

ST-A3DNet



ST-A3DNet



3DConvSE Component

$$F_{sq}(X_t) = \frac{1}{W \times H \times C} \sum_{i=1}^C \sum_{j=1}^W \sum_{n=1}^H X_t(n, i, j),$$

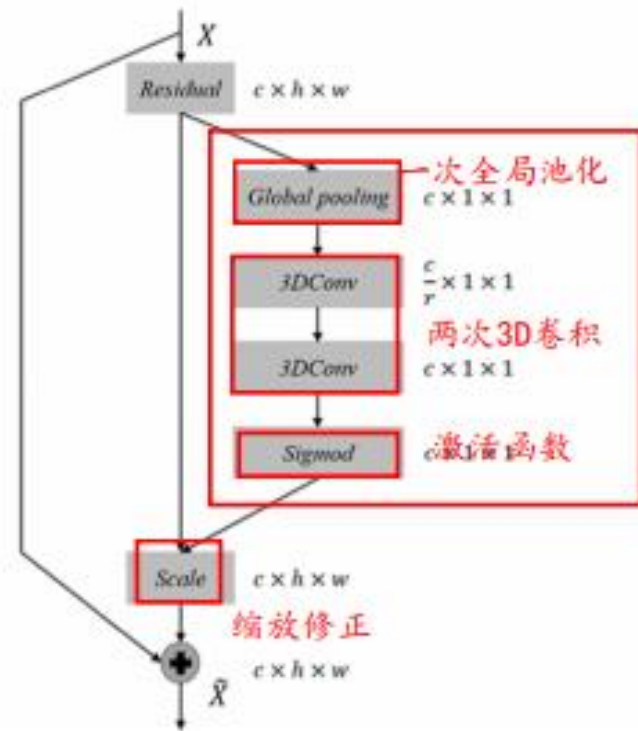
每个时间点全局交通流量的比例，对输入进行权重调整
 $z_t = F_{sq}(X_t),$

$$s = F_{ex}(z, W) = \text{Sigmoid}(W_2 * (\text{Relu}(\text{降维}(W_1 * z + b_1))) + b_2),$$

恢复原始尺寸

$$\tilde{X}_t = F_{scale}(X_t, s) = X_t \circ s,$$

对历史交通流地图信息进行缩放修正



不同时间通道信息的重要性有高有低，需要增强或抑制交通流信息

得出s

(c) 3DConvSE architecture

Adaptive Transformation

考虑不同时间和不同区域对预测时段交通流影响，提出自适应变换权重，即自动生成并匹配相应的权重到输入变量

Adaptive Transformation: 用于捕获时空灵活性，通过为不同的3D卷积挖掘分配不同的权值来实现

3D Convolution module: 特征提取

selection module: 为卷积训练匹配权值

过程

- Adaptive Transformation组件公式

$$X_{t,i}'^{(l+1)} = f\left(W_{t,i}^{(l+1)} * X_{t,i}'^{(l)} + b_{t,i}^{(l+1)}\right), l = 1, \dots, L,$$

- 自动生成匹配每个输入变量的权重

$$\alpha_{t,i} = \text{Sigmoid}\left(\text{FC}\left(3\text{DConvSE}\left(X_{t,i}^{(l)}\right)\right)\right),$$

时间t第i个3D卷积通道的权重

Weight Fusion

为了更灵活地整合特征，提出新的加权融合模块

- 首先融合三个通道输出的交通数据的时空特征

$$X_{t_{T+1}} = W_1 \odot X_{t_{T+1}}^c + W_2 \odot X_{t_{T+1}}^d + W_3 \odot X_{t_{T+1}}^w,$$

- 融合外部因素

$$X_{t_{T+1}} = \tanh (X_{t_{T+1}} \odot \varepsilon_T),$$

Algorithmic

ALGORITHM 1: ST-A3DNet Training Algorithmic

Input: The continuous historical flow observations $\{X_t | t = t_1, \dots, t_T\}$; the lengths of closeness, daily period and weekly period sequences: l_c, l_d, l_w ; the time interval between the last observed time interval; the predicted time interval Δt and external factors $\{\varepsilon_t | t = t_1, \dots, t_T\}$

Output: Learned ST-A3DNet model

// construct train dataset

```
1:  $\mathcal{D} \leftarrow 0$ 
2: for all available time interval  $t(0 \leq t \leq |T|)$  do
3:    $X_t^c = [X_{t-l_c}, X_{t-(l_c-1)}, \dots, X_{t-1}]$ 
4:    $X_t^d = [X_{t-l_d}, X_{t-(l_d-1)}, \dots, X_{t-d}]$ 
5:    $X_t^w = [X_{t-l_w}, X_{t-(l_w-1)}, \dots, X_{t-w}]$ 
   //  $X_{t+\Delta t}$  is the target at time interval  $t + \Delta t$ 
6:   Put  $(X_t^c, X_t^d, X_t^w, \varepsilon_t, X_{t+\Delta t})$  into  $\mathcal{D}$ 
7: end for
// training model
8: initialize all learnable parameters  $\theta$  in ST-A3DNet
9: repeat
```

从原始数据构建训练数据集

```
10:   randomly select a batch of instances  $\mathcal{D}_{batch}$  from  $\mathcal{D}$ 
11:   find  $\theta$  by minimizing loss function
```

优化对象

```
12: until stopping criteria is met
13: output the learned ST-A3DNet model
```

P

ART FOUR

实验

Datasets

Table 1. Statistics of the Traffic Dataset

	非旅游城市	旅游城市
Dataset	Chengdu	Xi'an
Location	In Chengdu, within the second Ring Road	In Xi'an, within the second Ring Road
Time interval	30 minutes	30 minutes
Raster size	(14,14)	(14,14)
Number of available time intervals	2592	2592
Data volume	10.6G	17.9G
Time span	1st Oct. 2016–30th Nov 2016	1st Oct. 2016–30th Nov 2016
Latitude and longitude range	[30.727818, 104.043333], [30.726490, 104.129076] [30.655191, 104.129591], [30.652828, 104.042102]	[108.92309, 34.279936], [109.008833, 34.278608] [109.009348, 34.207309], [108.921859, 34.204946]

数据处理：将14 X 14区域划分为约1 km × 1 km的网格，然后根据经纬度坐标和时间戳得到每个区域在每个时间的流入和流出。每隔30分钟将预处理数据叠加在一起，得到了总共的交通流量快照。

Experiment Setup

- 全时流量预测 & 高峰时段交通流量预测
- 训练集：测试集 — 8:2
- 高峰期：8:00am-9:00am 12:00pm-13:00pm 6:00pm-7:00pm
- ST-A3DNet层数：2
- 学习率：0.005
- 迭代次数：4000
- 优化器：ADAM
- 评估标准：MAE、RMSE、MAPE

QUESTIONS

Q1: ST-A3DNet与最先进的交通流量预测方法相比如何？

Q2: ST-A3DNet中的组件是如何影响性能的？

Q3:不同的设计，如ST-A3DNet中自适应3D卷积块的数量，如何影响ST-A3DNet的性能？

Q4: ST-A3DNet如何预测不同时间间隔的交通数据流性能？ST-A3DNet如何在测试数据集上执行？

Q1: Performance Comparison

Table 2. Performance Comparison of Different Models

Dataset	Model	Test(Full)			Test(Peak)		
		MAE	RMSE	MAPE(%)	MAE	RMSE	MAPE(%)
Chengdu	HA	39.21	79.08	20.86	42.63	97.04	25.67
	ARIMA	39.03	78.99	20.65	42.42	96.83	25.46
	GRU	35.57	55.31	32.37	38.91	54.59	33.82
	LSTM	36.29	47.47	37.49	38.79	55.18	40.97
	ConvLSTM	27.02	65.31	25.11	40.41	84.71	29.89
	STResNet	29.75	42.97	36.75	31.87	46.47	36.94
	ASTGCN	32.43	52.81	38.75	33.19	54.15	30.75
	ST-3DNet	28.67	46.20	33.67	30.54	47.32	32.89
	STSGCN	28.57	56.40	24.96	29.74	49.40	21.28
	STFGNN	29.85	61.69	22.54	31.24	50.23	20.44
	AGCRN	28.47	49.92	26.71	44.46	66.27	28.03
	ST-A3DNet(A)	19.95	31.56	19.32	19.74	31.03	20.17
Xi'an	HA	19.01	29.55	21.28	19.57	32.25	26.48
	ARIMA	18.89	29.42	21.09	19.48	32.16	26.37
	GRU	19.63	29.01	25.61	16.63	24.46	28.21
	LSTM	21.48	32.05	34.79	20.77	29.13	39.25
	ConvLSTM	21.22	32.99	26.06	19.51	30.54	30.08
	STResNet	18.12	26.65	40.41	15.65	23.49	46.93
	ASTGCN	18.11	27.65	36.51	18.01	28.21	27.16
	ST-3DNet	17.22	26.20	35.01	15.67	24.00	39.26
	STSGCN	16.04	26.45	30.07	19.62	27.54	25.41
	STFGNN	16.00	25.78	25.45	19.37	27.24	25.93
	AGCRN	17.58	27.34	37.85	25.94	36.75	32.84
	ST-A3DNet(A)	15.42	23.30	20.87	13.53	21.04	24.42

结论：本论文提出的模型表现最佳

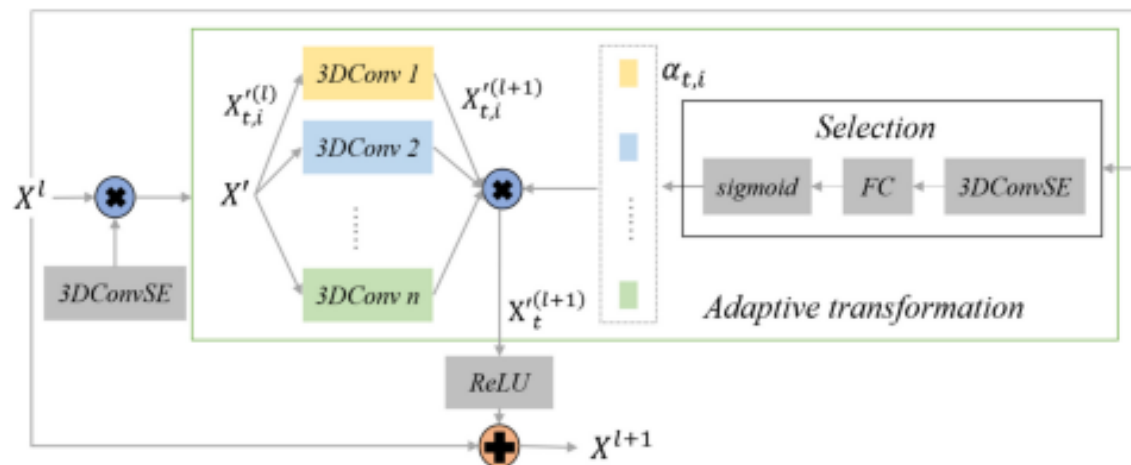
Q2:Ablation Study

Table 3. Performance Comparison of Ablation Study

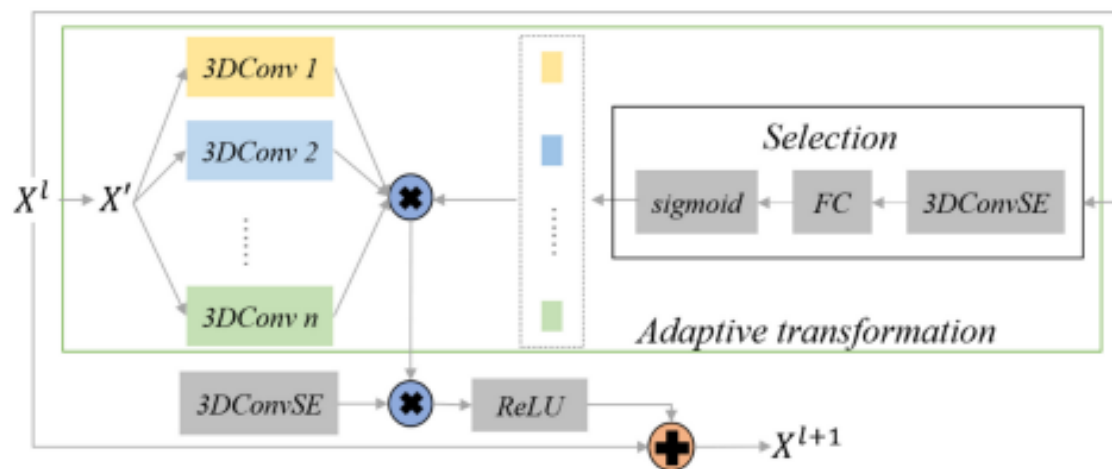
Dataset	Model	Test(Full)			Test(Peak)		
		MAE	RMSE	MAPE(%)	MAE	RMSE	MAPE(%)
Chengdu	ST-A3DNet(A)	19.95	31.56	19.32	19.74	31.03	20.17
	ST-A3DNet(B)	28.88	42.85	22.32	28.76	43.78	26.01
	ST-A2DNet	27.67	33.12	36.53	30.19	42.59	35.26
	ST-A3DNet(static)	29.69	40.65	33.19	31.19	42.77	35.81
	ST-A3DNet using Regular SE	28.01	44.54	23.92	33.73	49.37	32.15
	ST-A3DNet + L2	23.85	39.22	25.66	24.79	43.52	36.49
	ST-A3DNet-Ext	19.78	32.17	16.59	18.77	30.07	17.99
Xi'an	ST-A3DNet(A)	15.42	23.30	20.87	13.53	21.04	24.42
	ST-A3DNet(B)	19.83	29.85	30.16	19.51	29.72	39.05
	ST-A2DNet	17.94	26.52	39.32	15.41	23.17	43.68
	ST-A3DNet(static)	18.41	26.62	30.22	15.38	23.81	34.41
	ST-A3DNet using Regular SE	17.65	26.12	23.45	15.73	23.36	26.99
	ST-A3DNet + L2	15.17	23.40	22.32	15.10	24.68	33.23
	ST-A3DNet-Ext	15.02	22.91	21.68	13.62	20.01	24.07

- 组件位置
- 卷积方法
- 卷积核
- SE的类型
- 外部因素
- L2正则化

Q2:Ablation Study



(a) Adaptive 3D Convolution block(A)



(b) Adaptive 3D Convolution block(B)

原因:

在B中， $3DConvSE$ 组件在前面执行，首先会增强或抑制交通数据，这部分操作可能会破坏时空相关性，从而影响Adaptive Transformation组件的性能。

在A中， $3DConvSE$ 组件在Adaptive Transformation组件之后执行，Adaptive Transformation更好的捕捉数据的时空相关性并且本质上没有改变原始数据的特征，所以不会影响 $3DConvSE$ 组件的性能

Q3: Design Choices of ST-A3DNet

Table 4. Performance Comparison of ST-A3DNet with Different Number of Propagation Layers

Dataset	Model	Test(Full)			Test(Peak)		
		MAE	RMSE	MAPE(%)	MAE	RMSE	MAPE(%)
Chengdu	ST-A3DNet-1	21.43	32.41	21.28	21.75	33.58	25.53
	ST-A3DNet-2	19.95	31.56	19.32	19.74	31.03	20.17
	ST-A3DNet-3	20.49	32.65	17.14	20.15	31.03	18.34
	ST-A3DNet-4	20.58	32.64	17.94	19.94	31.83	18.88
Xi'an	ST-A3DNet-1	16.22	24.58	25.52	15.13	23.59	32.03
	ST-A3DNet-2	15.42	23.30	20.87	13.53	21.04	24.42
	ST-A3DNet-3	15.15	22.65	25.69	14.89	22.79	27.57
	ST-A3DNet-4	15.16	23.18	24.19	14.61	23.36	33.76

结论：单层网络性能不佳，至少需要覆盖两层网络，但额外的层数也不会提高网络性能。

Q4: Results with Different Time Intervals

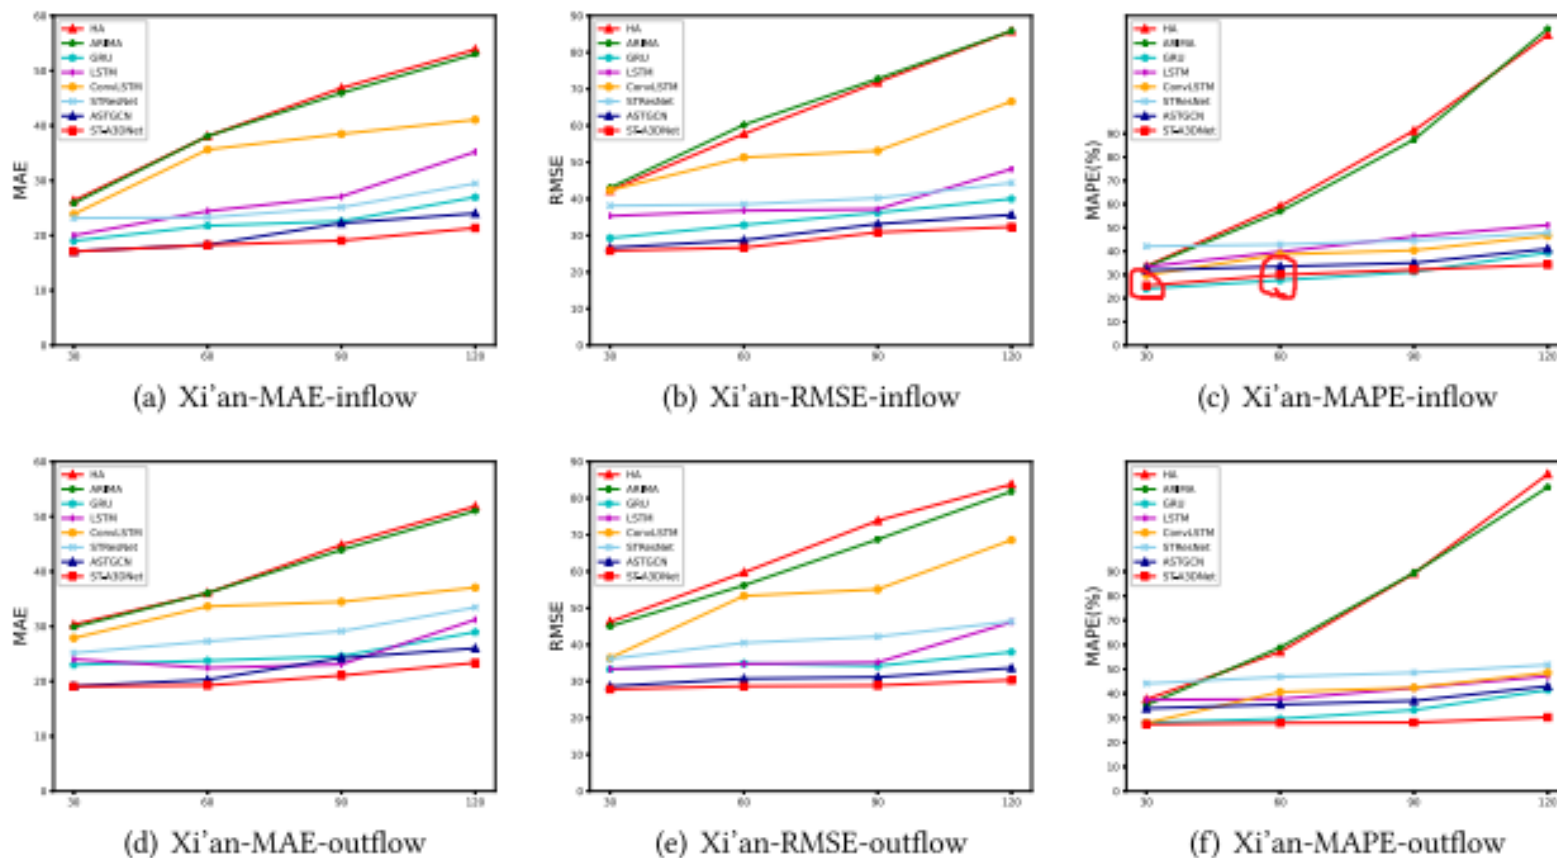



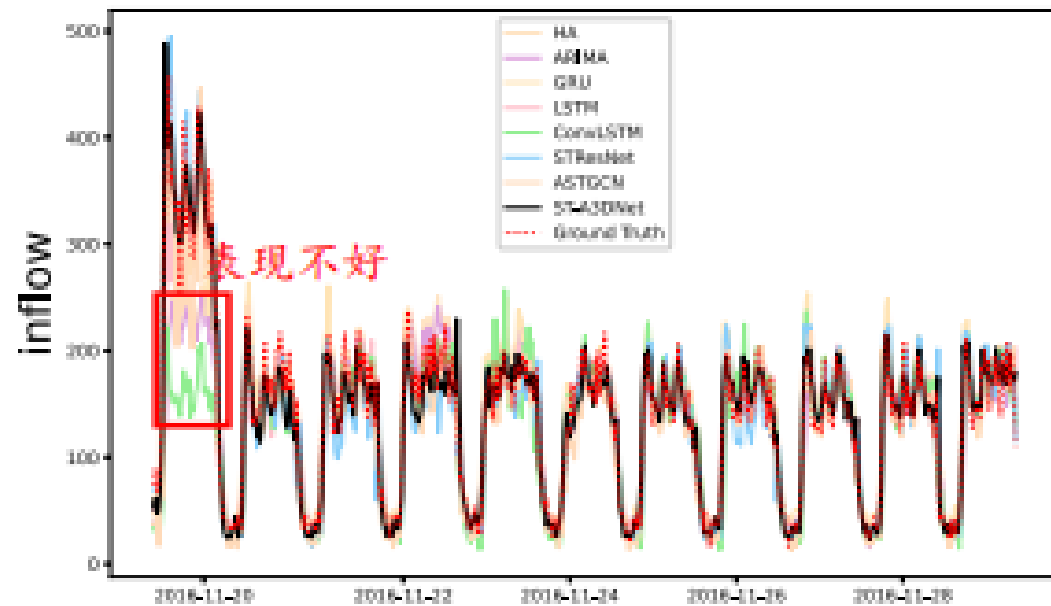
Fig. 6. Performance evaluation results of the inflow and outflow flow prediction of the models at different time intervals on the Xi'an dataset.

结论：该模型在长期预测和短期预测中都具有一定的有效性，特别是在预测难度较大、时空不确定性较强的长期交通预测任务中。

Test



(a) Xi'an



(b) Chengdu

Fig. 7. Performance of the inflow prediction of the models on the test dataset.

结论：时空灵活性对预测结果有一定的影响，本论文模型捕捉到了这一特征，所以预测结果与实际结果差距较小，实际效果优于其它模型

P

ART FIVE

结论

05

结论

- 本文提出一个新的深度学习模型ST-A3DNet
 - 这个模型同时预测时空网络中的输入/输出流
 - 可以捕捉时空相关性、时空灵活性和外部因素
- ✓ 在成都和西安两个真实数据集上对ST-A3DNet进行评估，
取得明显优于baseline的性能

感谢观看！

汇报人：闫林枝

> GOODBYE <