

基于物理引导的扩散概率模型的长期船舶轨迹插补

汇报人：韦浩文

日期：2024/9/22




引言

相关工作



方法



实验



总结



第一部分 引言



引言-研究背景



全球经济复苏导致国际贸易量大幅增长，海上运输迅速扩张。海上运输的普及加剧了对高质量AIS数据的需求。由于技术或人为等因素，可能导致AIS数据长期缺失即船舶轨迹长期缺失，引发严重的安全问题。AIS数据长期缺失是一个在时间和空间上都普遍存在的问题，这促使我们开发一个有效的长期船舶轨迹插补框架。



引言-研究意义



现有的轨迹插补方法在面对海上交通系统独特特征和处理长期数据缺失时存在局限性。

本文的研究解决了船舶轨迹插补中面临的两个难题

- (1) 如何表示船舶运动并将其编码到插补模型中
- (2) 如何在实现高精度插补的同时确保插补轨迹的连续性



第二部分 相关工作



相关工作-轨迹插补方法及局限性

轨迹插补方法可以分为两类：基于网络的插补方法和无网络的插补方法。

基于网络的插补方法

利用道路网络作为先验知识，依赖于道路网络的拓扑结构和历史轨迹数据的统计分析。主要有基于马尔科夫模型的方法（基于当前位置和历史信息，使用马尔科夫链来预测轨迹的下一个位置）和启发式搜索算法（通过搜索算法找到最优或可能的轨迹路径，如动态规划和逆强化学习）。

无网络的插补方法

不依赖于道路网络的结构，直接在观察到的轨迹点之间建立模型。主要有基于RNN的方法和基于Transformer的方法。

虽然上述方法显示出了很好的结果，但由于存在**两个显著的局限性**，它们无法直接适用于船舶轨迹插补问题。

一是车辆移动受到明确定义的道路网络的限制，而海上交通网络的提取和表示对于船舶更具挑战性。

二是船舶轨迹具有复杂性和不规则性，这些方法在处理长期船舶轨迹插补时会遇到困难。



第三部分

方法



方法-A 问题表述

定义1：船舶轨迹。

船舶轨迹 x 定义为一系列采样的GPS点位，每个点位表示船舶的具体位置，通常由维度和精度表示。这是船舶在一段时间内移动路径的记录。

定义2：观测和掩蔽轨迹。

观测轨迹 x_0^{co} 指的是实际观测到的轨迹数据，包含完整的船舶运动信息。掩蔽轨迹 x_0 指的是在插补任务中，部分观测轨迹数据会被有意“掩蔽”以模拟数据缺失的情况。

定义3：前向过程。

逐步将真实轨迹数据转化为随机噪声的过程。

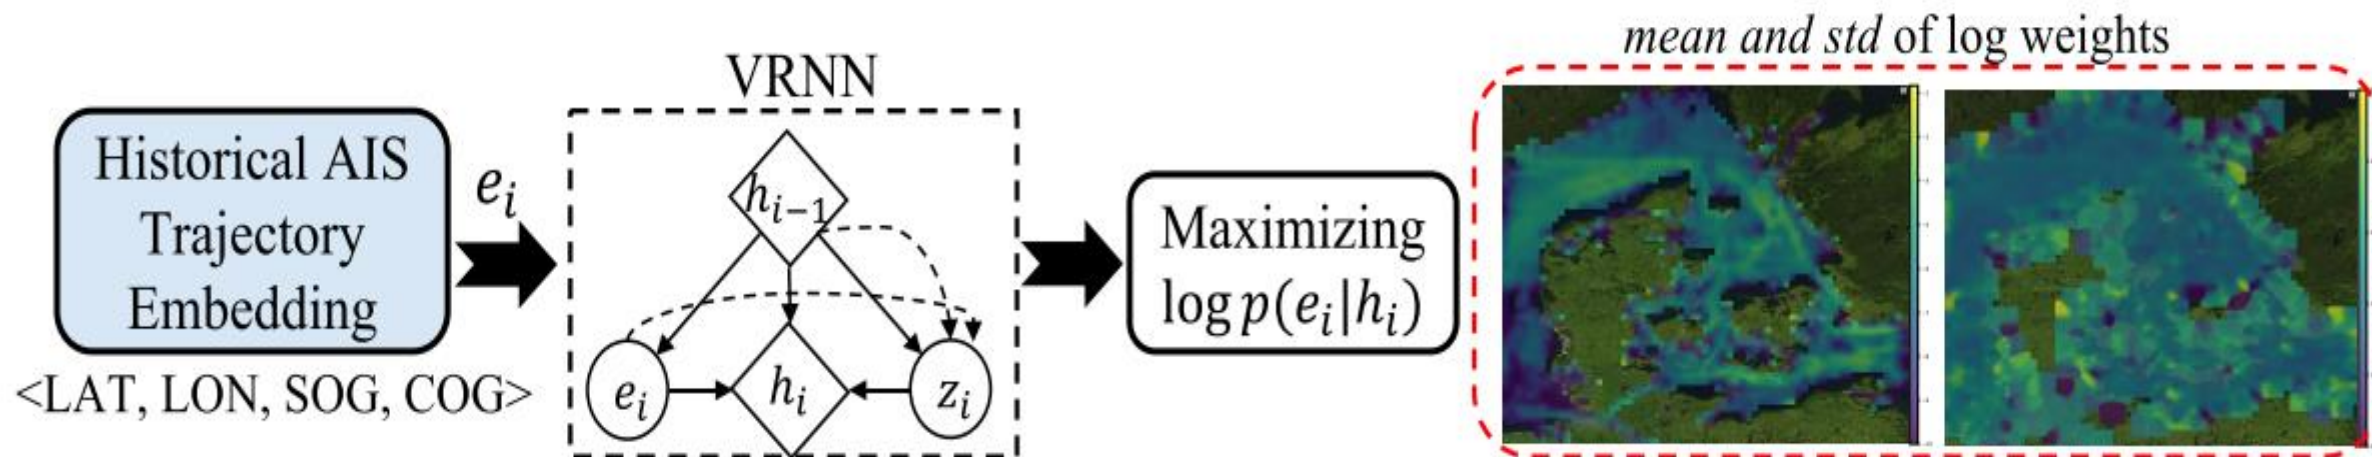
定义4：反向过程。

与前向过程相反，反向过程是从噪声数据中恢复原始轨迹数据的过程。

定义5：物理引导判别器。

用在模型训练阶段保证生成的轨迹数据符合物理规律的组件。

方法-B 轨迹嵌入模块



输入原始的船舶AIS轨迹数据（包括经度、纬度、航速和航向）。

由于船舶轨迹数据是连续的，首先需要对连续的轨迹数据进行**离散化处理**得到在特定分辨率下的嵌入表示。轨迹嵌入模块采用了**变分循环神经网络**（VRNN），训练时VRNN通过**最大化轨迹数据的对数似然**来优化模型参数。通过训练，VRNN能够提取船舶轨迹的特征并将这些特征转化为概率嵌入向量。

方法-C 观测轨迹的Transformer编码器




Figure 3: The model architecture of transformer encoder for observed trajectories.

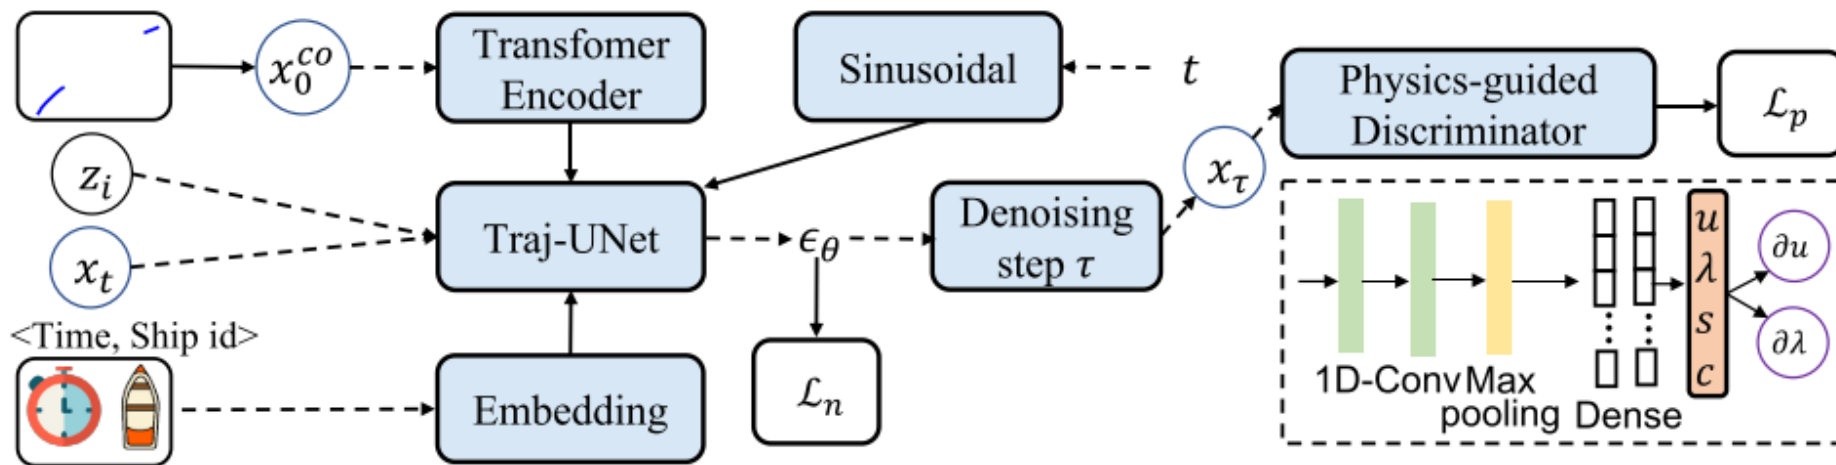
输入经过预处理和离散化的观测轨迹数据 x_0^{co}

基于傅里叶特征进行时间和空间编码得到嵌入矩阵 $E \in \mathbb{R}^{S \times d}$ ，其中S表示观测轨迹数据的长度，d表示观测轨迹的特征维度。

Transformer的多头自注意力机制通过计算每个轨迹点对其他所有点的注意力权重来工作，从而捕捉复杂的时空依赖关系。层归一化有助于稳定训练过程，而前馈网络则提供了额外的非线性处理能力。

输出将特征变量映射到更高维空间便于模型学习和处理，为嵌入矩阵 $A \in \mathbb{R}^{S \times d'}$

方法-D 物理引导扩散框架



1. 噪声预测模型的训练

使用从观测轨迹中得到的编码表示，结合历史船舶轨迹和外部因素（时间、船舶id）的嵌入信息，形成条件表示。使用正弦嵌入对扩散时间步长 t 进行处理。然后采用Traj-UNet架构预测噪声水平。

2. 物理引导判别器

物理引导扩散框架的总体损失函数包括两部分：

①**噪声预测损失**：用于衡量噪声预测模型预测的噪声与实际噪声之间的差异②**物理引导损失**：由物理引导判别器通过求解船舶轨迹连续性的微分方程以及结合运动学约束导出，用于衡量生成轨迹与物理约束之间的一致性。

注意：物理引导判别器仅在**训练**阶段使用，以最小化总体损失为训练目的，生成符合物理规律且与观测数据一致的完整轨迹。



第四部分 实验



数据集

AIS数据集

使用丹麦海事管理局提供的公开AIS数据集进行实验。数据集包含了2022年7月1日至2023年3月31日期间的货船和油轮的AIS观测记录。实验目标区域由一个边界框界定，其范围为纬度 53.5° 至 59.0° ，经度 7.5° 至 14.0° 。

数据预处理

移除异常速度记录 (≥ 30 节) 和停泊或锚定的船舶。按照最大时间间隔 (此处为 2 小时) 将非连续航程分成连续航程，删除长度小于 20 或持续时间小于 4 小时的 AIS 轨迹。将每条轨迹下采样为到 5 分钟的时间间隔，以最长 12 小时的序列长度对长轨迹进行分割。最后总共获得了 120,700 个船只轨迹样本，每个轨迹样本的长度固定为 144。



实验设置

数据集划分

将2022年7月1日到2023年9月30日的船舶轨迹数据用于预训练嵌入块。剩余的数据按照7:1:2的比例被分割为训练集、验证集和测试集。

缺失情况模拟

研究考虑了连续掩码场景，并在集合{6小时、8小时、10小时}中调整每个轨迹样本的插补掩码长度，以评估提出的插补模型的鲁棒性。在这些场景下，轨迹数据在连续掩码时间段内完全缺失。

参数设置

实验使用PyTorch 1.6.0和Python 3.6进行，使用RTX2080 GPU进行训练，运行平台基于Ubuntu 16.04操作系统。使用Adam优化器，初始学习率为 10^{-4} ，批量大小设置为512。

对于轨迹嵌入模块，AIS数据的嵌入分辨率为经度0.01度、纬度0.01度、航速5节、航向5度。对应的嵌入尺寸为256、256、128和128。

对于观测轨迹的Transformer编码器，隐藏层大小设置为128，头的数量设置为4。

对于反向去噪过程，扩散时间步数 T 为500，Traj-UNet中的每个下采样和上采样模块由两个堆叠的Resnet块组成。每个ResNet块所属的1D-CNN的卷积核大小设置为3。

对于物理引导判别器，判别器步长 τ 设置为20。分别将 β_1 和 β_2 设置为0.2和0.1。在这里，属于该判别器的TCN包括两个1D-Conv层和两个Dense层。



基线方法及评估指标

5个基线方法

1. LI: 对两个采样轨迹点采用线性插值方法, 并预测与插值直线距离在指定范围内的位置。
2. TraImpute: 一种无网络的启发式搜索算法, 根据历史轨迹中观察到的频率确定补全位置。
3. Transformer: 一种广泛使用的Seq2seq模型, 通过自我注意力机制进行了增强, 恢复的轨迹在解码器中生成。
4. 多任务AIS: 采用隐变量建模的循环神经网络来表示AIS数据和船舶轨迹重建。
5. CSDI: 一种最近的基于条件的分数扩散模型, 用于时间序列插补方法, 该方法利用了基于观测数据的分数扩散模型。

3个模型变体

- 1.Ours_NR: 移除了预训练的轨迹嵌入模块
- 2.Ours_NP: 移除了基于物理引导的判别器
- 3.Ours_ADD: 将基于物理的损失函数替换为直接计算轨迹角度的损失计算

评估指标

- 1.均方根误差 (RMSE) 2.平均绝对误差 (MAE)

此外, 为了评估轨迹的连续性, 还计算了连续点之间的轨迹角度误差。



实验结果-总体插补性能

Table 1: Overall imputation performance comparison (MAE/RMSE) across different missing scenarios with mask lengths of 6, 8 and 10 hours. We highlight the best performances in bold. Note that MAE and RMSE are in degrees of LAT and LON.

Model	6 Hours		8 Hours		10 Hours	
	LAT	LON	LAT	LON	LAT	LON
LI	0.0612/0.0902	0.0997/0.1444	0.0920/0.1323	0.1406/0.1989	0.1246/0.1765	0.1859/0.2608
TraImpute	0.0439/0.0843	0.0761/0.1289	0.0538/0.1233	0.0851/0.1916	0.0629/0.1242	0.1051/0.1681
Transformer	0.0433/0.0835	0.0749/0.1089	0.0475/0.0901	0.9009/0.1609	0.0518/0.0824	0.0893/0.1457
Multi-task AIS	0.0427/0.0810	0.0773/0.1197	0.0436/0.0833	0.0821/0.1709	0.0642/0.0944	0.1003/0.1566
CSDI	0.0328/0.0468	0.0542/0.0819	0.0391/0.0572	0.0755/0.1223	0.0492/0.0862	0.0832/0.1311
Ours-NR	0.0307/0.0459	0.0504/0.0796	0.0369/0.0516	0.0639/0.0987	0.0420/0.0671	0.0793/0.1243
Ours-NP	0.0268/0.0390	0.0482/0.0725	0.0329/0.0506	0.0606/0.0974	0.0374/0.0602	0.0625/0.1050
Ours	0.0296/0.0424	0.0478/0.0723	0.0324/0.0500	0.0592/0.0962	0.0366/0.0593	0.0607/0.1036

表1展示了在不同缺失场景下（掩码长度分别为6小时、8小时和10小时）整体插补性能（MAE/RMSE）比较。文章提出的框架基本上在所有缺失场景中都优于其他方法，特别是在高缺失场景下能获得更好的插补结果。



实验结果-插补轨迹连续性的消融实验

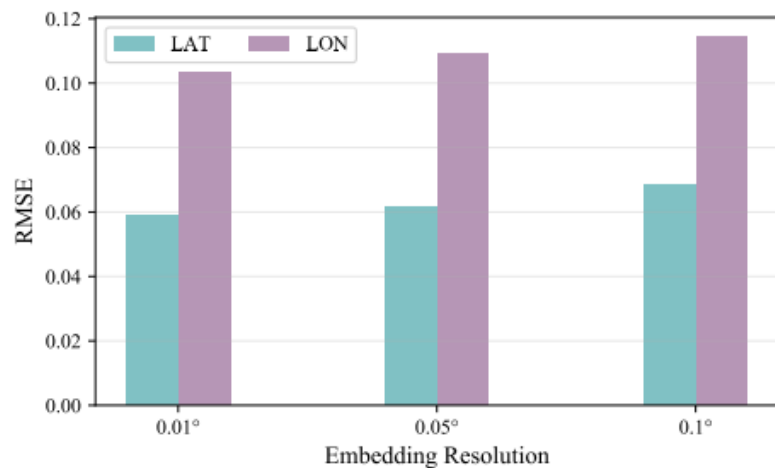
Table 2: Ablation study about the continuity of imputation trajectory. Note that the computation results of trajectory angles (MAE/RMSE) are in degrees.

Model	6 Hours	8 Hours	10 Hours
Ours-NR	28.64/47.14	29.10/47.23	31.83/48.14
Ours-NP	20.77/37.94	22.72/40.54	25.51/43.73
Ours-ADD	25.00/44.21	23.63/42.67	29.12/47.59
Ours	20.58/37.46	22.22/39.80	23.68/41.89


在表2中，计算真实轨迹和插补轨迹连续点之间的轨迹角度，比较不同缺失场景下角度误差的性能（MAE/RMSE）。物理引导判别器在每个缺失场景下都能产生更连续的轨迹插补结果，而直接添加角度损失组件（Ours_ADD）没有显示出明显的效果。



实验结果-超参数调优



(a) Varying of embedding resolution in the pre-trained embedding block



(b) Varying of discriminator step τ

Figure 4: Hyper-parameter Tuning.

图4 (a) 在预训练轨迹嵌入块嵌入分辨率为 $(0.01^\circ, 0.05^\circ, 0.1^\circ)$ 的范围内观察框架的插补性能。可以看到，当嵌入分辨率为 0.01° 时插补性能最佳，而随着嵌入分辨率的增加，性能会变差。表明本文提出的框架从精细的轨迹嵌入中收益。

图4 (b) 报告了物理引导判别器中不同判别步骤 τ 的影响。i) 当 τ 太小时，物理引导判别器试图学习更复杂的分布，导致轨迹连续性性能变差；ii) 当 τ 太大时，它已经捕获了去噪分布，遇到了性能瓶颈。



实验结果-案例研究

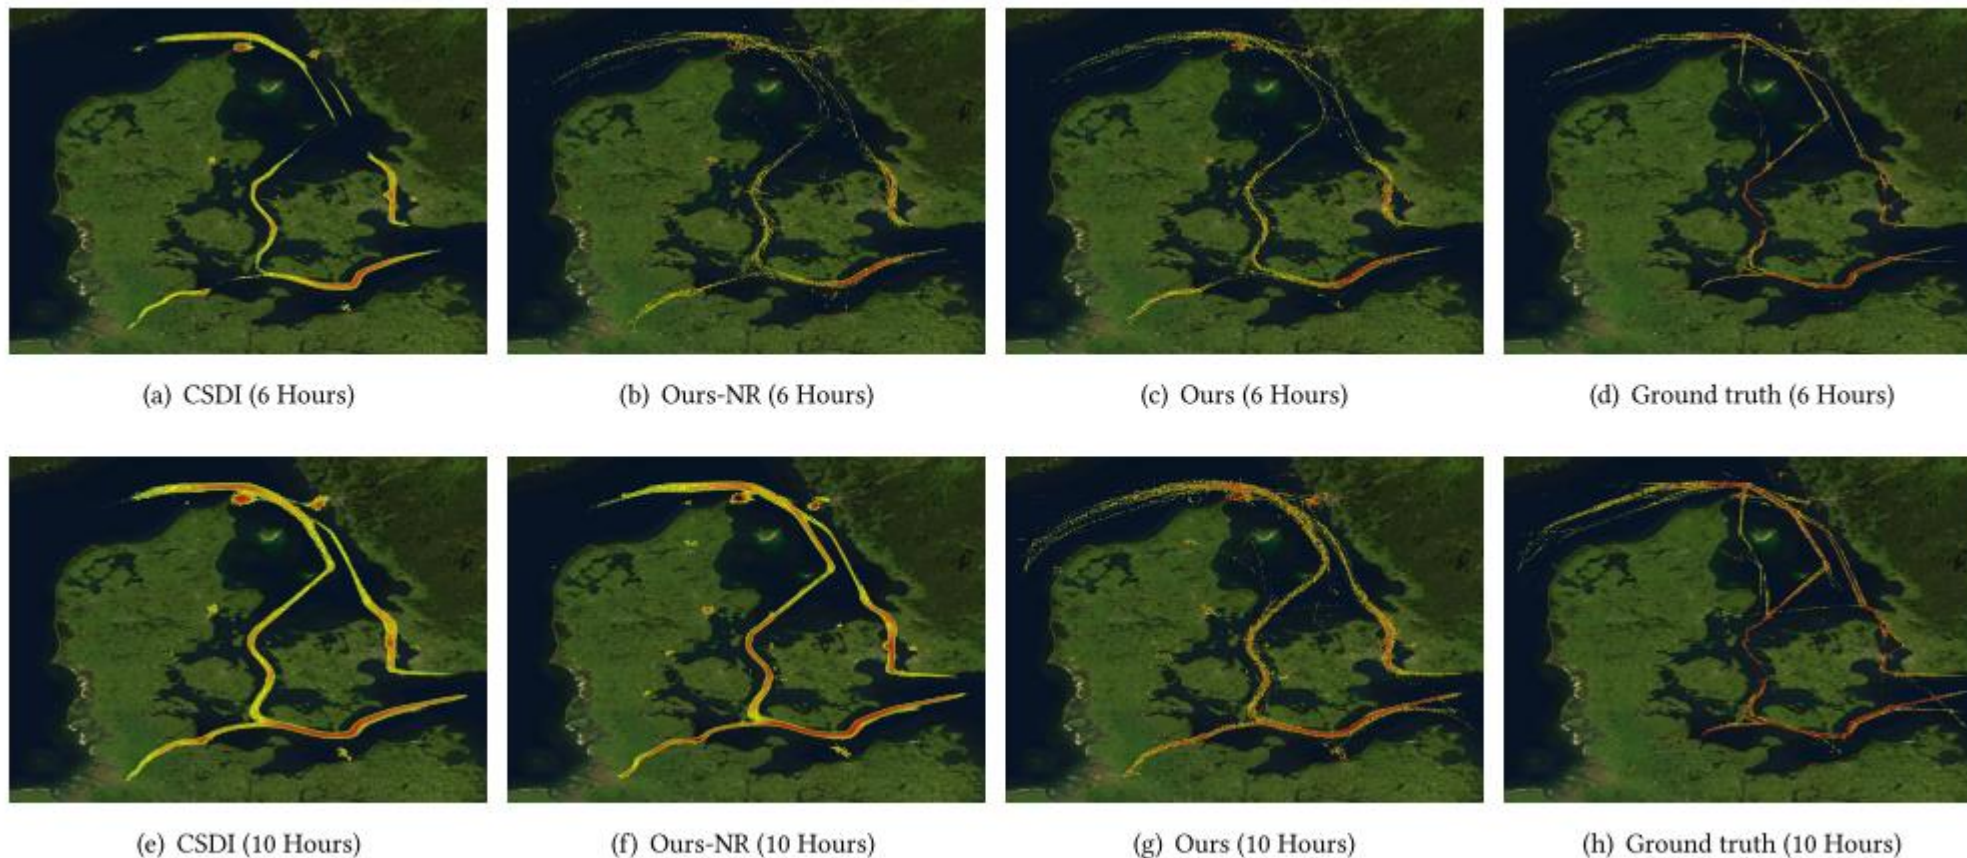


Figure 5: Heatmap comparison of imputation trajectories (about 24,000 tracks) for 6-Hour and 10-hour missing scenarios.


在6小时和10小时缺失场景下基于整个测试集的插补轨迹的热力图比较。文章提出的模型与真实数据呈现出相似的模式，特别是在高缺失的场景中，展示了比CSDI和Ours_NR更为详细的路线。




实验结果-案例研究



(a) Map visualization of two imputation examples



(b) Changes of imputation trajectory angles for example 1



(c) Changes of imputation trajectory angles for example 2

Figure 6: Two Screenshots of trajectory imputation (10-hour missing scenarios).

为了突出轨迹连续性的挑战，以10小时缺失场景为例，通过两个例子评估插补轨迹的连续性。图6表明，与Ours_NP和Ours_ADD相比，文章提出的框架显示出更小的轨迹角度误差。这表明，将物理引导判别器和扩散模型相结合，提高了长期插补任务的平滑性。



第五部分

总结



总结

总结

- 1.文章提出了一种新颖的物理引导扩散模型。这是首次将扩散模型与物理引导判别器相结合处理轨迹插补任务。它在保证轨迹更好的连续性的同时实现了精确插补。
- 2.文章采用基于概率网络表示的预训练轨迹嵌入块来捕捉船舶运动的模式。
- 3.对于反向去噪网络架构，文章采用了Traj-UNet，它在反向过程中整合了多尺度特征融合来预测噪声级别，其中，使用Transformer编码架构对观测轨迹进行建模，并结合历史船舶轨迹嵌入及外部因素的嵌入作为条件信息。
- 4.文章利用公开的AIS数据集验证了所提出框架的有效性，并报告了其在不同缺失场景下的优越性。

感谢观看