



A Graph Representation Learning Approach for Imbalanced Ship Type Recognition Using AIS Trajectory Data

一种用于基于船舶自动识别系统（AIS）轨迹数据的不平衡船型识别的图表示学习方法

IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS 2025

汇报人：庞媛媛

2025/4/25

目 录



背景



相关工作



方法



实验

动机+轨迹分类应用+相关研究局限

- 识别海运货轮的船型对海洋运输业的管理和效率提升很重要
- 传统CNN和RNN很难同时处理轨迹点的拓扑关系和属性信息

■ 基于轨迹分类的应用

- 推断人员出行模式
- 识别城际卡车所运载货物的类型，改善运输物流
- 确定船舶类型，服务于船舶管理和航行安全

■ 从轨迹点序列识别运动模式（子轨迹）和交通方式（完整轨迹）的方法

- 统计建模
- 应用基于规则的约束条件
- 机器学习算法

识别的本质：有效建模原始轨迹，提取运动特征

■ 相关研究

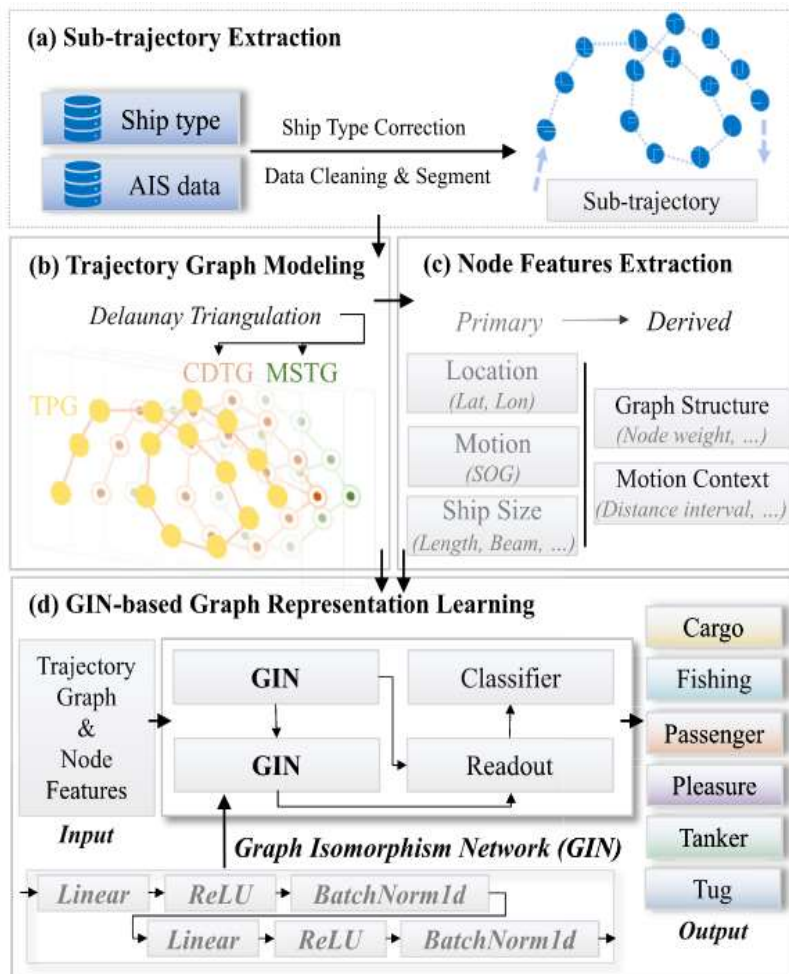
- 结合先验知识和统计知识，手动制定规则从运动数据中推导特征。--忽略轨迹数据潜在结构模式和序列依赖关系
- 机器学习（随机森林、逻辑回归）依靠地理、行为及船舶静态属性识别船舶类型—迁移能力差、过拟合风险
- 轨迹→光栅化图像，深度学习（MLP、CNNs）分析学习运动也正→在位置和运动学信息上导致精度损失
- 轨迹→矢量图，图学习保留轨迹内在结构关系，节点嵌入捕捉高精度位置和运动学细节—精度提高



传统GNNs变体在表示能力上存在性能瓶颈

- GIN图同构网络遵循GNN的邻域聚合方法，理论上是GNNs变体中用于表示任务的最强架构
“关注轨迹图中细微差别，提取深层次特征”

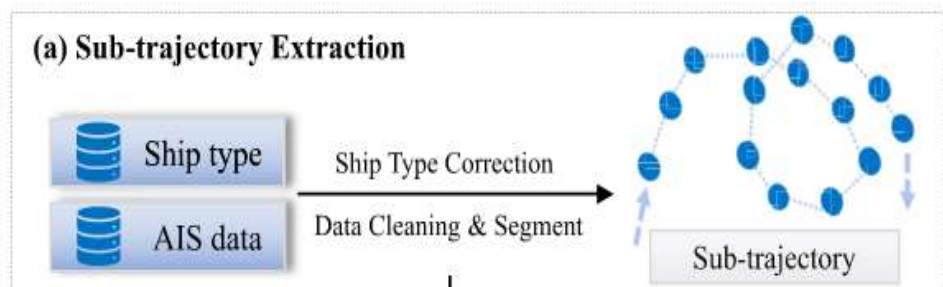
框架



- 子轨迹提取
 - 校正、数据清洗、简化和分段
- 轨迹图建模
 - 约束德劳内三角剖分图（CDTG）
 - 最小生成树图（MSTG）
 - 轨迹折线图（TPG）
- 节点特征提取
 - 原始特征（静态、动态信息from AIS数据）
 - 派生特征（from轨迹图）
- 基于图同构网络（GIN）的图表示学习
 - 通过堆叠线性层、激活函数层和归一化层构建一个图同构网络模型
 - 集成Readout层和Classifier层构建图表示学习框架：输入轨迹图和节点特征，输出预测的最有可能的船舶类型

Fig. 1. Graph representation learning framework for ship type recognition.

子轨迹提取



➤ 去除异常轨迹点

- 第一类：SOG > 35节/h的轨迹点
- 第二类：与前后轨迹点的空间距离 > 3km的轨迹点

➤ 去除异常子轨迹

- 按天分割子轨迹，去除点数量 < 100个的子轨迹 → 限制子轨迹最大长度，且确保携带信息量达到最小要求
- 去除SOG > 2节/h的轨迹点数量未超过总数30%的子轨迹 → 避免因低速异常活动轨迹导致的预测偏差

轨迹图建模




Fig. 2. DTG, TPG, CDTG and MSTG graph structures of a ship trajectory.

图结构要满足的要求

- 保留轨迹之前的顺序依赖关系→真实的船舶活动
- 减少无效边（连接表示差异较大的节点的边），稀疏性→计算效率
- 同类节点之间建立更多的连接边增强相似节点（自身表示、邻居结构、相邻结点表示）之间的信息传递

- 德劳内三角剖分图DTG—临近关系
- 轨迹折线图TPG—顺序依赖关系
- 约束德劳内三角剖分图CDTG：距离阈值=3km，简化DTG—稀疏
- 最小生成树图MSTG（选择一组边使得所有点连通且边的权重之和最小）——计算开销

节点特征提取

Feature type	Node feature	Description	Unit
Location	Lat	Latitude of the current trajectory point	decimal degree
	Lon	Longitude of the current trajectory point	decimal degree
Motion	SOG	Speed over ground of the current trajectory	knot/h
	Length	Length of the ship	meter
Size	Beam	Beam of the ship	meter
	Aspect ratio	Ratio of the ship's length to its beam	
Graph structure	Node weight	Number of occurrences of trajectory points at the same location	
	Time interval	Time interval between two consecutive neighboring trajectory points	
Motion Context	Distance interval	Spatial distance between two consecutive neighboring trajectory points	meter
	Heading difference	Difference in COG between two consecutive neighboring trajectory points	degree

原始特征：位置、运动状态、尺寸（船长、船宽、长宽比）

派生特征：图结构（节点权重、时间间隔）、运动环境特征（距离间隔、航向差）由轨迹图和轨迹计算得出

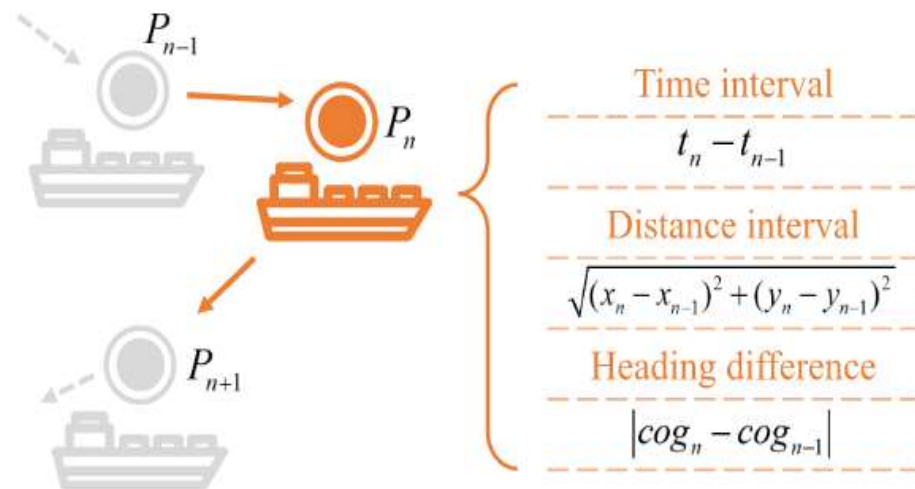
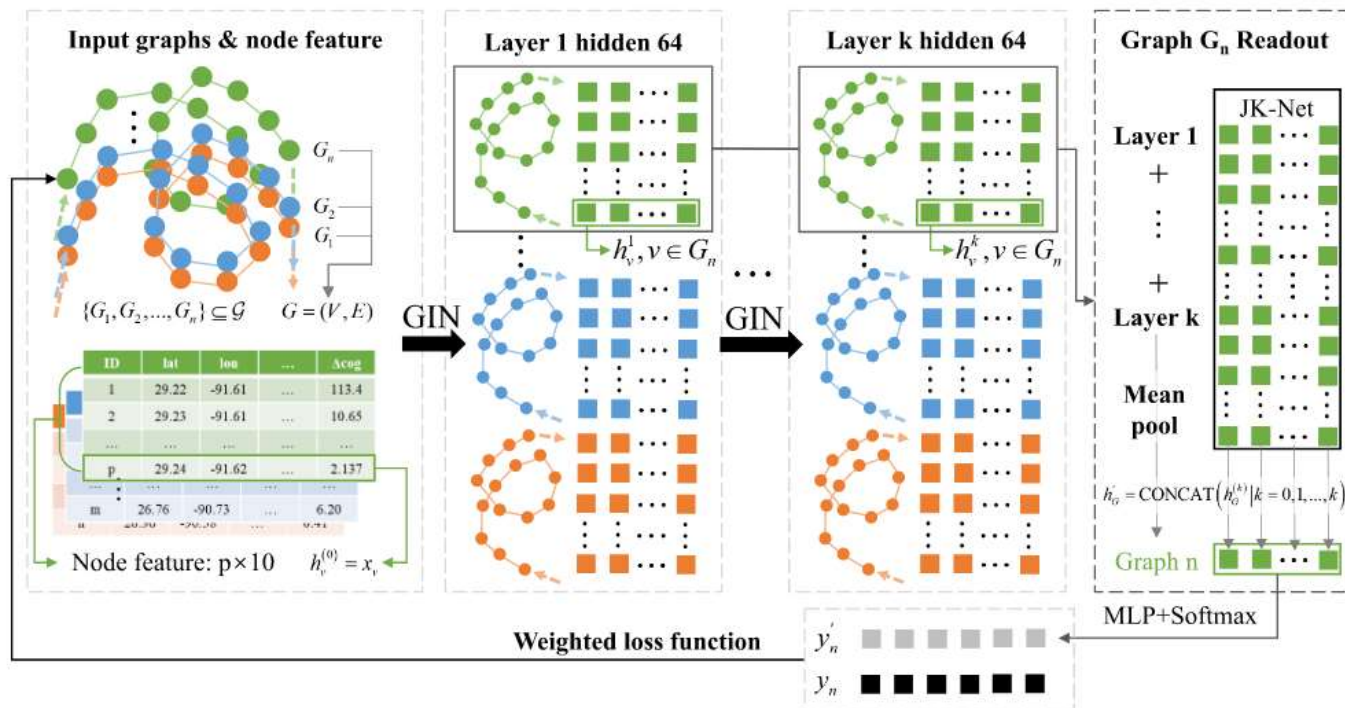


Fig. 3. Motion context features of network nodes.

基于图表示学习的船型识别模型——用于图表示学习的GNNs框架（整体）



图神经网络执行图卷积来学习节点表示：输入节点特征和图邻接矩阵，多个图卷积层堆叠，并迭代更新节点的特征嵌入。

“递归的邻居聚合学习模型”

例：对节点 v 进行第 k 次图卷积

➤ 聚合

消息传递函数 $M^{k-1}(\cdot)$ 将邻居节点表示转换为消息聚合函数 $agg^{k-1}(\cdot)$ 聚合得到邻居信息 a_v^k

$$a_v^k = agg^{k-1} \left(M^{k-1}(h_v^{k-1}, h_w^{k-1}, e_{vw}) \right), w \in N(v) \quad (1)$$

➤ 组合

组合函数 $comb^{k-1}(\cdot)$ 将 a_v^k 与节点 v 在第 $k-1$ 层的表示 h_v^{k-1} 组合，得到节点 v 在第 k 层的表示 h_v^k

$$h_v^k = comb^{k-1}(h_v^{k-1}, a_v^k) \quad (2)$$

➤ 读出函数-每层图卷积得到的节点表示聚合为图的特征嵌入 h_G

$$h_G = READOUT(\{h_v^k | v \in G\}) \quad (3)$$

h_G 用于预测图的标签 $y_G = f(h_G)$ ，输入的图集 $\{G_1, G_2, \dots, G_n\} \subseteq \mathcal{G}$ ，图的标签描述 $\{y_1, y_2, \dots, y_n\} \subseteq \mathcal{Y}$

➤ 跳跃知识网络聚合所有图卷积层得到的节点表示

$$h'_G = CONCAT(\{h_G^{(k)} | k = 0, 1, \dots, k\}) \quad (4)$$

➤ 分类：轨迹图表示 h'_G 输入到MLP降维，输出通过SoftMax转换为不同类别的概率分布。概率最大的类别为最终识别结果。

Fig. 4. Ship type recognition in AIS using GNNs graph representation learning.

基于图表示学习的船型识别模型——图同构网络卷积层（局部）

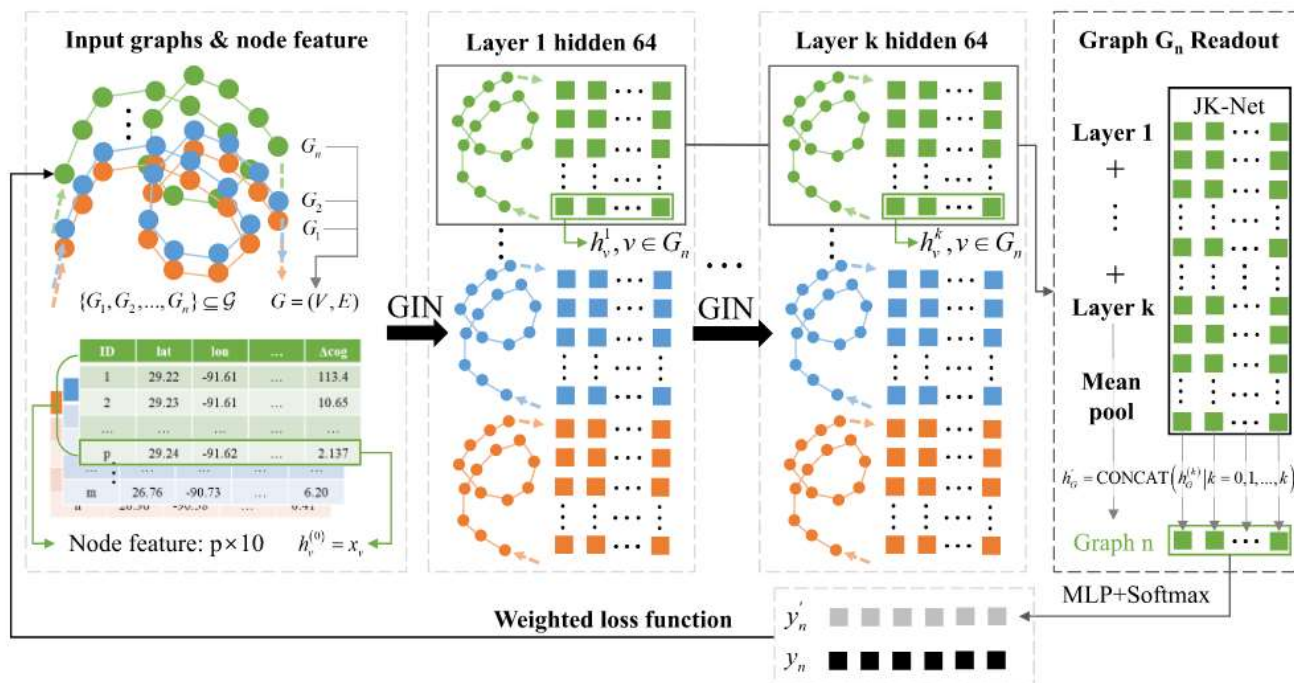


Fig. 4. Ship type recognition in AIS using GNNs graph representation learning.

➤ 广泛方法：GNNs采用邻居聚合策略
(缺点) 依赖于直觉、启发式方法和实验试错，缺乏理论基础指导模型构建。

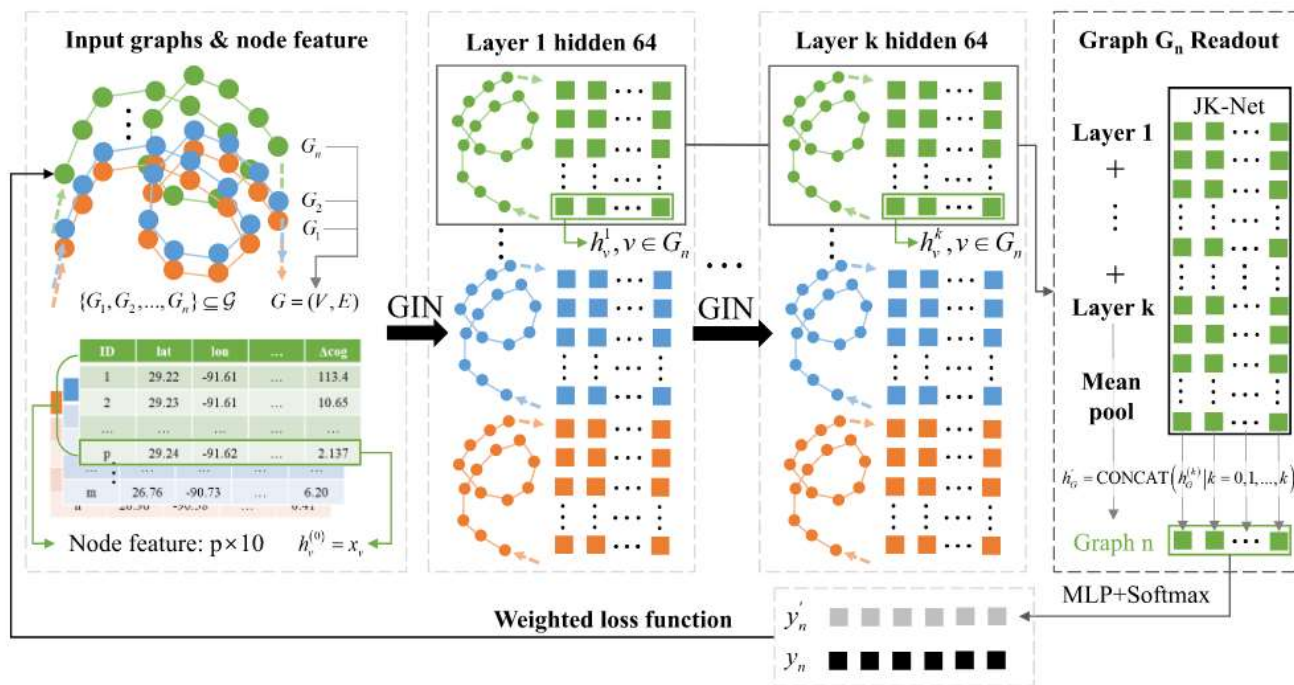
➤ GIN有理论基础、计算效率高，更强的图表示能力
灵感来源莱曼 (WL) 图同构测试，通过聚合相邻结点的特征更新节点表示，来区分图的结构。
WL测试判别同构图的能力 ← 节点特征更新过程的单射性

➤ 图同构网络中邻居聚合函数和特征组合函数必须为单射

➤ 如何使模型具备单射学习能力？
根据人工神经网络数学理论中的广义逼近定理，前馈神经网络能够逼近任意函数[46]。因此，节点特征更新过程可以使用多层感知器 (MLP) 进行建模，MLP被视为多个单射函数的组合。

$$h_v^k = \text{MLP}^k((1 + \binom{k}{1}) \cdot h_v^{k-1} + \sum_{w \in \mathcal{N}(v)} h_w^{k-1})$$

基于图表示学习的船型识别模型——损失函数加权层



- 船型识别面临样本不均衡问题：模型倾向于从样本数量较多的类型中学习知识，导致无法更好地识别样本较少的船型。
- 传统解决方法：图像处理、欺诈计策等领域采用采样或欠采样的方法处理原始数据集，（缺点）改变了初始分布和关系。
- 根据分布比例计算权重，训练期间将权重引入损失函数计算，使模型平等关注每个类别。

类别权重系数: $W_i = \frac{N}{n_i}$

对简单损失函数重新加权，使学习过程更关注少数类样本，是一种从不均衡样本中学习的简单有效的方法。

- 评估指标：交叉熵损失函数→多分类任务

$$L(y^*, y) = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^M y^*(ij) \log y(ij) W_i$$

$y^*(ij)$ 是样本的真实标签， $y(ij)$ 是模型预测的结果。

Fig. 4. Ship type recognition in AIS using GNNs graph representation learning.

实验

- 数据集：2023年5月的新泽西湾东部地区、墨西哥湾北部地区
- 训练集、验证集、测试集3:1:1
- 船舶类型：货船、油轮、游艇、客船、渔船和拖船
- 代码：<https://github.com/destiny1103/GIN-Ship-type>

TABLE II
NUMBER OF SHIPS AND SUB-TRAJECTORIES IN EXPERIMENTAL DATASET

Dataset	Number of Trajectory Points	Number of Ships	Number of Sub-trajectories
Gulf of Mexico	15,842,889	4,218	27,270
New Jersey Bight	6,864,329	2,718	14,319

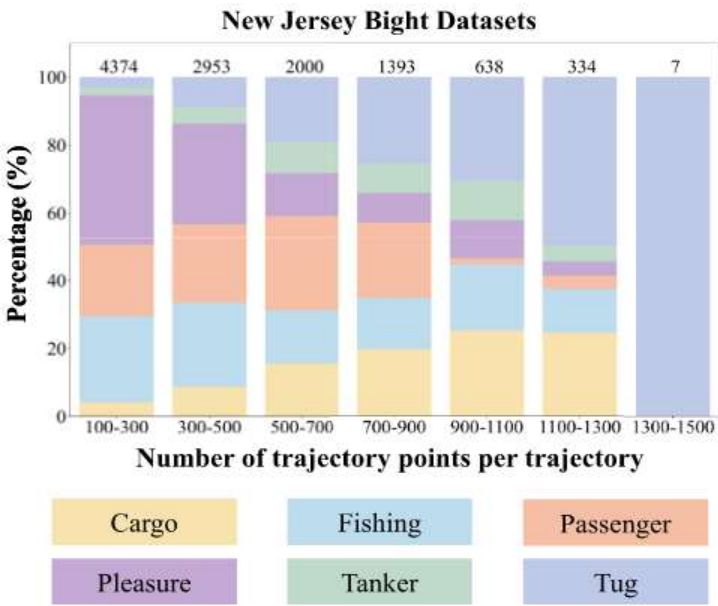



Fig. 6. Number and scale of six ships' trajectories.

轨迹图结构的讨论

TABLE III
COMPARISON OF PERFORMANCE AND EFFECTIVENESS OF DIFFERENT GRAPH STRUCTURES

	Graph Structure	Avg nodes	Avg edges	Train time (s/epoch)	Inf speed (graph/s)	Avg loss	Avg accuracy
Gulf of Mexico	CDTG	580.96	785.51	3.75	8,623	0.1793	0.942±0.006
	MSTG		289.14	3.66	9,278	0.1704	0.943±0.004
	TPG		289.98	3.39	10,036	0.1620	0.948±0.004
New Jersey Bight	CDTG	479.39	656.04	1.71	9,815	0.1688	0.944±0.003
	MSTG		239.05	1.57	11,427	0.1732	0.944±0.006
	TPG		239.19	1.49	11,726	0.1655	0.947±0.003

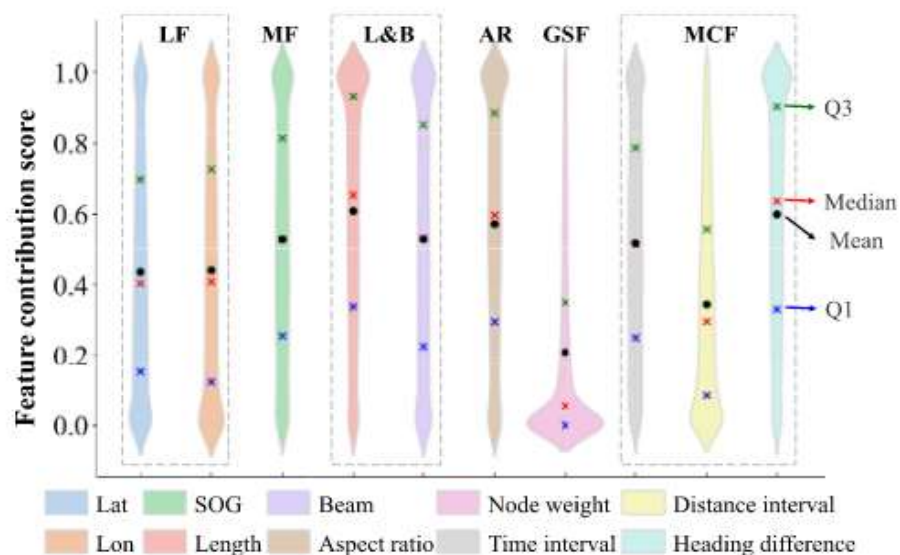
- 准确率：TPG高—顺序依赖关系√
- 损失：CDTG损失大—相邻结点连接次数多于MSTG
- 推理速度



- 单个轨迹对象进行图建模，应优先保留轨迹点间的顺序依赖关系。
- TPG图结构在平均损失、准确率、训练时间和推理速度方面具有显著优势。

特征贡献的讨论

- GNNExplainer方法来评估节点特征（原始特征、派生特征）的贡献
- 过程：
 - 节点特征掩码通过连续参数化来表示，利用重参数化技术将离散的特征选择过程转化为一个可微的优化问题。
 - 训练过程中，梯度下降法来优化掩码参数，同时应用稀疏性约束来分离出对预测最重要的特征。
 - 特征重要性得分通过Sigmoid函数归一化处理，取值范围为0到1。
- 优点：能同时识别关键的图结构模式、重要的节点特征，揭示它们在模型预测中的协同作用。
- 可视化：特征重要性小提琴图（根据测试集中所有图生成）



10个节点特征六组：

- ✓ 位置特征（LF）：低值和高值两端都较宽，贡献的可变性大，对预测不利；
- ✓ 运动特征（MF）、船长和船宽（L&B）、长宽比（AR）：高值较宽，贡献大；
- ✓ 图结构特征（GSF）：贡献最弱；
- ✓ 运动上下文特征（MCF）：转向差分布最高，有助于识别船型。

船舶类型识别结果与评估

模型准确率随训练次数增加的波动曲线

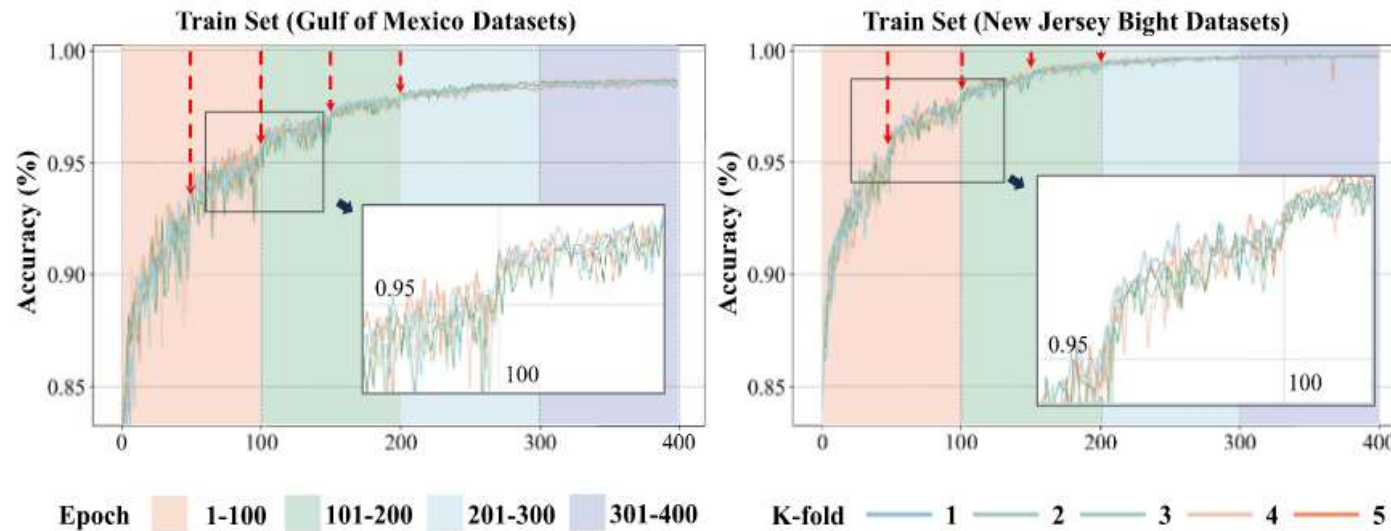


Fig. 8. Model accuracy curve of the training set.

- ✓ 随着训练次数的增加，模型对两个训练集中数据的拟合程度↑。
- ✓ 模型对新泽西湾数据集的拟合程度略，可能与训练集的规模有关。

总结

本文提出了一种基于AIS数据识别船舶类型的全新深度学习框架。利用图结构对船舶轨迹的邻近关系和顺序依赖进行建模，从而利用轨迹中的拓扑关系。然后，运用图表示学习从不同长度的轨迹图中提取轨迹点的深度特征，以识别船舶类型。个数据集上的识别准确率分别达到93.95%和92.33%，证明了其在准确性和鲁棒性方面的卓越性能。这一结果主要归因于以下几个方面：

首先，将船舶轨迹构建为图结构，使模型能够捕捉轨迹点之间的依赖关系。节点特征嵌入更有助于模型学习船舶的微观活动以及每项活动的细节。结果表明，提出的将轨迹图结构与图神经网络（GNNs）图表示学习相结合的方法是适用的，且性能优异。

其次，与经典的图卷积层相比，图同构网络（GIN）图卷积层能够更好地利用图神经网络的表示学习能力，有效捕捉船舶轨迹中的顺序依赖关系，以更新节点表示并提高识别准确率。

第三，通过自适应计算损失函数，有效解决了数据不平衡问题。根据训练样本的分布对每种预测类型的损失进行加权，以增强模型从小样本类别中学习的能力。对比实验的结果验证了该策略的有效性。

谢 谢！