



TransferTraj：一种具备区域与任务可迁移性的车辆轨迹学习模型

汇报人：韦浩文

时间：2025-11-9

目 录

- 01 背景
- 02 方法
- 03 实验
- 04 总结



1

背景



背景

■ 背景

位置感知设备广泛应用->车辆轨迹数据的可获取性不断提升->轨迹学习模型（轨迹预测、轨迹恢复、行程时间估计等）不断发展

■ 研究现状

□ 非迁移性轨迹学习模型：针对特定区域和任务设计

- 训练成本高
- 需要每个区域都具备大量可用的轨迹数据来支持模型的训练

□ 迁移性轨迹学习模型：通过预训练嵌入技术将车辆轨迹映射为嵌入向量来实现任务迁移性，区域迁移性尚未解决

■ 挑战

□ 区域迁移性——不同区域间空间特征和空间上下文分布的差异

□ 任务迁移性——不同任务在输入输出结构上和所学习的相关性上的差异

TransferTraj

兼具区域和任务迁移性的车辆轨迹学习模型

- 区域可迁移轨迹编码器（RTTE）——区域迁移性
 - ✓ 轨迹相对信息提取模块（TRIE）
 - ✓ 空间上下文混合专家模块（SC-MoE）
- 任务可迁移输入输出方案——任务迁移性



2

方法

TransferTraj

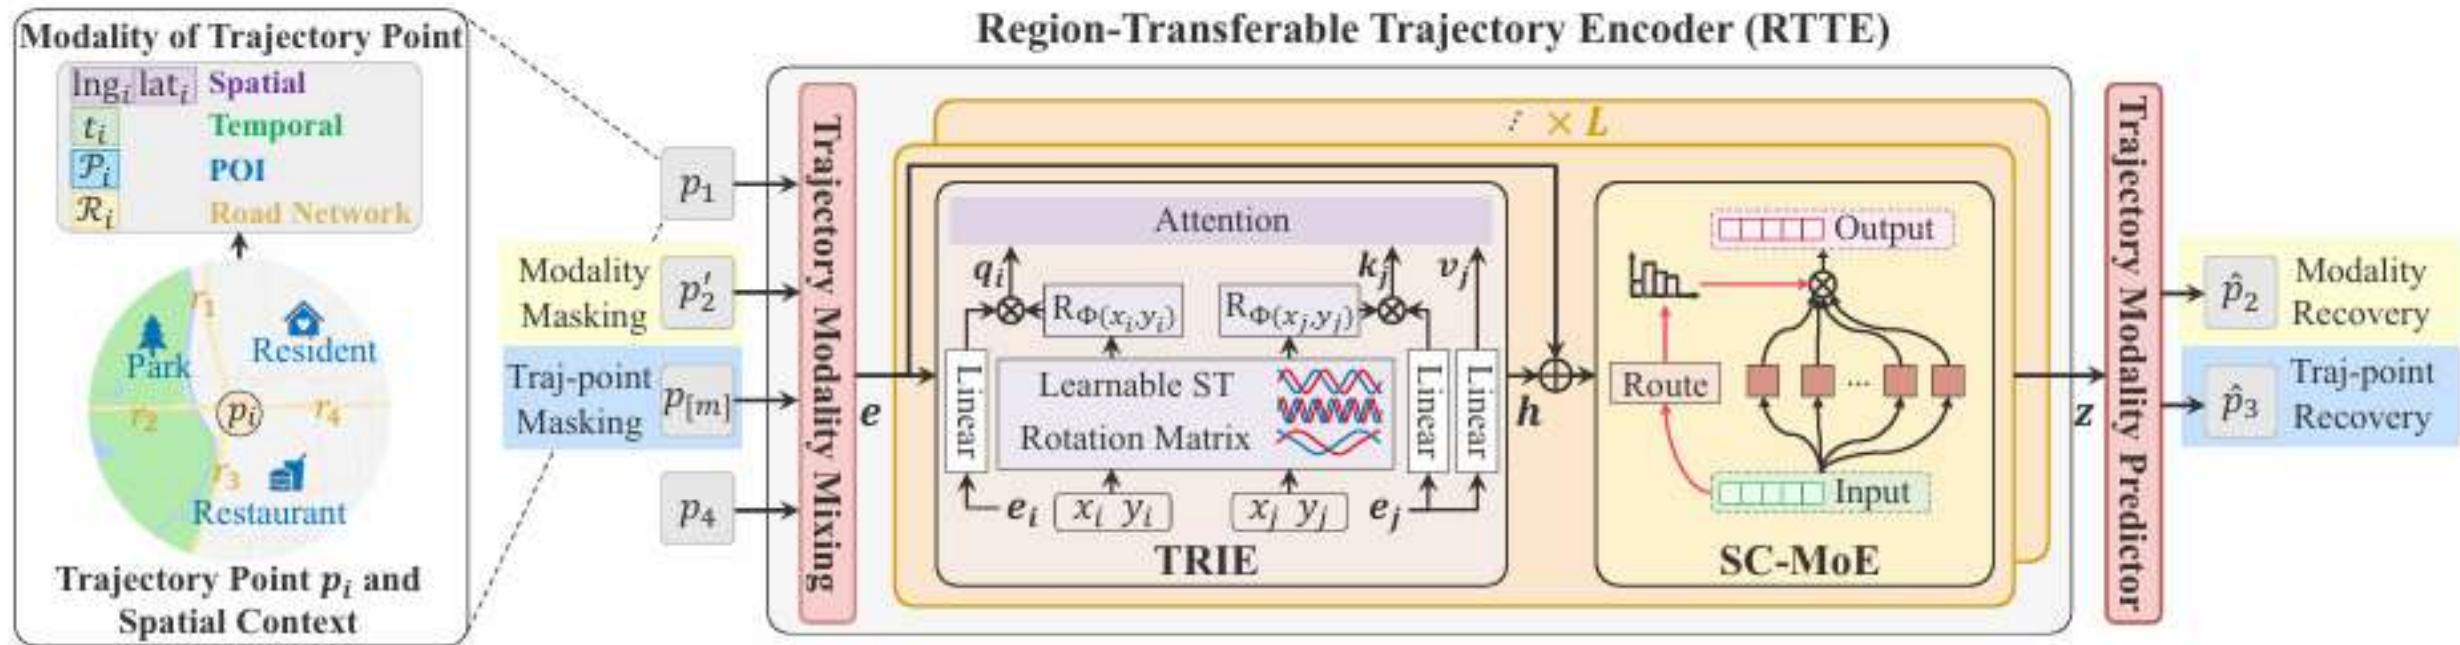


Figure 1: The framework of TransferTraj.



Trajectory Modality Mixing

■ 空间模态

- 1.计算相对位置——计算每个轨迹点相对于第一个轨迹点的相对坐标
- 2.嵌入生成——通过线性层将相对坐标映射为空间模态嵌入 $e_i^s \in \mathbb{R}^d$

■ 时间模态

- 1.时间特征拆解：将时间戳拆解为星期几、一天中的小时、一小时中的分钟、相对轨迹第一个时间戳的分钟差4维特征
- 2.傅里叶编码与嵌入生成：用可学习的傅里叶编码层对4维特征进行编码，再投影为时间模态嵌入 $e_i^t \in \mathbb{R}^d$

■ 兴趣点和路网模态

- 1.文本嵌入：用预训练的文本嵌入模型对POI和路网路段的文本描述生成语义嵌入
- 2.嵌入生成：对语义嵌入进行平均池化和线性变换得到兴趣点模态嵌入 $e_i^p \in \mathbb{R}^d$ 和路网模态嵌入 $e_i^r \in \mathbb{R}^d$

将4种模态的嵌入向量组织成长度为4的序列($e_i^s, e_i^t, e_i^p, e_i^r$)，输入Transformer，再经过平均池化融合4种模态的信息，得到轨迹点 p_i 的初始混合嵌入 $e_i \in \mathbb{R}^d$

轨迹相对信息提取模块（TRIE）

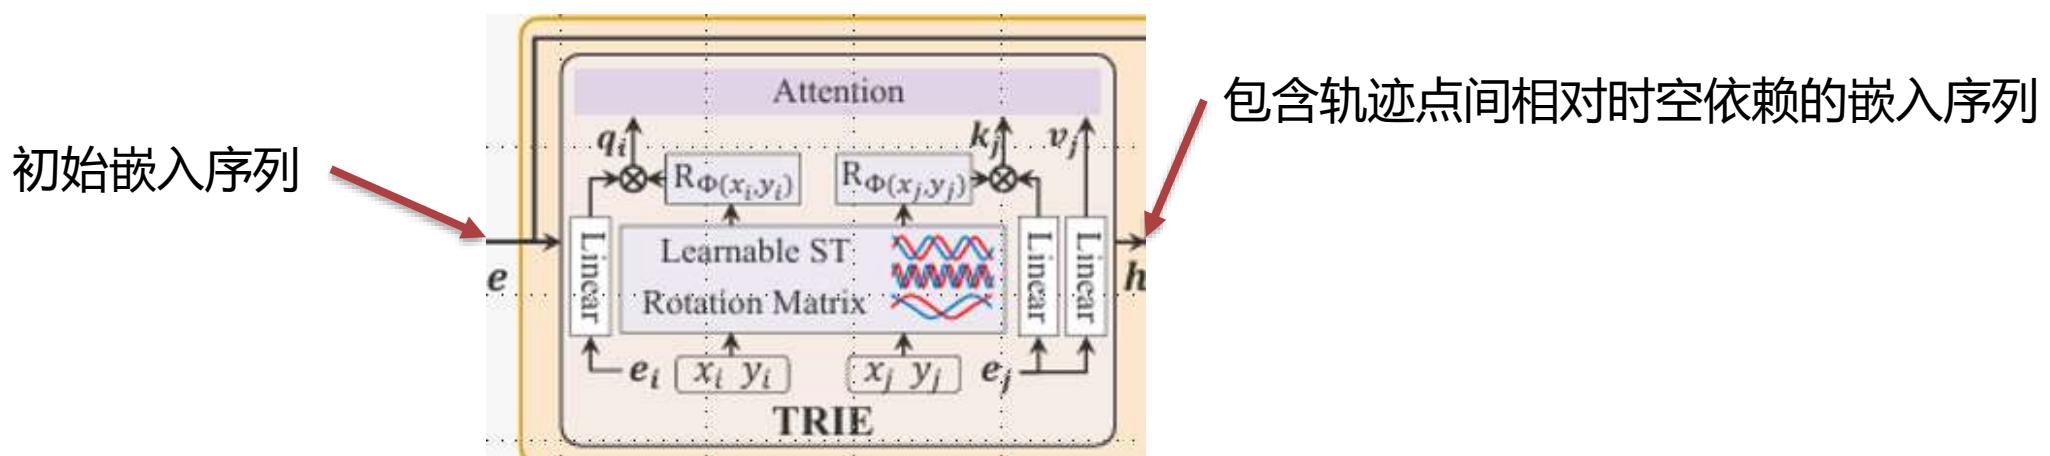
学习轨迹点间的相对时空依赖

1. 基于轨迹点的相对空间坐标 (x, y) 生成空间表示向量 $\Phi(x, y) = \mathbf{W}_\Phi(x||y)$
2. 构建分块旋转矩阵将相对坐标编码为相对空间关系

$$\mathbf{R}_{\Phi(x,y)} = \begin{bmatrix} \cos \phi_1(x,y)\theta_1 & -\sin \phi_1(x,y)\theta_1 & \cdots & 0 & 0 \\ \sin \phi_1(x,y)\theta_1 & \cos \phi_1(x,y)\theta_1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & \cos \phi_{d/2}(x,y)\theta_{d/2} & -\sin \phi_{d/2}(x,y)\theta_{d/2} \\ 0 & 0 & \cdots & \sin \phi_{d/2}(x,y)\theta_{d/2} & \cos \phi_{d/2}(x,y)\theta_{d/2} \end{bmatrix} \in \mathbb{R}^{d \times d} \quad (1)$$

3. 在Transformer的注意力权重中融入这种相对空间关系

$$q_i = \mathbf{R}_{\Phi(x_i,y_i)} \mathbf{W}_q e_i, \quad k_j = \mathbf{R}_{\Phi(x_j,y_j)} \mathbf{W}_k e_j, \quad v_j = \mathbf{W}_v e_j, \quad (2)$$



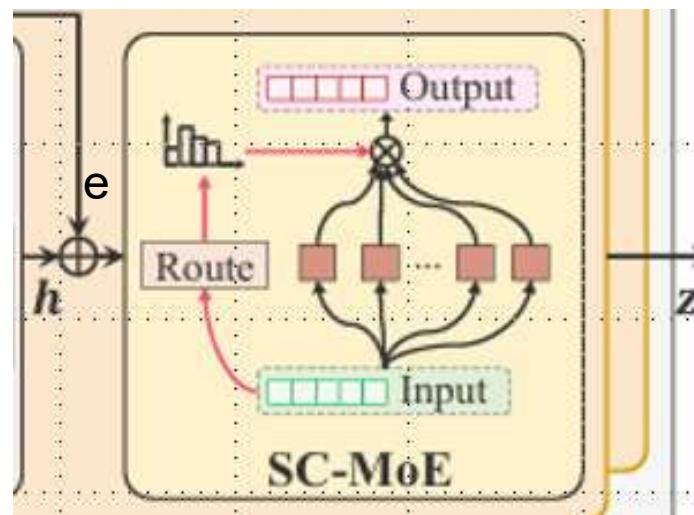
空间上下文混合专家模块（SC-MoE）

根据空间上下文选择不同的专家处理不同的轨迹运动模式

$$\mathbf{h}'_i = \sum_{j=1}^C G_j(\mathbf{h}_i + \mathbf{e}_i) E_j(\mathbf{h}_i + \mathbf{e}_i), \quad (3)$$

噪声Top-K门控

$$\begin{aligned} G(\mathbf{h}_i + \mathbf{e}_i) &= \text{Softmax}(\text{TopK}(H(\mathbf{h}_i + \mathbf{e}_i), k)) \\ H(\mathbf{h}_i + \mathbf{e}_i)_j &= ((\mathbf{h}_i + \mathbf{e}_i) \cdot W_g)_j + \mathcal{N}(0, 1) \cdot \text{Softplus}((\mathbf{h}_i + \mathbf{e}_i) \cdot W_{noise})_j \\ \text{TopK}(\mathbf{a}, k)_j &= \begin{cases} a_j & \text{if } a_j \text{ is in the top } k \text{ elements of } \mathbf{a} \\ -\infty & \text{otherwise.} \end{cases} \end{aligned} \quad (4)$$





Trajectory Modality Predictor

1. 空间模态

线性投影

2. 时间模态

线性投影 + Softplus 激活函数

3. 损失函数

均方误差

$$\mathcal{L}_i^s = (\hat{x}_i - x_i)^2 + (\hat{y}_i - y_i)^2, \quad \mathcal{L}_i^t = \|\hat{\mathbf{t}}_i - \mathbf{t}_i\|_2 \quad (5)$$

任务可迁移输入输出方案

模态与轨迹点先掩码再恢复

对于包含4种模态的轨迹点 $p_i = ((\text{lng}_i, \text{lat}_i), t_i, P_i, R_i)$

1. 模态掩码

① 空间掩码—— $p_i^{ms} = ([m], t_i, [m], [m])$

② 时间掩码—— $p_i^{mt} = ((\text{lng}_i, \text{lat}_i), [m], P_i, R_i)$

2. 轨迹点掩码—— $p_i^m = ([m], [m], [m], [m])$

基于上述方案的预训练过程：

从均匀分布 $U(1, n)$ 中选择子轨迹起始点 s 和终止点 e ，对子轨迹进行轨迹点掩码，对剩余轨迹点进行模态掩码（等概率随机选择时间模态或空间模态），预训练损失为所有被掩码模态的重建损失（MSE）之和

输入含掩码的轨迹-输出补全掩码的轨迹



3

实验

实验设置

3个真实世界车辆轨迹数据集
成都、西安和波尔图

3类生成式任务
轨迹预测、轨迹恢复以及起终点行驶时间估计

基线模型
轨迹预测：t2vec、Trembr、CTLE、Toast、TrajCL、START和LightPath
轨迹恢复：Linear、MPR、TrlImpute、DHTR、MTrajRec、RNTrajRec和MM-STGED
起终点行驶时间估计：RNE、TEMP、LR、GBM、ST-NN、MuRAT、DeepOD和DOT

2个变体
TransferTraj(wopt)：不含预训练
TransferTraj(woft)：省略微调

评估指标
MAE、MAPE、RMSE

实验结果

任务可迁移性：将TransferTraj及其变体和基线模型在三类任务（轨迹预测、轨迹恢复、起终点行程时间估计）上的性能分别进行了比较，均达到SOTA

区域可迁移性：在零样本和少样本两种设置下开展区域迁移实验。在零样本设置中，基线模型先在一个区域上预训练，再直接应用于其他区域。在少样本设置中，所有模型均先在一个区域上预训练，随后在其他区域上通过随机采样5000条轨迹进行微调。对于轨迹预测和起终点行程时间估计开展零样本实验，对于轨迹恢复开展少样本实验，均达到SOTA

消融实验

1. 移除TRIE
 2. 移除SC-MoE
 3. 移除POI和路网模态
- 性能均下降

SC-MoE模块的有效性分析

三类局部空间上下文：高密度区域（POI与路段总数 > 15 ）、中密度区域（POI与路段总数 $5 \sim 15$ ）和低密度区域（POI与路段总数 < 5 ）下激活专家模块的分布差异显著

Table 6: Ablation Study on Chengdu dataset.

Task	Metric	TP		TR		OD TTE		
		RMSE ↓ (meters)	MAE ↓ (meters)	RMSE ↓ (meters)	MAE ↓ (meters)	RMSE ↓ (minutes)	MAE ↓ (minutes)	MAPE ↓ (minutes)
wo TRIE		236.18	185.14	163.47	124.66	3.347	2.861	11.685
wo SC-MoE		227.36	167.75	166.48	127.45	3.240	2.585	11.584
wo POI modality		226.25	159.37	152.19	119.38	3.166	2.307	11.388
wo road network modality		223.59	165.44	164.07	124.53	3.128	2.221	11.631
TransferTraj		197.91	144.53	135.15	97.87	2.861	2.060	9.360

Red denotes the best result, and blue denotes the second-best result. ↓ means lower is better.

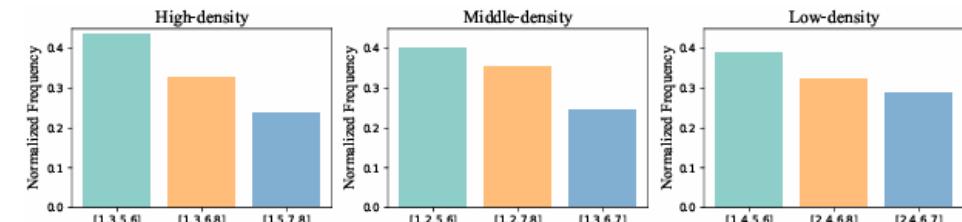


Figure 2: Expect activation distribution.



4

总结

总结

● **总结:** 本文提出了一种兼具区域和任务迁移性的车辆轨迹学习模型——TransferTraj。区域迁移性和任务迁移性的实现分别是由区域可迁移轨迹编码器（RTTE）和任务可迁移输入输出方案完成的。区域可迁移轨迹编码器（RTTE）通过轨迹相对信息提取模块（TRIE）提取轨迹点之间的相对时空依赖，通过空间上下文混合专家模块（SC-MoE）根据空间上下文选择不同的专家处理不同的轨迹运动模式实现跨区域的泛化性。任务可迁移输入输出方案则是通过模态与轨迹点先掩码再恢复的方式将所有的任务统一为输入含掩码的轨迹，输出补全掩码的轨迹。实验证明了模型的优越性。



谢谢大家!

汇报人: 韦浩文

时间: 2025-11-9