CL-DGCN: contrastive learning based deeper graph convolutional network for traffic flow data prediction

多模态交通流预测：基于对比学习的深层图卷积交通流预测模型

汇报人：张志航

2025/1/17

问题提出和研究方法

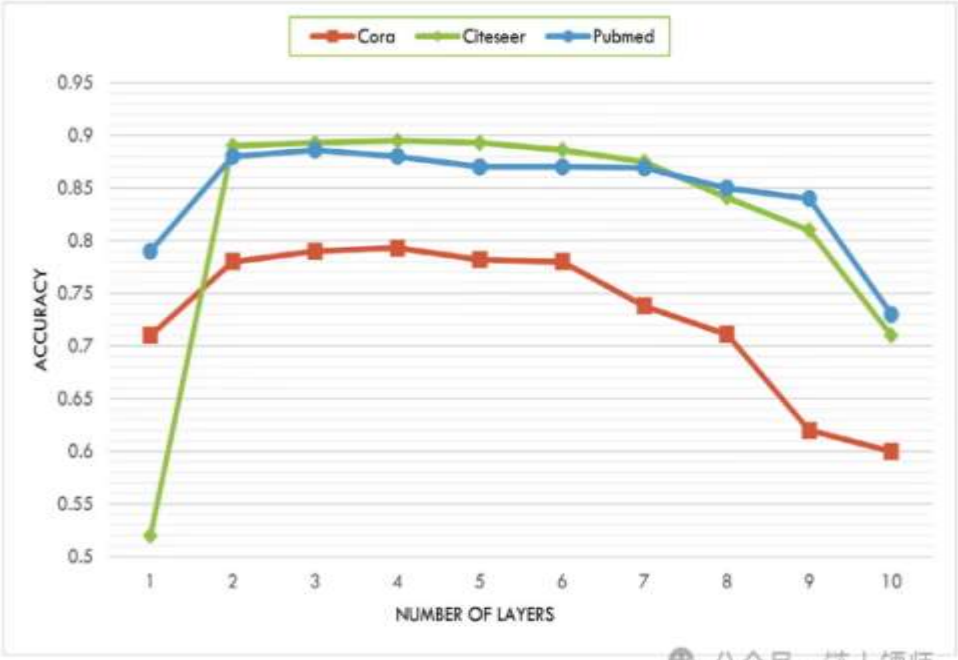

公众号 · 链上镖师

Fig. 1. The effect of different GCN layers classification results.

图1 不同GCN层数对分类准确率的影响

现有交通流数据预测任务研究普遍采用图卷积网络（GCN），当 GCN 层数堆叠过多时，模型精度会明显下降，这一现象被称为“多层灾难”（Multilayered Disaster）。在分类任务的实验中，随着层数增加，准确率在超过 7 层后迅速下滑；在交通流预测场景中，这一现象在 2 层后便出现，堆叠更多层并不能捕获三跳及以上邻居的信息。

根本原因在于一阶 切比雪夫多项式逼近的 GCN 本质上是低通滤波器，高频信息（例如急剧变化的流量）在多层传播中被削弱。因此，如何解决堆叠层数受限的问题并避免过度平滑，是交通流预测领域迫切需要突破的瓶颈。

作者提出对比学习深层图卷积网络（CL-DGCN）。模型基于“时序-空间-时序”结构，由两个 T-CN 模块、一个对比学习模块和一个超聚合函数（Hyper-Aggregation）改进的深层 GCN 组成。

总体架构

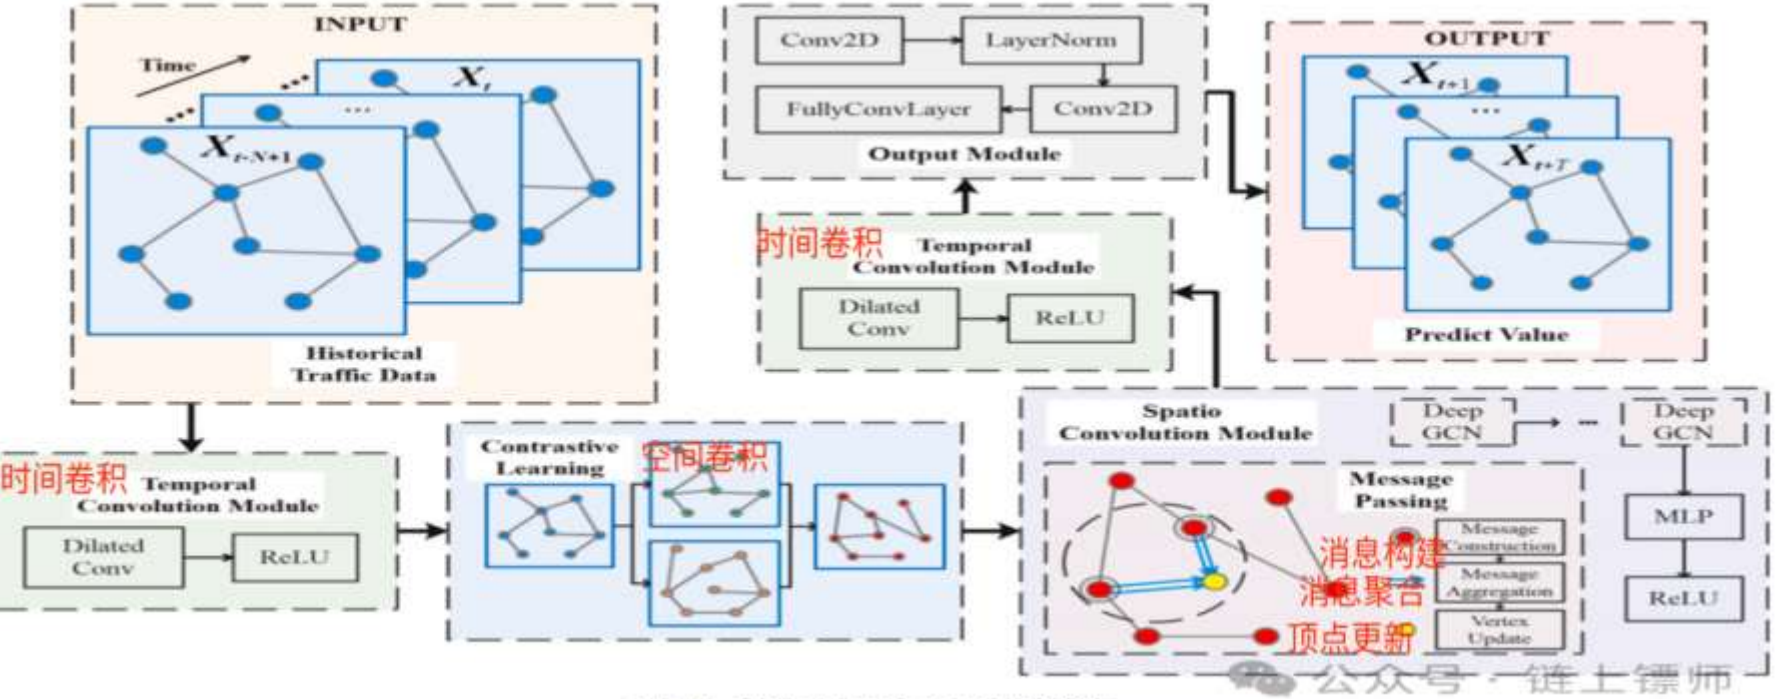

Fig. 6. Overall structure of CL-DGCN.

公众号 · 链上镖师

输入模块：输入历史 交通数据；
第一时序模块（T-CN）：通过一维卷积和膨胀卷积提取时间依赖；
对比学习模块：动态重建邻接矩阵，捕捉潜在空间关系；
深层GCN模块：采用超聚合函数改进GCN，实现堆叠 5 层而不过度平滑；
第二时序模块：进一步提取时间特征，输出预测序列

首先对历史交通数据进行时序卷积提取时间特征；然后使用对比学习重建空间拓扑；接着通过多层改进的 GCN 提取空间特征；最后再次通过时序卷积输出未来时刻的预测值。

超聚合函数（允许更深层次的GCN层堆叠）

传统 GCN 的消息传递方式是对邻居节点特征求和，导致过度平滑。作者提出超聚合函数：

1. **信息重构：** 重构邻居节点的消息，保证消息非负：

$$m_{v\leftarrow u} = \mathrm{ReLU}\left(h_u^l \cdot I(e_{uv})\right) + \epsilon$$

其中 h_u^l 为节点 u 的特征，$I(e_{uv})$ 为邻接矩阵指示函数，ϵ 为很小的常数。

2. **超聚合函数：** 为目标节点 v 计算邻居消息的加权和：

$$\mathrm{MP} * v = f * \mathrm{HA}(\alpha, m_{v\leftarrow u}, \mathcal{N}(v)) = \sum_{u\in\mathcal{N}(v)} \frac{\exp(\alpha m_{v\leftarrow u})}{\sum_{i\in\mathcal{N}(v)} \exp(\alpha m_{v\leftarrow i})} m_{v\leftarrow u}$$

其中 α 为可训练参数。当 $\alpha \to \infty$ 时，超聚合函数等价于最大值运算；当 $\alpha \to 0$ 时则退化为平均值运算。这种可调节聚合策略在训练过程中自动在“平均”与“最大”之间平衡，保留高频信息，缓解过度平滑。

3. **节点更新：** 结合原始节点特征和聚合消息，通过多层感知机 (MLP) 输出下一层特征：

$$h_v^{l+1} = \mathrm{MLP}\left(h_v^l + k\frac{h_v^l}{|h_v^l|_2} \cdot \frac{\mathrm{MP}_v}{|\mathrm{MP}_v|_2}\right)$$

其中 k 为可学习的放缩因子。

通过上述改进，改进型 GCN 可堆叠 5 层而不丢失高频信息，显著缓解“多层灾难”。

对比学习模块

引入无监督对比学习来动态重建图结构：

第一步

- **生成子图：** 针对原始图 $G=(A,X)$，随机删除部分边或遮掩节点属性，得到两个子图 $S=(\tilde{A}_1,\tilde{X}_1)$ 和 $T=(\tilde{A}_2,\tilde{X}_2)$。下图展示了破坏和重建的过程。

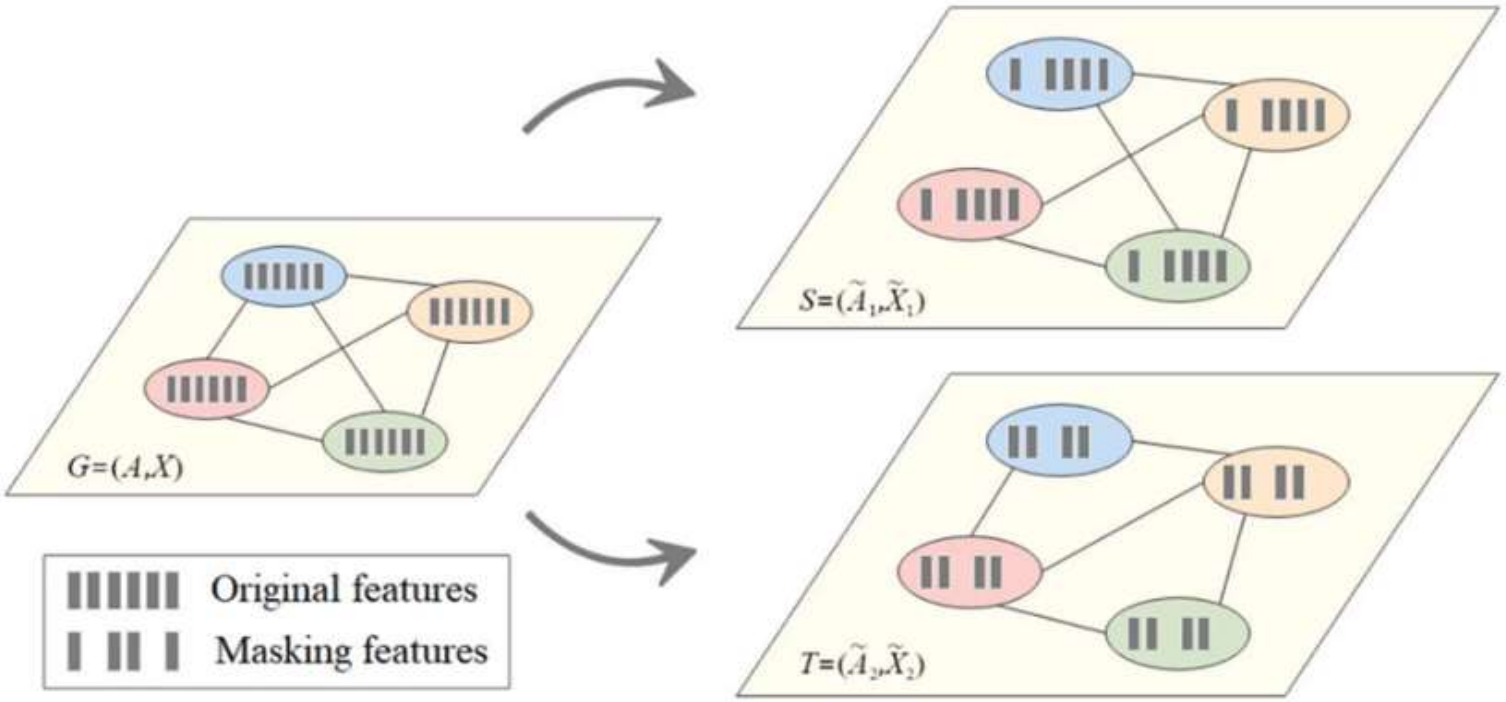

删除部分结点

删除部分边

学习模块

第二步

- **构建样本对：**两子图中相同节点构成**正样本对**，不同节点构成**负样本对**。负样本来自相同或不同子图。

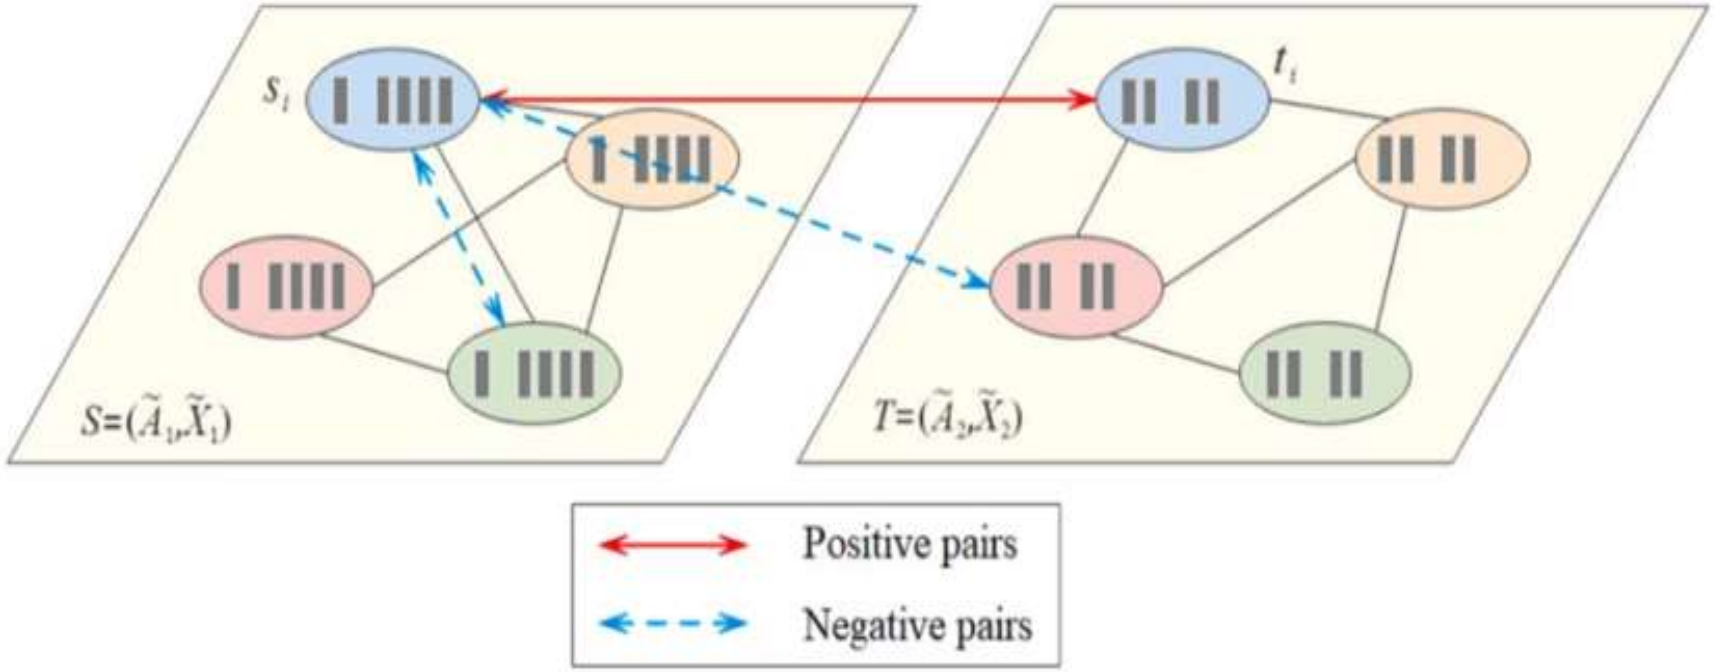

学习模块

第三步

- **对比损失函数：** 用非线性映射 $f\cdot$ 将节点表示映射到对比空间，以**NT-Xent**损失形式最大化正样本相似度、最小化负样本相似度：

$$\phi(s_i, t_i) = \log \frac{\exp\left(\rho(s_i, t_i)/\eta\right)}{\exp\left(\rho(s_i, t_i)/\eta\right) + \sum_{n \neq i} \exp\left(\rho(s_i, t_n)/\eta\right)}$$

目标函数最大化所有正对的平均值。 通过对比学习，模型得到更加鲁棒的节点嵌入，用于后续深层 GCN 特征提取。

利用上述方法，相似节点的表示更接近，而不相似节点的表示更分散。这使得后续处理不仅可以接收关于节点的数值信息，还可以同时接收节点之间的相关性和空间拓扑信息。

时序模块

采用Temporal Convolutional Network (TCN) 提取时间特征。TCN 通过一维卷积和膨胀卷积捕捉长时依赖：

$$y(t) = \sum_{i=0}^{k-1} f(i) \cdot x(t - d \cdot i)$$

其中 k 为卷积核大小，d 为膨胀系数。膨胀卷积扩展了感受野，使网络能够捕获长时间间隔的模式。下图是 T-CN 的蓝图示意。

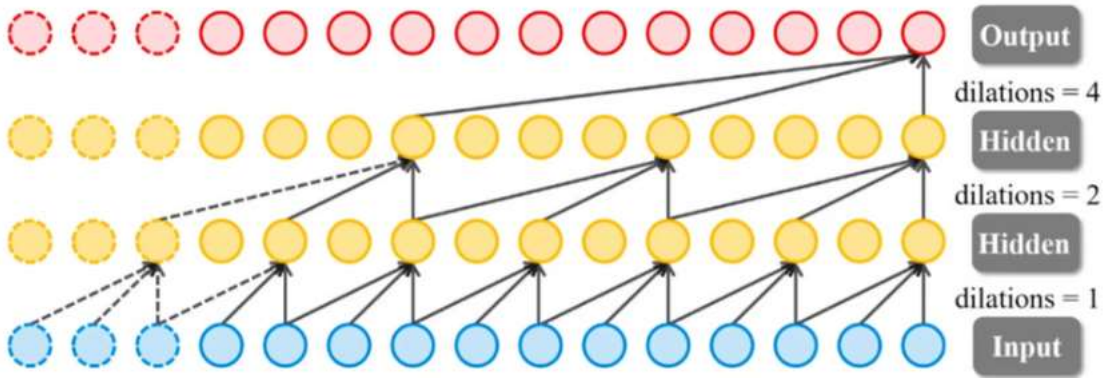

实验设置与结果

在四个公开数据集上验证模型：PEMSBAY、METR-LA、BEIJING 和 SZ-TAXI

评估采用以下指标:
均方根误差 (RMSE):
平均绝对误差 (MAE);
平均绝对百分误差 (MAPE)。

定量实验

Experiment results.

Datasets	Model	Time steps								
		3 steps (15 Min)			6 steps (30 Min)			12 steps (60 Min)		
		MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
PEMSBAY	T-GCN	2.67	4.98	5.94 %	3.22	5.88	6.44 %	3.42	6.32	6.64 %
	STGCN	2.46	4.64	4.88 %	2.65	5.04	5.33 %	3.03	5.73	6.13 %
	DCRNN	2.08	3.78	3.50 %	2.53	4.67	4.90 %	2.82	5.11	5.37 %
	MTGNN	2.12	3.81	4.05 %	2.39	4.64	4.89 %	2.82	5.03	5.29 %
	ASTGCN	2.35	4.06	4.28 %	2.54	4.78	5.60 %	2.87	5.43	5.96 %
	GMAN	2.24	3.88	4.06 %	2.49	4.64	4.88 %	2.82	5.03	5.29 %
	DGCRN	1.92	3.54	3.64 %	2.38	4.44	4.67 %	2.76	5.02	5.23 %
	DFDGCN	1.97	3.58	3.77 %	2.39	4.43	4.62 %	2.71	4.86	5.11 %
	CL-DGCN	**1.54**	**2.95**	**3.11 %**	**2.08**	**3.96**	**4.14 %**	**2.46**	**4.72**	**4.68 %**
METR-LA	T-GCN	6.60	13.49	13.97 %	7.40	13.73	16.17 %	10.40	17.33	18.82 %
	STGCN	6.21	12.89	13.56 %	7.36	13.02	14.62 %	9.48	16.85	17.07 %
	DCRNN	5.52	11.09	13.08 %	7.21	12.75	14.11 %	8.53	15.85	16.77 %
	MTGNN	5.63	11.26	13.55 %	7.20	13.14	14.44 %	8.64	15.13	16.61 %
	ASTGCN	5.78	12.26	13.05 %	7.42	13.31	15.06 %	8.98	16.17	17.88 %
	GMAN	5.64	11.66	13.50 %	[illegible]	[illegible]	[illegible]	8.55	15.46	17.44 %
	DGCRN	5.43	10.64	11.96 %	[illegible]	[illegible]	[illegible]	8.67	15.35	16.38 %
	DFDGCN	5.47	10.62	12.31 %	[illegible]	[illegible]	[illegible]	8.45	14.85	16.04 %
	CL-DGCN	**4.79**	**9.31**	**11.65 %**	**6.66**	**12.40**	**13.02 %**	**8.15**	**14.22**	**15.75 %**
BEIJING	T-GCN	5.71	11.61	11.91 %	6.15	12.12	13.82 %	8.82	17.10	17.09 %
	STGCN	5.12	10.25	9.64 %	6.21	12.85	12.47 %	8.04	16.53	16.01 %
	DCRNN	4.31	9.02	9.72 %	5.67	12.16	13.18 %	6.55	14.91	16.09 %
	MTGNN	4.08	8.62	9.03 %	5.06	11.53	11.89 %	5.95	13.75	14.45 %
	ASTGCN	4.62	9.74	10.17 %	6.07	12.65	12.48 %	6.79	15.27	14.94 %
	GMAN	4.86	9.60	11.02 %	5.98	12.11	12.44 %	6.03	13.77	14.55 %
	DGCRN	4.37	8.59	8.71 %	4.71	10.19	11.12 %	5.76	13.48	13.98 %
	DFDGCN	4.33	8.58	8.95 %	4.92	11.21	11.04 %	5.78	13.52	14.23 %
	CL-DGCN	**3.90**	**7.78**	**8.06 %**	**4.24**	**9.65**	**10.72 %**	**5.37**	**12.90**	**13.13 %**
SZ-TAXI	T-GCN	3.30	5.36	5.98 %	3.20	4.95	5.28 %	3.35	5.01	5.58 %
	STGCN	3.12	5.12	5.34 %	2.78	4.49	4.74 %	3.04	4.42	4.94 %
	DCRNN	2.60	4.13	4.56 %	2.60	4.26	4.59 %	2.99	4.10	4.26 %
	MTGNN	2.59	4.04	4.29 %	2.51	4.00	4.29 %	2.71	3.98	4.19 %
	ASTGCN	2.83	4.22	4.46 %	2.78	4.16	4.63 %	3.00	4.32	4.74 %
	GMAN	2.77	4.45	4.64 %	2.61	4.12	4.38 %	2.85	4.19	4.42 %
	DGCRN	2.48	4.00	4.11 %	2.47	3.74	3.72 %	2.61	3.83	4.06 %
	DFDGCN	2.47	3.98	4.28 %	2.50	3.73	3.94 %	2.63	3.86	4.14 %
	CL-DGCN	**2.17**	**3.46**	**3.84 %**	**2.30**	**3.58**	**3.67 %**	**2.29**	**3.30**	**3.70 %**

CL-DGCN模型在所有评估场景中都表现出显著的优越性能，且模型的泛化能力优秀

定性分析

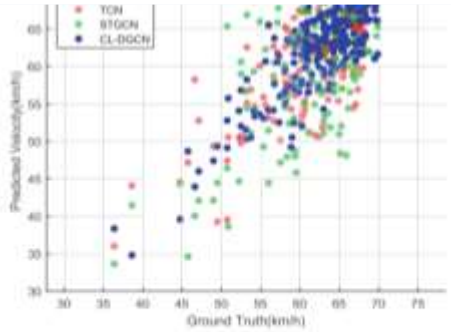

(a) Experiment result comparison of CL-DGCN, T-GCN and STGCN

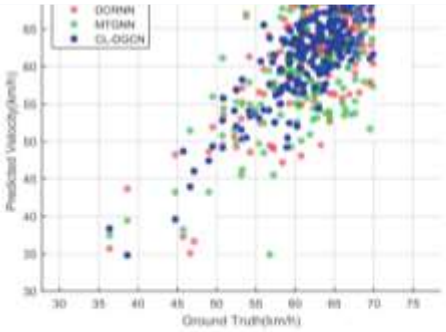

(b) Experiment result comparison of CL-DGCN, DCRNN and MTGNN

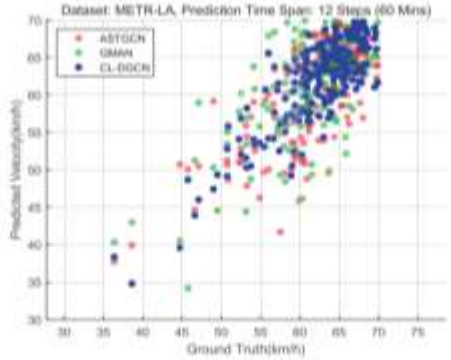

(c) Experiment result comparison of CL-DGCN,

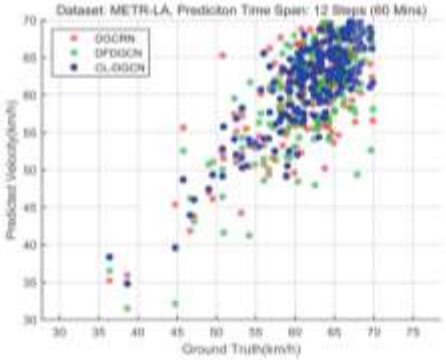

(d) Experiment result comparison of CL-DGCN,

地面真实分布在y=x线上，即结果越收敛于y=x线，预测性能越好

消融性分析

Datasets	Model	Time Steps								
		3 Steps (15 Min)			6 Steps (30 Min)			12 Steps (60 Min)		
		MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
PEMSBAY	**CL-DGCN**	**1.50**	**2.87**	**3.49 %**	**2.00**	**3.81**	**4.63 %**	**2.37**	**4.54**	**4.66 %**
	CL-DGCN-A	2.37	4.17	5.05 %	2.64	4.67	5.68 %	2.90	5.12	5.67 %
	CL-DGCN-B	2.06	3.87	4.68 %	2.21	4.05	4.86 %	2.72	5.26	5.82 %
	CL-DGCN-0	2.25	4.01	4.84 %	2.50	4.31	5.22 %	2.84	5.29	5.87 %
	CL-DGCN-1	2.03	3.90	4.72 %	2.75	5.23	6.36 %	3.25	6.23	6.87 %
	CL-DGCN-2	1.69	3.25	3.93 %	2.29	4.35	5.30 %	2.71	5.19	5.72 %
	CL-DGCN-3	1.54	2.96	3.58 %	2.08	3.96	4.82 %	2.47	4.72	5.20 %
	CL-DGCN-4	1.52	2.90	3.51 %	2.04	3.88	4.73 %	2.42	4.63	5.10 %
METR-LA	**CL-DGCN**	**4.63**	**9.16**	**10.90 %**	**6.44**	**12.13**	**14.06 %**	**8.10**	**14.32**	**15.49 %**
	CL-DGCN-A	6.40	13.31	15.99 %	7.64	13.77	16.60 %	9.85	17.58	19.35 %
	CL-DGCN-B	5.76	12.31	14.81 %	7.23	12.72	15.35 %	8.93	16.05	17.70 %
	CL-DGCN-0	6.29	12.99	15.61 %	7.48	13.69	16.47 %	9.34	16.49	18.16 %
	CL-DGCN-1	6.33	12.28	14.82 %	9.19	16.90	20.37 %	11.02	19.80	21.82 %
	CL-DGCN-2	5.27	10.24	12.35 %	7.66	14.08	16.98 %	9.18	16.50	18.18 %
	CL-DGCN-3	4.79	9.31	11.23 %	6.96	12.80	15.43 %	8.35	15.00	16.53 %
	CL-DGCN-4	4.70	9.12	11.01 %	6.82	12.55	15.13 %	8.18	14.71	16.20 %

CL-DGCN-A去掉了对比学习模块和更深层的GCN模块。而CL-DGCN-B模型去掉了图重构模块，将邻接矩阵直接作为后续模块的输入。此外，CL-DGCN(0-4)分别只含有0-4个GCN层。

主要贡献

理论突破：揭示“多层灾难”源于 GCN 的低通滤波效应，并提出超聚合函数解决过度平滑问题。
方法创新：提出对比学习+深层GCN框架，实现动态拓扑重建和深层特征提取，有效地捕捉了物理连通性以外的潜在空间相关性，并证明该框架可在五层 GCN 下稳定训练。
应用效果：在四个不同类型的交通数据集上取得平均 10 % 以上的性能提升；在长期预测任务中依然保持明显优势。
实证分析：通过定性对比和消融实验系统验证了各模块的有效性和必要性。

局限性和改进方向

局限性:

动态交通场景：当前对比学习构建仍基于静态邻接矩阵，面对突发拥堵或极端天气下拓扑迅速变化的场景可能性能下降。

计算开销：堆叠深层 GCN 会增加计算量，不利于实时大规模应用。

数据噪声敏感：模型依赖高质量输入，噪声或缺失数据可能降低准确性。

改进方向:

引入实时动态图表示学习，利用交通传感器、车联网等多源信息持续更新拓扑;

探索自监督或半监督方法，应对数据缺失和噪声;

设计轻量化的深层 GCN，提高模型推理速度，实现大规模实时部署。

北京工業大學

谢 谢！