



MoST: A Foundation Model for Multi-modality Spatio-temporal Traffic Prediction:

MoST: 面向多模态时空交通预测的基础模型

汇报人: 张志航

2025/5/15

背景

准确预测未来交通数据对于路线规划、交通信号控制和城市管理系统都很重要。已有时空基础模型试图学习跨城市共享的时空模式，从而在没有预先微调的情况下进行零样本预测。但现有方法大多局限于单一模态，难以刻画真实交通场景中的复杂背景。

多模态数据提供了关于时空数据产生条件的关键背景信息,这些背景线索有助于揭示多样的的时空模式。此外，由于不同城市之间具有类似背景的交通模式，这样的背景有助于跨城市的推广。




Figure 1: Daily traffic time series of three sensors from Chicago, NYC, and GBA. Sensors 1 and 2 are located in regions near schools, while Sensor 3 is situated along a highway.

核心挑战

构建多模态时空基础模型主要面临两个挑战：

1

多模态数据质量与可用性不一致

- 不同城市模态完整度差异显著
- 低活动区可能缺少POI数据，或数据质量差
- 稠密城区：卫星图片信息有限；郊区：POI稀疏
- 现有模型要么训练多套模型，要么只用共同模态

需要：灵活感知可用模态，自适应过滤噪声

2

不同区域的空间模式高度异构

- 商业区 vs 住宅区：早晚高峰流量趋势相反
- 高速 vs 普通道路：平均车速和拥堵范围不同
- 传统固定空间卷积与训练城市拓扑强耦合
- 统一空间网络难以泛化到未见城市

需要：背景条件化的空间建模，动态适配局部模式

为此，本文提出 MoST，通过模态自适应筛选与空间专家机制，解决模态噪声与空间泛化难题，提升零样本预测性能。

整体结构

整体来看，MoST 由两部分组成：

(1) **多模态精化模块**。它先使用不同编码器处理不同模态，再将它们映射到共享嵌入空间，并通过选择器识别和过滤低信噪比模态。

(2) **时空预测模块**。它利用精化后的多模态上下文，激活不同空间专家，建模当前区域相关的**局部空间模式**，最后将时间序列编码器的时间嵌入和空间感知的补丁嵌入通过非自回归解码器相结合预测未来交通状态。




Figure 2: Overall framework of MoST.

多模态精化

多模态编码器:使用特定于通道的编码器来从每个通道中提取特征,并将每种模态的特征投影到统一的D维度空间。

过程:

卫星图像使用 ResNet50 编码

人类活动数据使用 BERT 编码

位置模态则将经纬度归一化到 $[-1,1]$ 范围。

时间序列模态先进行实例归一化, 然后切分为块,每个块投影到 D 维空间,并嵌入时间戳。

定义模态状态矩阵 O , 并用0或者1表示是否存在


最后使用特定的线性层将每个通道的特征投影到统一的D维空间。得到统一表示:

$$E = E_{img} || E_{loc} || E_{act} || E_{TS}.$$


缺失模态处理策略

时间序列模态始终可用 (O 中固定为1)

缺失模态直接 mask, 无需重新训练, 灵活适配不同模态组合的城市



多模态精化



模态选择器:不同模态的数据质量和任务相关性存在显著差异，某些模态不仅无法提供有用信息，还可能引入噪声。而模态选择器能够在不同条件下自适应识别最相关且最可靠的模态。

主要思想：

把每个模态看作一个信息传输通道，并借鉴信噪比思想。分别估计每个模态的不确定性 U^* 和任务相关性 R^* ，然后计算每个模态的SNR（信噪比）。如果某个模态的信噪比很低，说明它携带的信息可能被噪声淹没，可能会影响预测。

时空预测

多模态引导的空间聚集块：

位于相似背景环境中的传感器通常表现出相似的空间模式，我们使用多模态数据来为不同的传感器选择合适的空间专家，提升跨城市泛化性能。

MoST 中有两类空间专家：

N模态共享专家：n表示输入模态数。某个模态被选择器激活后，对应的模态共享专家也会被激活。

N路由专家：由路由器根据多模态融合表示计算路由概率，并激活概率最高的专家。


对模态共享专家和路由专家输出结果加权融合，以生成融合后的空间感知补丁。

局部建模：

每个传感器只与其 top-k 邻居交互,通过邻接权重和空间感知对局部建模,避免过拟合拓扑。

时空解码器：

提取时序编码器最后一个 token 并复制多次，通过线性层和标准化 一次前向生成全部预测。



实验

数据集：

五个大规模交通数据集：

Taxi-NYC、Taxi-CHI、SD、GBA 和 GLA

训练指标：

平均绝对误差(MAE)

。

均方根误差(RMSE)。

训练过程：

采用15分钟的时间步长，并使用前10天的数据来预测随后的3天。

实验结果

Datasets	Metrics	Zero-shot			
		STGCN	GWN	OpenCity [32]	MoST
Taxi-NYC	MAE	5.45	9.80	3.93	2.41
	RMSE	15.88	20.28	12.91	7.73
Taxi-CHI	MAE	7.08	6.82	3.71	2.57
	RMSE	22.78	28.76	14.72	11.14
SD	MAE	40.23	110.58	32.95	25.69
	RMSE	62.00	145.11	52.85	45.40
GBA	MAE	41.64	78.93	39.65	23.32
	RMSE	62.11	99.12	58.89	41.75
GLA	MAE	53.14	141.80	32.86	26.89
	RMSE	76.17	173.35	52.97	46.42

MoST 在五个数据集上都优于零样本 STGCN、GWN 和 OpenCity

原因：

所有基线模型均仅采用单一数据模态建模，难以挖掘多模态数据中蕴含的丰富上下文信息，传统的端到端基线受到固定拓扑的限制，限制了它们对具有完全不同空间配置的不可见数据集的适应性。

消融研究

论文设计了三个变体

w/o Selector: 移除模态选择器, 默认所有模态同等贡献, 无须过滤。

w/o Moe: 移除专家路由和平衡损失。

w/ TS: 只保留时间序列, 去掉空间信息和多模态相关组件。

ultimately hinders their predictive accuracy.




Figure 3: Effect of variants of MoST.

结论:

去掉 Selector 会带来轻微性能下降, 说明某些模态确实可能对预测产生负面影响;

去掉 MoE 也会降低性能, 说明专家路由有助于建模局部时空依赖; 性能下降最明显的是 w/ TS, 说明仅依赖时间序列不足以支撑稳健的时空预测, 空间信息以及多模态数据是必不可少的。

缺失模态分析

分别移除卫星图像(w/o img)、位置(w/o loc)、人类活动数据(w/o act)、全部辅助模态(w/o MM)与具有所有可用通道(All)





Figure 5: Effect of missing modalities at inference.

缺失任意单一模态都会造成模型性能小幅下降。其中，缺失卫星影像数据带来的性能降幅最为明显，这表明遥感影像数据对于模型理解场景背景信息起到至关重要的作用。

案例分析

reliable modality selection accordingly.



(a) A selected satellite image



(b) An unselected satellite image

Figure 6: Two representative samples of modality selection.

图 6(a) 是 MoST 选择的卫星图像，其区域为靠近绿地公园的住宅区，具有较规律且语义丰富的交通模式；图 6(b) 则主要由绿地和湖泊组成，缺少可反映人类出行模式的人造结构，为交通预测提供的信息有限，没有被模型选中。这一案例说明，模态选择器并不是简单保留所有图像，而是倾向于选择对交通预测更有用的上下文信息。

总结

本文提出了首个多模态时空基础模型MOST,把多模态上下文引入跨城市时空交通基础模型,针对现实中的模态缺失、模态噪声和局部空间模式差异,分别设计了多模态精化模块和多模态引导的空间专家机制。通过实验表明,MoST优于多个零样本基线,显示了其优越性以及作为跨不同城市的多模式时空预测的基础模型的潜力。

谢 谢！