MTP: Exploring Multimodal Urban Traffic Profiling with Modality Augmentation and Spectrum Fusion

MTP：基于模式增强和光谱融合的多模式城市交通特征研究

汇报人：张志航

2025/1/17

背景和问题

现有的大多数交通信号建模方法往往依赖于原始的数据形式，即城市传感器的数值直接读数。然而，这种单峰方法从不同的角度忽视了多通道异质城市数据中存在的语义信息，阻碍了对交通信号的全面理解，限制了对复杂交通动态的准确预测。

传统的交通数据处理方法大多依赖于静态特征提取，如滑动窗口统计和支持向量机。它们假设数据分布是稳定的，不能适应实际交通系统的动态特征。而交通数据具有很强的时间相关性，如早高峰时段和非高峰时段主要道路的交通流量特征明显不同。

目前的主流方法是具有时间序列建模能力的神经网络。但是仅针对单一通道设计，无法实现空间、视觉和文本特征之间的深度关联。现实的交通数据已经从单一的结构化时间序列数据扩展到多模式形式，例如监控图像、文本信息和社交媒体反馈，所以传统的神经网络会限制多通道信息的利用。

实际交通场景中的核心挑战

单一模态局限：现有方法多依赖传感器数值读数，忽视视觉、文本等模态的互补语义，难以全面理解复杂交通动态；

跨模态融合难题：大型语言模型擅长文本处理、视觉语言模型能处理图文交互，但均难以同时建模时间序列动态、视觉直观模式与文本语义信息；时间动态适配不足

交通数据的动态性: 导致静态方法或单一模态模型在跨时段分析中准确性大幅下降。

为了解决上述问题，作者提出了一种新的多模式城市交通分析框架MTP。

问题定义

- *城市区域*U：划分为 M 个交通辖区，在时间区间 T 内进行交通状态画像；
- *数值表示*v_U：通过传感器、摄像头收集的结构化数据，包含交通背景、车辆位置、环境等信息；
- *图像增强表示*g_U：由原始时间序列转换生成，用于捕捉空间特征；
- *文本增强表示*t_U：基于原始数据生成的描述性文本，用于捕捉语义信息；
- *任务目标*：通过多模态特征融合得到增强表示 $x'_U = H(v_U, g_U, t_U|x)$，并基于 x'_U 预测交通状态标签 y_i。

整体框架

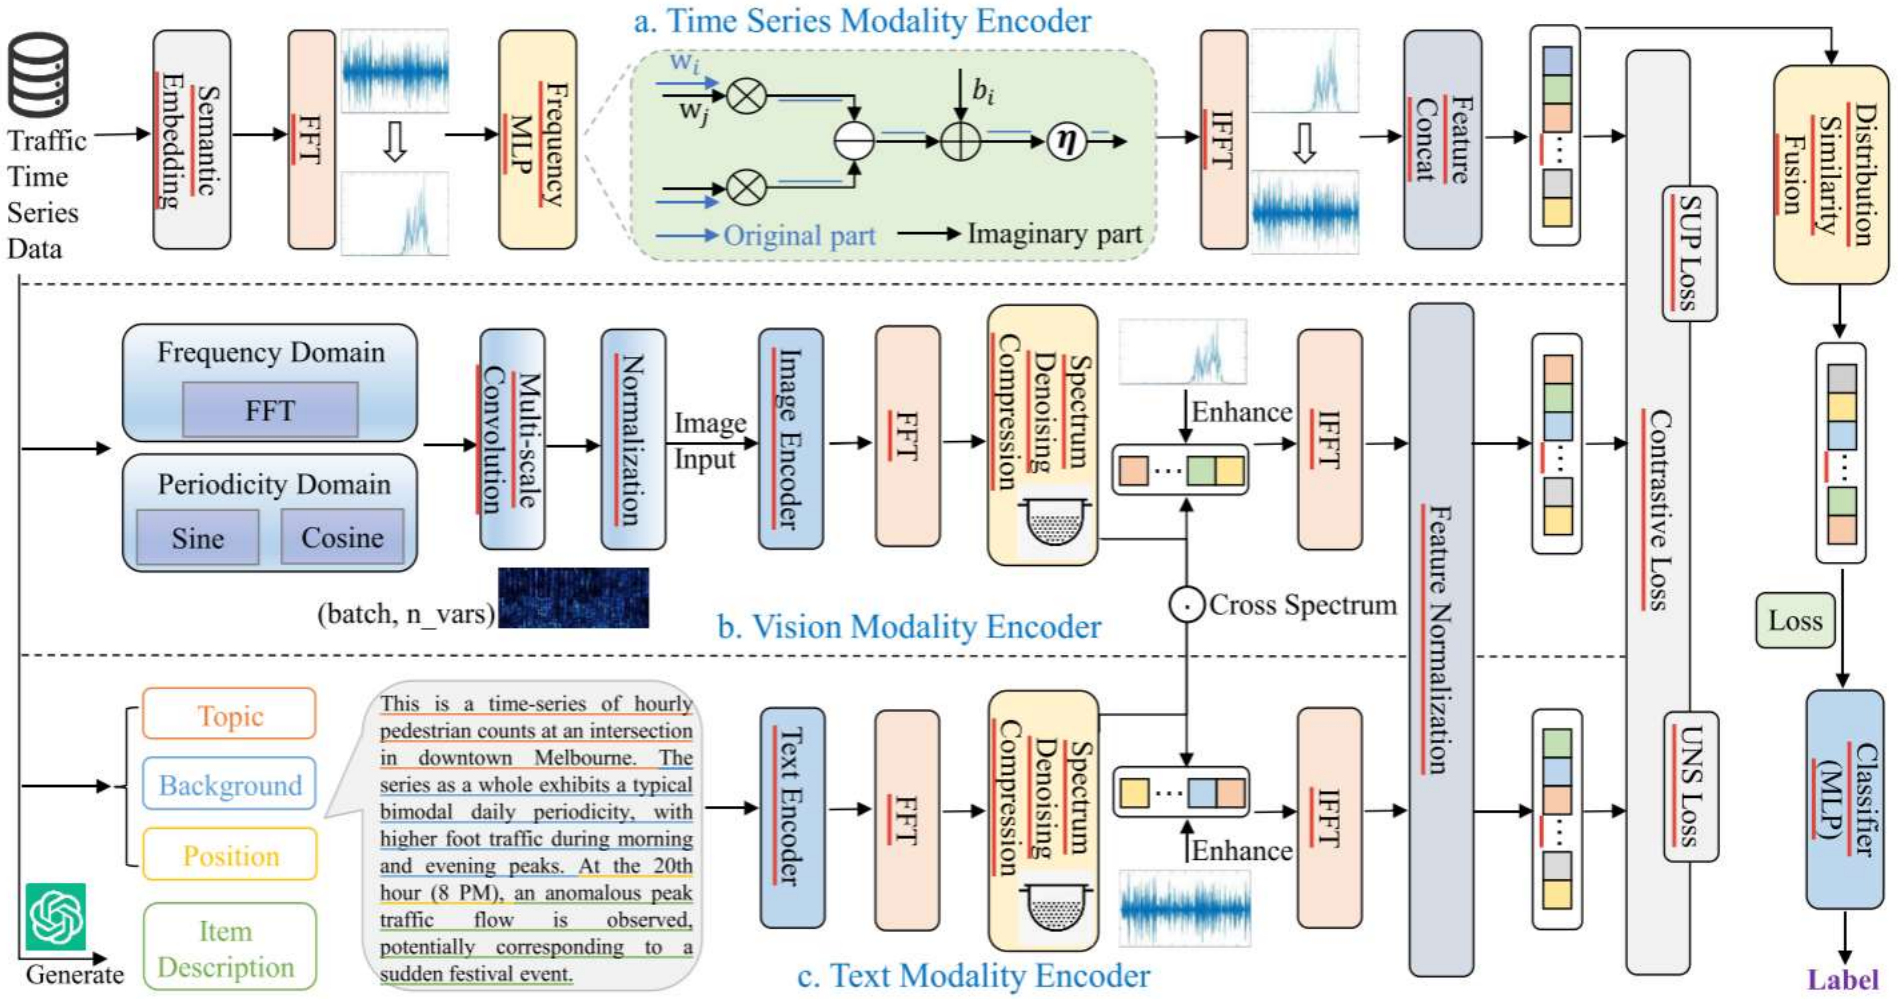

MTP通过数值、视觉和文本三个角度在频域中学习多通道特征，MTP由三个模式编码器分支和一个特征融合方案组成：a)时间序列通道编码器，b)视觉通道编码器和c)文本通道编码器。该框架融合的特征可以同时保留数字通道的时间模式、视觉通道的直观模式和文本通道的语义信息。

时间序列模态编码器

该模块主要利用频谱变换技术对原始流量时间序列数据进行处理。时间序列通道编码主要涉及语义嵌入、快速傅立叶变换(FFT)、频域多层感知(MLP)和快速傅立叶逆变换(IFFT)。

- **语义嵌入**：将输入数据 $X \in R^{(n \times l)}$ 通过可学习权重向量 ψ 映射为隐藏表示 $D \in R^{(n \times l \times m)}$，引入丰富语义信息，公式为 $D = X \times \psi$；
- **频域转换**：通过快速傅里叶变换（FFT）将空域数据转换到频域，提取多尺度与周期性特征，公式为$\mathcal{D}^v[k] = \sum_{i=0}^{n-1} D^v[i] e^{-j\frac{2\pi ki}{n}}$；
- **频域 MLP 处理**：通过复数权重矩阵与偏置对频域特征进行非线性映射，增强特征表达能力，公式为$\mathcal{Z} = ReLU(\mathcal{H}W + B)$，支持多层堆叠；
- **空域转回**：通过逆快速傅里叶变换（IFFT）将优化后的频域特征转回空域，为后续融合提供支持。

$$D^v[i] = \sum_{i=0}^{n-1} \mathcal{D}^v[k] e^{j\frac{2\pi ki}{n}}, \qquad (6)$$

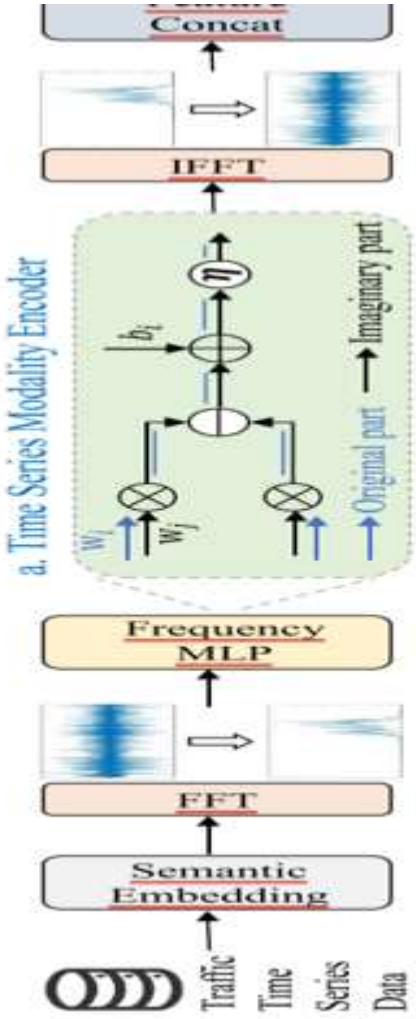

视觉模态编码器

视觉通道编码器的过程是首先将交通时间序列数据转换成图像，然后对图像进行频域处理以提取视觉特征。

模态转换：结合频域编码器（FFT 提取频率信息）与周期性域编码器（$P_t = [sin(2\pi t/\phi), cos(2\pi t/\phi)]$），将时间序列转换为多维度表示 X^g；

多尺度卷积：通过 1D 卷积捕捉局部依赖，2D 卷积捕捉全局结构，经双线性插值调整为 64×64 图像尺寸并归一化；

频域优化：

- *FIR 滤波器去噪*：基于汉明窗构建滤波器组，公式为$\omega_i = 0.54 - 0.46cos(z\pi i/s - 1)$，对频域特征加权滤波，保留核心频率；
- *频谱压缩*：通过元素乘法与求和实现频谱高效压缩，公式为$\mathcal{X}^g_{spe} = \sum_{i=1}^{s} \frac{1}{c}|\mathcal{X}^g|^2 \odot r^i$；
- *平均池化*：平滑频谱以去除高频噪声，公式为$\mathcal{X}^g_{pool} = Average(\mathcal{X}^g_{spe} \odot \delta^g)$；

跨模态增强：结合文本模态特征优化图像频谱，公式为$\mathcal{X}^g_{out} = \mathcal{X}^g_{spe} \odot \mathcal{X}^t_{pool}$；

空域转回：通过 IFFT 将频域特征转回空域，得到视觉模态最终特征。

$$\boldsymbol{X}^g[i] = \sum_{i=0}^{n-1} \boldsymbol{\mathcal{X}}^g_{out}[k] e^{j\frac{2\pi k i}{n}}. \qquad (13)$$

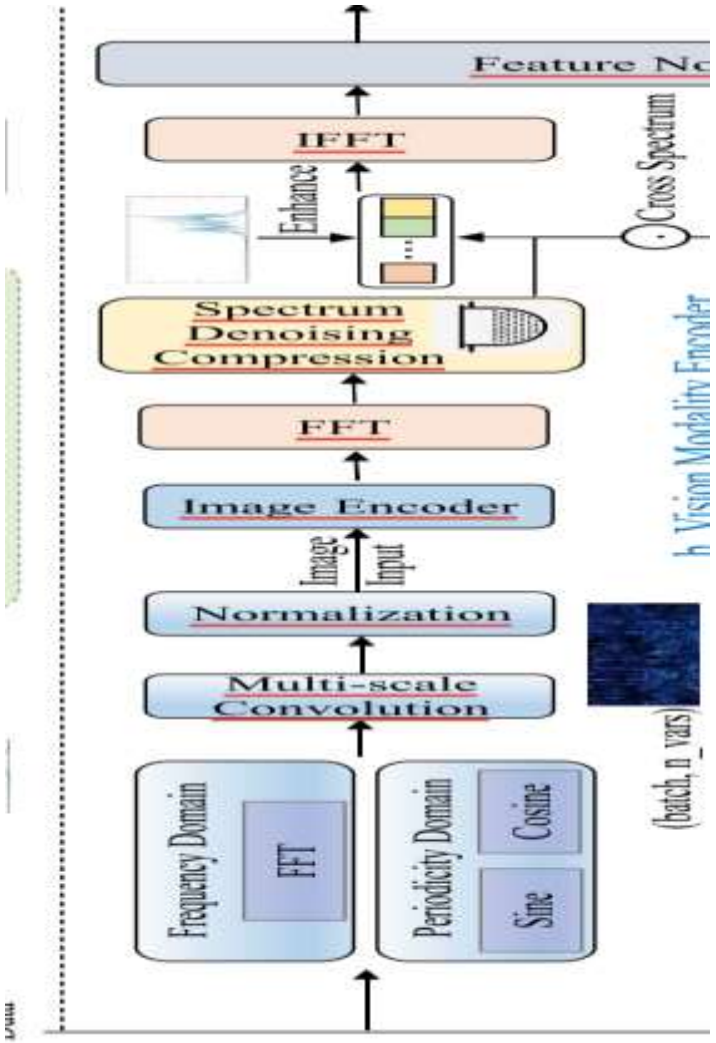

文本通道编码器

文本生成 / 输入：若原始数据无文本，通过 LLM[Q]（如 ChatGPT）生成事件描述，并提取主题、背景、车辆位置等上下文信息；若有文本则直接输入；

频域转换与优化：将文本编码器生成的向量 X^t 通过 FFT 转换到频域，经 FIR 滤波、平均池化处理后，结合图像模态特征进行跨模态增强，公式为

$$\mathcal{X}_{out}^{t} = \mathcal{X}_{spe}^{t} \odot Average\left(\mathcal{X}_{spe}^{g} \odot \delta^{g}\right);$$

空域转回：通过 IFFT 得到文本模态最终特征，用于后续融合。

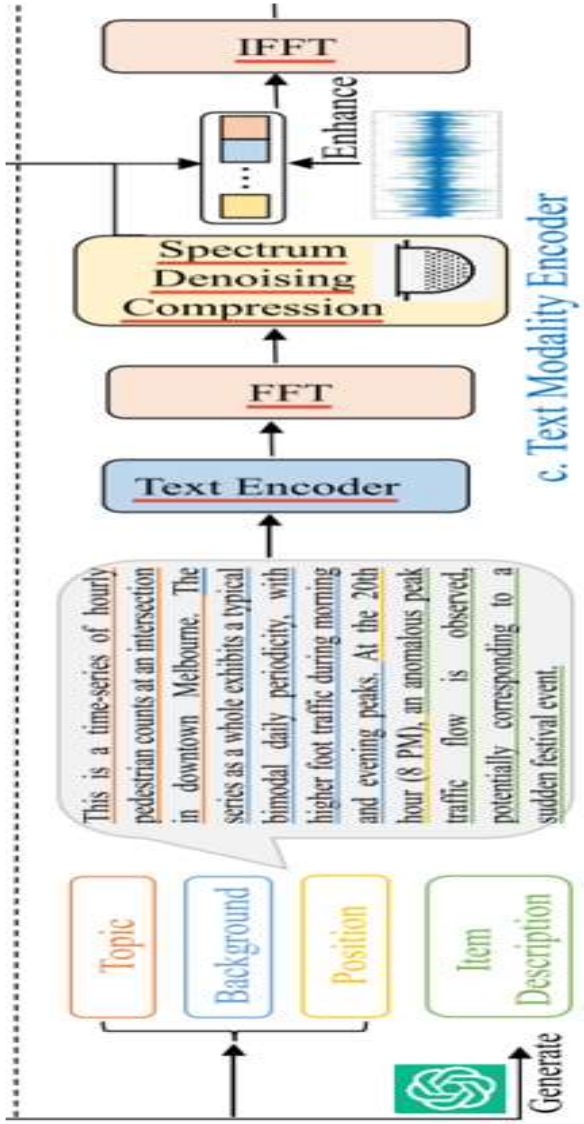

跨模态融合与损失函数

每种模式经过频谱变换和频域处理后，通过对比学习和分布相似融合两种方案实现特征融合。
对比损失的意义在于通过减小同一交通场景中不同通道特征之间的距离来实现跨通道特征的语义对齐，同时增加无关通道特征之间的距离，从而增强多通道特征的一致性。

对比学习：

- *有监督损失*（L (SUP)）：缩小同一交通场景下不同模态特征的距离，增强类内一致性；
- *无监督损失*（L (UNS)）：基于 InfoNCE 损失，对齐不同模态的特征分布，扩大无关模态特征距离；

分布相似度融合：通过 JS 散度计算三种模态两两之间的分布相似度 Δ，基于 Δ 加权融合三种模态特征，公式为$\hat{x} = (1-\Delta)(K^v x^v + K^g x^g + K^t x^t) + \Delta x^v + \Delta x^g + \Delta x^t$；

分类损失：采用多分类交叉熵损失（L (CE)）优化分类结果；$\mathcal{L}(CE) = -\mathbb{E}_{y\sim\hat{Y}} \sum_{i=1}^{m} y_i log(y_i')$.

总损失：$\mathcal{L} = \alpha\mathcal{L}(SUP) + \beta\mathcal{L}(UNS) + \gamma\mathcal{L}(CE)$，其中 α 、 β 、 γ 为平衡超参数。

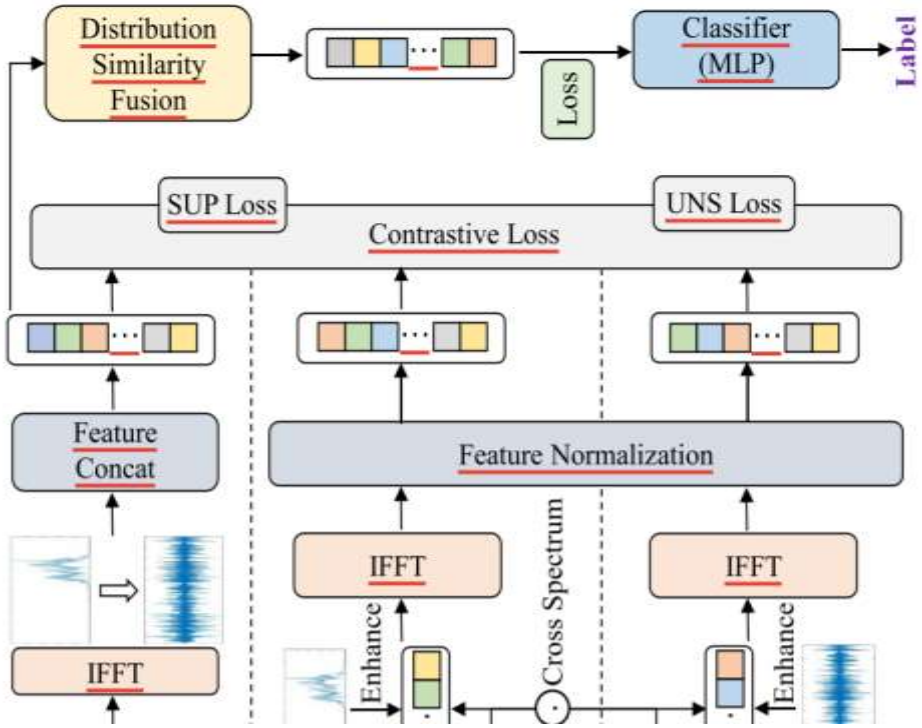

实验结果

将提出的模型(MTP)在度量F1-得分(F1)和准确度(ACC)方面与最先进的基线进行了比较

Dataset	ShapeNet		TST		PatchTST		SVP-T		LightTS		ModernTCN		CAFO		InterpGN		**MTP**	
	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc
Chinatown	0.7206	0.7259	0.9472	0.9563	0.9714	0.9767	0.9456	0.9592	0.9680	0.9708	0.9712	0.9767	0.9784	0.9825	0.9541	0.9659	**0.9820**	**0.9839**
Melbourne	0.7186	0.7314	0.8426	0.8421	0.8897	0.8877	0.8030	0.8065	0.8670	0.8655	0.8732	0.8786	0.8876	0.8860	0.8392	0.8364	**0.9669**	**0.9635**
PEMS-BAY	0.6365	0.6790	0.6712	0.6882	0.6838	0.6929	0.6573	0.6844	0.6736	0.6860	0.6950	0.7055	0.6637	0.6840	0.6770	0.6989	**0.7091**	**0.7200**
METR-LA	0.7186	0.7314	0.7143	0.7224	0.7295	0.7425	0.7158	0.7269	0.7113	0.7229	0.7483	0.7562	0.7158	0.7266	0.7262	0.7385	**0.7590**	**0.7684**
DodgerLoop	0.1500	0.2153	0.3529	0.4125	0.5435	0.5750	0.3817	0.4250	0.5156	0.5625	0.2442	0.3750	0.3607	0.4500	0.1519	0.2250	**0.5676**	**0.6000**
PEMS-SF	0.6373	0.6503	0.7900	0.7919	0.7468	0.7446	0.8215	**0.8266**	0.7384	0.7514	0.7594	0.7630	0.7857	0.7919	0.6246	0.6705	**0.8310**	0.8227

性能比较：我们首先将我们提议的框架的性能与八个最先进的基线进行了比较。MTP始终达到最先进的结果，在大多数情况下表现优于所有基线。

消融性分析

Variant	Melbourne				DodgerLoop			
	Acc	Pre	Rec	F1	Acc	Pre	Rec	F1
MTP	**0.9672**	**0.9671**	**0.9669**	**0.9669**	**0.6000**	**0.6978**	**0.5923**	**0.5848**
w/o Visual	0.7593	0.7617	0.7595	0.7584	0.2375	0.0674	0.2348	0.1048
w/o Textual	0.9659	0.9660	0.9657	0.9657	0.5375	0.6268	0.5247	0.5315
w/o TS	0.6839	0.6845	0.6833	0.6766	0.5875	0.6015	0.5788	0.5676

MTP是完整的模型；
w/o V：无视觉；
w/o T：无文本；
w/o TS：无时间序列。

最显著的影响是在消融视觉分支(‘w/o V’)，移除文本分支(w/o T)会导致F1分数的可测量的下降，而不使用原始时间序列(w/o TS)会导致性能显著下降，因此，我们提出的通道增强和融合是该模型优越性能的核心驱动因素。

敏感性分析

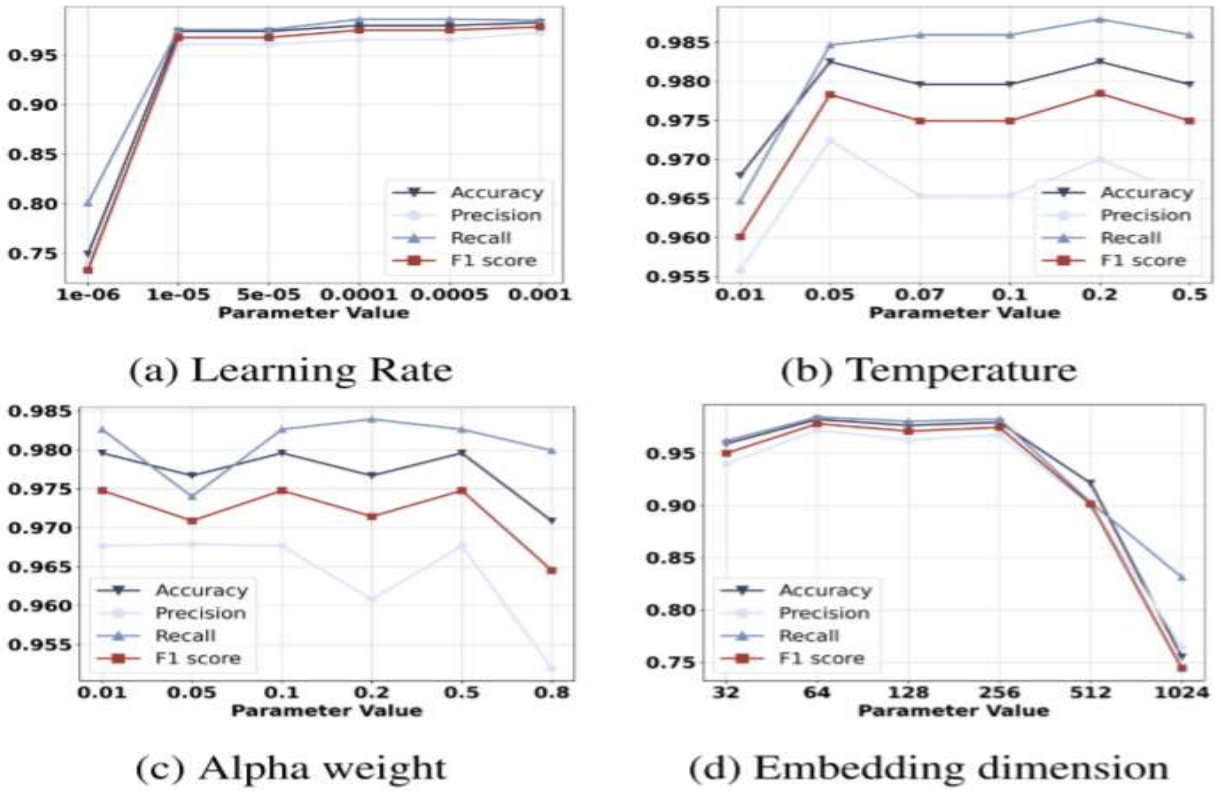

结果表明，我们的框架在不同的超参数下表现出健壮性。这验证了MTP是稳定的，不需要广泛的超参数调整。

定性分析

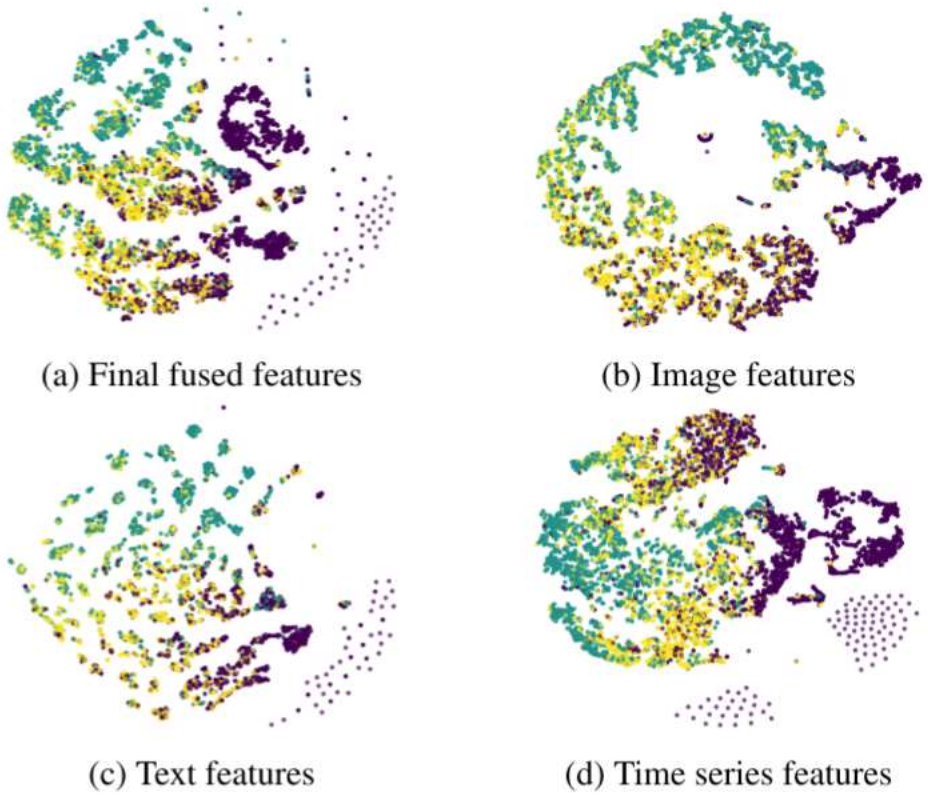

完整的框架学习的最终融合功能，形成了高度内聚和明显分离的集群（a）。不同颜色表示的不同类别的样本被清楚地分开，重叠最小。相比之下，来自单一模态的特征分布更分散和混合。这表明我们的融合模块成功地整合了互补信息，产生了更强大和更具区分性的最终表示。

总结

本文提出了一种新的多通道城市交通状况分析框架MTP，从数字、视觉和文本三个角度学习频域中的多通道特征。
MTP使用频率多层感知将原始数据转换为周期图像和频率图像来执行视觉增强，并基于诸如用于文本增强的主题和背景等信息来生成描述性文本，再设计了分层对比学习来融合这三种模式。有效解决了传统单一模态方法难以全面捕捉交通动态的问题。

北京工業大學

谢 谢！