Robust Inter-Series Dependency Modeling for Time Series Forecasting via Information-Theoretic Alignment

基于信息论对齐的稳健序列间依赖建模用于时间序列预测

汇报人：张志航

2026/11/8

背景

多变量时间序列对于预测现实世界系统的未来动态至关重要。目前多变量时间序列预测面临的两个主要挑战：单个变量复杂的时间模式（时序依赖）和不同变量之间的动态相关性（序列间依赖）

最近iTransformer开创了将每个变量作为独立token的Variate Transformer范式，大大提升了序列间依赖的建模能力。但作者在后续研究中发现，这类方法仍然存在两个很明显的短板。

问题一

输入表示过度依赖时间戳。现有方法通常使用从时间戳衍生的可学习编码来捕捉时间周期性信息，然而，时间戳的格式在不同数据集之间可能存在差异，缺失或错误的时间戳等问题可能无法得到有效处理。此外，其实际有效性尚未完全确定。

为了调查这种时间信息的实际效用，我们在 iTransformer 上进行了消融研究，将时间戳嵌入移除，用单个线性层对输入信号进行采样。结果反而在八个数据集上带来了性能提升，这说明现有方法对时间戳的依赖其实是不必要的。

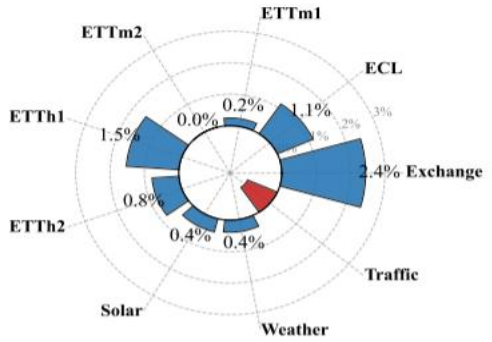


Figure 1. Impact of timestamps on iTransformer. The radar chart presents an improved (blue) or decreased (red) percentage.

问题二

序列间依赖建模的不一致性。
Transformer由两个关键部分组成：多头自注意力层和前馈网络层。
分析Variate Transformer结构发现一个潜在的限制：序列间依赖仅在浅层的自注意力层中被建模。而更深层的前馈网络层仅专注于捕捉每个单独变量内的时间特征。这就导致浅层和深层的建模目标存在天然的不一致，很容易学到虚假相关性，不仅泛化能力差，还会增加模型优化的难度

现有的改进方法是它们将学到的序列间依赖集成到自注意层中，通常作为注意力掩码或偏置。但是 1)这些方法并未解决建模时间依赖性与序列间依赖性不一致的问题。2) 改进方法的建模很难迁移其他架构上。

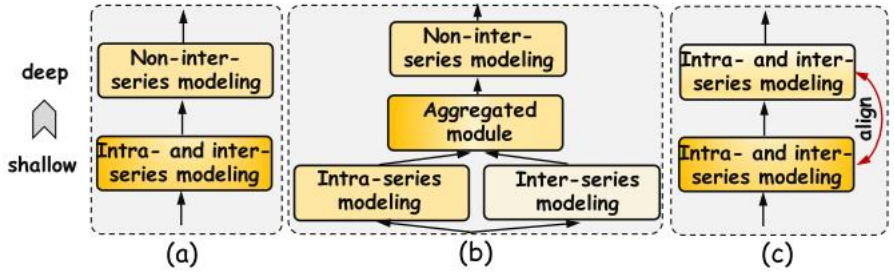


Figure 2. A comparison of paradigms for modeling temporal and inter-variable dependencies. (a) and (b) illustrate existing Transformer-based approaches for modeling IVD. (c) depicts the consistent dependency modeling paradigm proposed in this work.

系统架构

作者提出了CGTFra，它包括了三个核心部分：
1.通用的自适应频域掩码重采样（FMR)：不用时间戳也能捕捉周期性
2.一个动态图学习（DGL）框架：在深层的网络层显式建模序列间依赖
3.一致性对齐损失（CAL）：进一步协调了浅层与深层网络间建模。

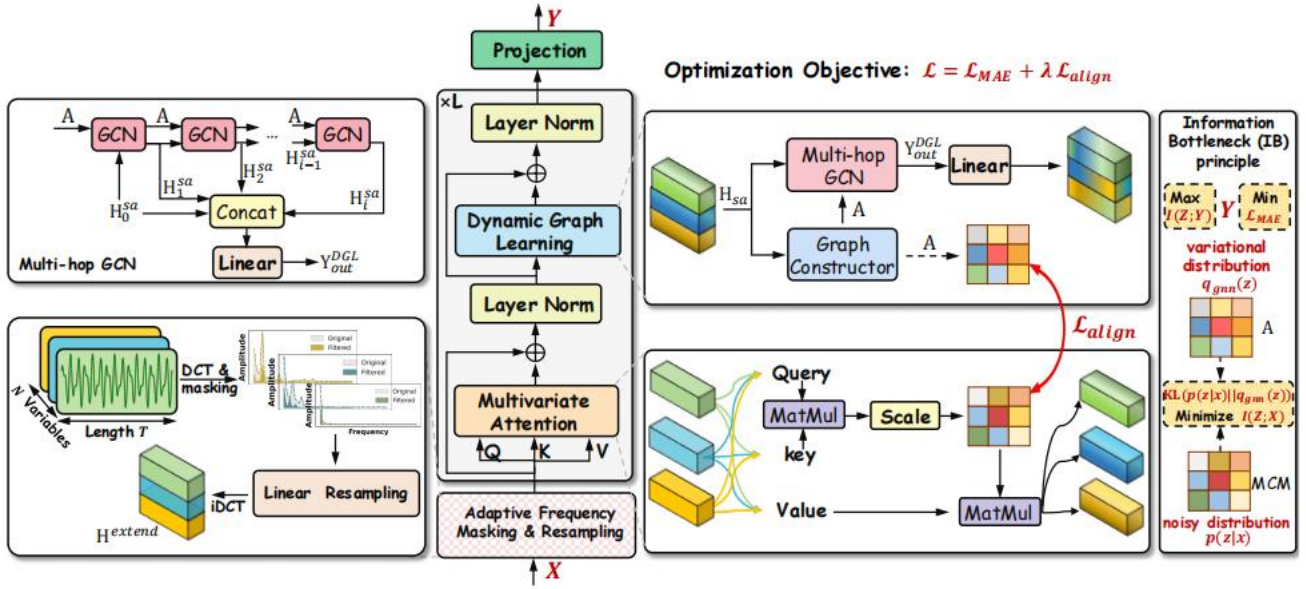


Figure 4. Illustration of proposed CGTFra. The output of the i-hop GCN is denoted by $\mathbf{H}_i^{sa}$. The deep CGTFra can be constructed by stacking multiple layers (×L) of self-attention and DGL modules. At this stage, each layer is subjected to alignment constraints (CAL). The right panel illustrates the Variational Information Bottleneck principle within CGTFra. The alignment loss $\mathcal{L}_{align}$ minimizes the KL divergence between the noisy encoder distribution $p(z|x)$ (MCM) and the compressed variational distribution $q_{gnn}(z)$ (A), effectively filtering noisy IVD while preserving predictive information maximized. See Appendix F for theoretical derivations.

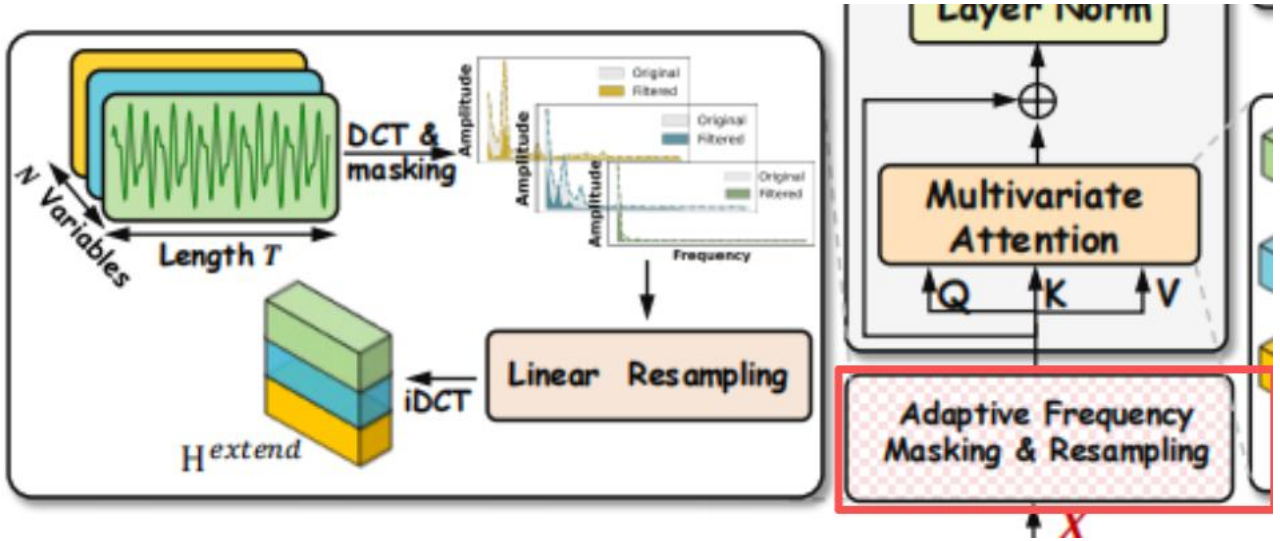
公众号 · 我的科研日记

FMR

自适应频域掩码重采样

第一步：DCT 变换。将每个变量的历史时间序列转换到频域。
第二步：自适应频率掩码。构建一个可学习的掩码矩阵M，不同变量可以学习不同的频率权重。
第三步：Linear Resampling,对经过掩码处理的频域特征进行线性重采样
第四步：iDCT 把处理后的频域特征转换回时域表示

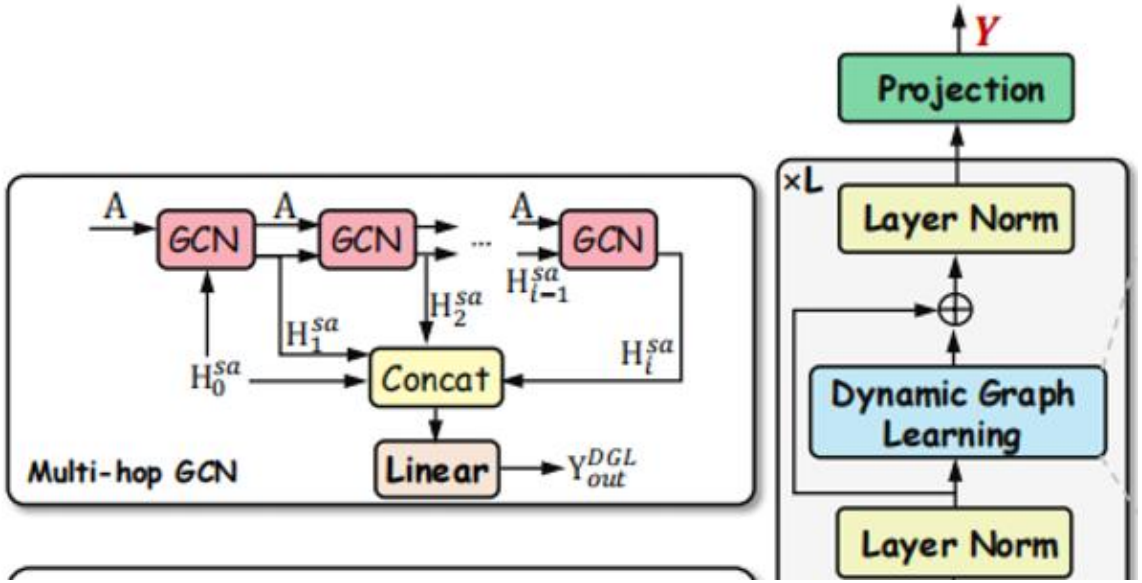
。



这一模块的核心目的：在不依赖时间戳编码的情况下，增强时间序列的特征表示

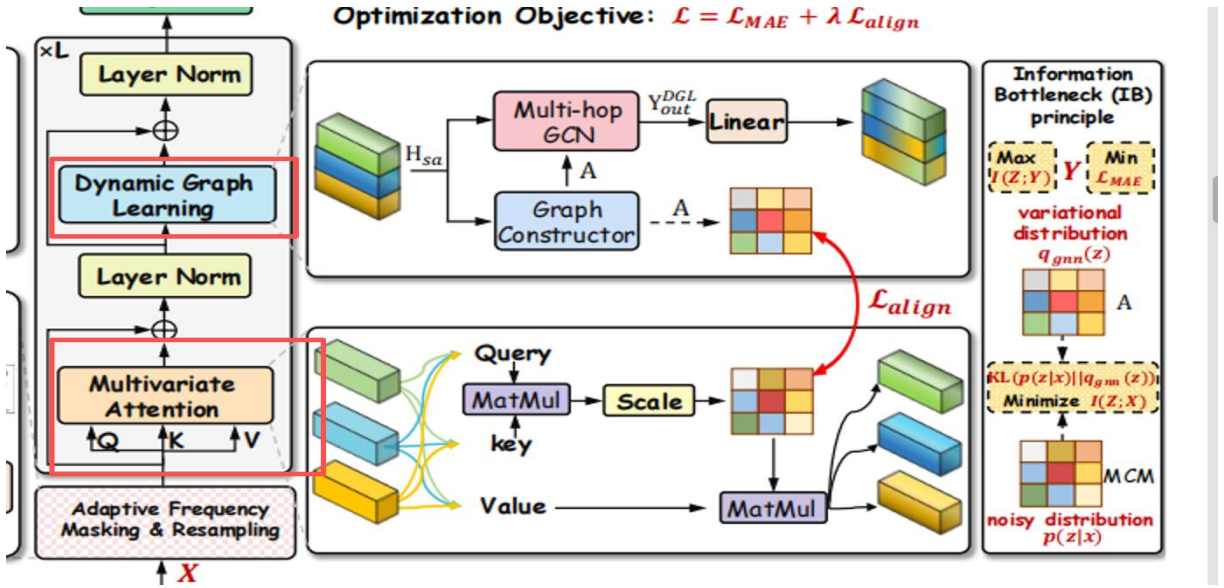
DGL

传统 Transformer在注意力层之后使用 FFN，而作者认为 FFN 缺乏显式的序列间信息聚合。因此，作者使用 DGL 替换 FFN，将自注意力输出与可学习节点嵌入结合，动态构建邻接矩阵，并通过多跳 GCN 聚合变量间的依赖信息。



CAL

虽然在深层和浅层都做序列间依赖建模，但自注意力和图学习的特性其实有差异。自注意力捕捉的是全局密集的依赖，里面容易混进虚假相关性；而图学习擅长捕捉稀疏的间接依赖,为了解决这个问题，作者首次提出 用一致性对齐损失约束两者学习到的依赖分布，通过 KL 散度约束注意力关系矩阵 MCM 与动态图邻接矩阵 A 之间的分布差异。



最后，整个模型通过预测 MAE 损失和一致性对齐损失联合训练,保持预测性能的同时减少无关的变量依赖信息。

实验结果

作者在13个公开的长短周期数据集上做了全面测试，和13个SOTA方法做了对比，整体结果如下：

Table 1. Long-term forecasting results with fixed input length T=96 and forecasting horizons $F \in \{96, 192, 336, 720\}$. The results are averaged from four forecasting horizons. Full results, short-term forecasting results, and the additional comparison scenarios (with different input lengths) are all provided in Appendix J. **Bold**: best results, underline: second best one.

Models	CGTFra (*Ours*)		DUET (KDD'25)		TimePro (ICML'25)		Soatten (AAAI'25)		VCformer (IJCAI'24)		FilterNet (NeurIPS'24)		iTransformer (ICLR'24)		MSGNet (AAAI'24)		PatchTST (ICLR'23)	
Metrics	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTm1	0.388	**0.386**	0.390	0.393	0.391	0.400	0.394	0.402	0.387	0.397	**0.384**	0.398	0.407	0.410	0.398	0.411	0.387	0.400
ETTm2	0.277	**0.316**	0.280	0.324	0.281	0.326	0.287	0.331	0.285	0.330	**0.276**	0.322	0.288	0.332	0.288	0.330	0.281	0.326
ETTh1	**0.434**	**0.427**	0.443	0.436	0.438	0.438	0.447	0.440	0.439	0.437	0.440	0.432	0.454	0.447	0.452	0.452	0.469	0.454
ETTh2	**0.369**	**0.394**	0.372	0.397	0.377	0.403	0.379	0.405	0.377	0.403	0.378	0.404	0.383	0.407	0.396	0.417	0.387	0.407
Exchange	**0.312**	**0.382**	0.318	0.384	0.352	0.399	0.359	0.404	0.355	0.402	0.356	0.395	0.360	0.403	0.399	0.430	0.367	0.404
Weather	**0.238**	**0.260**	0.251	0.273	0.251	0.276	0.245	0.273	0.258	0.282	0.245	0.272	0.258	0.278	0.249	0.278	0.259	0.281
ECL	**0.165**	**0.253**	0.172	0.258	0.169	0.262	0.166	0.259	0.180	0.267	0.173	0.268	0.178	0.270	0.194	0.300	0.205	0.290
Solar	**0.224**	**0.228**	0.237	0.233	0.232	0.266	0.229	0.261	-	-	-	-	0.233	0.262	-	-	0.270	0.307
Traffic	**0.427**	**0.257**	0.451	0.269	-	-	0.437	0.286	0.483	0.325	0.463	0.310	0.428	0.282	-	-	0.555	0.362

CGTFra在绝大多数数据集上都取得了最优性能，尤其在变量数多的数据集比如ECL、Traffic上优势更明显。

框架通用性验证

为了验证框架通用性，把三个核心模块分别嵌入到现有的主流模型中。

Table 2. Verification of Framework Generality. Results are averaged from four forecasting horizons. Full results, additional valuation metrics and further analysis are in Appendix K. For a fair comparison, the results in Table 1 are taken from their officially released reports, whereas the results below are reproduced under our experimental environment (with identical hyperparameters as publicly released by the authors), and consequently, some discrepancies exist. "–" denotes that the original method was not evaluated on certain datasets, or that we encountered out-of-memory issues. "iTrans" and "Filter" denote iTransformer and FilterNet, respectively.

Datasets		ETTm1		ETTm2		ETTh1		ETTh2		Exchange		Weather		ECL		Solar		Traffic	
Metrics		MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
DUET	original	0.391	0.394	0.279	0.322	0.449	0.440	0.372	0.398	0.309	0.380	0.247	0.270	0.172	0.258	**0.241**	**0.246**	0.451	0.269
	+ **DGL**	**0.389**	**0.391**	**0.277**	**0.320**	0.444	0.436	**0.368**	**0.395**	**0.296**	**0.373**	0.247	0.272	0.166	0.255	0.243	0.258	**0.448**	**0.268**
	+ **CAL**	0.390	0.392	0.279	0.322	**0.438**	**0.432**	0.369	**0.395**	0.305	0.376	**0.237**	**0.263**	**0.164**	**0.253**	0.242	0.253	0.452	0.269
iTrans	original	0.408	0.412	0.293	0.337	0.457	0.449	0.384	0.407	0.369	0.409	0.262	0.283	0.176	0.268	0.235	0.261	**0.422**	0.282
	+ **FMR**	0.403	0.406	**0.291**	**0.333**	0.448	**0.440**	**0.381**	**0.406**	0.358	0.404	0.259	0.282	0.175	0.266	**0.229**	**0.260**	0.423	**0.281**
	+ **DGL**	0.400	0.406	0.293	0.335	0.449	0.442	0.390	0.412	0.368	0.409	0.252	0.278	0.169	0.263	0.234	0.263	0.434	0.288
	+ **CAL**	**0.397**	**0.403**	**0.291**	**0.333**	**0.444**	**0.440**	0.385	0.408	**0.354**	**0.403**	**0.249**	**0.276**	**0.163**	**0.257**	0.233	0.262	0.436	0.286
VCformer	original	0.404	0.406	0.292	0.334	0.488	0.460	**0.384**	**0.405**	**0.358**	**0.403**	0.269	0.286	0.186	0.278	-	-	-	-
	+ **FMR**	**0.398**	0.402	0.291	0.333	0.457	**0.441**	0.385	0.406	0.367	0.409	0.265	0.285	0.182	0.275	-	-	-	-
	+ **DGL**	**0.398**	**0.401**	0.289	0.333	0.456	0.447	0.389	0.410	0.363	0.404	**0.249**	**0.275**	0.174	0.266	-	-	-	-
	+ **CAL**	**0.398**	0.402	**0.287**	**0.331**	**0.451**	0.444	**0.384**	0.406	0.361	0.406	**0.249**	**0.275**	**0.167**	**0.261**	-	-	-	-
CASA	original	**0.391**	**0.400**	0.279	0.323	**0.442**	**0.440**	0.383	0.406	-	-	0.249	0.276	0.172	0.265	0.226	0.261	**0.427**	**0.278**
	+ **FMR**	0.392	0.401	**0.277**	**0.322**	**0.442**	**0.440**	**0.378**	**0.404**	-	-	**0.245**	**0.273**	**0.169**	**0.263**	**0.223**	**0.259**	0.444	0.279
Filter	original	0.384	**0.398**	0.277	**0.322**	0.451	**0.437**	**0.379**	**0.405**	-	-	0.253	0.280	0.179	0.272	-	-	0.460	0.304
	+ **FMR**	**0.383**	**0.398**	**0.276**	**0.322**	**0.450**	**0.437**	**0.379**	**0.405**	-	-	**0.248**	**0.276**	**0.177**	**0.271**	-	-	**0.455**	**0.300**

三个模块几乎在所有数据集上都能带来稳定的性能提升，其中动态图学习的提升最显著，直接验证了深层序列间依赖建模的重要性

消融实验

Table 3. Ablation studies on five diverse datasets. The results are averaged from four forecasting horizons. Full results are provided in Table 15 of Appendix. F/D/C: FMR/DGL/CAL.

Part	F/D/C	ETTm1 MSE	ETTh1 MSE	Weather MSE	ECL MSE	Traffic MSE
CGTFra	✓/✓/✓	**0.388**	**0.434**	**0.238**	**0.165**	**0.427**
aba1	✓/✗/✗	0.397	0.442	0.245	0.170	0.431
aba2	✓/✓/✗	0.389	0.437	0.242	0.168	0.430
aba3	✗/✓/✓	0.392	0.437	0.243	0.173	0.444

aba1和aba2 验证了 DGL的必要性
aba2 和 CGTFra 验证 CAL的必要性
aba3 和 CGTFra 验证了FMR的必要性

序列间依赖建模能力可视化

作者从Weather数据集里选了4个高度相关的变量做分析，对比真实值和预测值的PCC和DTW，可以看到预测的相关度和真实值非常接近，说明模型能准确捕捉变量间的依赖关系。

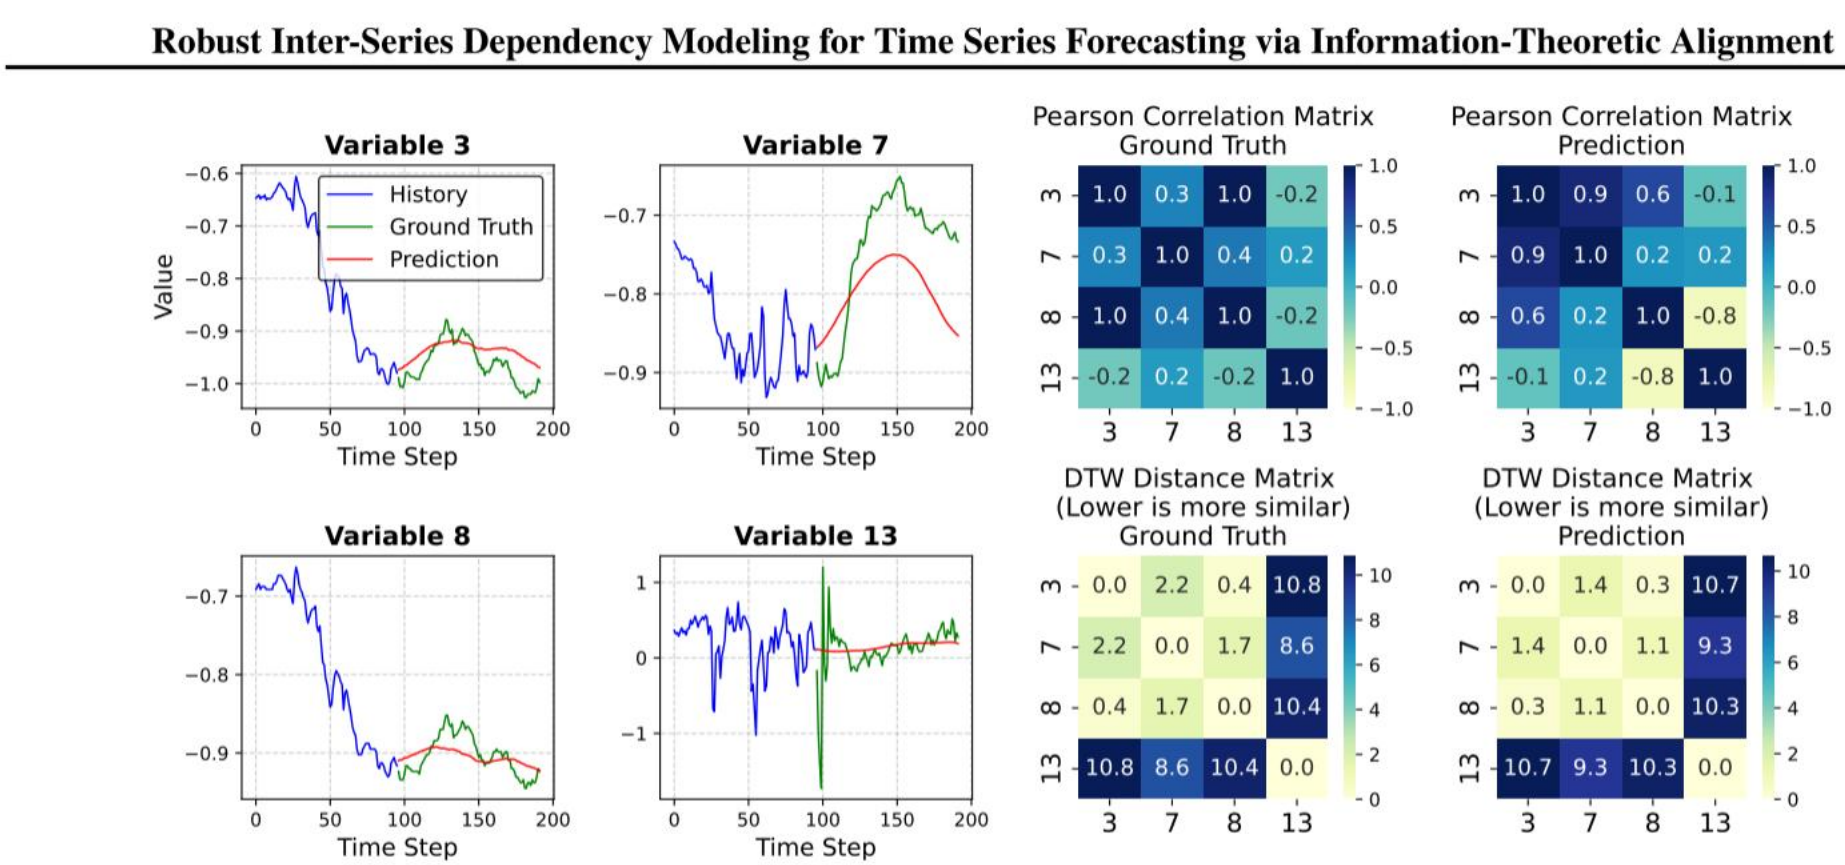
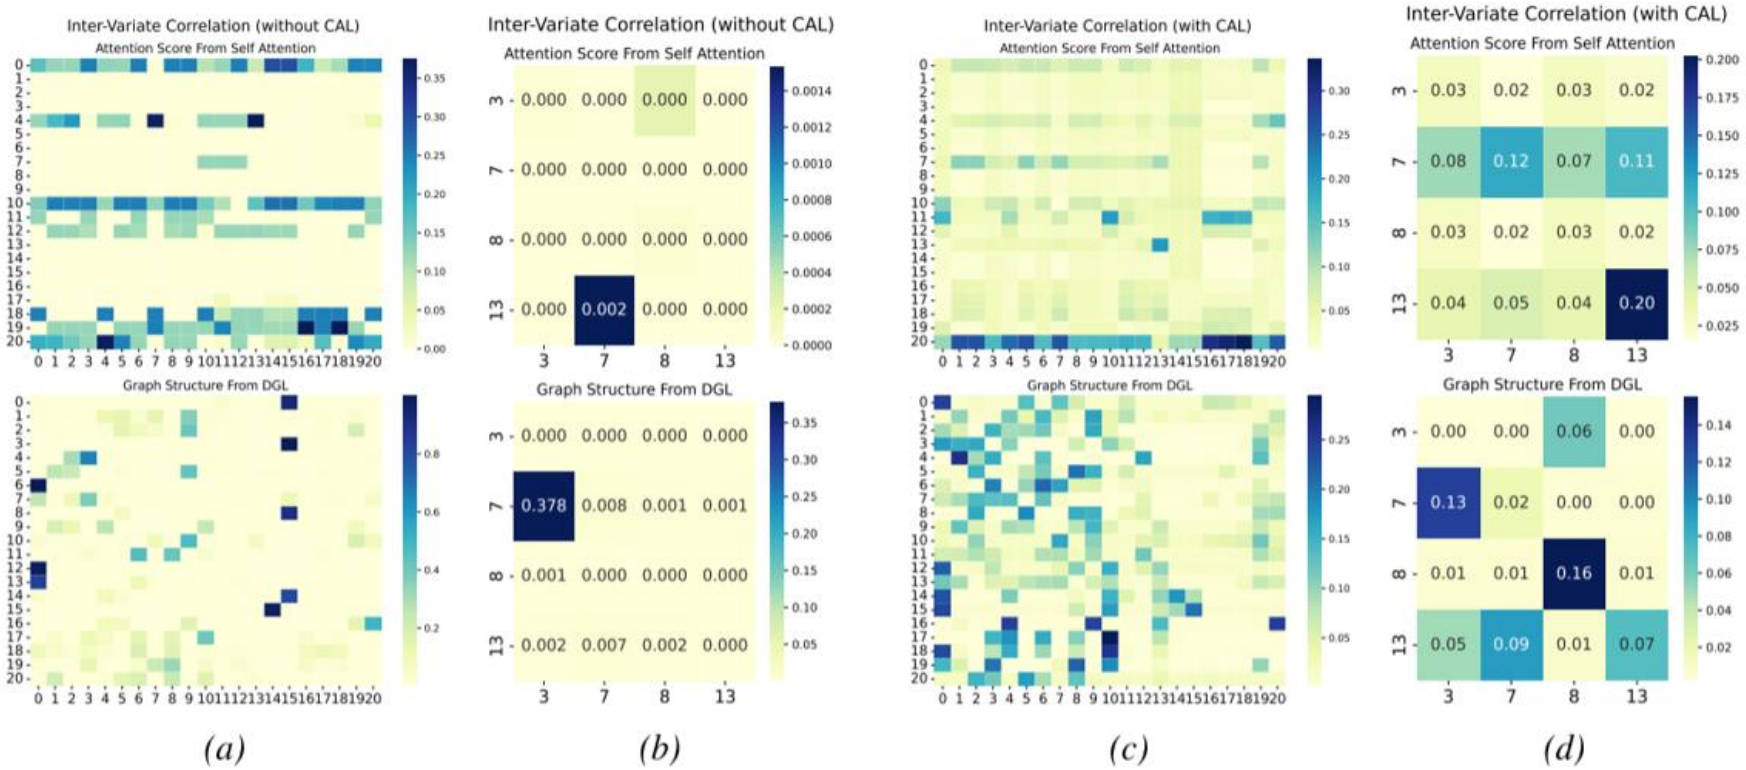


Figure 7. Prediction curves for CGTFra (Input 96-Predict 96) and the DTW and PCC comparison between ground truth and predicted sequences among variables [3, 7, 8, 13]. According to DTW and PCC, variable 3 exhibits a strong association with variable 8, while variable 7 also shows substantial correlations with both variables 3 and 8, as indicated by small DTW distances and high PCC.

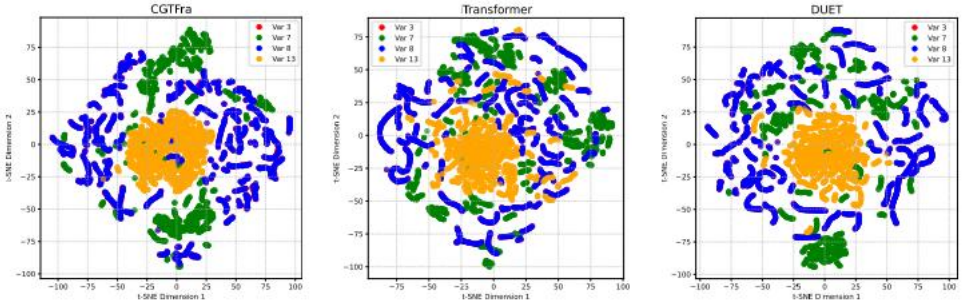
可视化

我们展示CGTFra两个变量间相关性矩阵：一个来自自注意力层，另一个来自DGL。我们发现：在没有CAL约束的情况下，无论是自注意力层还是DGL，都无法成功捕捉关键的依赖关系。加入CAL之后，两种机制都能准确建模显著的相关关系，而且各有侧重：自注意力更擅长直接依赖的捕捉，图学习更擅长间接依赖的捕捉，两者通过约束达到了很好的平衡。



可视化

最后看t-SNE嵌入的可视化结果，CGTFra学习到的变量嵌入不仅同类变量聚集更紧密，不同变量的距离也更符合真实的依赖关系，说明表示能力明显优于iTransformer和DUET。CGTFra在学习单个变量特征方面具有更强的表现力，同时能更准确地捕捉变量间的相互依赖关系。



(a) CGTFra (b) iTransformer (c) DUET

Figure 9. T-SNE visualization for variable 3, 7, 8, and 13 on the 1500 samples of Weather test set.

谢 谢！