VecCity: A Taxonomy-guided Library for Map Entity Representation Learning

VecCity：分类学指导下的地图实体表征学习库

汇报人：张志航

2025/3/27

背景问题和方案

电子地图由兴趣点(POI)、路段、地块等多种实体组成，在各种应用中具有重要作用。近年来，预先训练的表示学习已经成为生成通用的、与任务无关的数据表示的一种强有力的方法。地图实体表示学习（MapRL） 利用预训练技术生成通用且可复用的数据表示，为高效管理与利用地图实体数据提供了关键技术支撑。并取得了快速进展。

但目前MapRL面对两个核心挑战:

一：零散的研究领域。现有的研究通常将这些实体的建模视为单独的领域，从而限制了跨领域的技术、方法和模块的可重用性。然而，现实世界中的电子地图应用程序通常需要综合使用所有三种实体类型。

二：缺乏统一的基准。这一领域缺乏标准化的数据集和基准。这种缺失阻碍了模型之间的公平比较，使得很难得出通用的设计原则。

为了解决第一个挑战，我们提出了一种新的MapRL模型分类方法，即基于方法的分类方法，它将MapRL模型的基本组成部分分成四个关键元素：地图数据、编码器模型、预训练任务和下游任务。采用功能方法将编码器模型分成三个范例:基于标记、基于图和基于序列。每个范例都支持专门的预训练任务。两个核心元素-编码器模型和预训练任务-没有与特定的地图实体类型紧密耦合。核心组件与特定于实体的约束的这种分离促进了MapRL的更统一和可转移的框架，促进了跨域集成和知识共享。

为了应对第二个挑战，我们引入了VecCity库，这是我们的分类法指导下的一个MapRL模型开发工具包。该库将地图实体和辅助数据组织为三个原子文件类型。VecCity通过涵盖编码器、预训练任务和下游任务的接口功能进一步标准化了模型实施。

MAPRL的分类学

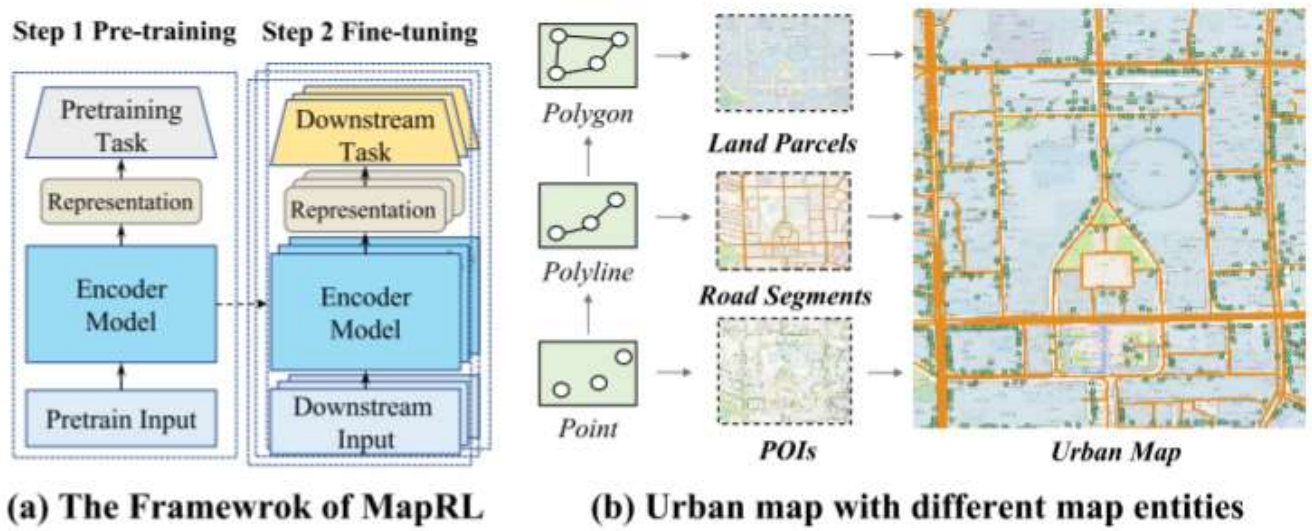

(a) The Framewrok of MapRL (b) Urban map with different map entities

MapRL模型的训练过程包括两个关键阶段：预训练和微调。在预训练过程中，MapRL模型将地图数据作为输入，使用编码器模型将其转换为表示向量。通过预训练任务对编码器的参数进行优化。在微调阶段，利用下游任务来进一步优化编码器。

下面将介绍MapRL模型的四个基本组成部分：地图数据、编码器模型、预训练任务和下游任务。

地图数据：1）映射实体：点、折线和面，每个元素代表一种不同类型的地图实体。对于每个地图实体，都有ID、类型、几何形状和特征。几何形状提供定义其结构的坐标，而特征捕获其各种属性。2）辅助数据：轨迹（即具有相应时间戳的位置序列）和关系网络。MapRL模型利用这些轨迹来推断用户的个人偏好并且促进道路段的路线规划和动态状态估计。利用实体之间的关系来构建邻接矩阵以及表示用户行为。

MAPRL的分类学

编码器模型：将输入的地图数据转换为地图实体的表示矢量。我们将编码器模型分为三种类型：基于令牌的、基于图的和基于序列的，分别用于对地图实体的特征、关系网络和轨迹序列进行建模。

基于令牌的模型：直接从地图实体的特征生成表示向量，用于构建基础语义嵌入

基于图的模型：利用关系网络形式的辅助数据来捕获地图实体之间的关系和空间结构信息

基于序列的编码器：捕获轨迹类型辅助数据内的地图实体之间的时间依赖关系。使用深度学习模型（Transformer,RNN），将沿轨迹的地图实体的嵌入编码到表示向量序列中。

预训练任务:

基于令牌的编码器:令牌关系推理(TokRI)。表征关系对比学习(TRCL)。增强令牌对比学习(AToCL)。

基于图的模型:节点特征推理(NFI)，图形自动编码器(GAU)，邻居对比学习(NCL)，增广图对比学习(AGCL)。

基于序列的模型:轨迹预测(TrajP)，掩蔽弹道恢复(MTR)，增广轨迹对比学习(ATrCL)。

MAPRL的分类学

下游任务：由下游模型和微调损耗两部分组成。下游模型使用编码器生成的表示向量来执行特定任务。微调损失调整编码器参数以提高表示向量对这些任务的适应性。
向量点（POI）的下游任务：POI分类(POIC)。下一个POI预测(NPP)。轨迹用户链接(TUL):
路段的下游任务：平均速度推断(ASI)。行程时间估计(TTE)。相似轨迹搜索(STS)。
地块的下游任务:地块分类(LPC)。流动推断(FI)
有两种针对下游任务的微调策略：下游微调：只有下游模型被微调，而MapRL编码器的参数保持冻结。
ii)端到端微调：该方法调整下游模型和MapRL编码器的参数，使整个模型能够联合优化。

完整的MapRL模型可以集成多种类型的编码器和预培训任务，利用它们的互补优势来增强表示学习。对于编码器模块，现有模型通常遵循“Token→Graph→Sequence”建模流水线。该流水线首先使用基于令牌的编码器提取基本特征，然后通过基于图的编码器捕获关系结构，最后使用基于序列的编码器对时间依赖进行建模。在这条流水线的每个阶段，MapRL模型可以针对不同的预训练任务同时使用多个编码器。

对于编码器通道，MapRL模型遵循两种预训练范例。*i*)顺序训练：编码器分阶段进行训练--首先是基于令牌的，然后是基于图的，最后是基于序列的--每个阶段都会精炼前一个阶段的输出。*ii*)联合训练：使用多任务学习同时优化所有编码器，使模型能够以集成的方式捕获实体特征、结构关系和时间模式。这些范例提供了模型实现的灵活性。

VECCITY

VECCITY由三个功能模块组成，与MapRL模型的四个关键元素相对应。

数据模块:对应于地图数据元素，此模块负责数据准备和处理。地图实体和辅助数据以统一原子文件表示。由三种文件类型组成：geo-表示地图实体，traj-存储轨迹数据，rel-捕获关系网络。这增加了数据的可重用性和统一性，简化了数据处理。

上游模块：配合编码器和预训练任务，负责表示编码和模型预训练。

VecCity库提供上游模块两个关键接口：

encode()：实现MapRL模型的编码器。它将从原子文件中提取的数据作为输入，并输出地图实体的表示矢量。

preTrading_loses():该接口管理预训练任务的执行情况，

通过数据掩蔽、数据增强等方法来准备样本，并计算相应的损失值。

下游模块：与下游任务元素相关联，管理下游任务的模型微调和评估。

有两个关键接口

DETWORWER_MODEL()：对于分类任务，输出层是SoftMax分类器，

而对于连续预测任务，输出层是线性回归层。

FINETTUNING_LOSS()：定义了用于微调的损耗函数。

交叉熵用于分类任务，MSE用于回归任务，InfoNCE用于对比学习任务。

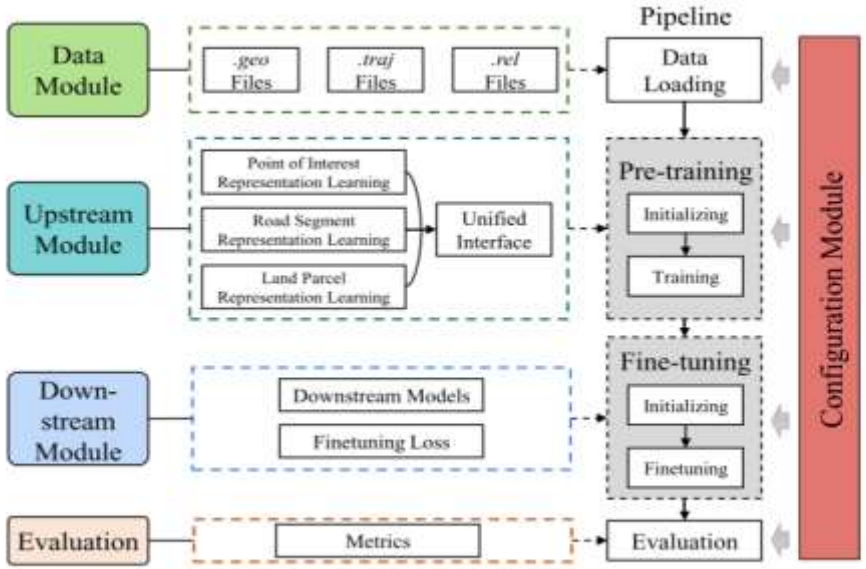

Figure 2: The overall pipeline for *VecCity*.

实验结果：

利用 VecCity对 21 个主流模型于统一环境下在 POI、路段和地块的三类下游任务上进行了广泛的对比实验

POI MapRL的实验结论：
集成基于令牌和基于序列的编码器的模型(例如，CTLE、HIER)优于基于令牌的模型，这表明了轨迹数据的价值。然而，对于组合了基于令牌和序列的编码器模型，关系网络提供的优势很少。因为关系网络提供的信息与轨迹数据提供的信息显著重叠。一旦轨迹数据内的依赖性被充分利用，

关系网络提供的附加信息就有限。
对于基于令牌的模型，那些包含关系网络的模型(例如，TEASER)的表现优于没有关系网络的模型(例如SkipGram)。

使用标记关系推理任务的基于标记的模型，如P2Vec，通常优于使用标记关系对比学习(TRCL)的模型。

Data	Task	Metric	SkipG	Tale	Teaser	Hier	P2Vec	CACSR	CTLE
New York	POIC	ACC@1↑	0.07±0.00	0.06±0.01	0.07±0.01	0.07±0.01	**0.08±0.01**	0.06±0.02	0.06±0.01
		F1↑	0.01±0.00	0.02±0.01	0.01±0.01	0.01±0.00	**0.02±0.01**	0.01±0.00	0.01±0.00
	NPP	ACC@1↑	0.10±0.02	0.14±0.01	0.10±0.02	0.12±0.00	0.13±0.01	0.14±0.05	**0.15±0.01**
		ACC@5↑	0.25±0.04	0.33±0.00	0.25±0.05	0.29±0.01	0.16±0.00	0.33±0.04	**0.33±0.01**
	TUL	ACC@1↑	0.57±0.03	0.67±0.00	0.57±0.02	0.58±0.03	0.64±0.01	0.64±0.03	**0.69±0.00**
		F1↑	0.26±0.03	0.44±0.01	0.27±0.03	0.28±0.04	0.33±0.00	0.39±0.07	**0.45±0.01**
Tokyo	POIC	ACC@1↑	0.35±0.01	0.22±0.00	**0.38±0.02**	0.34±0.04	0.32±0.00	0.30±0.04	0.30±0.04
		F1↑	0.02±0.01	**0.05±0.01**	0.02±0.01	0.01±0.01	0.04±0.00	0.02±0.00	0.02±0.00
	NPP	ACC@1↑	0.16±0.00	0.16±0.01	0.16±0.01	**0.16±0.00**	0.16±0.01	0.16±0.06	0.16±0.00
		ACC@5↑	0.32±0.01	0.30±0.00	0.30±0.04	**0.34±0.00**	0.33±0.01	0.33±0.01	0.33±0.01
	TUL	ACC@1↑	0.43±0.01	0.40±0.01	0.44±0.02	0.44±0.03	0.45±0.00	0.46±0.10	**0.50±0.00**
		F1↑	0.23±0.01	0.23±0.01	0.23±0.01	0.23±0.01	0.25±0.00	0.28±0.10	**0.29±0.00**
Chicago	POIC	ACC@1↑	0.07±0.00	0.10±0.00	0.07±0.01	0.08±0.00	**0.12±0.01**	0.10±0.01	0.10±0.02
		F1↑	0.01±0.00	0.02±0.01	0.00±0.00	0.01±0.00	**0.02±0.01**	0.02±0.01	0.02±0.01
	NPP	ACC@1↑	0.08±0.02	0.10±0.01	0.06±0.03	0.10±0.03	0.15±0.01	0.15±0.05	**0.18±0.01**
		ACC@5↑	0.24±0.05	0.24±0.01	0.18±0.08	0.26±0.06	0.36±0.01	**0.40±0.04**	0.38±0.01
	TUL	ACC@1↑	0.46±0.08	0.62±0.01	0.43±0.07	0.55±0.02	0.66±0.01	0.67±0.07	**0.76±0.01**
		F1↑	0.20±0.07	0.37±0.01	0.19±0.01	0.30±0.01	0.42±0.01	0.44±0.06	**0.60±0.03**
Singapore	POIC	ACC@1↑	0.09±0.04	0.04±0.01	0.06±0.00	0.12±0.04	0.07±0.00	0.10±0.04	**0.13±0.03**
		F1↑	0.00±0.00	0.01±0.01	0.01±0.01	0.00±0.00	**0.03±0.01**	0.01±0.00	0.00±0.00
	NPP	ACC@1↑	0.03±0.00	0.05±0.01	0.03±0.00	0.05±0.02	0.08±0.01	**0.11±0.04**	0.10±0.03
		ACC@5↑	0.06±0.01	0.10±0.00	0.07±0.01	0.11±0.03	0.18±0.01	**0.18±0.05**	0.14±0.05
	TUL	ACC@1↑	0.26±0.06	0.31±0.01	0.27±0.06	0.27±0.08	0.40±0.01	0.40±0.05	**0.44±0.03**
		F1↑	0.11±0.04	0.17±0.01	0.14±0.01	0.16±0.01	0.18±0.01	0.18±0.07	**0.25±0.00**
San Francisco	POIC	ACC@1↑	0.06±0.03	0.01±0.00	0.06±0.01	**0.07±0.02**	0.04±0.01	0.06±0.02	0.06±0.01
		F1↑	0.00±0.00	0.01±0.01	0.00±0.00	0.00±0.00	**0.02±0.01**	0.01±0.01	0.00±0.00
	NPP	ACC@1↑	0.02±0.01	0.01±0.00	0.02±0.00	0.04±0.01	0.03±0.01	0.03±0.03	**0.06±0.00**
		ACC@5↑	0.06±0.01	0.06±0.01	0.06±0.01	0.10±0.01	0.06±0.01	0.06±0.06	**0.12±0.01**
	TUL	ACC@1↑	0.25±0.08	0.34±0.01	0.30±0.11	0.35±0.12	0.52±0.01	0.53±0.06	**0.61±0.01**
		F1↑	0.13±0.01	0.15±0.00	0.10±0.06	0.15±0.05	0.26±0.01	0.29±0.02	**0.32±0.01**
Per. Avg. Rank			5.8	5.7	4.5	4.2	3.0	2.9	**2.4**

实验结果

路段MapRL模型的实验结论：
全流水线模型的性能最佳：与使用部分流水线的模型相比，使用完整token-graph-sequence流水线的模型(如START)实现了最高的性能。

多个培训前任务可提高绩效。结合了基于序列的任务和基于图的任务的JCLRNT模型优于采用两个基于序列的任务（MTR和ATrCL）的START模型。表明，任务多样性越高，性能提升也越显著

Data	Task	Metric	RN2Vec	HRNR	SARN	Toast	HRoad	START	JCLRNT
Beijing	ASI	MAE↓	3.58±0.01	3.16±0.00	2.81±0.00	2.74±0.01	**2.71±0.01**	2.72±0.01	2.80±0.02
		RMSE↓	5.73±0.00	5.59±0.00	5.48±0.00	5.51±0.01	5.41±0.00	**5.39±0.00**	5.48±0.01
	TTE	MAE↓	661±14.0	631±19.3	596±20.8	533±33.0	585±16.3	**512±19.9**	514±38.3
		RMSE↓	2978±48	2968±42	2581±84	2576±79	2554±35	2502±37	**2464±36**
	STS	ACC@3↑	0.76±0.03	0.82±0.03	0.84±0.03	0.79±0.10	0.87±0.01	**0.90±0.03**	0.90±0.04
		MR↓	12.4±1.54	11.5±1.94	13.30±2.17	12.8±2.81	14.0±1.42	10.9±1.98	**10.4±1.15**
Chendu	ASI	MAE↓	6.57±0.06	6.42±0.04	5.99±0.02	6.36±0.03	**5.93±0.02**	6.05±0.01	6.35±0.08
		RMSE↓	14.0±0.07	13.7±0.07	13.3±0.04	13.3±0.16	**13.2±0.00**	13.5±0.01	13.5±0.13
	TTE	MAE↓	106±0.06	100±0.04	**88.3±4.27**	95.0±2.44	88.5±5.48	95.8±3.12	97.0±4.08
		RMSE↓	155±0.07	150±0.05	157±6.70	150±2.75	**137±5.67**	151±3.84	148±3.79
	STS	ACC@3↑	0.69±0.04	0.73±0.06	0.68±0.13	0.69±0.02	0.68±0.05	**0.76±0.03**	0.72±0.00
		MR↓	48.1±1.67	43.0±3.37	36.6±3.14	22.4±3.66	24.4±3.01	19.2±2.72	**18.7±2.53**
Xi'an	ASI	MAE↓	6.33±0.03	5.79±0.12	**5.36±0.03**	5.63±0.01	5.41±0.07	5.38±0.07	5.67±0.02
		RMSE↓	13.1±0.37	11.2±0.10	**10.6±0.01**	10.8±0.12	10.7±0.05	10.8±0.07	10.9±0.06
	TTE	MAE↓	137±6.67	134±5.09	110±4.26	122±4.52	110±3.68	115±15.4	**108±6.82**
		RMSE↓	199±8.23	203±11.9	**169±5.63**	191±3.62	172±8.94	170±13.9	178±8.34
	STS	ACC@3↑	0.71±0.01	0.74±0.04	0.72±0.07	**0.80±0.03**	0.73±0.01	0.75±0.04	0.77±0.02
		MR↓	12.9±1.71	12.1±1.48	12.5±3.62	16.5±4.28	19.0±2.95	**10.8±3.54**	11.9±3.15
Porto	ASI	MAE↓	4.39±0.00	4.40±0.00	4.29±0.00	4.36±0.01	**4.20±0.01**	4.21±0.00	4.35±0.05
		RMSE↓	7.90±0.00	**7.58±0.00**	7.78±0.00	7.93±0.05	7.71±0.01	7.79±0.04	7.79±0.05
	TTE	MAE↓	99.5±1.78	101±1.98	97.2±1.38	98.4±1.81	98.5±2.83	97.5±6.92	**96.8±1.30**
		RMSE↓	150±3.60	147±2.60	143±1.80	147±2.48	**140±2.22**	158±7.04	145±1.03
	STS	ACC@3↑	0.80±0.10	0.82±0.11	0.83±0.03	**0.90±0.06**	0.83±0.04	0.88±0.02	0.87±0.04
		MR↓	14.3±1.91	12.0±1.81	17.9±3.40	12.1±4.03	17.2±1.80	13.7±2.44	**11.4+3.38**
San Francisco	ASI	MAE↓	2.98±0.00	2.51±0.00	2.49±0.01	2.56±0.00	2.48±0.01	2.45±0.00	**2.42±0.01**
		RMSE↓	5.80±0.00	5.38±0.01	5.29±0.01	5.29±0.00	**5.25±0.00**	5.33±0.00	5.37±0.00
	TTE	MAE↓	289±1.02	288±1.01	279±3.21	274±9.01	270±7.61	**268±10.2**	275±9.30
		RMSE↓	1479±4.3	1449±4.4	1499±3.6	**1372±28**	1451±16	1497±38	1446±21
	STS	ACC@3↑	0.84±0.04	0.91±0.00	0.86±0.07	**0.94±0.04**	0.92±0.01	0.90±0.07	0.87±0.05
		MR↓	7.20±3.19	7.00±0.01	8.48±2.05	9.22±3.29	6.55±1.22	6.71±2.01	**6.49±1.63**
Per Avg Rank			6.3	4.9	3.9	3.9	3.2	2.9	**2.8**

实验结果

地块MapRL模型的实验结论：
整合POI数据可提高性能，利用POI数据的模型 其性能优于不使用POI数据的模型。这些模型将地块中的POI类别视为要素，丰富了地块功能特征的表示。这种方法提供了有价值的上下文信息，从而提高了模型的整体性能。

目前的局限：现有的地块MapRL模型大多采用基于令牌+基于图的编码结构，侧重于从关系网络中提取信息。然而，这些模型忽略了轨迹内的顺序依赖关系，限制了它们的有效性。

Table 5: Performance comparison of land parcel MapRL methods on various datasets.

Data	Task	Metric	ZEMob	GMEL	HDGE	MVURE	MGFN	ReMVC	HREP
Beijing	LPC	ACC@1↑	0.43±0.03	0.46±0.03	0.41±0.00	0.48±0.00	0.59±0.02	**0.75±0.02**	0.50±0.01
		F1↑	0.11±0.00	0.61±0.03	0.22±0.01	0.28±0.01	0.65±0.04	**0.71±0.02**	0.38±0.01
	FI	MAE↓	30.9±0.03	27.7±0.01	20.8±2.91	29.6±0.83	30.1±0.02	27.8±0.02	**20.6±0.33**
		RMSE↓	55.3±0.04	59.0±0.04	44.8±2.79	53.7±1.36	54.5±0.02	52.7±0.04	**42.6±0.86**
	MI	MAE↓	0.43±0.03	0.46±0.03	0.34±0.03	**0.27±0.01**	0.30±0.03	0.30±0.01	0.32±0.00
		RMSE↓	0.80±0.02	0.74±0.02	0.70±0.03	0.71±0.02	0.76±0.04	0.69±0.02	**0.66±0.01**
Chengdu	LPC	ACC@1↑	0.36±0.01	0.38±0.04	0.42±0.03	0.48±0.00	0.48±0.08	**0.66±0.03**	0.54±0.01
		F1↑	0.17±0.03	0.16±0.03	0.27±0.06	0.27±0.01	0.35±0.12	**0.59±0.03**	0.46±0.01
	FI	MAE↓	155±0.03	155±0.02	159±2.02	156±3.10	158±5.69	**148±0.02**	156±2.8
		RMSE↓	441±0.02	441±0.04	403±1.12	443±4.28	**337±24.4**	431±0.03	396±9.7
	MI	MAE↓	**3.64±0.03**	4.62±0.04	5.17±0.01	3.97±0.71	5.14±0.02	5.29±0.04	5.47±0.12
		RMSE↓	29.7±0.02	29.7±0.03	28.7±0.15	29.6±0.12	29.3±1.14	29.1±0.06	**28.3±0.07**
Xi'an	LPC	ACC@1↑	0.36±0.03	0.36±0.03	0.44±0.02	0.53±0.01	0.48±0.09	0.57±0.00	**0.59±0.01**
		F1↑	0.19±0.04	0.42±0.03	0.25±0.01	0.26±0.02	0.28±0.07	**0.46±0.03**	0.45±0.02
	FI	MAE↓	134±0.03	133±0.02	124±5.87	127±3.85	**119±9.30**	132±0.04	129±0.80
		RMSE↓	326±0.02	324±0.03	289±26.3	318±4.77	**241±28.4**	325±0.03	297±9.10
	MI	MAE↓	3.83±0.03	3.71±0.04	3.92±0.03	**3.33±0.35**	3.70±0.11	3.91±0.05	4.02±0.04
		RMSE↓	17.7±0.03	17.6±0.03	**16.6±0.14**	17.4±0.00	16.8±1.32	16.8±0.05	16.7±0.20
Porto	LPC	ACC@1↑	0.34±0.04	0.33±0.04	0.42±0.05	0.30±0.01	0.30±0.01	**0.44±0.03**	0.36±0.02
		F1↑	0.21±0.01	0.38±0.03	0.41±0.07	0.27±0.02	0.20±0.03	**0.41±0.04**	0.32±0.03
	FI	MAE↓	528±0.03	525±0.01	501±18.0	402±21.8	477±37.3	527±0.01	**289±12.1**
		RMSE↓	595±0.02	592±0.04	582±14.4	472±21.1	443±36.8	595±0.03	**355±27.3**
	MI	MAE↓	44.9±0.02	41.1±0.03	30.8±4.57	37.8±0.65	29.8±7.26	39.4±0.05	**28.3±5.30**
		RMSE↓	72.3±0.02	56.2±0.04	45.7±4.91	54.1±4.68	45.5±9.79	56.7±0.03	**42.2±8.93**
San Francisco	LPC	ACC@1↑	0.84±0.02	0.64±0.01	0.82±0.01	0.84±0.02	0.83±0.01	**0.86±0.03**	0.84±0.01
		F1↑	0.53±0.03	0.56±0.01	0.50±0.03	0.52±0.05	0.44±0.10	0.47±0.04	**0.57±0.03**
	FI	MAE↓	509±0.04	514±0.01	387±23.1	349±23.7	356±46	445±0.01	**324±25.8**
		RMSE↓	910±0.04	917±0.02	693±35.8	700±44.2	748±80	852±0.02	**624±31**
	MI	MAE↓	**5.88±0.03**	7.40±0.02	6.51±0.51	6.46±0.42	6.40±0.84	6.87±0.04	5.89±0.50
		RMSE↓	23.5±0.01	22.3±0.01	21.5±0.28	20.6±1.21	20.2±2.34	22.7±0.03	**19.1±1.51**
Per Avg Rank			5.67	5.10	4.00	3.73	3.53	3.50	**2.43**

MapRL模型的可扩展性分析

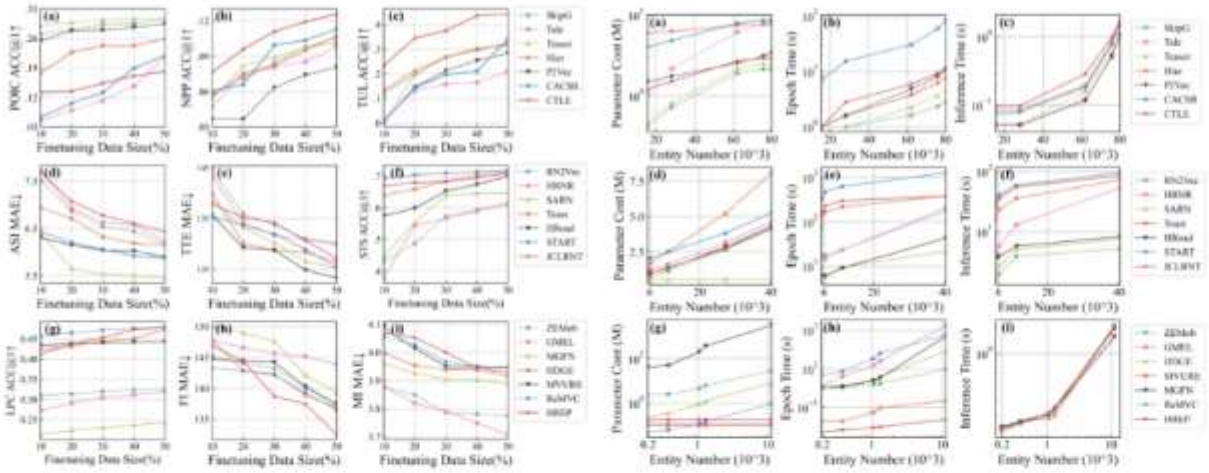

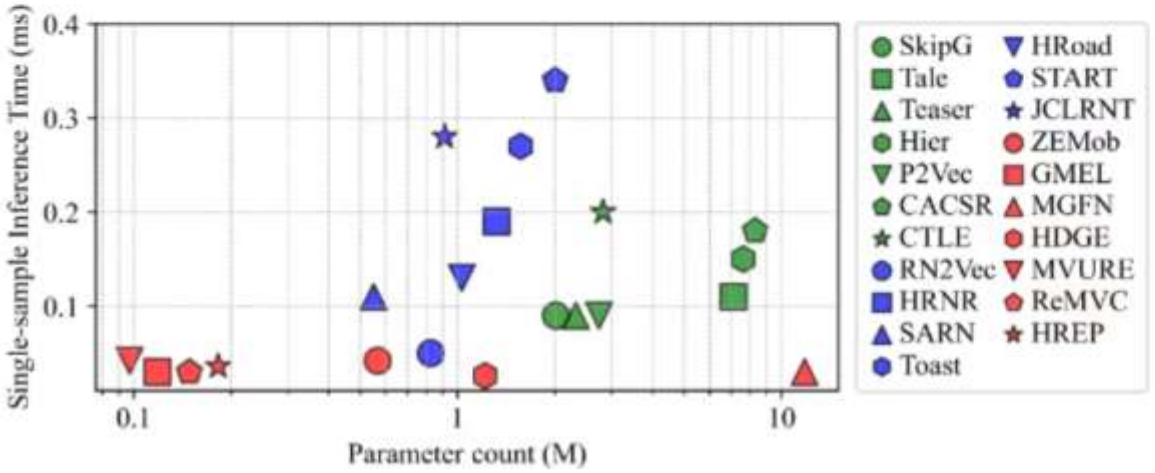

从有效性、效率以及模型大小和推理时间之间的权衡三个方面考虑。

基于令牌的模型：展现出了极佳的可扩展性。由于结构相对简单，它们在处理海量数据时，依然能保持较低的训练耗时和参数规模。

基于图的模型：效率高度依赖于预训练任务的复杂度。例如，采用图自编码器任务的模型，随着图节点数量的增加，其训练时间呈现出超线性增长的趋势，这在大规模路网中可能成为瓶颈。

相比之下，采用更高效采样策略或简化图结构的模型则表现出更强的鲁棒性。

基于序列的模型：引入序列编码器显著提升了模型在轨迹相关任务上的精度，但是基于序列的模型普遍面临参数量激增和推理延迟的问题。特别是在线推理阶段，复杂的序列计算使得其响应速度远低于其他两类模型。因此，它们更适合对精度敏感但对延时容忍度较高的离线分析场景。

深入研究预训练任务的组合效应

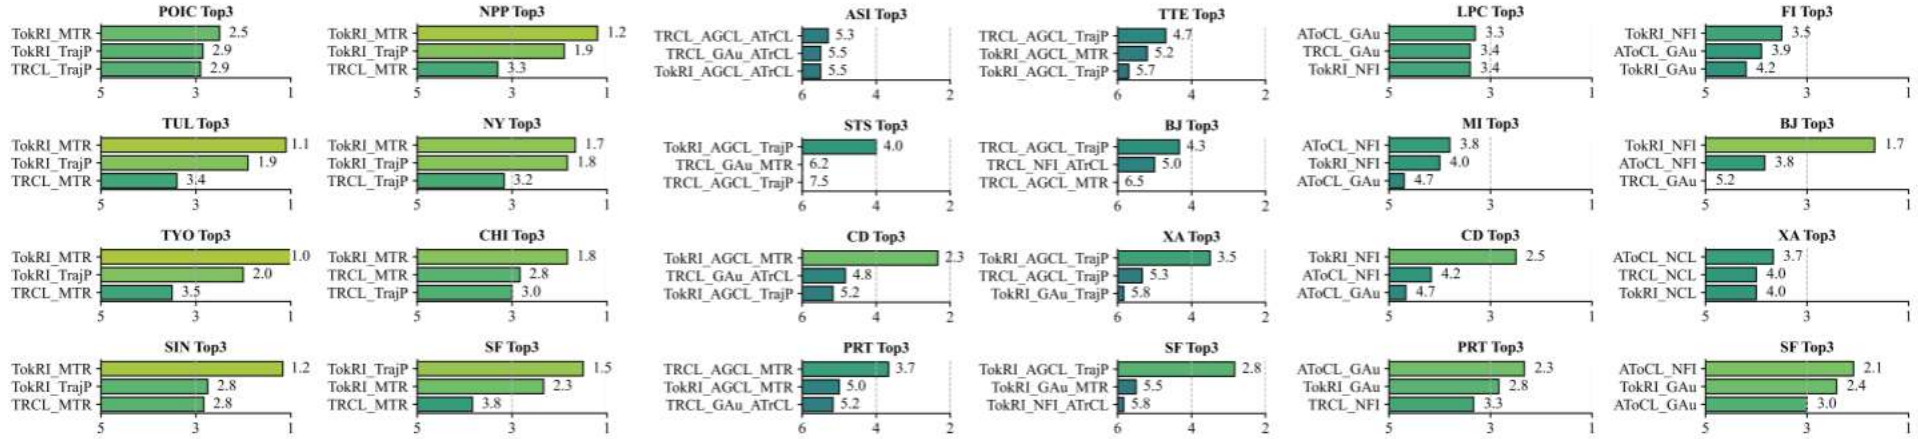

(a) Top 3 combinations for POI map entity. (b) Top 3 combinations for segment map entity. (c) Top 3 combinations for parcel map entity.

在前面的实验中已知利用多个预训练任务可以提高MapRL模型的性能。此任务的目标为确定MapRL的最佳预训练任务组合。通过组合不同类别的预训练任务来构造候选组合集。

结论：

对于POI实体：TokRI+MTR始终排名最高，TokRI 专注于捕捉显式的类别与属性语义，而 MTR 通过对轨迹序列的掩码重建，有效捕捉了长距离的时序依赖，两者形成了良好的互补。在数据稀疏的场景下，轨迹预测任务因其更关注局部时序依赖，表现出更强的鲁棒性。

对于路段实体：AGCL在所有场景中都优于其他方案，它有效地捕获了地理关系网络中的重要空间依赖关系，这对路段建模至关重要。

对于地块实体：AToCL实现了最佳性能，其增强技术增强了模型在过滤噪声的同时捕获关键语义特征的能力。

深入研究预训练任务的组合效应

预训练任务的结论：

对于基于令牌的编码器：对语义特征进行编码是基于令牌的编码器的一项关键功能。TokRI非常适合于结构化分类属性，而AToCL的基于扩充的对比学习更好地处理高维和冗余的语义特征，使其对地块尤为有效。

基于图形的编码器：AGCL非常适合于地理关系网络，因为它有效地捕获了关键的空间依赖关系。相比之下，GAU和NFI在社会关系网络中的表现更好，它们能够对相似性驱动的连接性进行建模。

基于序列的编码器：MTR擅长捕获长范围的序列依赖，是基于序列的任务的最佳选择，但它需要密集的数据才能有效。相比之下，TrajP在稀疏数据场景下更可靠。

北京工業大學

谢 谢！