Qwen3-ASR Technical Report

2026/03/01

I Introduction

I Introduction

范式转变：E2E → LALM

- 自底向上的声学匹配➡利用LLM的语言建模能力和世界知识，对音频信号形成高层次理解，基于理解再转录
- 优势：天然解决长音频、噪声鲁棒性、命名实体识别、多语言和方言覆盖等传统难题

时间戳预测需求：

- 实际部署（如字幕生成）常需转录结果附带时间戳
- 传统方法：CTC/CIF等后处理方式获取时间戳
- LALM方法可在任意粒度上提供更准确、更快速的时间戳预测

本文贡献：

- 实现业界领先（SOTA）的端到端 ASR 和 LID 性能
- 提出首个基于 LLM 的语音强制对齐架构，Qwen3 - ForcedAligner - 0.6B
- 全面开源模型与完整工具链

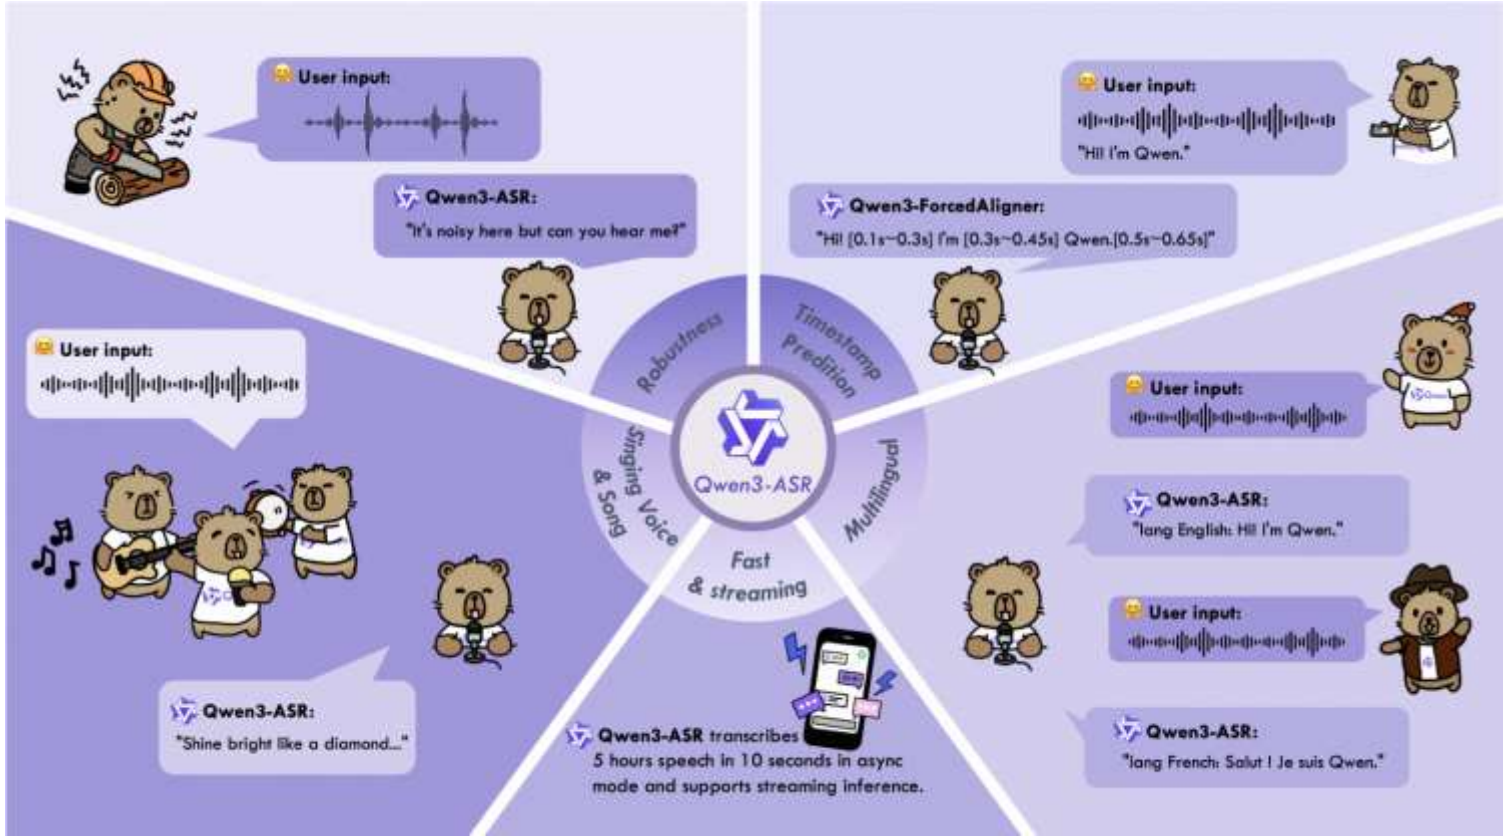

Qwen3-ASR系列：一体化ASR模型，多语言语音强制对齐模型

II Qwen3-ASR

II Qwen3-ASR 模型架构

基础模型：构建于具备强大音频理解能力的 Qwen3-Omni 基础之上。

AuT 编码器 (Audio Transformer)：

- 采用 Attention-Encoder-Decoder (AED) 架构，独立于 Qwen3-Omni 进行预训练。
- 将 128 维的 Fbank 特征进行 8 倍下采样，生成 12.5Hz 的音频 token 序列。
- 动态注意力窗口：采用 1秒至 8 秒的动态 Flash Attention 窗口，使其既能处理短切片的流式推理（Streaming），又能处理长音频的离线推理（Offline）。

模型规格：

- 1.7B 版本：300M AuT 编码器 + Projector + Qwen3-1.7B 语言模型。
- 0.6B 版本：180M AuT 编码器 + Projector + Qwen3-0.6B 语言模型。

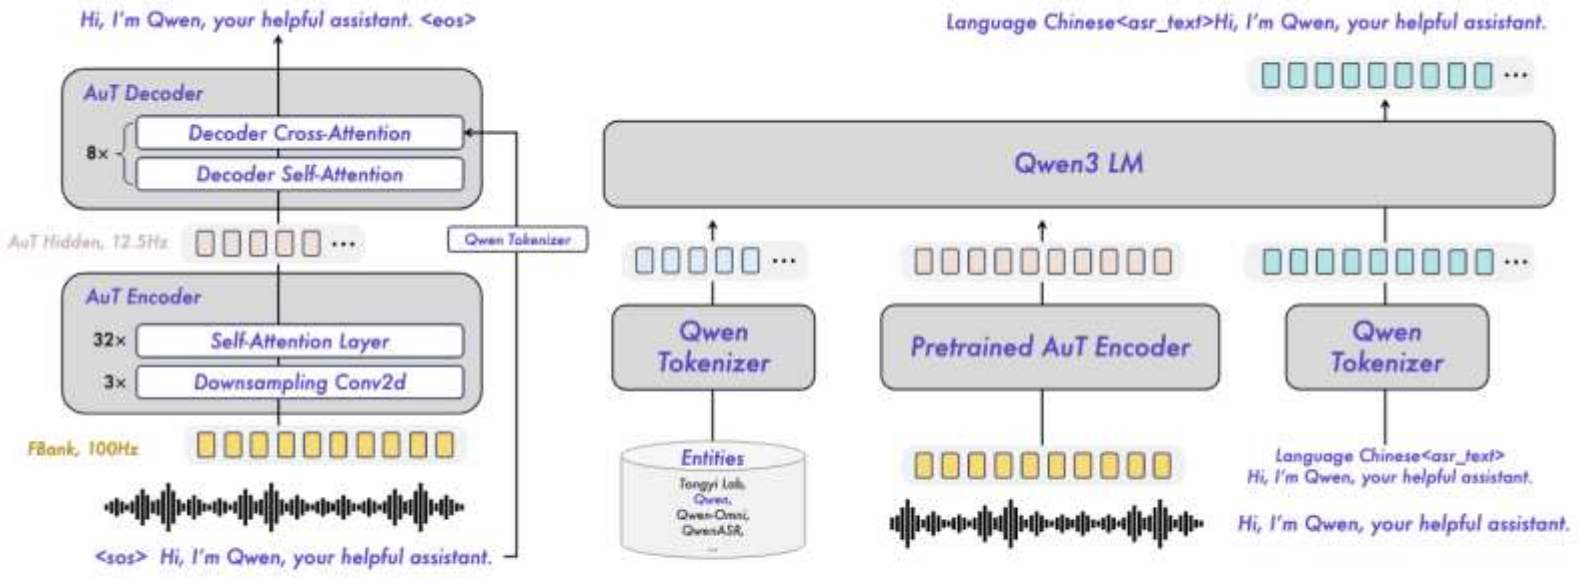

Figure 2: Architecture of AuT (left) and the overview of Qwen3-ASR (right).

II Qwen3-ASR 训练策略

AuT 预训练：使用约 4000 万小时的伪标签 ASR 数据（以中英文为主），训练出一个能提供稳定音频表征的编码器。

Omni 多模态预训练：利用多任务音、视、文数据（高达 3 万亿 token）对大语言模型进行预训练，赋予其多模态理解能力。

ASR 监督微调：使用全新的多语种高质量数据，使模型适应 ASR 专属的输入输出格式（带明确的 <asr_text> 标签）。在此阶段还加入了非语音数据、流式增强数据和上下文偏置数据，使其专职于 ASR 任务，防止被不相干的自然语言指令干扰。

强化学习：使用群组序列策略优化（GSPO），利用约 5 万条复杂环境和功能性数据进行 RL 训练。显著提升了模型在

Qwen3-ASR output style

Output style 1: For recognizable speech
<|im_start|>assistant
language English<asr_text>Today we release models including Qwen3-ASR-1.7B.<|im_end|>

Output style 2: For no speech detected
<|im_start|>assistant
language None<asr_text><|im_end|>

II Qwen3-ASR 的核心特性

精准的中英双语ASR：在中英文多个基准测试中领先开源同行。

超强多语种与方言覆盖：完美支持 30 种国家/地区语言，以及 22 种汉语方言（包括粤语、吴语、闽南语、东北话、四川话等）。

超长音频与流式推理：单次推理原生支持长达 20 分钟的音频；统一了离线批处理与在线流式识别框架。

歌声与伴奏歌曲识别：不仅能识别清唱，还能直接转录带有复杂背景音乐（BGM）的完整流行歌曲，具有极强的抗干扰能力。

Model	Supported Languages	Supported Dialects	Inference Mode	Seq. Len.	Audio Types
Qwen3-ASR-1.7B & Qwen3-ASR-0.6B	Chinese (zh), English (en), Cantonese (yue), Arabic (ar), German (de), French (fr), Spanish (es), Portuguese (pt), Indonesian (id), Italian (it), Korean (ko), Russian (ru), Thai (th), Vietnamese (vi), Japanese (ja), Turkish (tr), Hindi (hi), Malay (ms), Dutch (nl), Swedish (sv), Danish (da), Finnish (fi), Polish (pl), Czech (cs), Filipino (fil), Persian (fa), Greek (el), Hungarian (hu), Macedonian (mk), Romanian (ro)	Anhui, Dongbei, Fujian, Gansu, Guizhou, Hebei, Henan, Hubei, Hunan, Jiangxi, Ningxia, Shandong, Shaanxi, Shanxi, Sichuan, Tianjin, Yunnan, Zhejiang. Cantonese (Hong Kong accent), Cantonese (Guangdong accent), Wu language, Minnan language.	Offline / Streaming	1200s	Speech, Singing Voice, Songs with BGM
Qwen3-ForcedAligner-0.6B	Chinese, English, Cantonese, French, German, Italian, Japanese, Korean, Portuguese, Russian, Spanish	–	NAR	300s	Speech

II Qwen3-ASR 的推理效率

测试环境：基于 vLLM 框架（v0.14.0），支持离线批量生成和在线异步并发。启用 CUDA Graph ，推理精度：bfloat16

Qwen3-ASR-0.6B 的效率：

- 首字延迟（TTFT）：在异步在线模式下，平均 TTFT 低至 92 毫秒。
- 超高吞吐量：在 128 并发下，实时率（RTF：处理时间与音频实际时长的比值）最低 0.064。吞吐量最高 2000（即 1 秒钟能够处理 2000 秒时长的语音）。

Qwen3-ASR-1.7B 的表现：同样在 128 并发下实现约 0.10～0.13 的实时率，兼顾了高准确度与出色的工业级吞吐。

Model		Offline		Online async			
	Conc.	RTF	Throughput	TTFT avg. (ms)	TTFT p95 (ms)	RTF	Throughput
Qwen3-ASR-0.6B	1	0.00923	108.34	92	105	0.00940	106.38
	2	0.01124	177.94	103	168	0.01108	180.51
	4	0.01284	311.53	132	203	0.01224	326.80
	8	0.01600	500.00	228	417	0.01472	543.48
	16	0.02384	671.14	459	882	0.01936	826.45
	32	0.03808	840.34	820	1575	0.02912	1098.90
	64	0.06336	1010.10	1631	3196	0.04352	1470.59
	128	0.11264	1136.36	3210	6195	0.06400	2000.00
	256	0.21504	1190.48	-	-	-	-
	512	0.44544	1149.43	-	-	-	-
Qwen3-ASR-1.7B	1	0.01482	67.48	102	113	0.01483	67.43
	2	0.01540	129.87	117	170	0.01530	130.72
	4	0.01712	233.64	135	192	0.01688	236.97
	8	0.02072	386.10	224	382	0.02000	400.00
	16	0.02896	552.49	443	791	0.02640	606.06
	32	0.04608	694.44	847	1570	0.03968	806.45
	64	0.07360	869.57	1597	2942	0.06208	1030.93
	128	0.13056	980.39	3392	6227	0.10496	1219.51
	256	0.24320	1052.63	-	-	-	-
	512	0.50176	1020.41	-	-	-	-
Qwen3-ForcedAligner-0.6B	1	0.00889	112.49	-	-	-	-
	2	0.00232	862.07	-	-	-	-
	4	0.00432	925.93	-	-	-	-
	8	0.00832	961.54	-	-	-	-
	16	0.01696	943.40	-	-	-	-
	32	0.03584	892.86	-	-	-	-
	64	0.08192	781.25	-	-	-	-
	128	0.19712	649.35	-	-	-	-

III Qwen3-ForcedAligner

III Qwen3-ForcedAligner 简介

任务：根据相应的转录文本,估计语音中每个单词或字符的起始和结束时间戳。强制对齐任务➡“槽位填充”任务。给定一段语音和带有特殊 token [time]（代表时间戳槽位）的文本，模型直接预测每个槽位对应的离散时间戳索引。

核心贡献与亮点：

- 精确的时间戳预测：在人工标注的测试集上，相比其他强制对齐方法（如 MFA、NFA），其累积平均偏移量（AAS）大幅降低了 67%~77%。
- 应用场景广泛：单模型原生支持 11 种语言，支持长达 300 秒的语音片段，甚至支持跨语种（代码混杂）场景。用户可以灵活地自定义预测任意单词或字符级别的时间戳。
- 推理速度快：摒弃了大模型常用的“下一个词预测（Next-token prediction）”范式，采用非自回归（NAR）推理，极大提升了预测速度。

III Qwen3-ForcedAligner 模型设计

音频处理：使用预训练的 AuT 编码器处理输入语音，提取帧级别的语音嵌入。每帧的时长为 80 毫秒。

文本格式化与离散化：

- 在转录文本的每个单词或字符前后添加起始/结束时间戳标签，随后替换为特殊的 [time] token 并输入分词器。
- 真实的时间戳被离散化：将具体的时间值除以 80ms，转化为离散的索引。

跨语言联合建模：

- 语音和文本嵌入序列共同输入 Qwen3-0.6B LLM，最后通过一个线性层输出全序列的时间戳索引预测。
- 优势：多语种通用

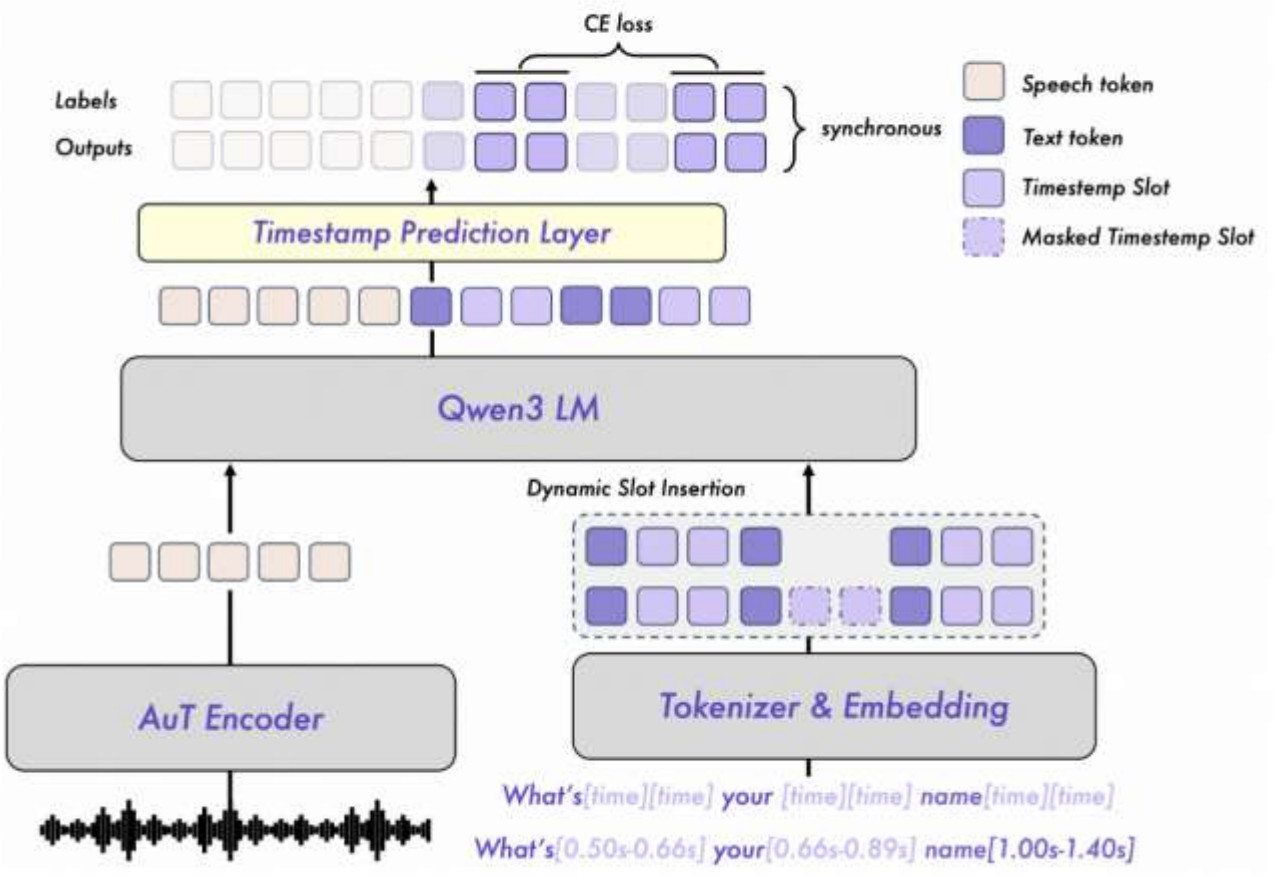

III Qwen3-ForcedAligner 训练与推理

高效的训练策略：

伪标签降噪蒸馏：人工精标成本极高➡ MFA（蒙特利尔强制对齐）生成伪标签➡进行平滑与蒸馏处理➡比原始 MFA 更稳定、精确的结果。

无偏移因果训练：采用输出与标签非错位对齐，让模型能显式识别时间戳插槽并填入准确的索引位置；仅在 [time] 槽位处计算 Loss，使模型100%聚焦于时间戳预测。

动态槽位插入：训练时随机决定是否插入槽位，大幅提升模型应对复杂文本的泛化能力。

灵活且极速的推理：

灵活易用：用户在推理时可在文本中任意单词或字符前后插入时间戳槽位，模型均能自动对齐。

非自回归 (NAR) 同步解码：无需像传统大模型那样逐字生成。能同时预测所有槽位的离散索引（计算极简：实际时间 = 预测索引 × 80 毫秒）

高吞吐量：实时率（RTF）低至接近 0.001

Model		Offline		Online async			
	Conc.	RTF	Throughput	TTFT avg. (ms)	TTFT p95 (ms)	RTF	Throughput
Qwen3-ForcedAligner-0.6B	1	0.00889	112.49	-	-	-	-
	2	0.00232	862.07	-	-	-	-
	4	0.00432	925.93	-	-	-	-
	8	0.00832	961.54	-	-	-	-
	16	0.01696	943.40	-	-	-	-
	32	0.03584	892.86	-	-	-	-
	64	0.08192	781.25	-	-	-	-
	128	0.19712	649.35	-	-	-	-

IV Experiments

IV 实验评估指标和对象

对比基线模型：

- 闭源商业 API：GPT-4o-Transcribe, Gemini-2.5-Pro, Doubao-ASR。
- 开源标杆模型：Whisper-large-v3, FunASR-MLT-Nano, GLM-ASR-Nano。

四大评估基准：

- 公共测试集：涵盖英文、标准普通话及多种中文方言。
- 内部鲁棒性测试集：涵盖16种英语口音、22种中文方言、极低信噪比、老人与儿童语音、绕口令以及多人汉语对话等复杂场景。
- 多语言测试集：覆盖 30 种语言，包括 Common Voice, Fleurs, MLS 等。
- 歌唱与音乐识别： 测试清唱以及带背景音乐（BGM）的长音频歌曲识别。

核心评估指标：

- 识别准确率：词错误率（针对英文的WER）/ 字符错误率（针对中文的CER）—— 越低越好。
- 语种识别：语种识别准确率（LID Accuracy）—— 越高越好。
- 时间戳精度：累积平均偏移量AAS—— 越低越好。

  评估数据集中所有时间戳槽的预测时间戳和参考时间戳之间的平均绝对差： $\mathrm{AAS} = \frac{1}{N}\sum_{i=1}^{N}|\hat{n}_i - n_i|$

IV 实验数据集

数据集分类	数据集名称	语言 / 领域	数据集简介
英文开源基准	LibriSpeech (clean/other)	英语	业界经典的英文有声读物语音识别基准，分清晰/带噪两部分。
	GigaSpeech	英语	源于播客、有声读物和 YouTube 的大规模多领域英文语音集。
	Common Voice (CV-en)	英语	Mozilla 发起的全球众包语音数据集，含丰富的口音和音色。
	Fleurs-en / MLS-en	英语	Fleurs 英文平行语料集，以及基于多语种有声读物的 MLS 英文集。
	TED-LIUM / VoxPopuli	英语	TED 演讲音频数据集及欧洲议会多语种演讲英文子集。
中文开源基准	WenetSpeech (net/meeting)	中文普通话	超万小时规模中文语音集，涵盖网络视频、会议等真实场景。
	AISHELL-2	中文普通话	高质量中文语音交互测试基准。
	SpeechIO	中文普通话	针对复杂声学环境和口音的中文评测基准。
	Fleurs-zh / CV-zh	中文普通话	Fleurs 及 Common Voice 的中文普通话子集。
中文方言及口音	WenetSpeech-Yue / Chuan	粤语 / 四川话	方言扩展集，含长短句粤语及不同难度的四川话。
	KeSpeech	中文多种方言	包含多种方言及浓厚地方口音的普通话数据集。
	CV-yue / Fleurs-yue	粤语	常见开源语料库中的粤语测试子集。
	CV-zh-tw	繁体中文(台湾)	台湾口音的普通话子集。
内部鲁棒性测试	Internal Robustness Suite	英语 / 中文方言	官方内部极限测试集（带口音、老年人、强噪声、22种方言混合等）。
歌声与歌曲识别	M4Singer / MIR-1k-vocal / Opencpop / PopCS	中文演唱	高质量中文流行歌曲演唱及歌声识别开源数据集（无伴奏）。
	EntireSongs (en/zh)	完整歌曲(中/英)	含背景音乐(BGM)的完整歌曲测试集，验证对伴奏的抗干扰性。

IV 中英文语音识别表现

公共基准测试：

英文： 在真实世界数据上表现优异，在 LibriSpeech 等学术集上逼近 SOTA。

中文普通话： 优势明显，在复杂会议场景数据集 WenetSpeech 上大幅超越所有基线。

中文方言： 无需特定定制，在发音差异极大的粤语（含长音频测试）中保持极高准确度

内部鲁棒性测试：

口音与方言混合： 在 16 种英语口音、粤语以及混合 22 种中文方言对话的数据集测试中，取得最低错误率。

复杂声学挑战： 面对老人儿童语音、高噪音、绕口令、以及多人对话等高难度场景，Qwen3-ASR-1.7B 展现出较强的鲁棒性。

	GPT-4o -Transcribe	Gemini-2.5 -Pro	Doubao-ASR	Whisper -large-v3	Fun-ASR -MLT-Nano	Qwen3-ASR -0.6B	Qwen3-ASR -1.7B
English (en)							
LibriSpeech *clean | other*	**1.39** | 3.75	2.89 | 3.56	2.78 | 5.70	1.51 | 3.97	1.68 | 4.03	2.11 | 4.55	1.63 | **3.38**
GigaSpeech	25.50	9.37	9.55	9.76	-	**8.88**	**8.45**
CV-en	9.08	14.49	13.78	9.90	9.90	9.92	**7.39**
Fleurs-en	**2.40**	2.94	6.31	4.08	5.49	4.39	3.35
MLS-en	5.12	**3.68**	7.09	4.87	-	6.00	4.58
Tedlium	7.69	6.15	4.91	6.84	-	**3.85**	**4.50**
VoxPopuli	10.29	11.36	12.12	12.05	-	**9.96**	**9.15**
Chinese (zh)							
WenetSpeech *net | meeting*	15.30 | 32.27	14.43 | 13.47	N/A	9.86 | 19.11	6.35 | -	**5.97** | **6.88**	**4.97** | **5.88**
AISHELL-2-test	4.24	11.62	2.85	5.06	-	3.15	**2.71**
SpeechIO	12.86	5.30	2.93	7.56	-	3.44	**2.88**
Fleurs-zh	2.44	2.71	2.69	4.09	3.51	2.88	**2.41**
CV-zh	6.32	7.70	5.95	12.91	6.20	6.89	**5.35**
Chinese Dialect							
KeSpeech	26.87	24.71	5.27	28.79	-	7.08	**5.10**
Fleurs-yue	4.98	9.43	4.98	9.18	-	5.79	**3.98**
CV-yue	11.36	18.76	13.20	16.23	-	9.50	**7.57**
CV-zh-tw	6.32	7.31	4.06	7.84	-	5.59	**3.77**
WenetSpeech-Yue *short | long*	15.62 | 25.29	25.19 | 11.23	9.74 | 11.40	32.26 | 46.64	- | -	7.54 | 9.92	**5.82** | **8.85**
WenetSpeech-Chuan *easy | hard*	34.81 | 53.98	43.79 | 67.30	**11.40** | **20.20**	14.35 | 26.80	- | -	13.92 | 24.45	11.99 | 21.63

	GPT-4o -Transcribe	Gemini-2.5 -Pro	Doubao-ASR	Whisper -large-v3	Fun-ASR -MLT-Nano	Qwen3-ASR -0.6B	Qwen3-ASR -1.7B
Accented English							
Dialog-Accented English	28.56	23.85	20.41	21.30	19.96	**16.62**	**16.07**
Chinese Mandarin							
Elders&Kids	14.27	36.93	4.17	10.61	4.54	4.48	**3.81**
ExtremeNoise	36.11	29.06	17.04	63.17	36.55	17.88	**16.17**
TongueTwister	20.87	4.97	3.47	16.63	9.02	4.06	**2.44**
Dialog-Mandarin	20.73	12.50	6.61	14.01	7.32	7.06	**6.54**
Chinese Dialect							
Dialog-Cantonese	16.05	14.98	7.56	31.04	5.85	**4.80**	**4.12**
Dialog-Chinese Dialects	45.37	47.70	19.85	44.55	19.41	**18.24**	**15.94**

IV 多语言 ASR 识别和语种识别能力

多语言 ASR 表现：

在 MLS、Common Voice 和 MLC-SLM 测试集上，Qwen3-ASR-1.7B 稳定超越 Whisper-large-v3。

在内部的“多语言新闻基准”（News-Multilingual）测试中取得最佳综合表现，证明其强大的泛化能力。

语种识别精度：

机制： 通过自然语言提示（Prompt）机制，在语音解码前精准识别语种。

精度： 在四大测试集上全面超越内置语种识别功能的 Whisper。Qwen3-ASR-1.7B 的平均语种识别准确率达 97.9%（对比 Whisper 为 94.1%）。

	GLM-ASR -Nano-2512	Whisper -large-v3	Fun-ASR -MLT-Nano	Qwen3-ASR -0.6B	Qwen3-ASR -1.7B
Open-sourced Benchmarks					
MLS	13.32	8.62	28.70	13.19	**8.55**
CommonVoice	19.40	10.77	17.25	12.75	**9.18**
MLC-SLM	34.93	15.68	29.94	15.84	**12.74**
Fleurs	16.08	5.27	10.03	7.57	**4.90**
Fleurs†	20.05	6.85	31.89	10.37	**6.62**
Fleurs††	24.83	**8.16**	47.84	21.80	12.60
Qwen-ASR Internal Benchmarks					
News-Multilingual	49.40	14.80	65.07	17.39	**12.80**

Language coverage: *MLS* includes 8 languages: {da, de, en, es, fr, it, pl, pt}.
CommonVoice includes 13 languages: {en, zh, yue, zh_TW, ar, de, es, fr, it, ja, ko, pt, ru}.
MLC-SLM includes 11 languages: {en, fr, de, it, pt, es, ja, ko, ru, th, vi}.
Fleurs includes 12 languages: {en, zh, yue, ar, de, es, fr, it, ja, ko, pt, ru }.
Fleurs† includes 8 additional languages beyond *Fleurs*: {hi, id, ms, nl, pl, th, tr, vi}.
Fleurs†† includes 10 additional languages beyond *Fleurs*†: {cs, da, el, fa, fi, fil, hu, mk, ro, sv}.
News-Multilingual includes 15 languages: {ar, de, es, fr, hi, id, it, ja, ko, nl, pl, pt, ru, th, vi}.

Table 6: **Language identification accuracy (%) ↑ on open-source multilingual test sets.**

	Whisper-large-v3	Qwen3-ASR-0.6B	Qwen3-ASR-1.7B
MLS	**99.9**	99.3	**99.9**
CommonVoice	92.7	**98.2**	**98.7**
MLC-SLM	89.2	**92.7**	**94.1**
Fleurs	94.6	**97.1**	**98.7**
Avg.	94.1	**96.8**	**97.9**

IV 歌曲识别和流式语音识别能力

歌唱与带 BGM 歌曲的精准转录：

面对完整的带背景音乐（BGM）歌曲，Whisper 和 FunASR 基本失效（结果为 N/A），Qwen3-ASR 在中文歌曲数据集上表现优秀：错误率仅 13.91%，填补了常规 ASR 与复杂音乐转录间的技术鸿沟

流式推理表现：

流式模式下虽有微小波动，但依然保持了极高的识别精度（例如 LibriSpeech-clean：离线 1.63 vs 流式 1.95），完全满足高可用实时场景。

	GPT-4o -Transcribe	Gemini-2.5 -Pro	Doubao-ASR -1.0	Whisper -large-v3	Fun-ASR-MLT -Nano	Qwen3-ASR -1.7B
Singing						
M4Singer	16.77	20.88	7.88	13.58	7.29	**5.98**
MIR-1k-vocal	11.87	9.85	6.56	11.71	8.17	**6.25**
Opencpop	7.93	6.49	3.80	9.52	**2.98**	3.08
Popcs	32.84	15.13	8.97	13.77	9.42	**8.52**
Songs with BGM						
EntireSongs-en	30.71	**12.18**	33.51	N/A	N/A	14.60
EntireSongs-zh	34.86	18.68	23.99	N/A	N/A	**13.91**

Model	Infer. Mode	Librispeech	Fleurs-en	Fleurs-zh	Avg.
Qwen3-ASR-1.7B	Offline	1.63 | 3.38	3.35	2.41	2.69
	Streaming	1.95 | 4.51	4.02	2.84	3.33
Qwen3-ASR-0.6B	Offline	2.11 | 4.55	4.39	2.88	3.48
	Streaming	2.54 | 6.27	5.38	3.40	4.40

IV 时间戳对齐精度测试

精度显著提高(AAS 偏移量极低):

在人工标注测试集上，Qwen3 相比传统强制对齐方法，平均时间偏移量相对降低了 67% ~ 77%。

超长音频稳定:

基准模型面对长音频时，时间戳误差显著增大（偏移量最高达数千毫秒）

Qwen3 即使在长达 300秒的拼接音频上，时间戳误差依然稳定保持在较低水平

	Monotonic-Aligner	NFA	WhisperX	Qwen3-ForcedAligner-0.6B
MFA-Labeled Raw				
Chinese	161.1	109.8	-	**33.1**
English	-	107.5	92.1	**37.5**
French	-	100.7	145.3	**41.7**
German	-	122.7	165.1	**46.5**
Italian	-	142.7	155.5	**75.5**
Japanese	-	-	-	**42.4**
Korean	-	-	-	**37.2**
Portuguese	-	-	-	**38.4**
Russian	-	200.7	-	**40.2**
Spanish	-	124.7	108.0	**36.8**
Avg.	161.1	129.8	133.2	**42.9**
MFA-Labeled Concat-300s				
Chinese	1742.4	235.0	-	**36.5**
English	-	226.7	227.2	**58.6**
French	-	230.6	2052.2	**53.4**
German	-	220.3	993.4	**62.4**
Italian	-	290.5	5719.4	**81.6**
Japanese	-	-	-	**81.3**
Korean	-	-	-	**42.2**
Portuguese	-	-	-	**50.0**
Russian	-	283.3	-	**43.0**
Spanish	-	240.2	4549.9	**39.6**
Cross-lingual	-	-	-	**34.2**
Avg.	1742.4	246.7	2708.4	**52.9**
Human-Labeled				
Raw	49.9	88.6	-	**27.8**
Raw-Noisy	53.3	89.5	-	**41.8**
Concat-60s	51.1	86.7	-	**25.3**
Concat-300s	410.8	140.0	-	**24.8**
Concat-Cross-lingual	-	-	-	**42.5**
Avg.	141.3	101.2	-	**32.4**

V 总结

主要介绍开源了 Qwen3-ASR系列模型，包括两个自动语音识别（ASR）系统和一个在大规模语音语料库上训练的强制对齐（FA）模型，均基于大规模语音语料库进行训练。在复杂的声学条件下表现出稳健的性能,对口音和方言具有良好的适应性,并且在歌声和其他真实语音场景中也保持了有效性

- **技术突破：**Qwen3-ASR 家族结合了强大的音频理解底座（Qwen3-Omni）与四阶段精细化训练（融入RL），实现了同级别或更大规模开源模型中最好的 SOTA 表现。
- **鲁棒性：**从 30 种语言到 22 种方言，从极具挑战的极限噪音到长音频和流行歌曲转录，提供全场景覆盖能力。
- **时间戳对齐：**通过提出 Qwen3-ForcedAligner-0.6B，打破了以往时间戳对齐模型依赖特定语种且速度慢的局限，提供了一个端到端 5 分钟内极速处理的统一多语种方案。
- **开源：**权重模型、微调代码及统一的用户友好推理框架均采用 Apache 2.0 协议开源，极大降低了学术界和工业界在高级音频处理领域的准入门槛。

谢 谢！