Clip

(contrastive language-image pre-training)

基于对比学习的多模态预训练模型

背景介绍 --- OpenAI在2021年提出

传统的计算机视觉模型（ImageNet 训练的分类器）只能对固定的类别进行分类，依赖昂贵的人工标注，泛化能力差
视觉和语言“各自为政”，无法跨模态理解

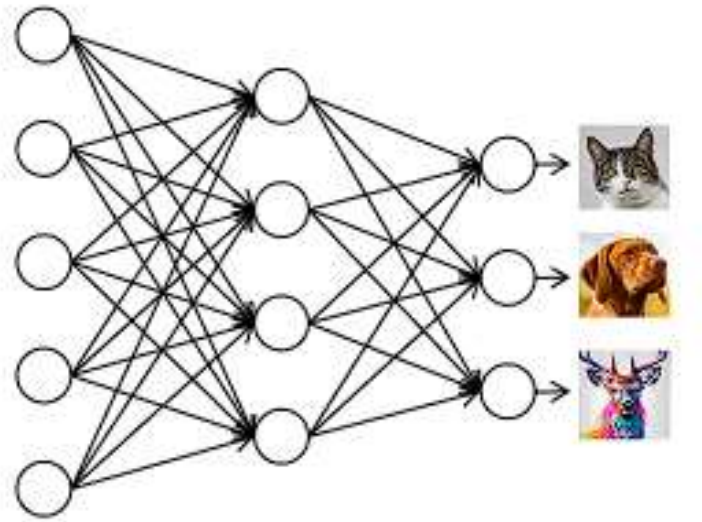

一条黑色的狗

一只白色的猫

Learning directly from rawtext about images is a promising alternative whichleverages a much broader source of supervision.
直接从原始文本中学习图像信息是一种具有前景的替代方案

从自然语言文本中学习图片中的信息，实现 “看图说文本、看文本找图片” 的跨模态匹配，并且摆脱对人工标注的依赖，实现自发的学习
一张图是否匹配一段文字

核心思想-对比学习，从分类到图文匹配

数据-收集4亿个文本图片对

训练目标： 不再预测图片属于哪个固定类别，而是预测一段文本是否是这张图片的正确描述，实现了“零样本迁移”，即无需针对特定任务微调即可识别新物体。

为什么用对比学习

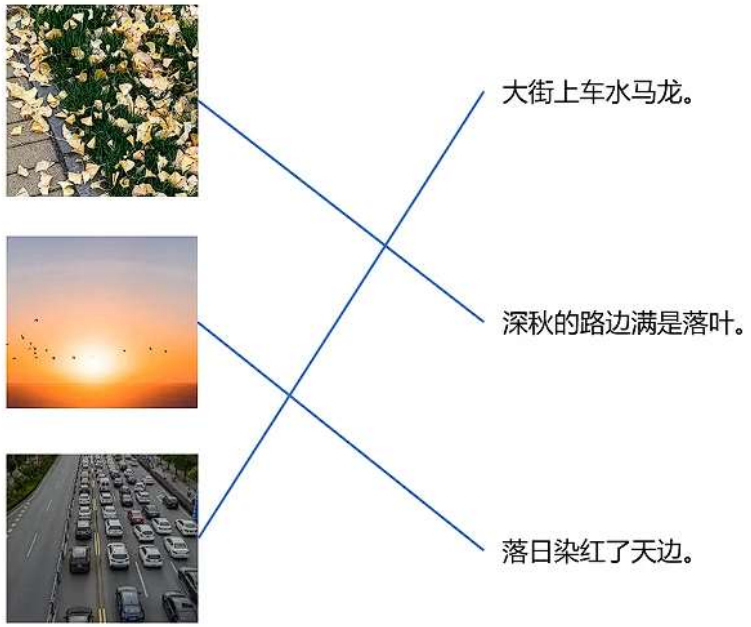

模型训练

双编码器结构

- 图像编码器：处理图片，主要是ResNet和ViT
- 文本编码器：处理文字，Transformer架构

两者输出统一维度的特征向量。

统一空间

两个编码器将图片和文本映射到同一嵌入空间。矩阵中的每一个元素都是图像和文本特征向量的余弦相似度，在这个空间里，匹配的图文向量距离近，不匹配的远。对角线余弦相似度尽可能最大

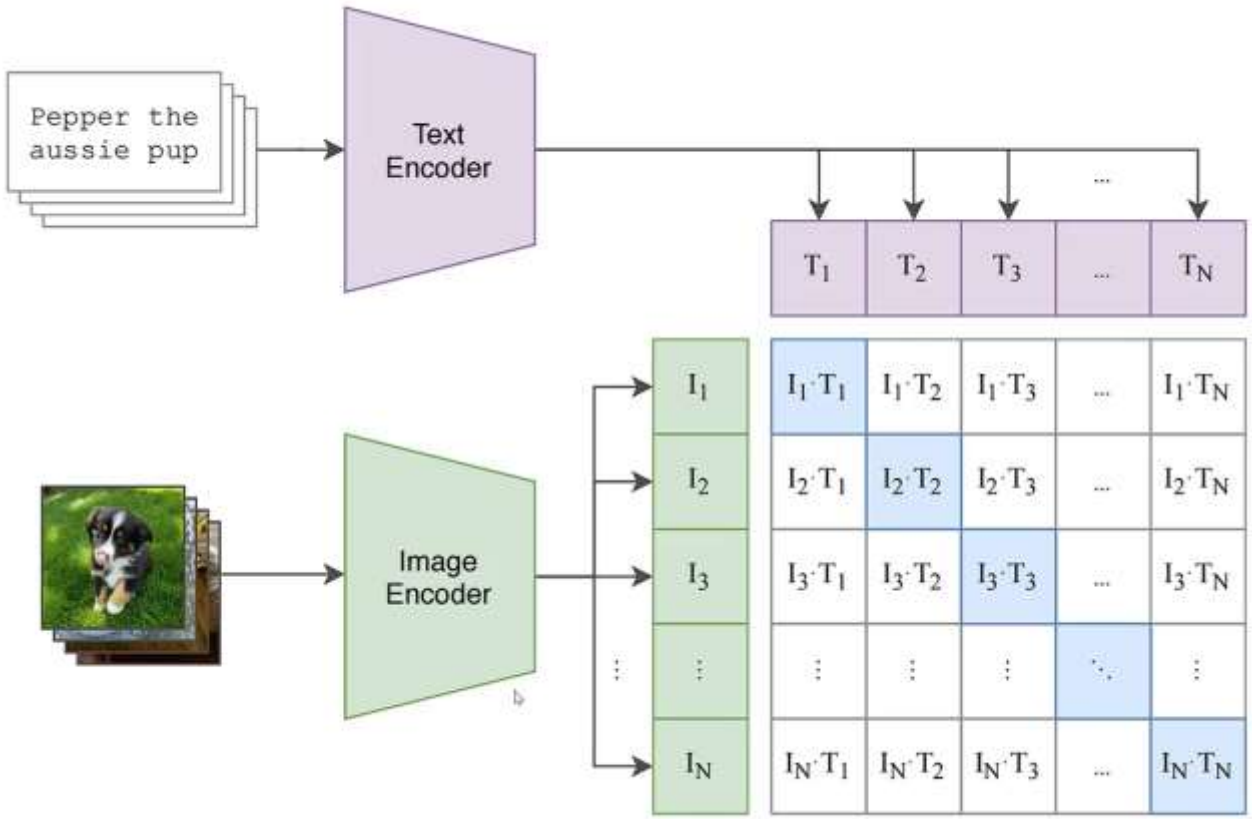

模型推理-zero-shot零样本推理

以ImageNet千分类为例

构造1000个描述性句子--->编码器--->文本向量

图片-->编码器--->计算余弦相似度-->相似度最高

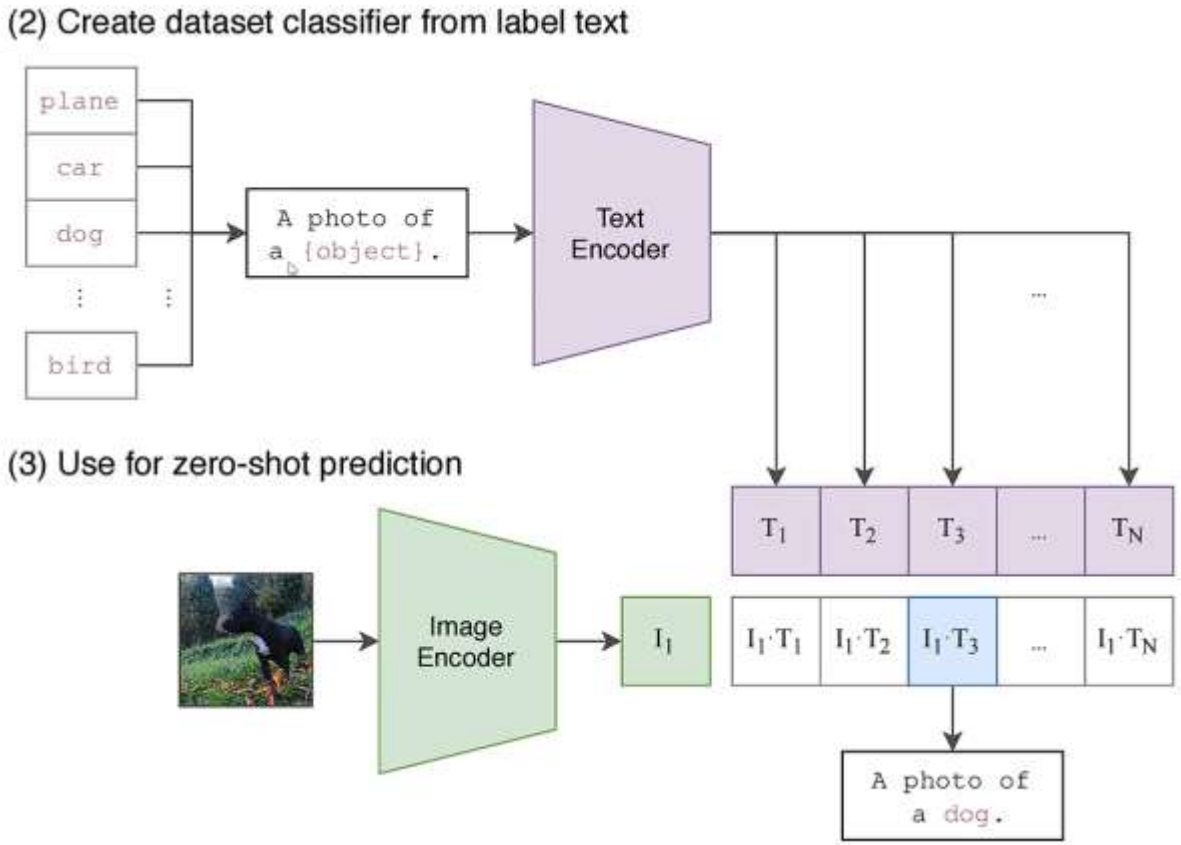

模型优势和改进

通用性强：无需微调，可直接用于图像分类、图文检索、生成式 AI 辅助等多种任务。

泛化能力强：训练数据覆盖海量场景，能识别不常见的图文组合（如 “戴帽子的熊猫”），只要能用文字描述出来。

轻量化：结构简洁，部署成本较低，可用于终端设备（如手机端简单图文匹配）。

问题	模型	解决方案
只能理解“整体”，看不清细节	FG-CLIP 2	细粒度对齐，能分辨“左边穿蓝衣的男孩”
训练效率低，需要大量数据	SigLIP	Sigmoid损失函数，训练更快更稳定
缺乏生成能力	BLIP、Flamingo	引入交叉注意力，支持视觉问答、图像描述
遥感图像语义分割	**CLIP2RS**	**双粒度对齐 + 两阶段训练**

CLIP2RS

Leveraging Pretrained Vision-Language Model for Semantic Segmentation of Remote Sensing Images

双粒度对齐 + 两阶段训练

利用预训练视觉-语言模型进行遥感图像语义分割

.

背景：遥感图像语义分割

任务定义：对遥感图像每个像素做语义类别分类
遥感应用：城市规划、灾害监测、军事侦察等
数据特点：多样性、复杂性、海量性

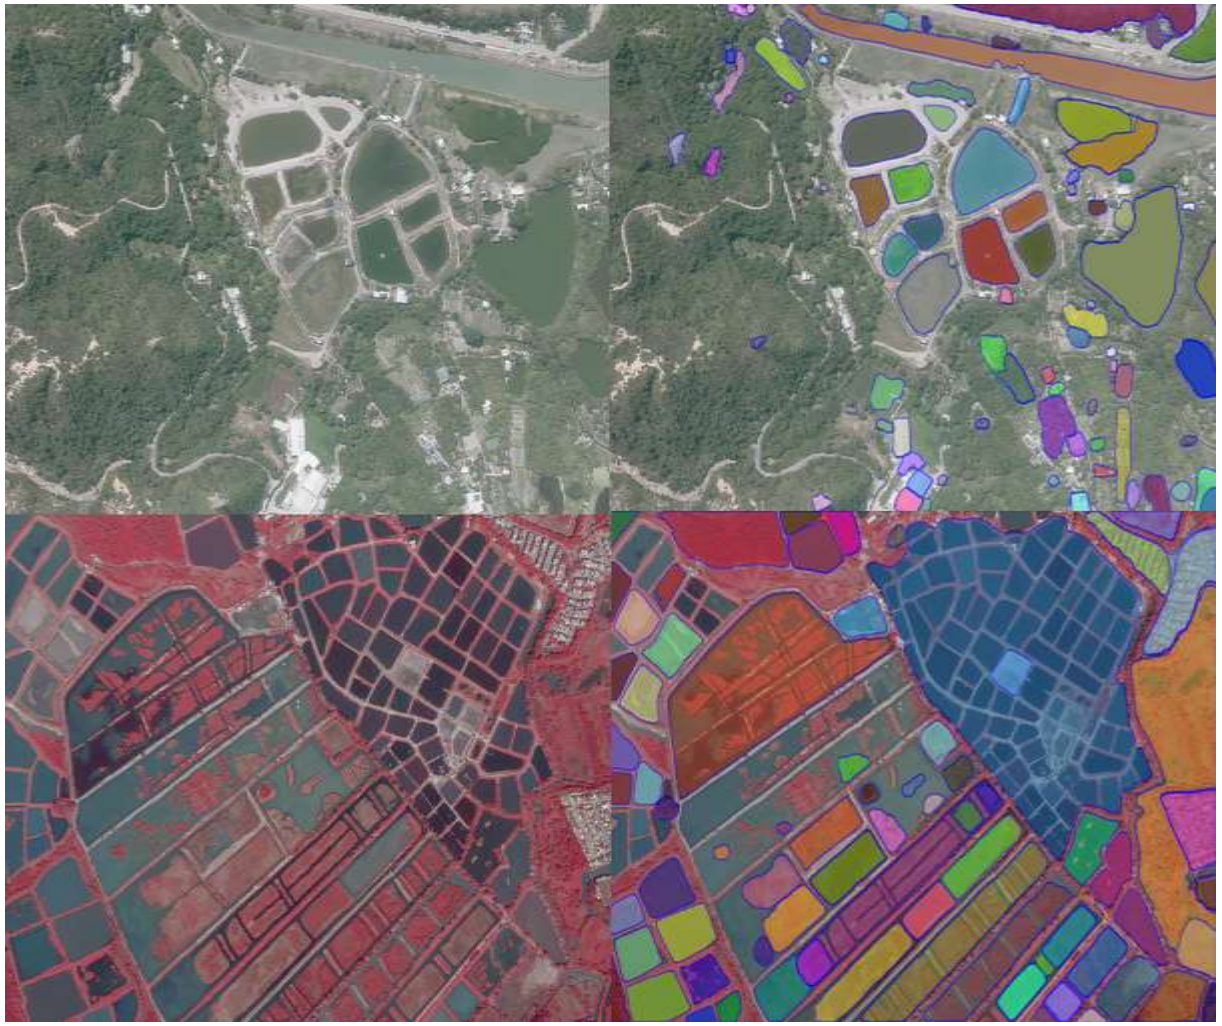

挑战&本文动机

挑战

- **类内差异大：** 同一类别（如“船”）在不同场景中外观差异巨大
- 跨域**鸿沟：** CLIP等视觉-语言模型在自然图像上表现好，但直接用于遥感图像效果差（俯视视角、传感器差异）
- **样本极度不平衡：** 高分辨率图像中，大物体（的像素远多于小物体，模型偏向大类别，忽略小物体

本文动机

- 引入CLIP的视觉和语言知识作为指导
- 两阶段训练 → 解决跨域鸿沟
- 双粒度对齐 → 解决样本不均衡
- 双粒度提示 → 增强文本描述能力

两阶段训练策略(Two-Stage Training)

第一阶段：文本适应

冻结预训练的CLIP模型，仅训练可学习的上下文向量（Prompt），生成适配遥感类别的文本描述，弥合跨域鸿沟。

第二阶段：视觉微调

冻结文本端，利用第一阶段生成的文本知识，指导图像编码器的微调，使模型学习到更具判别性的视觉特征。

先让文本适配遥感，再让视觉适配文本

五芒星代表不同类别的文本特征，圆形代表对应的视觉特征。

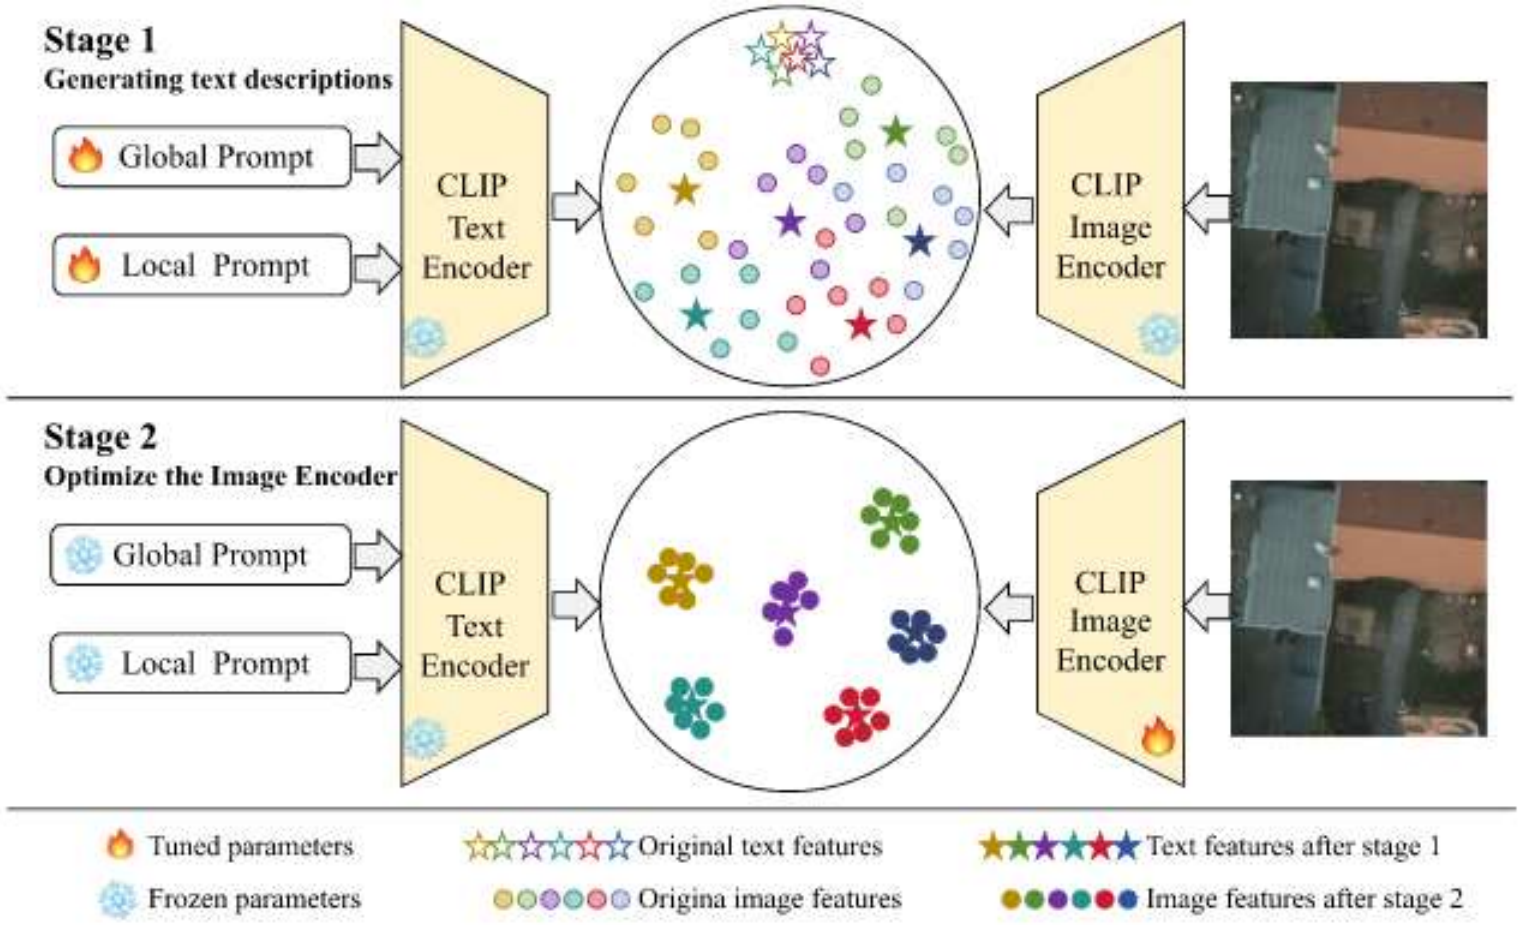

第一阶段后，离散的视觉特征中生成独特的文本特征。
第二阶段后，同一类别的视觉特征会围绕其对应的文本特征聚集

双粒度对齐框架-全局与局部协同

局部对齐（像素级）：
提取像素的视觉特征与局部文本特征计算相似度，得到相似度图，与真实的像素级标签对比，计算辅助损失L_aux，为了得到更精细的预测，局部特征输入到一个轻量级的解码器，计算局部损失 L_local

全局对齐（图像级）
全局图像特征和全局文本特征计算相似度，得到相似度图，真实的图像标签进行对比，用于二元交叉熵损失L_global，相当于多标签分类，只要这张图里有一个小物体，全局损失就会给这个类别一个正样本信号

协同作用

- 局部对齐指导每个像素的分类，确定物体的边界和具体位置
- 全局对齐也是本文的核心，防止模型因为大物体像素太多而忽略小物体，解决“样本不平衡”问题

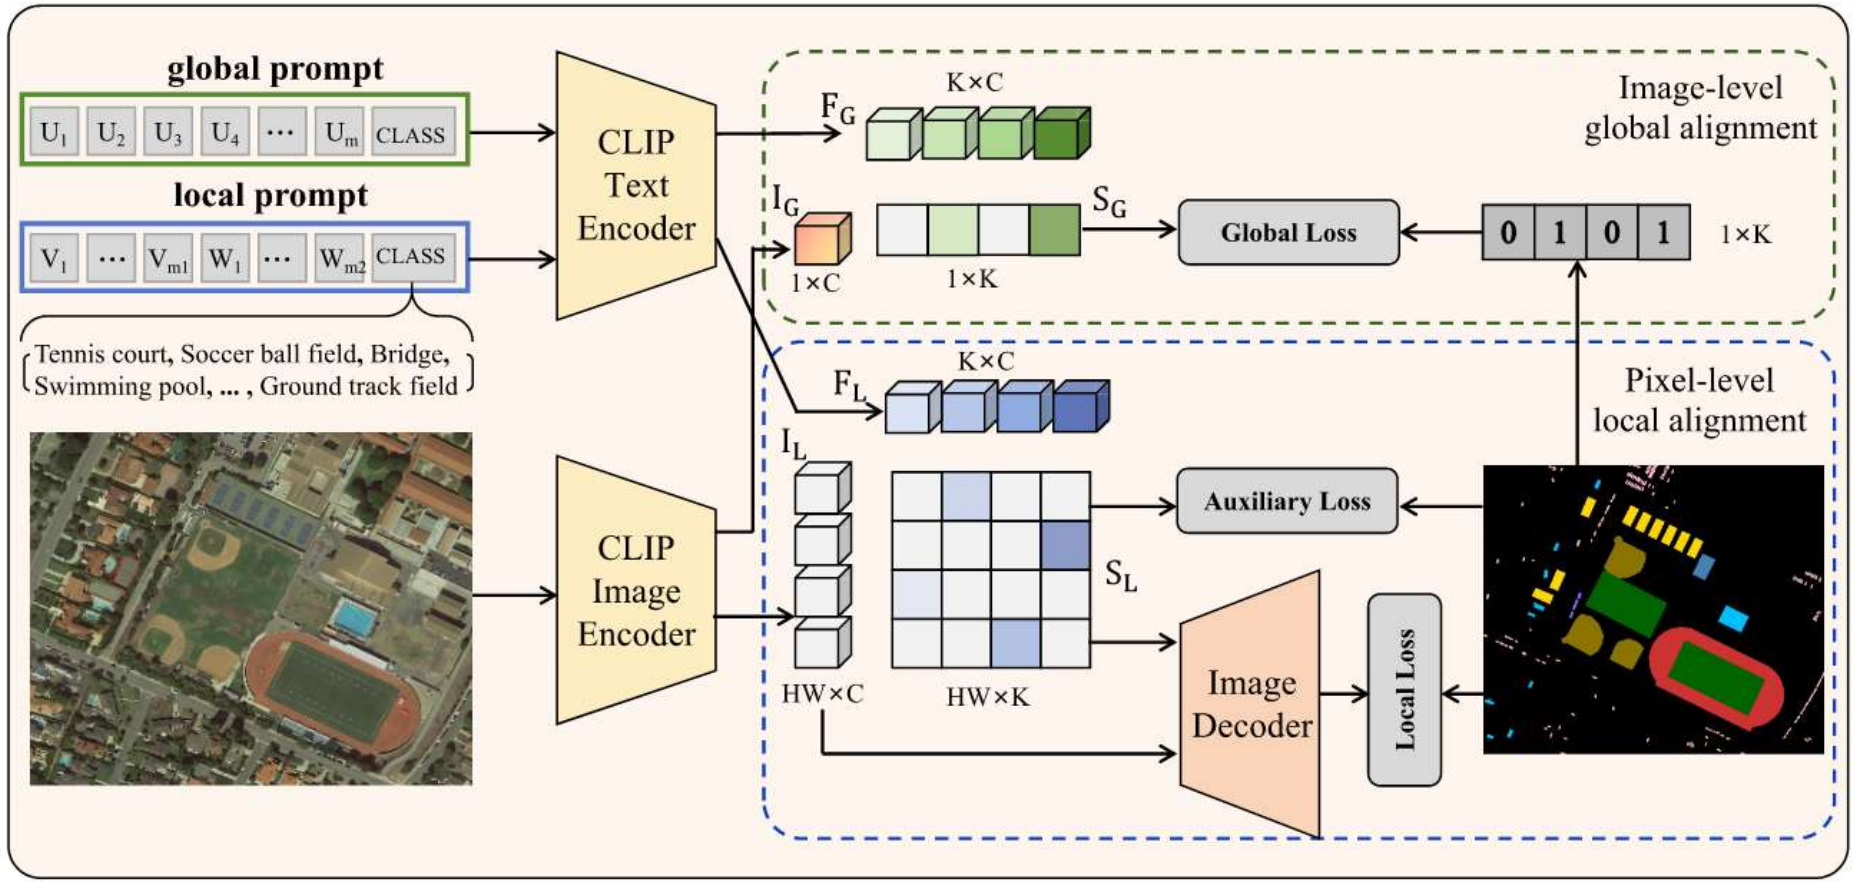

双粒度对齐框架-全局与局部协同

三分支加权损失

- 全局损失 L_global：图像级多标签分类，解决类别不平衡
- 辅助损失 L_aux：像素级对齐，加速模型收敛
- 局部损失 L_local：最终分割，主任务监督

$$\mathcal{L}_{\text{task}} = \alpha \mathcal{L}_{\text{global}} + \beta \mathcal{L}_{\text{aux}} + \gamma \mathcal{L}_{\text{local}}$$

局部损失 γ=0.4：分割是像素级任务，主损失权重最高
全局损失 α=0.3：给足够权重，平衡小目标梯度
辅助损失 β=0.3：辅助收敛，权重适中

双粒度提示

局部Prompt：为了全面捕捉类别间的共性和差异，既包含所有类别共享的“通用上下文”，又有每个类别专属的“特定上下文”。比如描述“汽车”，既学所有交通工具的共性，又抓遥感图像里汽车的独特特征（比如鸟瞰视角的形状）。

全局Prompt： 采用统一的上下文格式，所有类别共享，匹配图像的全局特征，图像级的全局分类，解决小物体在像素级容易被忽略的问题。

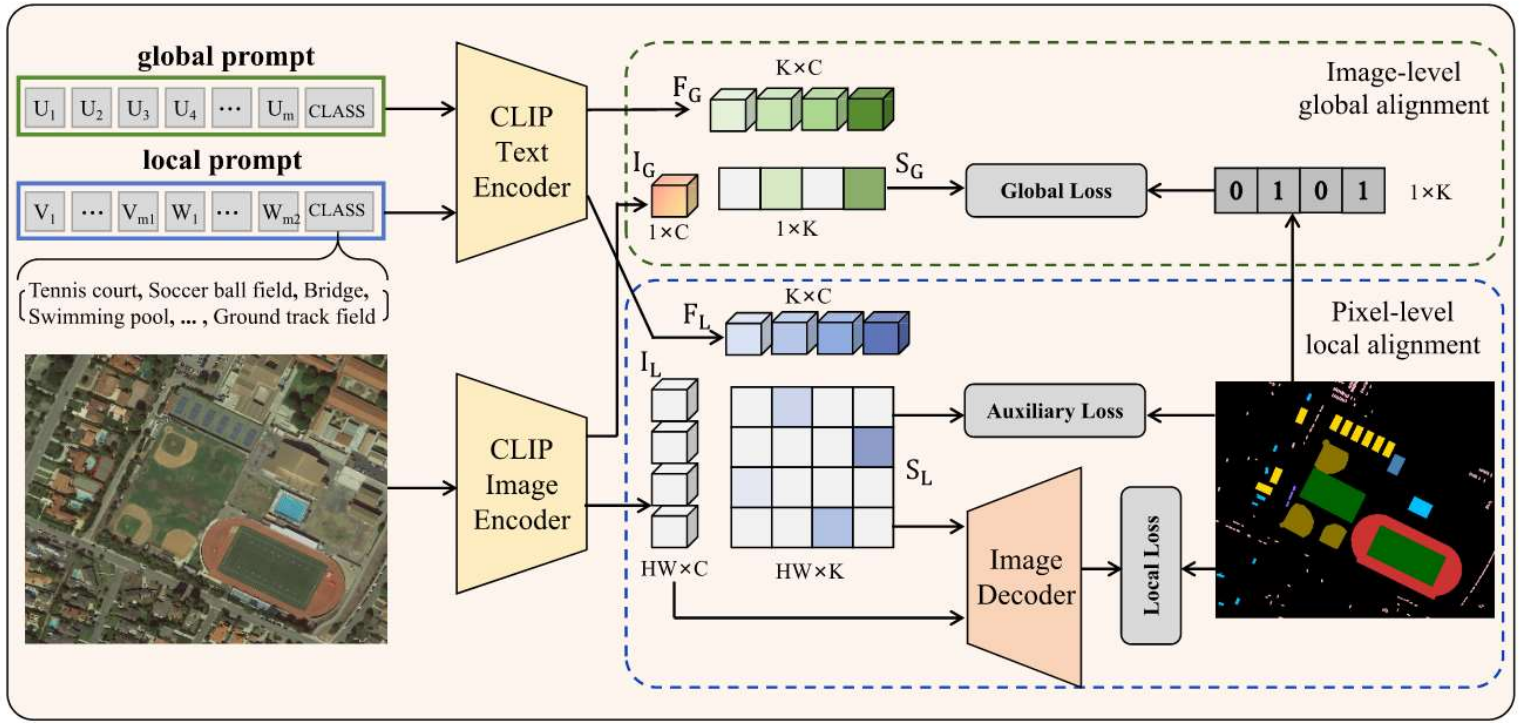

实验结果

数据集

iSAID： 大规模实例分割数据集，包含 15 类地物（如飞机、船、储油罐等）
ISPRS Potsdam： 城市航拍数据，包含 6 类（路面、建筑、树木、汽车等）
ISPRS Vaihingen： 另一个城市航拍数据集，特征与 Potsdam 类似。

结果

CLIP2RS 在三个数据集上均取得了当前最优
iSAID数据集：用ViT-B做骨干，平均交并比达到68.0%，比专门的遥感预训练模型UperNet-RingMo还高0.8%；
Potsdam数据集：平均F1分数93.80%、总体精度93.35%，比第二名HBCNet分别高0.42%、1.38%；
Vaihingen数据集：平均F1分数、总体精度、平均交并比全是第一

结果

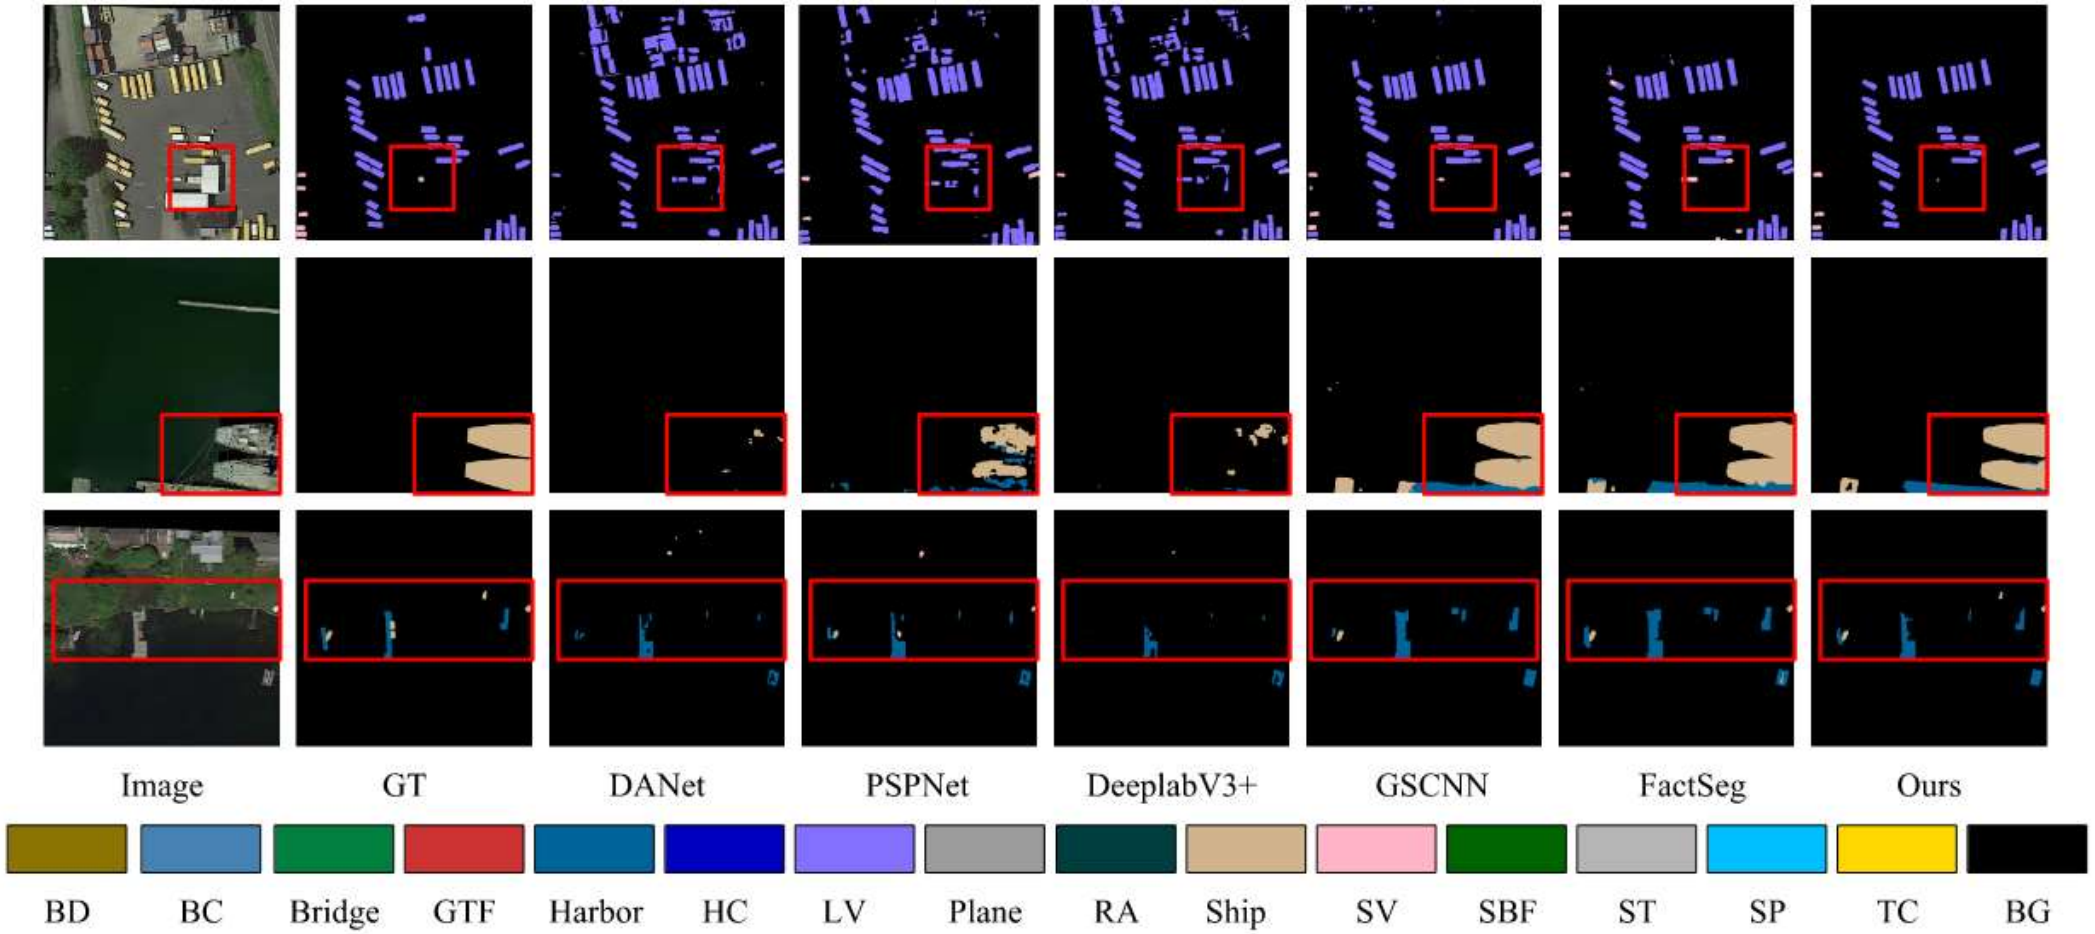

iSAID数据集里，小样本目标存储罐，其他方法全认错，CLIP2RS能精准分割；
船只的比例和外观差异很大。我们的CLIP2RS仍能展示比其他方法更好的分割结果，

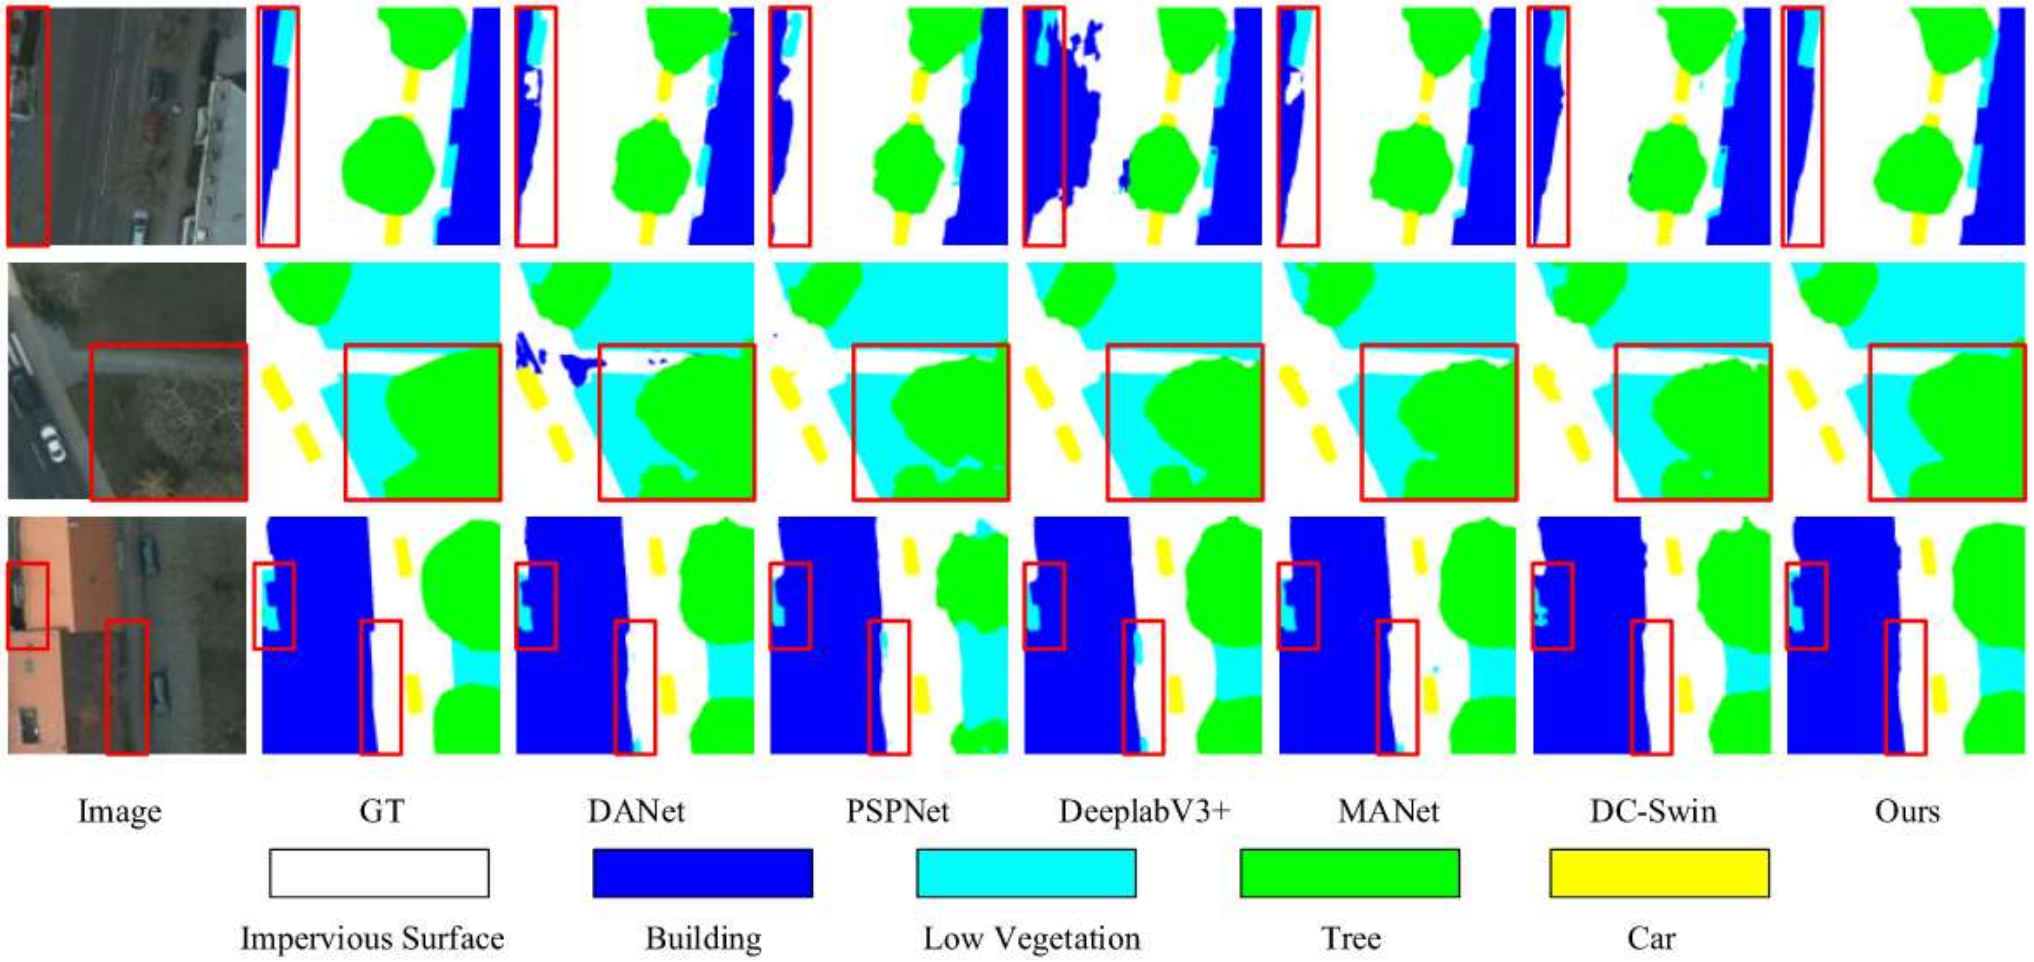

Potsdam数据集里树木和低矮植被错落且颜色相似，难以区分，CLIP2RS能精准区分；建筑物的轮廓和边界，分割得比其他方法更完整。

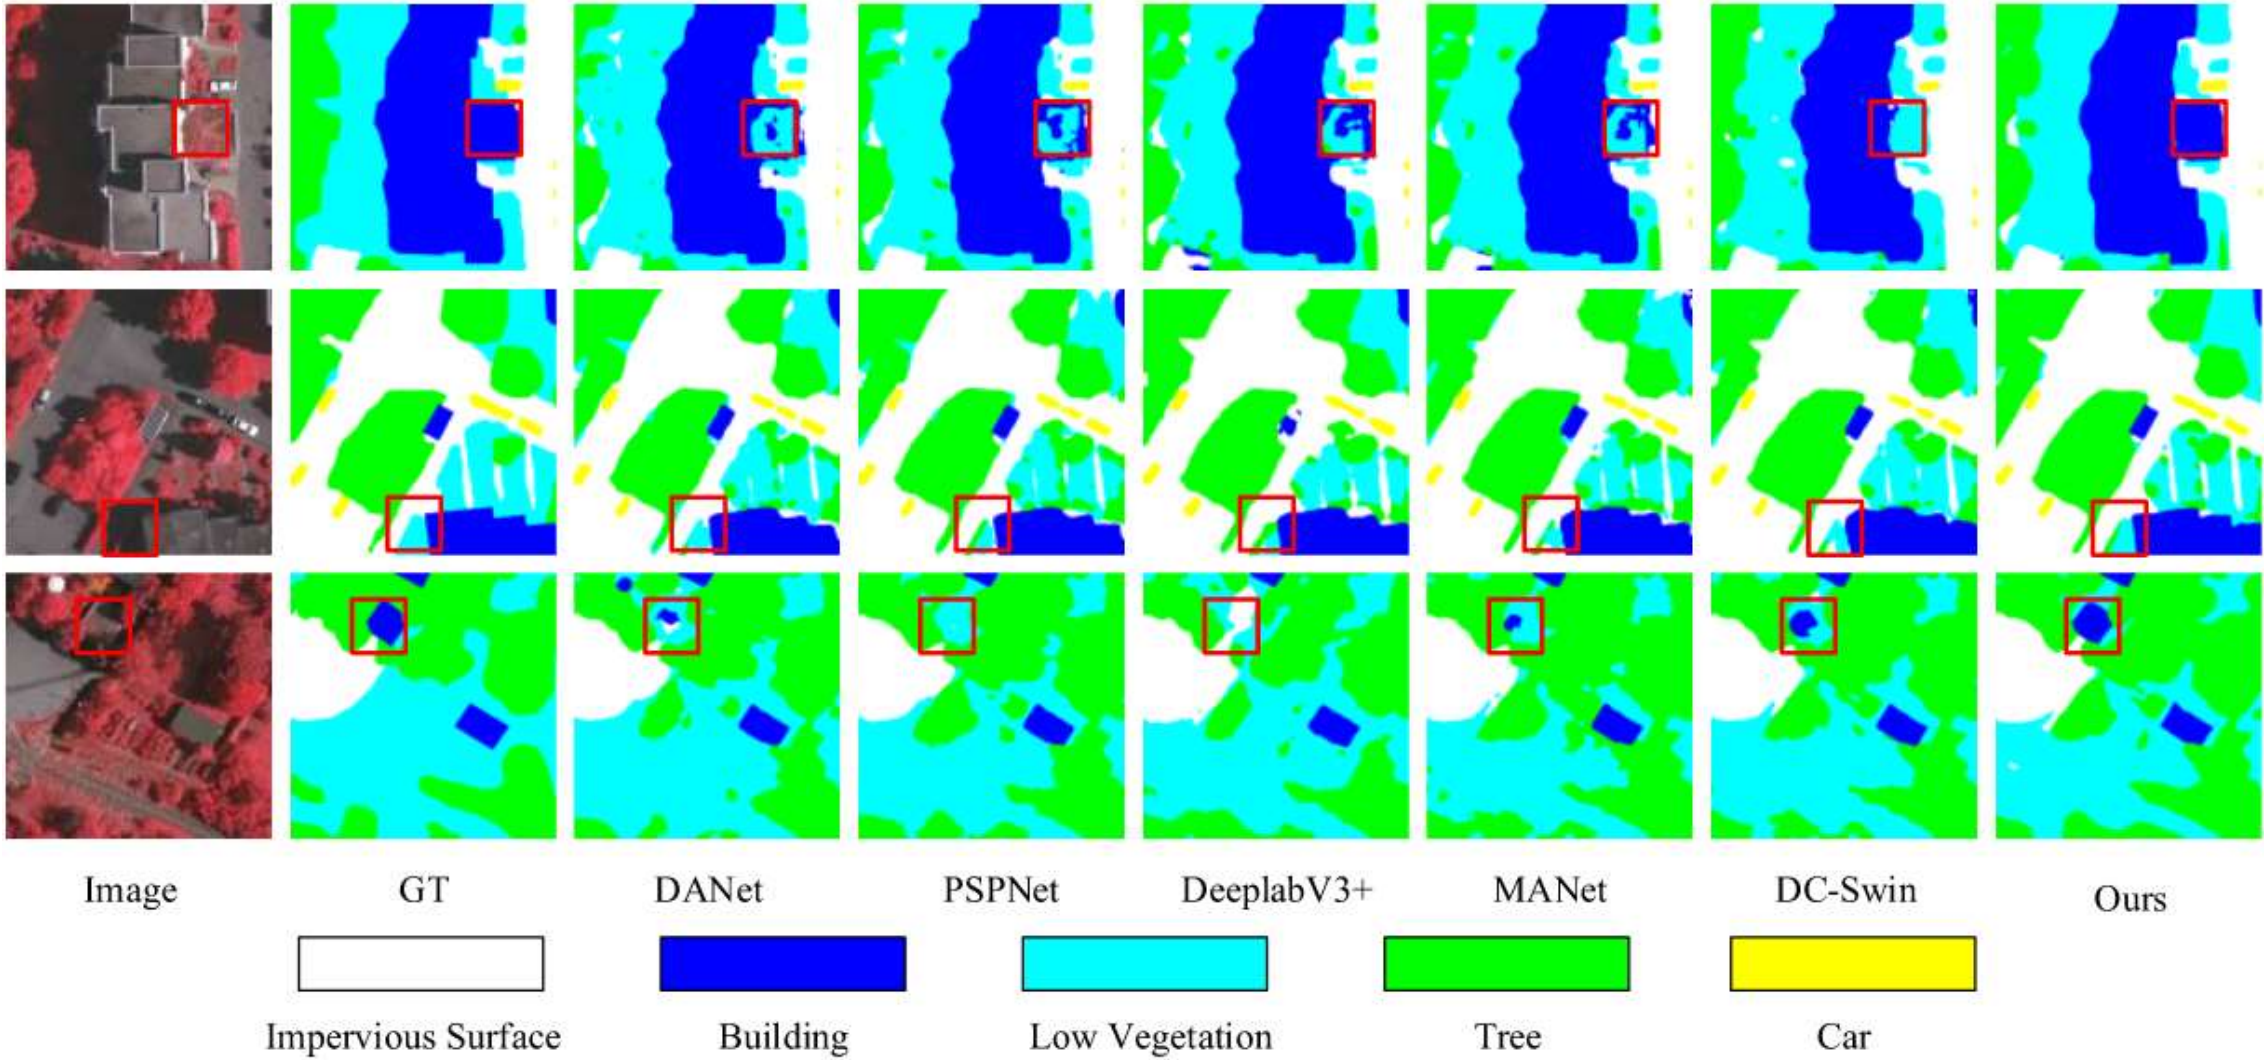

Vaihingen数据集里，小面积的低矮植被不会被误判成树木，不同外观的建筑物都能完整分割，对比其他方法优势超明显。

消融实验

Strategy	Framework	mIoU(%)	IoU of each category(%)														
			BD 1.9%	BC 2.7%	Bridge 1.4%	GTF 7.6%	Harbor 9.6%	HC 0.3%	LV 11.6%	Plane 9.7%	RA 4.6%	Ship 12.4%	SV 12.3%	SBF 15.9%	ST 1.7%	SP 1.1%	TC 7.2%
one-stage	single-granularity	64.8	72.5	55.2	41.7	58.4	57.2	40.0	65.3	85.2	69.1	71.2	53.9	73.1	61.0	47.9	87.1
one-stage	dual-granularity	66.0	76.1	60.4	42.4	56.7	57.5	42.2	65.6	85.7	70.9	70.7	52.6	74.3	65.0	50.1	88.2
two-stage	single-granularity	66.9	77.6	62.9	43.8	**59.4**	**57.8**	40.4	64.7	**86.9**	71.5	70.6	53.3	**75.8**	71.1	48.1	88.8
two-stage	dual-granularity	**68.0**	**79.3**	**65.8**	**45.7**	57.8	55.7	**43.5**	**65.7**	85.6	**72.5**	**72.1**	**54.1**	74.6	**74.7**	**53.2**	**89.9**

两阶段训练策略的必要性：尝试了一阶段训练，即同时优化图像编码器和文本提示。例如，在iSAID数据集中，采用双粒度框架和单粒度框架设置，两阶段训练相比单阶段训练分别提升了2.1%和2%的mIoU。

双粒度对齐框架的有效性：仅从细粒度层面对齐像素级视觉文本特征。，在相同训练策略下，双粒度比对框架表现出更优异的性能，显著提升了样本较少类别对象的分割性能

消融实验

Global	Local	Potsdam			Vaihingen		
		mF1(%)	OA(%)	mIoU(%)	mF1(%)	OA(%)	mIoU(%)
UC	UC	86.99	84.82	79.66	83.56	84.11	77.01
	CSC	93.39	93.17	88.10	90.82	91.44	83.52
	HC_CSC	93.44	93.30	88.16	91.59	91.95	84.33
	UC_CSC	**93.80**	**93.35**	**88.32**	**91.82**	**91.98**	**84.65**
CSC	UC	85.26	84.63	77.17	82.72	83.39	75.98
	CSC	93.19	93.02	87.39	89.68	90.99	82.39
	HC_CSC	93.22	93.08	87.67	89.76	91.11	82.67
	UC_CSC	93.33	93.13	88.08	90.12	91.17	82.82
HC_CSC	UC	86.57	84.75	79.23	82.83	83.64	76.24
	CSC	93.28	93.07	87.82	90.20	91.32	83.08
	HC_CSC	93.34	93.13	88.10	90.62	91.46	83.13
	UC_CSC	93.43	93.21	88.13	90.74	91.56	83.35
UC_CSC	UC	86.33	84.78	78.39	83.15	84.02	76.63
	CSC	93.25	93.01	87.92	90.18	91.25	82.92
	HC_CSC	93.33	93.10	88.05	90.35	91.37	83.10
	UC_CSC	93.53	93.25	88.17	91.25	91.59	84.17

双粒度提示设计的有效性：
我们在Potsdam和Vaihingen数据集上分别尝试了16种提示组合。
UC：在所有类的共享上下文向量
CSC：类特定上下文，上下文向量独立于每个类;
HC CSC：手工制作提示
UC CSC：统一上下文与类别特定上下文结合。

结论：全局用统一上下文UC、局部用通用 + 专属 UC_CSC效果最优，双粒度 Prompt 兼顾类别共性 + 特性，增强文本描述能力。

总结

本文3大核心模块均不可或缺：
两阶段训练：将自然图像CLIP迁移到遥感分割，缓解领域鸿沟
双粒度对齐：同时利用像素级和图像级信息，缓解类别不均衡
双粒度提示：共享+特有上下文，增强文本描述能力

结论：
在三个数据集上达到 SOTA
小物体分割精度提升明显
不用大规模遥感数据预训练，单靠自然图像预训练的CLIP，就能在遥感分割上打败专门的遥感模型。这不仅降低了模型训练的成本，还为遥感图像分析开辟了“视觉+语言”的新方向。