


Spatio-Temporal Data Enhanced Vision-Language  
Model for Traffic Scene Understanding  
**时空数据增强的交通场景理解视觉-语言模型 (ST-CLIP)**



# 背景与动机

## 背景

车载摄像头 + GPS 产生海量带时空标签交通图像；交通场景理解 (TSU) 是自动驾驶、导航、路况分析的核心技术。



痛点1：传统 VLM（如 CLIP）忽略时空轨迹信息，只看图像，不看 GPS、车速、轨迹

痛点2：只看低层视觉特征，缺乏高层关联（如道路宽度、路面材质等）

本文解决思路

设计 ST-CLIP，提出时空感知多维度提示学习（SCAMP），双向弥补上述缺陷

# 任务定义与基础预备知识




TABLE I  
ASPECTS AND CLASS-SPECIFIC WORDS FOR TSU

| Aspects       | Class-specific Words                      |
|---------------|-------------------------------------------|
| Scene         | field, vehicles, alley, stall, unknown    |
| Surface       | normal, broken, soil, unknown             |
| Width         | normal, narrow, extremely narrow, unknown |
| Accessibility | easy, hard, extremely hard                |

## TSU 任务全新定义（本文改进）

输入：交通图像+ 配套时空轨迹上下文

输出：多维度文本描述

四大描述维度：场景 Scene、路面 Surface、道路宽度 Width、通行难度 Accessibility

## 基线基础：CLIP 模型极简原理

双编码器（图像 ViT / 文本 Transformer）+ 对比预训练；传统提示学习固定文本 prompt，无法适配交通时空动态信息



# 整体框架


模型主干：冻结预训练 CLIP，仅微调 SCAMP 提示模块

## SCAMP 两大核心子模块：

① 动态时空上下文表征模块：GPS 轨迹→路段级→轨迹窗口 时空向量


② 双层多维度提示注意力机制：

Patch 跨模态注意力（底层视觉）+ 图像跨维度注意力（高层语义关联）



推理流程：时空向量嵌入可学习提示→双层注意力优化提示表征→CLIP 文本编码器预测 4 维度类别→模板生成路况描述

# 创新模块 1——动态时空上下文表征



步骤 1：原始 GPS 轨迹→路段级轨迹（FMM 地图匹配）

路网定义为有向图，原始 GPS 坐标匹配到标准道路段

步骤 2：路段双特征编码

静态属性：道路 ID、车道数、道路长度等拼接嵌入

动态时序属性：单位时间车流、平均通行速度

步骤 3：滑动窗口 Tracklet+Transformer 编码

以拍摄图像的路段为中心取窗口，Transformer 生成全局时空向量，作为动态提示的先验



## 创新模块2—— 双层多维度提示注意力机制


双层注意力解决 “底层视觉” + “高层语义耦合” 两大问题

### 1. 底层：Patch-wise 跨模态注意力


图像分 Patch，不同维度提示（场景 / 路面 / 宽度）自适应关注图片不同区域（场景关注远景，路面 / 宽度关注道路前景）

### 2. 高层：Image-wise 跨维度注意力

建模 4 个维度内在关联（宽路面更容易通行、破损路面通行难度高），消除多维度预测矛盾



(a) Low-level Cross-modal Attention Heatmap




(b) High-level Cross-aspect Attention Heatmap



# 实验结果

| Dataset            | Beijing     |             |             |             |             |             |               |             |
|--------------------|-------------|-------------|-------------|-------------|-------------|-------------|---------------|-------------|
| Aspect             | Scene       |             | Surface     |             | Width       |             | Accessibility |             |
| Metrics            | ACC ↑       | F1 ↑        | ACC ↑       | F1 ↑        | ACC ↑       | F1 ↑        | ACC ↑         | F1 ↑        |
| ResNet-50          | 0.487±0.023 | 0.410±0.035 | 0.831±0.011 | 0.447±0.027 | 0.336±0.032 | 0.285±0.018 | 0.638±0.039   | 0.314±0.031 |
| ViT-B/32           | 0.490±0.029 | 0.415±0.017 | 0.824±0.008 | 0.441±0.011 | 0.350±0.028 | 0.290±0.014 | 0.645±0.032   | 0.351±0.025 |
| RN50+GAT           | 0.475±0.024 | 0.399±0.017 | 0.814±0.029 | 0.420±0.014 | 0.304±0.021 | 0.251±0.022 | 0.620±0.025   | 0.289±0.017 |
| RN50+LSTM          | 0.468±0.015 | 0.407±0.018 | 0.822±0.025 | 0.432±0.020 | 0.307±0.028 | 0.259±0.033 | 0.633±0.015   | 0.295±0.023 |
| CLIP <sub>ZS</sub> | 0.434       | 0.312       | 0.801       | 0.425       | 0.330       | 0.268       | 0.633         | 0.298       |
| CoOp               | 0.654±0.033 | 0.578±0.029 | 0.721±0.024 | 0.452±0.018 | 0.548±0.013 | 0.523±0.012 | 0.620±0.021   | 0.485±0.029 |
| CoCoOp             | 0.583±0.015 | 0.508±0.021 | 0.662±0.032 | 0.397±0.028 | 0.498±0.042 | 0.458±0.035 | 0.651±0.013   | 0.443±0.026 |
| CLIP-Adapter       | 0.440±0.026 | 0.351±0.019 | 0.790±0.020 | 0.431±0.027 | 0.336±0.014 | 0.285±0.011 | 0.622±0.024   | 0.314±0.016 |
| Tip-Adapter        | 0.589±0.034 | 0.530±0.027 | 0.804±0.012 | 0.433±0.018 | 0.557±0.024 | 0.486±0.033 | 0.725±0.013   | 0.515±0.020 |
| Tip-Adapter-F      | 0.671±0.024 | 0.571±0.021 | 0.849±0.009 | 0.480±0.013 | 0.571±0.032 | 0.488±0.028 | 0.732±0.021   | 0.522±0.019 |
| ST-CLIP            | 0.758±0.021 | 0.697±0.017 | 0.857±0.010 | 0.488±0.008 | 0.598±0.022 | 0.551±0.027 | 0.802±0.025   | 0.580±0.026 |
| Improved           | 13.1%       | 20.6%       | 0.9%        | 1.7%        | 4.7%        | 5.3%        | 9.6%          | 11.1%       |



## 基线三类对比:

- 纯视觉模型: ResNet50、ViT
- 图像 + 时空简单融合: ResNet+LSTM
- CLIP 提示类 SOTA: CoOp、CoCoOp、CLIP-Adapter、Tip-Adapter-F

**数据集:** 北京、成都真实滴滴车载图像 (7k+/8k + 样本)

**结论:** ST-CLIP 在 4 个维度 ACC、F1 全部最优; 性能超过基线 16 样本, 少样本泛化极强



# 消融实验 + 定性案例分析




Fig. 5. Ablation study on Beijing dataset for four tasks.



无时空 NST、无静态特征 NSF、无跨模态注意力 NCM、无跨维度注意力 NCA

结论：所有模块缺一不可，跨维度高层注意力、时空上下文贡献最大

定性案例对比最强基线 Tip-Adapter-F：

- 基线只看图，忽略拥堵轨迹，误判通行难度
- ST-CLIP 融合时空轨迹，精准判断拥堵、土路难通行



# 总结

核心创新：

- ① 业界首次将 GPS 时空轨迹嵌入 CLIP 提示学习用于交通场景理解
- ② 动态时空上下文表征，实现每张图像专属动态 prompt
- ③ 双层多维度注意力，联合建模底层视觉与高层语义关联

核心实验结论

在两大城市真实滴滴数据集少样本设置下全面超越现有 SOTA，时空信息对通行难度预测提升最显著