

TIPSV2

Advancing Vision-Language Pretraining with
Enhanced Patch-Text Alignment

TIPSV2: **基于增强 Patch-Text 对齐的视觉语言预训练**

视觉-语言预训练的两大类方法

- 弱监督对比学习：CLIP, SigLIP, — 提供鲁棒的图文对齐与零样本能力，弱于密集任务
- 自监督学习：DINO, iBOT — 擅长空间理解，适用于密集下游任务，但缺乏文本对齐
- 主流大模型全局对齐强，但图像块与文本稠密对齐很差，零样本分割效果差，

CLIP 数据来自互联网上的图文对，非常擅长图像分类，缺乏空间约束：它不需要理解图中像素块之间的关系。



Two cats laying on a big bed

One cat playing with a small toy

A photo of tabby cat

A photo of Siamese cat



TIPS: 谷歌2024年提出

增强文本监督

PaliGemma (一种视觉语言模型) 给图片生成包含空间信息的描述。
互联网标题可能是“**汽车**”，“**一辆黑色的 SUV 停在建筑物前面**”。

细节多，但可能缺乏互类别词

解决: ViT 的输出端加了两个 [CLS] Token。

(Object-centric): 学习原始噪声文本，抓取具体的物体类别。


(Spatial/Dense): 学习合成文本，抓取空间布局和场景关系。



为了让模型理解像素块之间的关系，TIPS 借鉴了自监督学习

自蒸馏: 教师网络从学生网络自身派生出来，用 EMA 更新

掩码图像建模MIM: 遮住图的一部分，给学生模型，根据周围的信息猜被遮住的部分。强迫模型去理解局部和整体的关系。




发现

核心前置发现：蒸馏提升 Patch-Text 对齐

通常模型越大越好，但在密集预测任务上，蒸馏后的小模型性能反超大模型。

传统的预训练方法（如iBOT）只关注掩码区域，可见部分不参与 loss 计算，它们只作为上下文信息，帮助模型推理被 mask 的部分应该是什么。蒸馏学生模型的所有Patch都进行了监督，实验发现给可见 Patch 加损失→对齐暴涨，改造原版 iBOT 得到 iBOT++



Model	PC59	PC60	VOC21	ADE150
TIPS ViT-L (student)	33.5	30.4	30.5	20.8
TIPS ViT-g (teacher)	11.4	10.8	19.7	2.6



TIPSV2 三大核心改进


iBOT++: 图像建模损失从仅监督掩码部分→ 监督所有部分 (掩码+可见)

Head-only EMA: 仅对投影头做 EMA, 主干编码器不用 EMA, 减半参数量、节省显存
效果: 减少42%训练参数性能几乎不变


多粒度文本标注: 引入Gemini生成丰富标注
Alt-text + PaliGemma + Gemini
→ 随机交替使用不同粒度

三个模块叠加构成 TIPSV2 完整预训练方案, 依托原TIPS 双 CLS+CLIP+DINO+iBOT 损失架构。

TIPSV2框架



TIPS框架






iBOT++（改进点1）

蒸馏后的小模型性能反超大模型，蒸馏之所以有效，是因为它对学生模型的所有Patch（包括可见的）都进行了监督。

原版 iBOT：只对被掩码token计算损失，可见token不受任何监督，可见token自由漂移，不保持局部语义

iBOT++：对所有token（掩码+可见）计算损失，所有图像块都和教师特征对齐，同时捕获全局信息 + 保持局部语义

$$\mathcal{L}_{\text{iBOT++}} = - \sum_{i=1}^N h_t(f_t(I)_i)^T \log h_s(f_s(I_{\text{mask}})_i) \quad (3)$$





Head-only EMA（改进点2）

EMA（指数移动平均）

在自监督学习（如 DINO、iBOT）中，会维护两个网络：
学生网络：正常训练，参数不断更新
教师网络：不通过梯度更新，而是用学生的参数做EMA

教师更稳定，为学生提供“正确答案”，防止模型学到坍塌解。

原始做法的问题（Full EMA）

教师和学生都包含：视觉编码器（ViT） + 投影头（projection head）

这意味着内存中需要同时存两份完整的模型参数

训练开销大，尤其当模型很大时（如 ViT-g）

Head-only EMA 的核心思想

因为有 CLIP 对比损失 的存在，视觉编码器本身不容易坍塌
坍塌主要可能发生在投影头部分，因此只对投影头做 EMA 更新

学生和教师共享同一个编码器，学生头和教师头分开，只对头做 EMA

指标	Full EMA	Head-only EMA
参数量	2× (encoder + head)	1× encoder + 2× head (头很小)
训练显存	高	减少 42% 参数)
性能	基线	几乎不降，甚至略好



多粒度文本（改进点3）

三级文本

Web alt-text: 网页上的原始标签，通常短、噪声大、物体为中心

合成文本: 用 VLM 生成的描述，更结构化、更关注空间关系

Gemini Flash 合成文本: 基于图像 + alt-text + PaliGemma 生成，更丰富、更细致

长文本单独使用反而不好，因为过于详细会让对比学习任务变简单，模型学不到鲁棒特征

TIPS 模型有两个 CLS token:

第一个 CLS: 只用 web alt-text，学习通用的物体识别。

第二个 CLS: 随机交替使用 PaliGemma 或 Gemini 生成的文本，专注空间关系和细节

Image	Alt Text	PaliGemma Captions	Gemini Flash Captions (New!)
	giant panda young animal china	A panda bear laying on a branch in a tree.	A giant panda naps on a wooden branch in a tree, with its legs dangling and head on the branch, surrounded by greenery.
	girl and dog ready for spring jpg	A woman in a dress holding a dog on a leash	A cartoon-style illustration of a woman in a blue dress with red sunglasses and a dog on a leash with a quote about spring underneath.
	best 6b38c 4k 55aa9 car 9324c wallpapers e296a top 7d35f free b508d best 795b7 4k 49569 car backgrounds wallpaperaccess	A blue car driving down a road surrounded by trees.	A blue Mercedes-Benz AMG GT Roadster driving on a road surrounded by fall foliage.



消融实验：逐个叠加模块验证有效性

Model	Seg. ↑ PASCAL	Depth ↓ NYUv2	Normals ↓ NYUv2	ImageNet ↑ KNN	I→T Ret. ↑ Flickr	T→I Ret. ↑ Flickr	Zero-shot Seg. ↑ ADE150
TIPS ViT-g (reproduced)	82.8	0.375	23.1	83.2	92.0	81.0	3.5
+ iBOT++	82.5	0.369	22.7	84.4	93.9	<u>81.7</u>	17.6
+ Multi-granularity Captions	<u>83.7</u>	<u>0.354</u>	22.7	<u>84.3</u>	<u>95.0</u>	85.4	<u>18.1</u>
+ Head-only EMA	83.8	0.353	<u>22.8</u>	84.1	95.4	85.4	19.1

- +iBOT++：零样本 ADE 分割平均交并比增加14.1，稠密任务全面大涨
- + 多粒度文本：图文检索进一步提升
- +Head-only EMA：开销下降，指标小幅上涨

逐个添加三大模块，每项改进均正向增益，证明设计合理。



零样本分割性能



Method	Zero-shot Segmentation $\uparrow$			
	PC59	PC60	VOC21	ADE150
SigLIP2 SO/14	-	19.6	26.8	15.6
SILC B/16	31.6	-	-	19.3
DINOv2 (dino.txt) L/14	30.9	-	-	20.6
TIPS L/14	<u>33.5</u>	<u>30.4</u>	<u>30.5</u>	<u>20.8</u>
TIPSV2 L/14 (ours)	37.1	33.9	44.4	24.7

稠密任务（零样本分割）：TIPSV2全数据集领先
TIPSV2的特征图更平滑，物体边界更清晰。
在不使用任何分割标签的情况下，TIPSV2仅靠预训练就实现了SOTA的零样本分割性能。



分割结果可视化对比

全局图文检索：在7个案例中有5个获得最佳或次优

Model	I→T Retrieval ↑			T→I Retrieval ↑			0-Shot ↑ ImageNet
	COCO	Flickr	DOCCI	COCO	Flickr	DOCCI	
CLIP L/14	56.3	85.2	44.4	36.5	65.2	40.4	75.5
OpenCLIP G/14	67.3	92.9	-	51.4	79.5	-	80.1
SigLIP2 g/16	72.8	<u>95.4</u>	-	56.1	86.0	-	<u>85.0</u>
SILC G/16	73.2	-	-	54.7	-	-	83.7
DINOv2 (dino.txt) L/14	-	-	-	45.4	77.1	-	81.4
PE-core G/14	<u>75.4</u>	96.2	-	58.1	85.7	-	85.4
TIPS g/14	<u>74.0</u>	93.0	<u>57.2</u>	<u>59.4</u>	84.5	<u>58.8</u>	79.9
TIPsv2 g/14 (ours)	75.7	95.1	68.9	60.7	<u>85.9</u>	72.8	80.7

TIPsv2能准确分割出桌子、鸟类的轮廓，而之前的TIPS和SigLIP2出现了明显的漏分或错分。
这证明了我们的方法能让模型真正‘看’懂图像的每一个细节，并与文本对应起来。




Image Ground truth TIPsv2 (ours) TIPS SigLIP2