Transformer-Based RGB-T Tracking With Channel and Spatial Feature Fusion
基于Transformer的RGB-T跟踪中的通道和空间特征融合

背景

RGB：纹理、颜色丰富，怕暗光、遮挡、恶劣天气

TIR：不受光照影响，穿透雨 / 雾 / 黑夜，但缺乏纹理

RGB-TIR跟踪：可见光（RGB）+ 热红外（TIR）双模态融合，在低光、恶劣天气下实现稳定目标跟踪。

应用场景：自动驾驶、无人机监控、机器人感知

目标：高效、准确地融合两种模态的特征，解决单一模态跟踪失效问题，实现全天候、复杂环境稳定跟踪

RGB

Thermal

挑战&本文动机

现有方法

- **类间接融合（如TBSI、ViPT、BAT）**：依赖中间模块或提示学习，增加了计算负担，容易导致信息丢失或维度压缩。
- **通道/空间融合（如SiamCDA、DAFNet）**：只关注单一维度，缺乏联合建模。

本文：直接特征交互，不经过中间模块

- 提出 CSTNet：首个在 ViT中引入直接特征交互的 RGB-T 跟踪器

- 两大模块：
  JSCFM：联合建模通道与多级空间特征
  SFM：基于类交叉注意力的空间建模与融合

- 轻量版CSTNet-small：速度提升50%，性能仅降1-2%。支持嵌入式实时部署

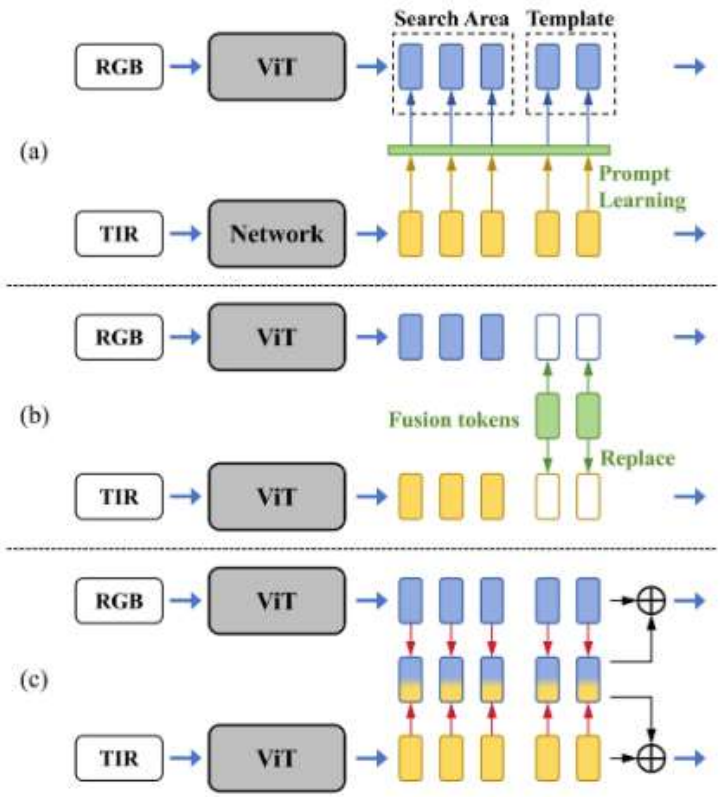

整体框架

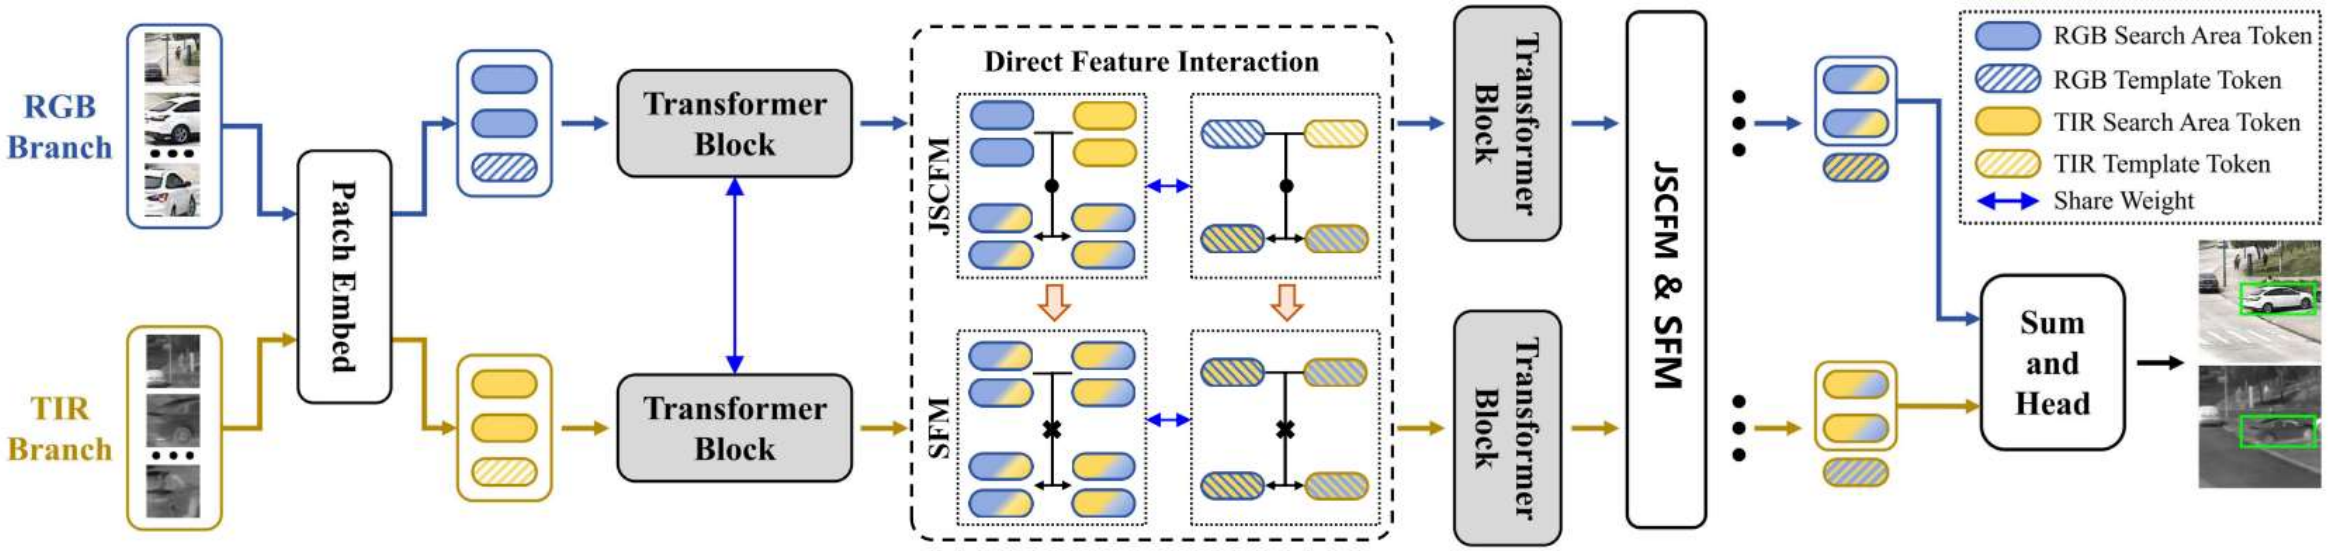

主干：双边共享权重 ViT骨干网络（RGB/TIR 分支结构一致，权重共享）

输入：模板帧（目标位置区域）+ 搜索区帧（可能包含目标的区域），图像切分为patch，投影为token向量+位置编码，加入可学习的位置信息

融合模块：JSCFM + SFM 级联，插入 ViT 第 4、7、10 层（多阶段融合）

特征整合：搜索区 RGB+TIR 特征直接相加（替代拼接降维，保留完整信息）

用 ViT 做主干，通过通道 - 空间联合融合模块实现双模态直接交互，兼顾精度与速度。

JSCFM模块（联合空间 - 通道融合模块）

输入：来自某一层 ViT 的 RGB 特征和TIR 特征

1.线性融合：全连接层进行通道维度拼接 得到融合特征X，初步混合两个模态的信息。

2.并行分支：

SE 模块：全局平均池化+全连接层+激活函数得到每个通道的权重，权重乘以原特征，通道增强，抑制不重要通道，更关注重要通道

LSA 模块：不同尺寸的深度可分离卷积（1×1,3×3, 5×5, 7×7）并行提取多尺度空间特征

3.SE和LSA的输出逐元素相加→融合通道增强和多尺度空间信息。再加到原始的 RGB 特征和TIR特征上-保留原始信息，避免退化

4.GIM 全局集成模块：RGB和TIR特征再拼接-全连接层-分割，两个模态在全局层面再做一次信息交换。

目标：同时利用通道维度和空间多尺度维度的信息来增强跨模态特征。

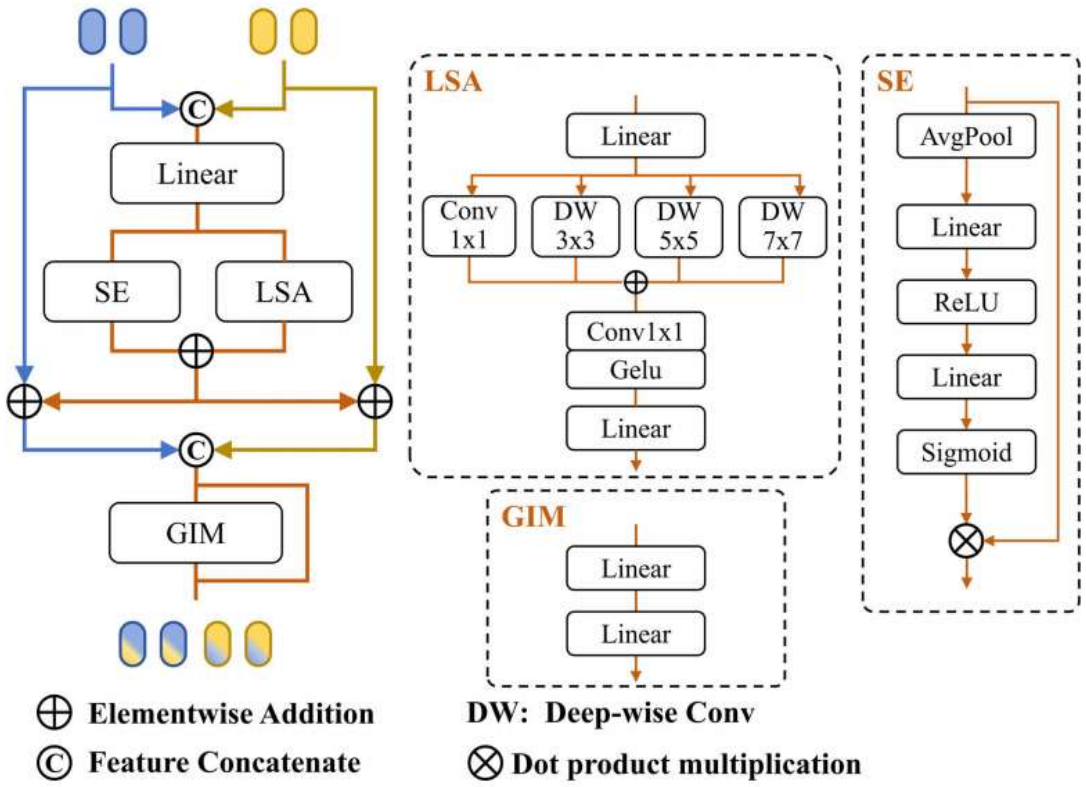

SFM模块（空间融合模块）

输入：JSCFM 输出的特征

LPU：深度可分离卷积提取局部空间信息，然后加回原特征，增强局部空间邻域的关系，后面的交叉注意力做准备。

CAM（核心）：共享的线性层得到Query、Key、Value。对 TIR 特征同样操作，交叉注意力：

Attention(Q_r,K_t,V_t) Attention(Q_t,K_r,V_r)

让 RGB 借助 TIR 的热信息，让 TIR 借助 RGB 的细节信息

CFN：用卷积提取空间特征,全连接层处理通道特征

目的：进一步解耦并融合空间和通道特征

结果：输出进一步融合后的特征，用注意力机制，让RGB和TIR的空间特征直接交互

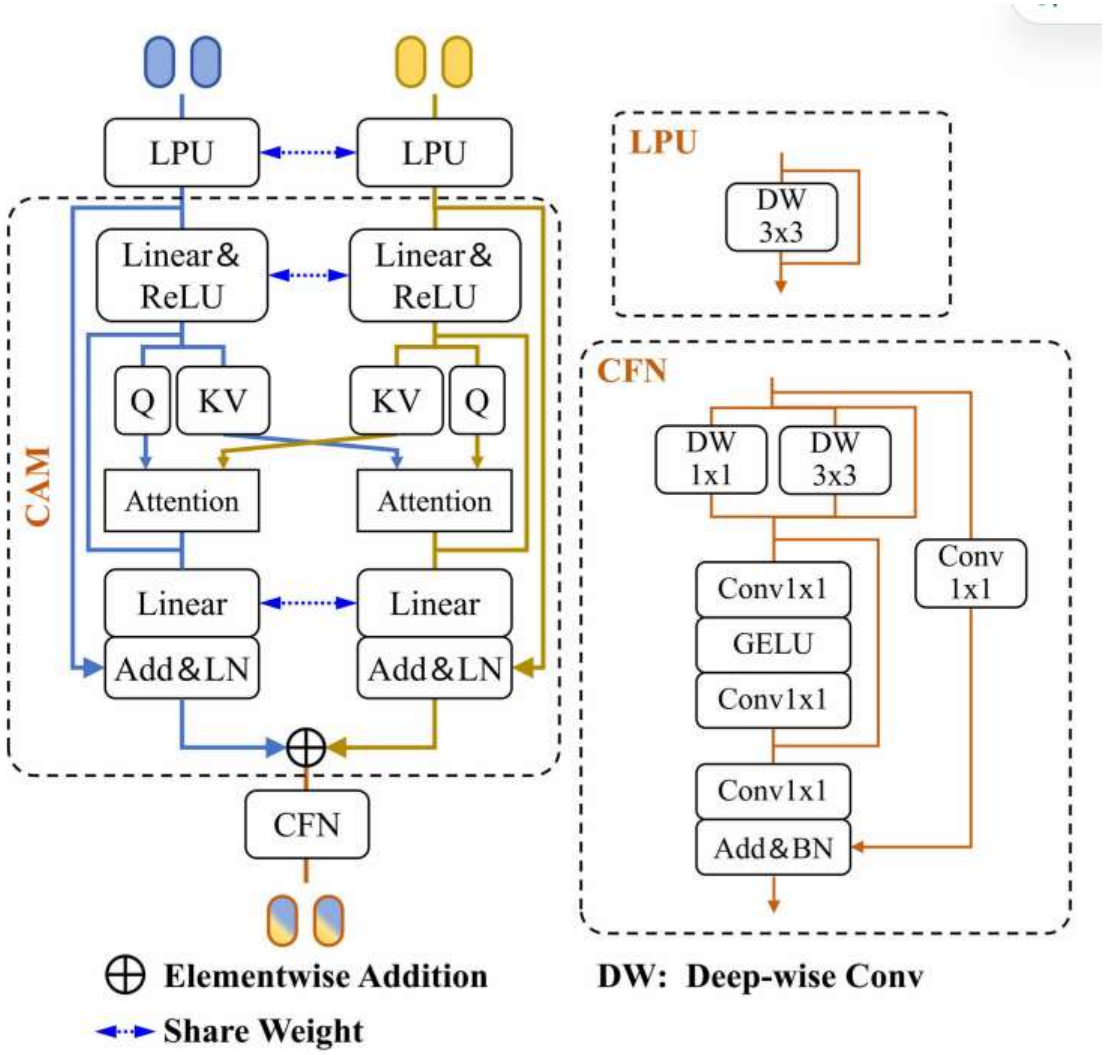

JSCFM模块和SFM协同

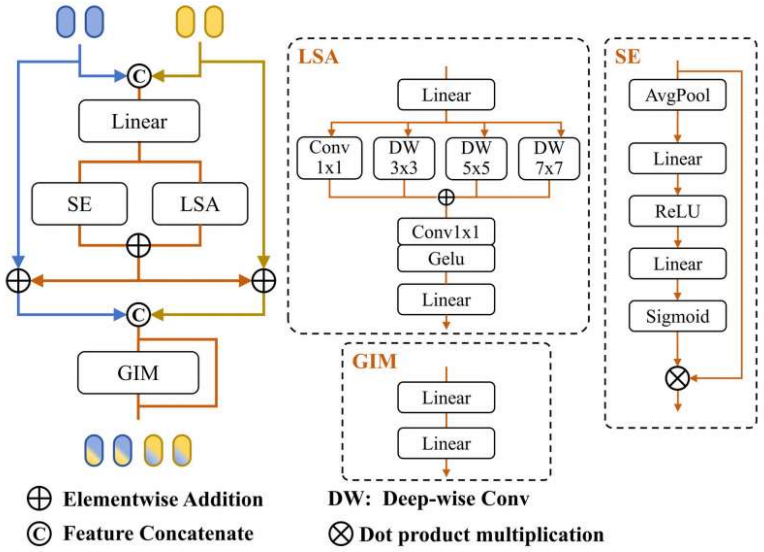

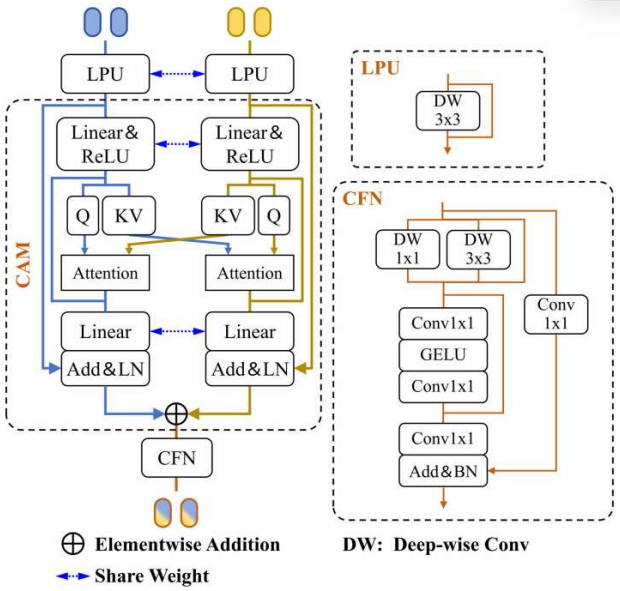

JSCFM 先做“通道+多尺度空间增强”：把两个模态的特征打磨得更好，

SFM再做“空间交互”：在增强后的特征基础上，让两个模态的空间信息互相融合。

原因：SFM的交叉注意力需要输入的特征已经具备良好的通道和空间表示，JSCFM提供这个基础。

CSTNet-small：从 CSTNet 中排除 JSCFM 和 SFM 模块，利用 CSTNet 权重作为预训练权重。效果：参数量↓54.4%，速度↑50%，性能仅↓1-2%

实验结果

评测数据集

训练数据：LasHeR (训练集)。

测试数据：LasHeR, RGBT234, RGBT210, GTOT, VTUAV, UniRTL。

核心评价指标

精度指标：PR（精确率）、SR（成功率）、NPR（归一化精确率）

效率指标：Params（参数量）、FLOPs（计算量）、FPS（帧率）

Method	Source	Baseline	VTUAV [18]		RGBT210 [16]		RGBT234 [17]		LasHeR [14]		
			MPR	MSR	PR	SR	PR	SR	PR	NPR	SR
TFNet [39]	TCSVT2021	MDNet	-	-	77.7	52.9	80.6	56	-	-	-
AGMINet [40]	TIM2022	MDNet	-	-	-	-	84.0	59.2	48.8	42.9	34.3
DMCNet [41]	TNNLS22	MDNet	-	-	79.7	55.9	83.9	59.3	49.0	43.1	35.5
APFNet [42]	AAAI2022	MDNet	-	-	79.9	54.9	82.7	57.9	50.0	43.9	36.2
DMSTM [43]	TIM2023	MDNet	-	-	-	-	78.6	56.2	55.7	50.3	40.0
X-Net [44]	Arxiv2023	MDNet	-	-	-	-	85.2	62.2	50.8	-	44.6
QAT [45]	ACM MM2023	MDNet	80.1	66.7	86.8	61.9	88.4	64.4	64.2	59.6	50.1
CAT++ [27]	TIP2024	MDNet	-	-	82.2	56.1	84.0	59.2	50.9	44.4	35.6
SiamCDA [20]	TCSVT2021	Siamese	-	-	-	-	76.0	56.9	-	-	-
DFAT [46]	Inf Fusion23	Siamese	-	-	-	-	75.8	55.2	-	-	-
SiamMLAA [22]	TMM2023	Siamese	-	-	-	-	78.6	58.4	-	-	-
MFNet [47]	IVC2022	DCF	-	-	-	-	84.4	60.1	59.7	55.4	46.7
HMFT [18]	CVPR2022	DCF	75.8	62.7	78.6	53.5	78.8	56.8	-	-	-
LSAR [48]	TCSVT2023	DCF	-	-	-	-	78.4	55.9	-	-	-
CMD [49]	CVPR2023	DCF	-	-	-	-	82.4	58.4	59.0	54.6	46.4
MPT [50]	TIM2024	DCF	-	-	-	-	76.9	55.0	35.5	-	31.3
AMNet [7]	TCSVT2024	DCF	-	-	-	-	85.5	60.7	61.4	55.9	47.7
ProTrack [51]	ACM MM2022	Transformer	-	-	79.5	59.9	78.6	58.7	53.8	-	42.0
ViPT [5]	CVPR2023	Transformer	-	-	83.5	61.7	83.5	61.7	65.1	-	52.5
MACFT [23]	Sensors2023	Transformer	**80.1**	**66.8**	-	-	85.7	62.2	65.3	-	52.5
RSFNet [52]	ISPL2023	Transformer	-	-	-	-	86.3	62.2	65.9	-	52.6
DFMTNet [53]	IEEE Sens.J23	Transformer	-	-	-	-	86.2	63.6	65.1	-	52.0
TBSI [4]	CVPR2023	Transformer	-	-	**85.3**	**62.5**	87.1	63.7	69.2	65.7	55.6
STTANet [54]	TIM2024	Transformer	-	-	82.5	60.2	85.5	63.2	66.7	-	53.4
STMT [55]	TCSVT2024	Transformer	-	-	83.0	59.5	86.5	63.8	67.4	63.4	53.7
TATrack [28]	AAAI2024	Transformer	-	-	**85.3**	61.8	87.2	64.4	70.2	**66.7**	56.1
BAT [6]	AAAI2024	Transformer	-	-	-	-	86.8	64.1	70.2	-	56.3
TransAM [7]	TCSVT2024	Transformer	-	-	-	-	**87.7**	**65.5**	70.2	66.0	55.9
CSTNet-small	-	Transformer	**82.2**	**69.3**	85.1	62.1	86.7	64.1	**70.3**	66.3	**56.4**
CSTNet	-	Transformer	77.5	66.0	**86.0**	63.5	**88.4**	**65.2**	**71.5**	**67.9**	**57.2**

实验结果

精度：CSTNet和CSTNet-small在所有数据集上达SOTA，超BAT/TBSI 等主流方法 1%-3%

效率：

CSTNet：参数量↓28.7%，FLOPs↓9.5%，RTX3090 上 62FPS

CSTNet-small：参数量↓54.4%，FLOPs↓31.6%，速度提升 50%

在Jetson Xavier上（英伟达专为自主机器和边缘 AI 应用设计的高性能、高能效的计算机模组。）：21 / 33 FPS，满足实时部署

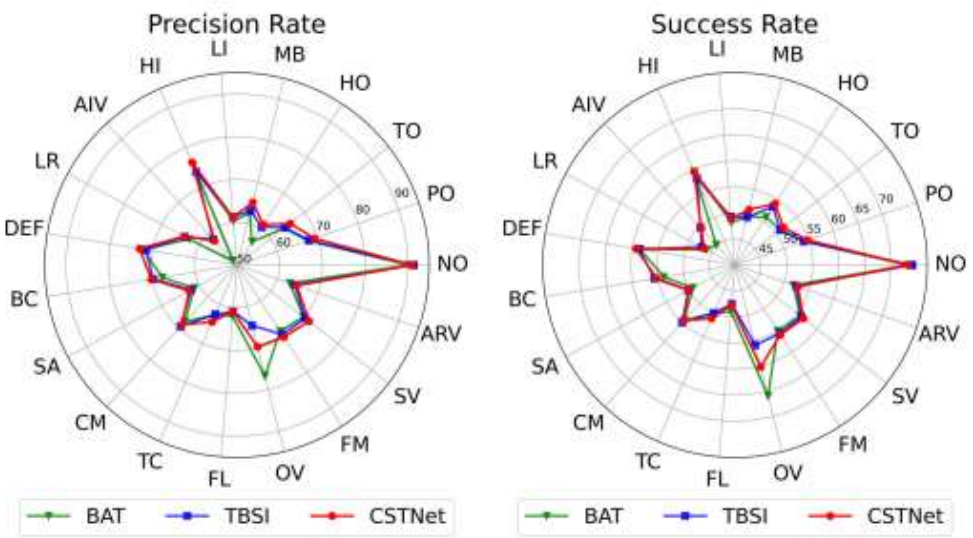

COMPARISON OF PARAMETERS, FLOPS, AND FPS ON GPU RTX 3090TI, GPU RTX 2080, AND NVIDIA JETSON XAVIER

	3090Ti/2080		Xavier	Params	Flops
	torch	onnx	onnx		
TBSI	60 / 28	71 / 40	-	201.98M	82.5G
CSTNet	62 / 36	74 / 44	21	144.00M	74.7G
CSTNet-small	**94 / 47**	**126 / 65**	**33**	**92.12M**	**56.4G**

结果

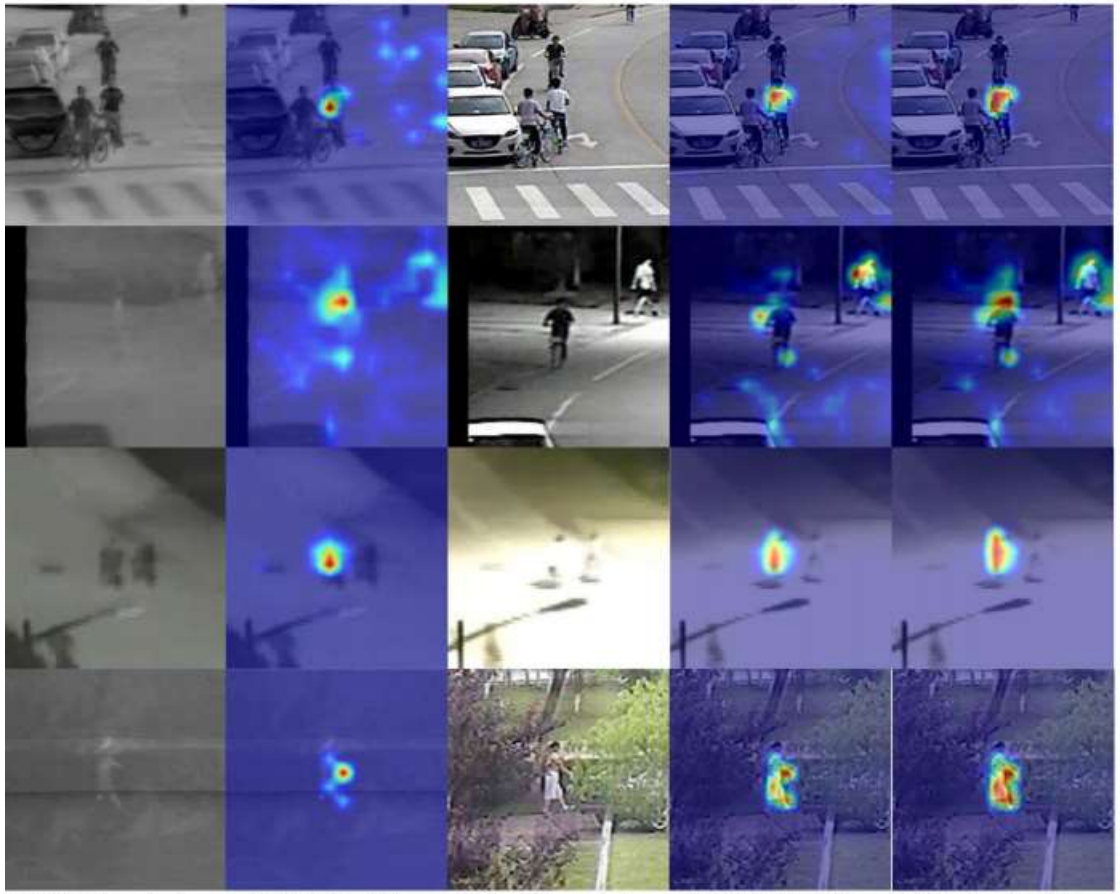

(1) TIR Search Area (2) TIR Heat Map (3) RGB Search Area (4) RGB Heat Map (5) Fusion Heat Map

(1) RGB Search Area (2) TIR Search Area (3) TBSI (4) BAT (5) CSTNet

热力图可视化：融合特征能同时关注RGB纹理区和TIR热源区

跟踪效果：低光照、遮挡场景下的稳定性对比

总结与局限

优点：

首次实现ViT中的直接跨模态交互

JSCFM实现通道-空间联合建模，SFM实现跨模态空间注意力

CSTNet-small实现轻量化实时部署

局限（论文自述）：

忽略时空特征建模（仅用外观）

对强光照、完全遮挡、相似物体仍易失败

CSTNet-small的压缩范式是否可推广未知