# CoPS: Conditional Prompt Synthesis for Zero-Shot Anomaly Detection

## CoPS：条件提示合成用于Zero - shot异常检测

汇报人：李德志

2026/9/27

北京工業大學

# 目　　录



背景



相关工作



方法



实验

## 研究背景与动机

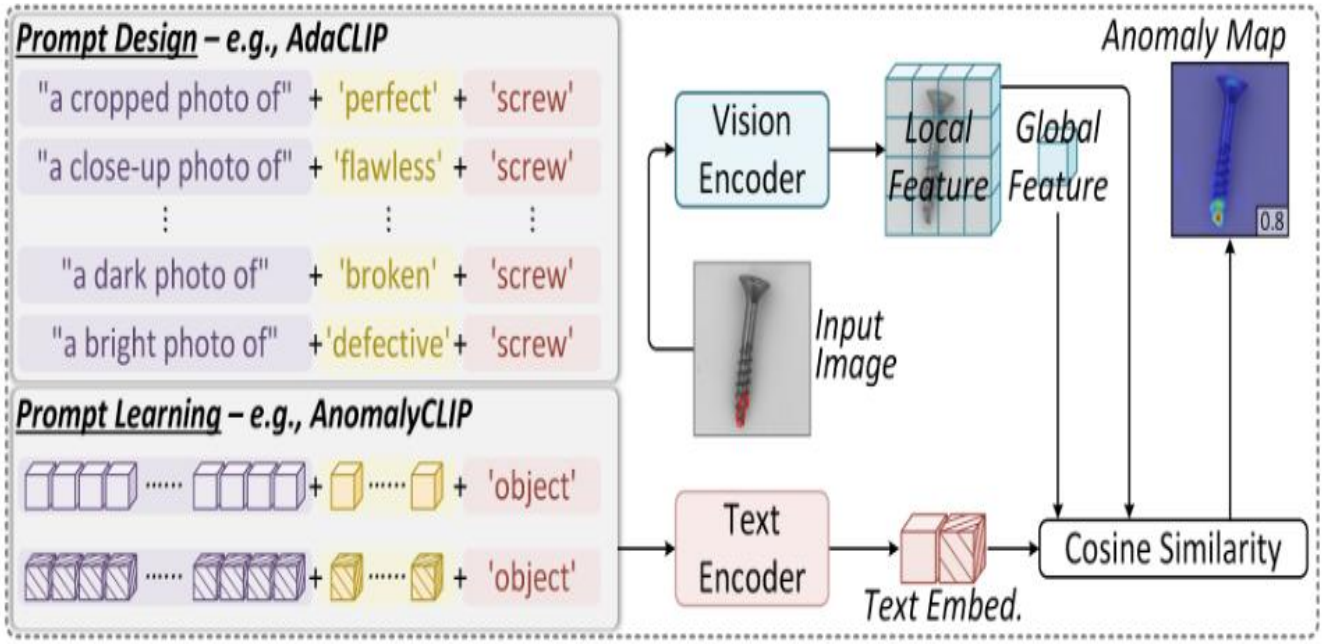
已有 CLIP-based ZSAD 方法大致分为两类：

**第一类是 Prompt Design**

例如通过人工设计大量模板，把“perfect / flawless / broken / damaged”等词组合起来。这类方法直观、可解释，但高度依赖专家经验和反复调参。

**第二类是 Prompt Learning**

例如把上下文词、状态词替换成可学习 token，让模型自动学习提示词表示。这减少了人工设计成本，但也带来一个新问题：学到的token往往是静态的，对所有测试图像都一样。



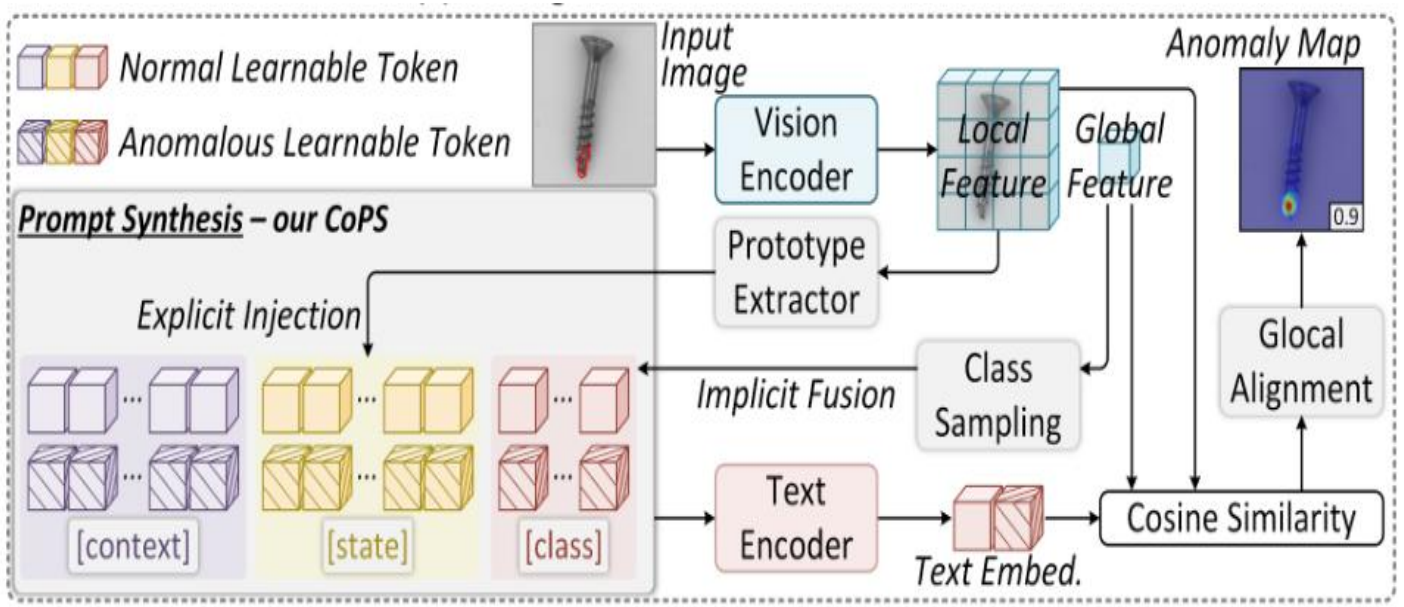
(a) Existing CLIP-based Methods for ZSAD

## 研究背景与动机

现有方法仍面临两大挑战：

- **静态提示问题**：固定的可学习 token 难以捕捉正常与异常状态连续、多样的模式，限制了模型对未见类别的泛化；
- **类别标签稀疏问题**：简单的类别无关文本（如 “object”）提供的信息过于稀疏，模型容易过拟合到狭小的语义子空间。

针对上述问题，本文提出 **CoPS**（Conditional Prompt Synthesis），一种以视觉特征为条件动态合成提示的 CLIP-based ZSAD 框架。



(b) Our Proposed CoPS for ZSAD

# 整体框架

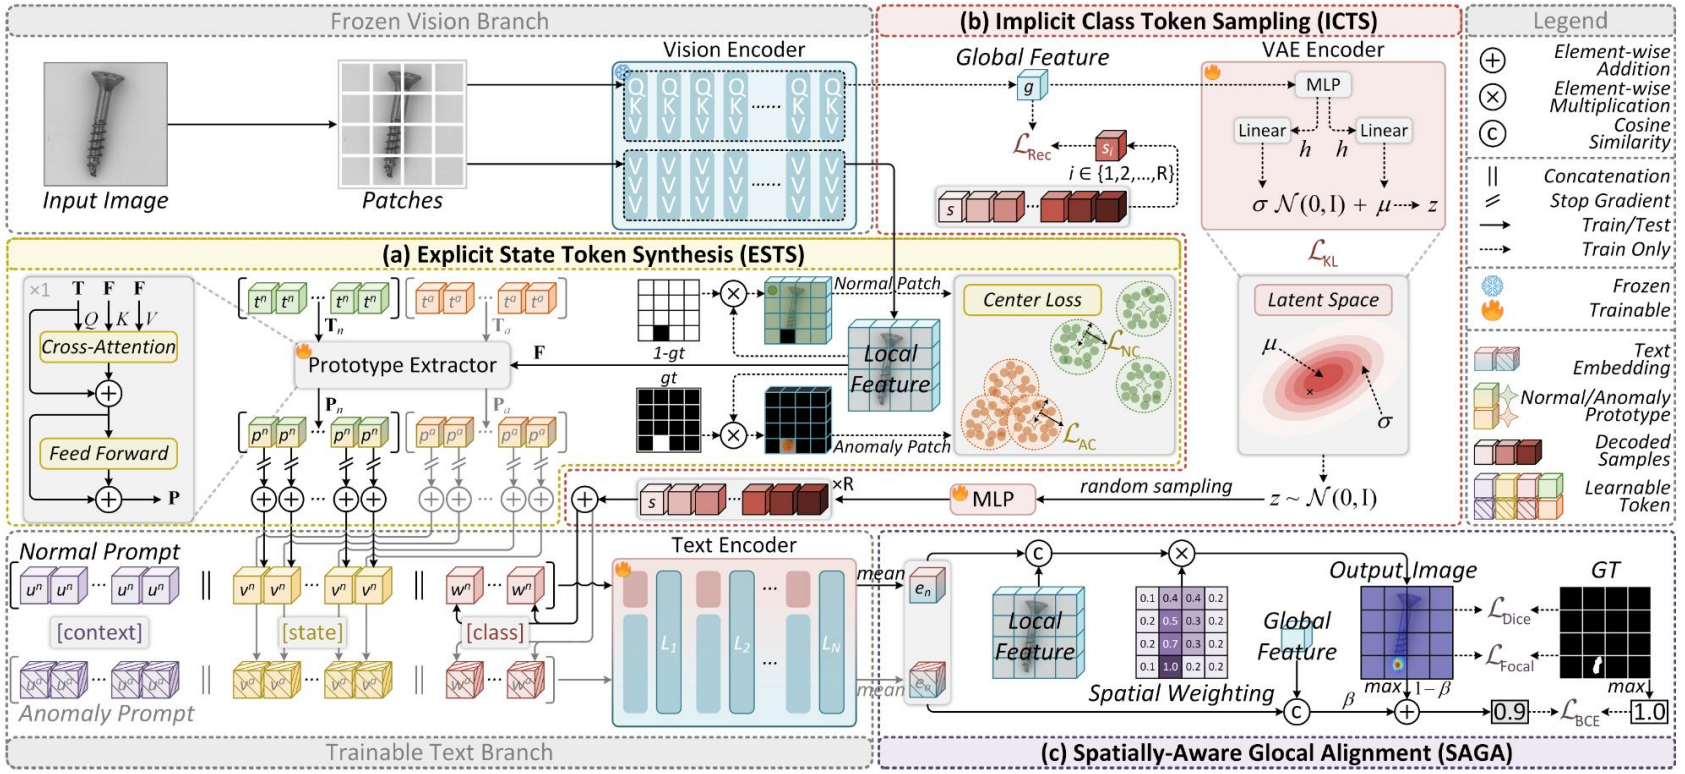



Figure 2. Schematic of CoPS. (a) ESTS extracts normal and anomaly prototypes from fine-grained local features and injects them into the state words. (b) ICTS leverages a VAE to model semantic global features and fuses decoded samples into the class words. (c) SAGA applies distance-aware spatial attention to align textual embeddings with global and local visual features.

- **显式状态 token 合成（ESTS）**

从局部 patch 特征中提取正常/异常原型，并显式注入 state tokens。

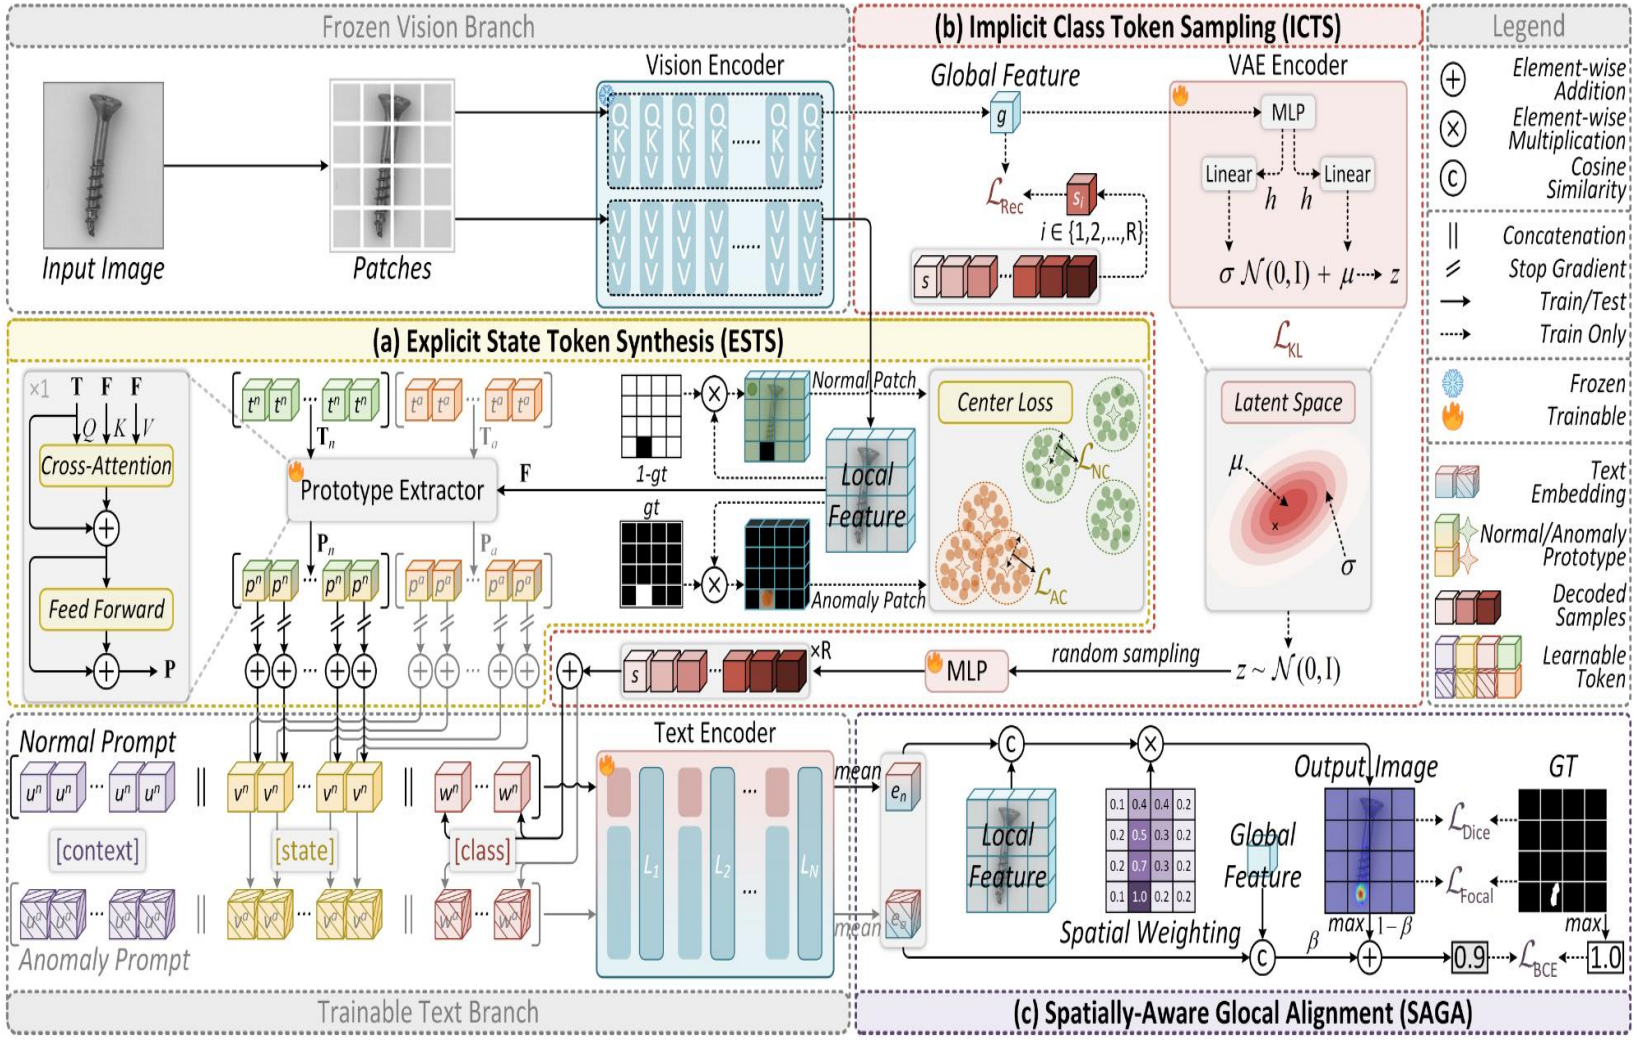
- **隐式类别 token 采样（ICTS）**

用 VAE 建模全局图像语义分布，采样得到更丰富的 class tokens。

- **空间感知全局- 局部对齐（SAGA）**

用原型距离引导空间注意力，同时融合全局与局部相似度，提升分类和定位效果。

# 显式状态 token 合成（ESTS）



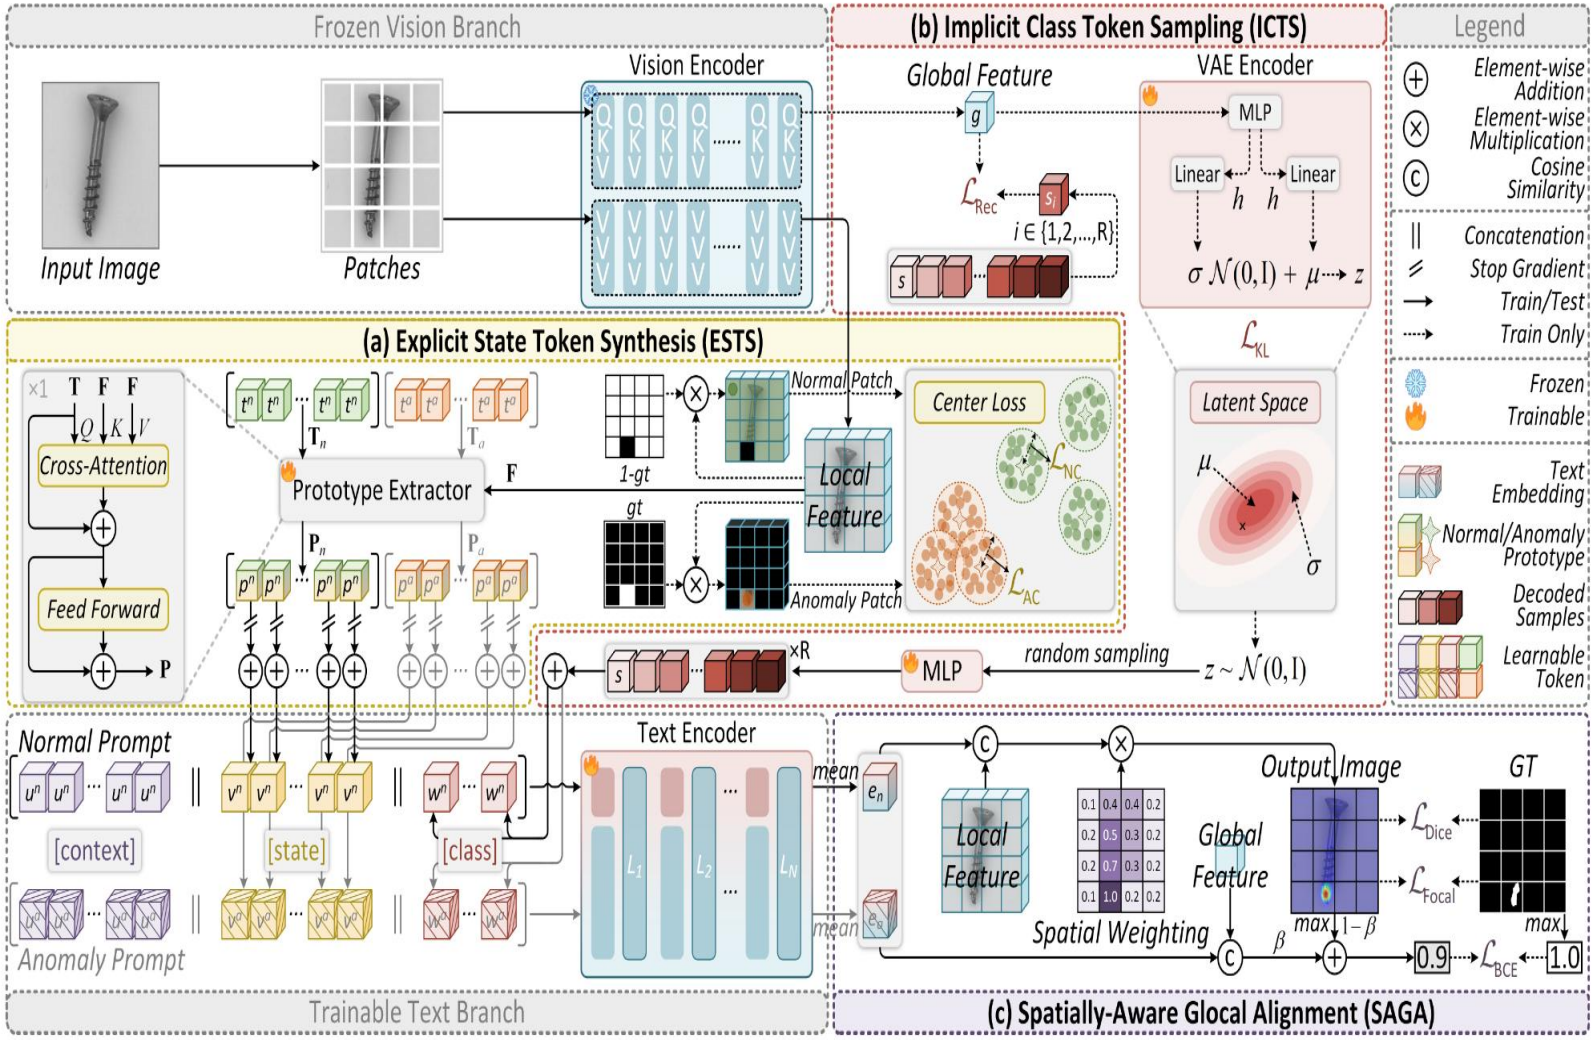

## ➢ 详细设计

从图像的局部 patch 特征中提取正常原型和异常原型，并将这些细粒度视觉原型显式注入到表示 normal、anomaly、defective 等状态语义的 token 中，使状态词不再只是固定文本语义，而是能结合当前图像中的真实局部视觉模式。

## ➢ 作用

ESTS 能利用局部视觉原型强化文本提示中的状态表达，从而提升异常区域定位能力和正常/异常判别能力。

# 隐式类别 token 采样（ICTS）



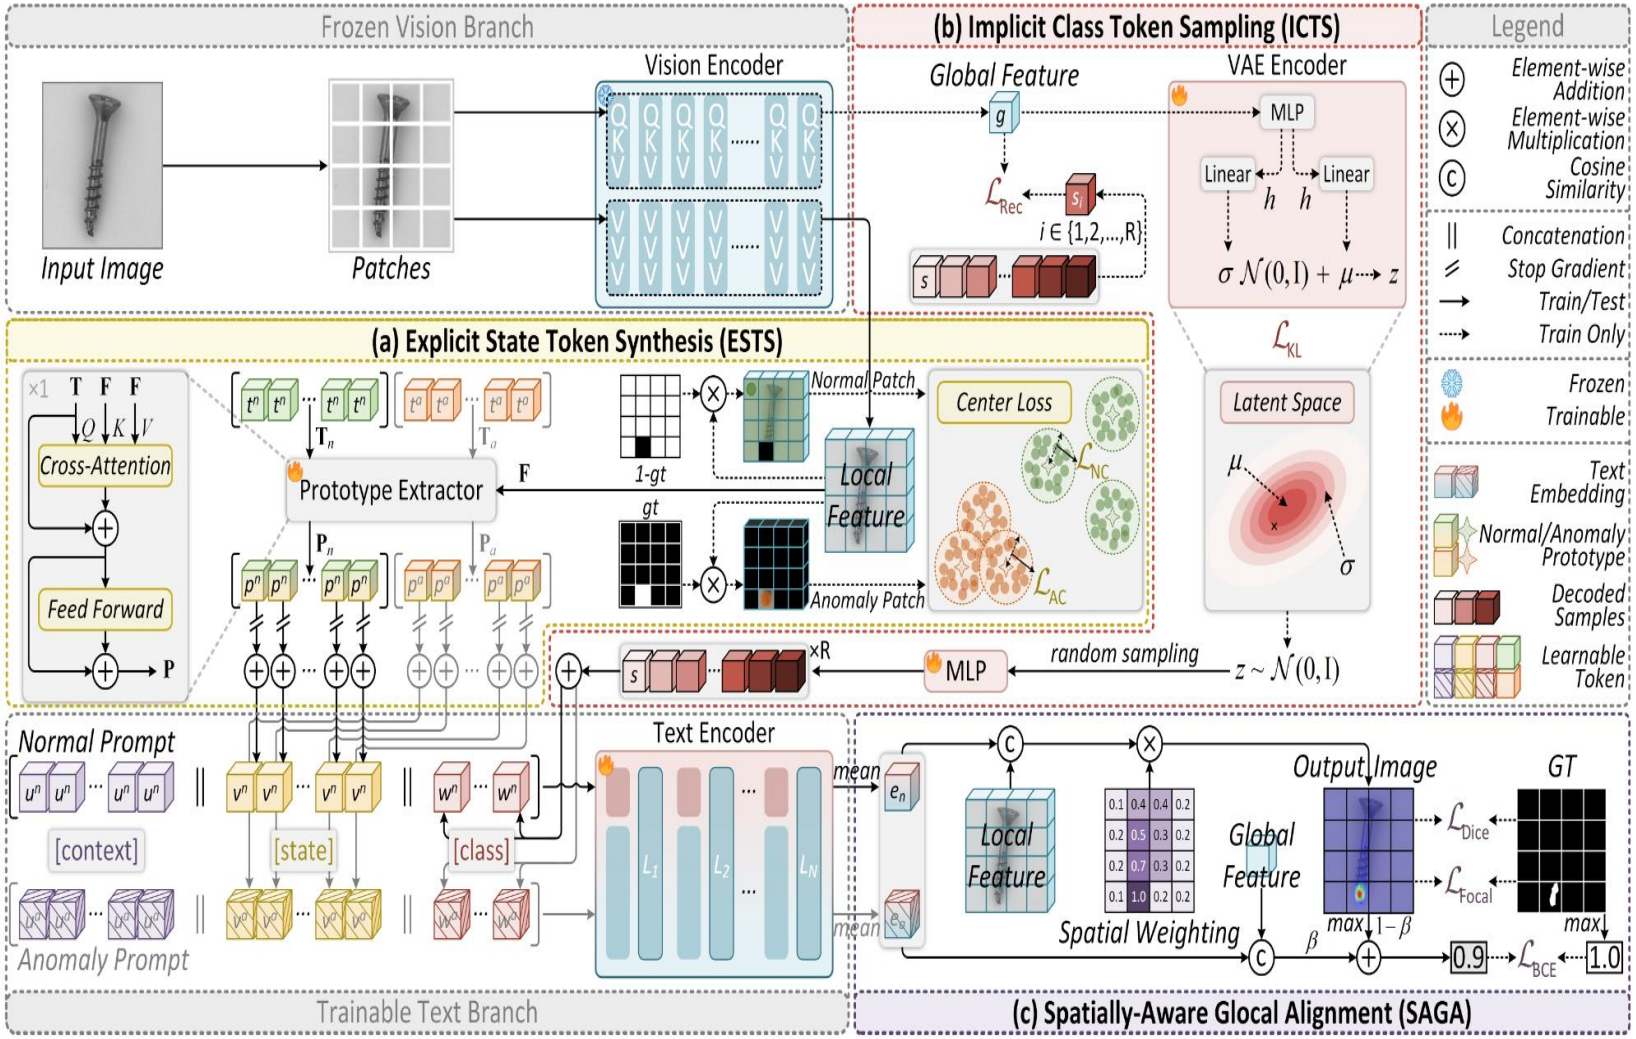

## ➢ 详细设计

利用图像的全局特征，通过 VAE 建模类别相关的潜在语义分布，并从该分布中采样生成多个隐式类别语义向量，再将这些向量融合到 class token 中，使类别词能够适应当前输入图像的整体语义。

## ➢ 作用

ICTS 通过全局语义采样让 class token 更具动态性和泛化能力，从而帮助文本嵌入更好地与视觉特征对齐，提升零样本异常检测中的类别适应性。

# SAGA：空间感知全局对齐




## ➢ 详细设计

利用文本嵌入与局部 patch 特征计算相似度生成异常热力图，再根据热力图对局部特征进行空间加权，最后将加权后的局部特征与整图全局特征融合，并与正常/异常文本嵌入进行对齐。

## ➢ 作用

SAGA 不只判断整张图是否异常，也会关注异常可能出现的位置，使全局语义对齐受到局部异常区域的引导，从而同时提升异常热力图的定位质量和图像级异常分类性能。

# 实验

- **数据集：**工业数据集：MVTec-AD、VisA、BTAD、MPDD、DTD-Synthetic
  医学数据集：HeadCT、BrainMRI、Br35H、ISIC、ColonDB、ClinicDB、Kvasir、Endo
- **实验采用标准 ZSAD 设置：**在一个辅助数据集上训练，在类别不重叠的工业或医学数据集上测试。模型使用 OpenAI CLIP ViT-L/14@336px 作为 backbone，输入图像 resize 到 518 x 518。
- **对比方法：**WinCLIP、APRIL-GAN、CLIP-AD、AdaCLIP（提示设计类）；AnomalyCLIP、FAPrompt（提示学习类）。
- **评价指标：**

| 指标 | 评价层面 | 输入对象 | 衡量内容 |
|---|---|---|---|
| I-AUROC | 图像级 | 每张图的异常分数 | 是否能区分正常图和异常图 |
| I-AP | 图像级 | 每张图的异常分数 | 异常图检出的精确率-召回率表现 |
| P-AUROC | 像素级 | 每个像素的异常分数 | 是否能区分正常像素和异常像素 |
| P-AP | 像素级 | 每个像素的异常分数 | 异常区域分割的精确率-召回率表现 |

# 实验结果

Table 1. Performance comparison of various SOTA methods on industrial and medical datasets under ZSAD setting, as measured by I-AUROC% / I-AP%. The best results are highlighted in bold, and the second-best results are underlined.

| Domain ↓ | Method → / Dataset ↓ | Prompt Design | | | | Prompt Learning | | |
|---|---|---|---|---|---|---|---|---|
| | | WinCLIP CVPR'23 | APRIL-GAN CVPRw'23 | CLIP-AD IJCAI'24 | AdaCLIP ECCV'24 | AnomalyCLIP ICLR'24 | FAPrompt ICCV'25 | CoPS |
| Industrial | MVTec-AD | 91.8 / 95.1 | 86.1 / 93.5 | 89.8 / 95.3 | 92.0 / 96.4 | 91.5 / 96.2 | 91.9 / 95.9 | **95.0 / 97.8** |
| | VisA | 78.1 / 77.5 | 78.0 / 81.4 | 79.8 / 84.3 | 83.0 / 84.9 | 82.1 / 85.4 | 84.0 / 86.7 | **85.4 / 88.0** |
| | BTAD | 83.3 / 84.1 | 74.2 / 71.7 | 85.8 / 85.2 | 91.6 / 92.4 | 89.1 / 91.1 | 92.3 / 90.1 | **93.6 / 94.9** |
| | MPDD | 61.5 / 69.2 | 76.8 / **82.9** | 71.6 / 76.3 | 76.4 / 80.4 | 73.7 / 76.5 | 76.5 / 80.3 | **78.6** / 81.1 |
| | DTD-Synth | 95.0 / 97.9 | 83.9 / 93.6 | 91.5 / 96.8 | 92.8 / 97.0 | 94.5 / 97.7 | 94.9 / 97.6 | **95.2 / 98.1** |
| Medical | HeadCT | 83.7 / 81.6 | 89.3 / 89.6 | 93.8 / 92.2 | 93.4 / 92.2 | 95.3 / 95.2 | **96.1** / 96.6 | **96.1 / 97.1** |
| | BrainMRI | 92.0 / 90.7 | 89.6 / 84.5 | 92.8 / 85.5 | 94.9 / 94.2 | 96.1 / 92.3 | 95.9 / 96.2 | **97.4 / 97.6** |
| | Br35H | 80.5 / 82.2 | 93.1 / 92.9 | 96.0 / 95.5 | 95.7 / 95.7 | 97.3 / 96.1 | 97.2 / 96.1 | **98.7 / 98.5** |
| Average Performance | | 83.2 / 84.8 | 83.9 / 86.3 | 87.6 / 88.9 | 90.0 / 91.7 | 90.0 / 91.3 | 91.1 / 92.4 | **92.5 / 94.1** |

Table 2. Performance comparison of various SOTA methods on industrial and medical datasets under ZSAD setting, as measured by P-AUROC% / P-AP%. The best results are highlighted in bold, and the second-best results are underlined.

| Domain ↓ | Method → / Dataset ↓ | Prompt Design | | | | Prompt Learning | | |
|---|---|---|---|---|---|---|---|---|
| | | WinCLIP CVPR'23 | APRIL-GAN CVPRw'23 | CLIP-AD IJCAI'24 | AdaCLIP ECCV'24 | AnomalyCLIP ICLR'24 | FAPrompt ICCV'25 | CoPS |
| Industrial | MVTec-AD | 85.1 / 18.0 | 87.6 / 40.8 | 89.8 / 40.0 | 86.8 / 38.1 | 91.1 / 34.5 | 90.4 / 34.6 | **93.4 / 41.9** |
| | VisA | 79.6 / 5.00 | 94.2 / 25.7 | 95.0 / 26.3 | 95.1 / **29.2** | 95.5 / 21.3 | **95.7** / 21.4 | **95.7** / 23.4 |
| | BTAD | 71.4 / 11.2 | 91.3 / 32.9 | 93.1 / **46.7** | 87.7 / 36.6 | 93.3 / 42.0 | 93.7 / 40.4 | **94.6** / 42.6 |
| | MPDD | 71.2 / 14.1 | 95.2 / 24.9 | 96.7 / 26.3 | 95.2 / 28.5 | 96.2 / 28.0 | 93.9 / 26.2 | **97.5 / 30.9** |
| | DTD-Synth | 82.5 / 11.6 | 96.6 / **67.3** | 97.1 / 62.3 | 94.1 / 52.8 | 97.6 / 52.4 | 97.6 / 53.5 | **98.4** / 58.5 |
| Medical | ISIC | 83.5 / 62.4 | 85.8 / 69.8 | 81.6 / 65.5 | 85.4 / 70.6 | 88.4 / 74.4 | 90.4 / 77.7 | **93.8 / 85.6** |
| | ColonDB | 64.8 / 14.3 | 78.4 / 23.2 | 80.3 / 23.7 | 79.3 / 26.2 | 81.9 / 31.3 | 85.2 / 36.7 | **85.6 / 37.2** |
| | ClinicDB | 70.7 / 19.4 | 86.0 / 38.8 | 85.8 / 39.0 | 84.3 / 36.0 | 85.9 / 42.2 | 85.5 / 45.1 | **88.8 / 49.9** |
| | Kvasir | 69.8 / 27.5 | 80.2 / 42.4 | 82.5 / 46.2 | 79.4 / 43.8 | 81.8 / 42.5 | 84.0 / 46.6 | **85.8 / 51.5** |
| | Endo | 68.2 / 23.8 | 84.1 / 47.9 | 85.6 / 51.7 | 84.0 / 44.8 | 86.3 / 50.4 | 88.4 / 55.8 | **90.0 / 58.7** |
| Average Performance | | 74.7 / 20.7 | 87.9 / 41.4 | 88.8 / 42.8 | 87.1 / 40.7 | 89.8 / 41.9 | 90.5 / 43.8 | **92.4 / 48.0** |

- 在ZSAD设置下，通过I - AUROC % / I-AP %来衡量各种SOTA方法的工业和医疗数据集上的性能比较。最好的结果用粗体突出，次好的结果用下划线突出。

- 在ZSAD设置下，通过P - AUROC % / P-AP %来衡量各种SOTA方法在工业和医疗数据集上的性能比较。最好的结果用粗体突出，次好的结果用下划线突出。

| 指标 | CoPS 平均结果 | 相比此前最佳方法提升 |
|---|---|---|
| 图像级 I-AUROC | 92.5% | +1.4% |
| 图像级 I-AP | 94.1% | +1.7% |
| 像素级 P-AUROC | 92.4% | +1.9% |
| 像素级 P-AP | 48.0% | +4.2% |

- CoPS 不只提升了图像级分类，也明显增强了像素级异常定位。尤其在医学分割相关数据集上，P-AP 的提升比较突出，说明模型对病灶区域的覆盖和定位更稳定。

# 消融实验

采用I - AUROC % / P-AUROC %来衡量ZSAD设定下CoPS中不同组分在工业和医疗数据集上的性能消融情况。

Table 3. Performance ablation of different components in CoPS on industrial and medical datasets under ZSAD setting, as measured by I-AUROC% / P-AUROC%. The best results are highlighted in bold, and the second-best results are underlined.

| Module ↓ | Model Variants | | | | | | | Ours |
|---|---|---|---|---|---|---|---|---|
| | (A) | (B) | (C) | (D) | (E) | (F) | (G) | |
| **ESTS** | × | ✔ | × | × | ✔ | ✔ | × | ✔ |
| **ICTS** | × | × | ✔ | × | ✔ | × | ✔ | ✔ |
| **SAGA** | × | × | × | ✔ | × | ✔ | ✔ | ✔ |
| MVTec-AD | 91.1 / 92.0 | 93.2 / 93.0 | 91.7 / 92.0 | 92.4 / 92.2 | 94.5 / 93.3 | 93.5 / 93.3 | 92.6 / 92.2 | **95.0 / 93.4** |
| BTAD | 91.6 / 92.4 | 93.0 / 93.7 | 92.0 / 92.9 | 91.9 / 94.0 | 93.4 / 93.8 | 93.3 / 94.4 | 92.4 / 94.2 | **93.6 / 94.6** |
| HeadCT | 94.2 / - | 94.8 / - | 94.3 / - | 94.6 / - | 95.0 / - | 95.5 / - | 95.6 / - | **96.1 / -** |
| Endo | - / 88.5 | - / 89.0 | - / 88.6 | - / 88.9 | - / 89.3 | - / 89.7 | - / 89.1 | **- / 90.0** |
| Average | 92.3 / 91.0 | 93.7 / 91.9 | 92.7 / 91.2 | 93.0 / 91.7 | 94.3 / 92.1 | 94.1 / 92.5 | 93.5 / 91.8 | **94.9 / 92.7** |

- 单独加入 ESTS、ICTS 或 SAGA，相比基础 prompt learning 框架都有提升。
- ESTS 对图像级和像素级指标的贡献最大，说明正常/异常原型对零样本泛化非常关键。
- ICTS 主要提升 prompt 的语义多样性，尤其有助于图像级分类。
- SAGA 对定位质量帮助明显，通过空间权重减少误检和漏检。

# 消融实验

状态 token 和类别 token 长度的消融

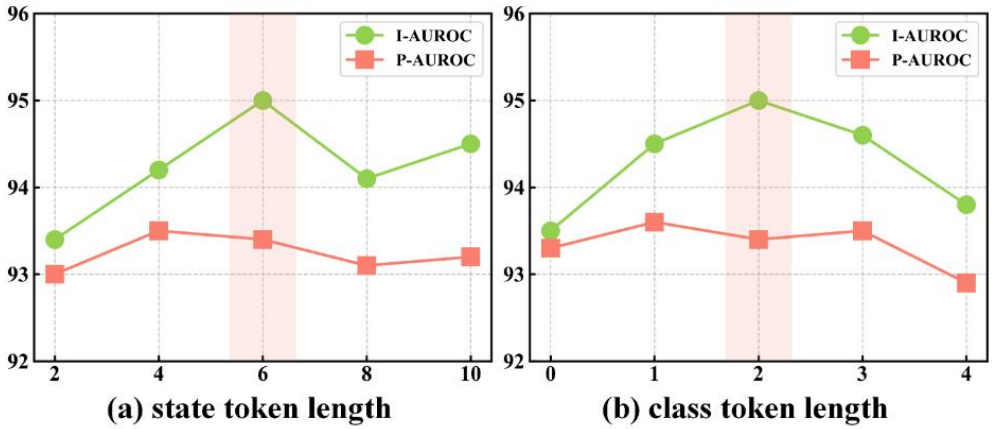



Figure 5. Performance ablation of state and class token length.

状态 token 长度 M=6、类别 token 长度 N=2 时效果最好。过短会表达不足，过长则可能带来过拟合。

距离系数和 glocal 系数的消融

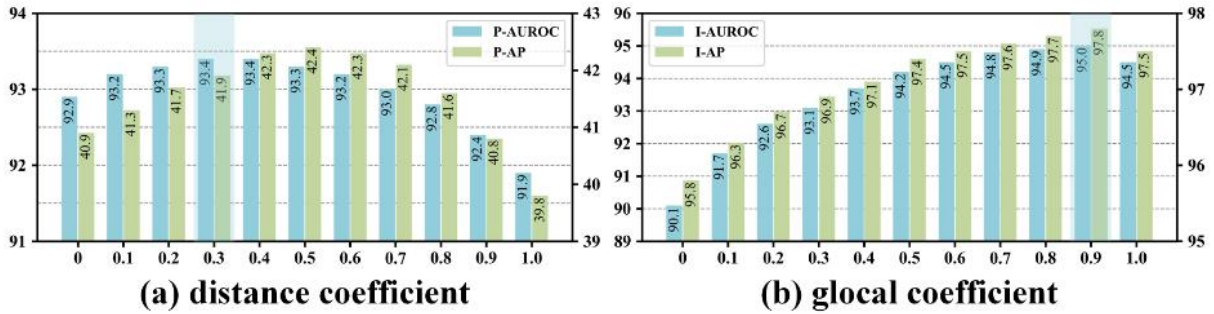



Figure 6. Performance ablation of distance and glocal coefficient.

SAGA 中的距离系数 alpha=0.3、glocal 系数 beta=0.9 表现较好。尤其是 beta=1.0 时性能下降，说明只依赖全局信息不够，局部异常响应对零样本检测仍然重要。

# CoPS 与 AdaCLIP、AnomalyCLIP 的定性可视化对比

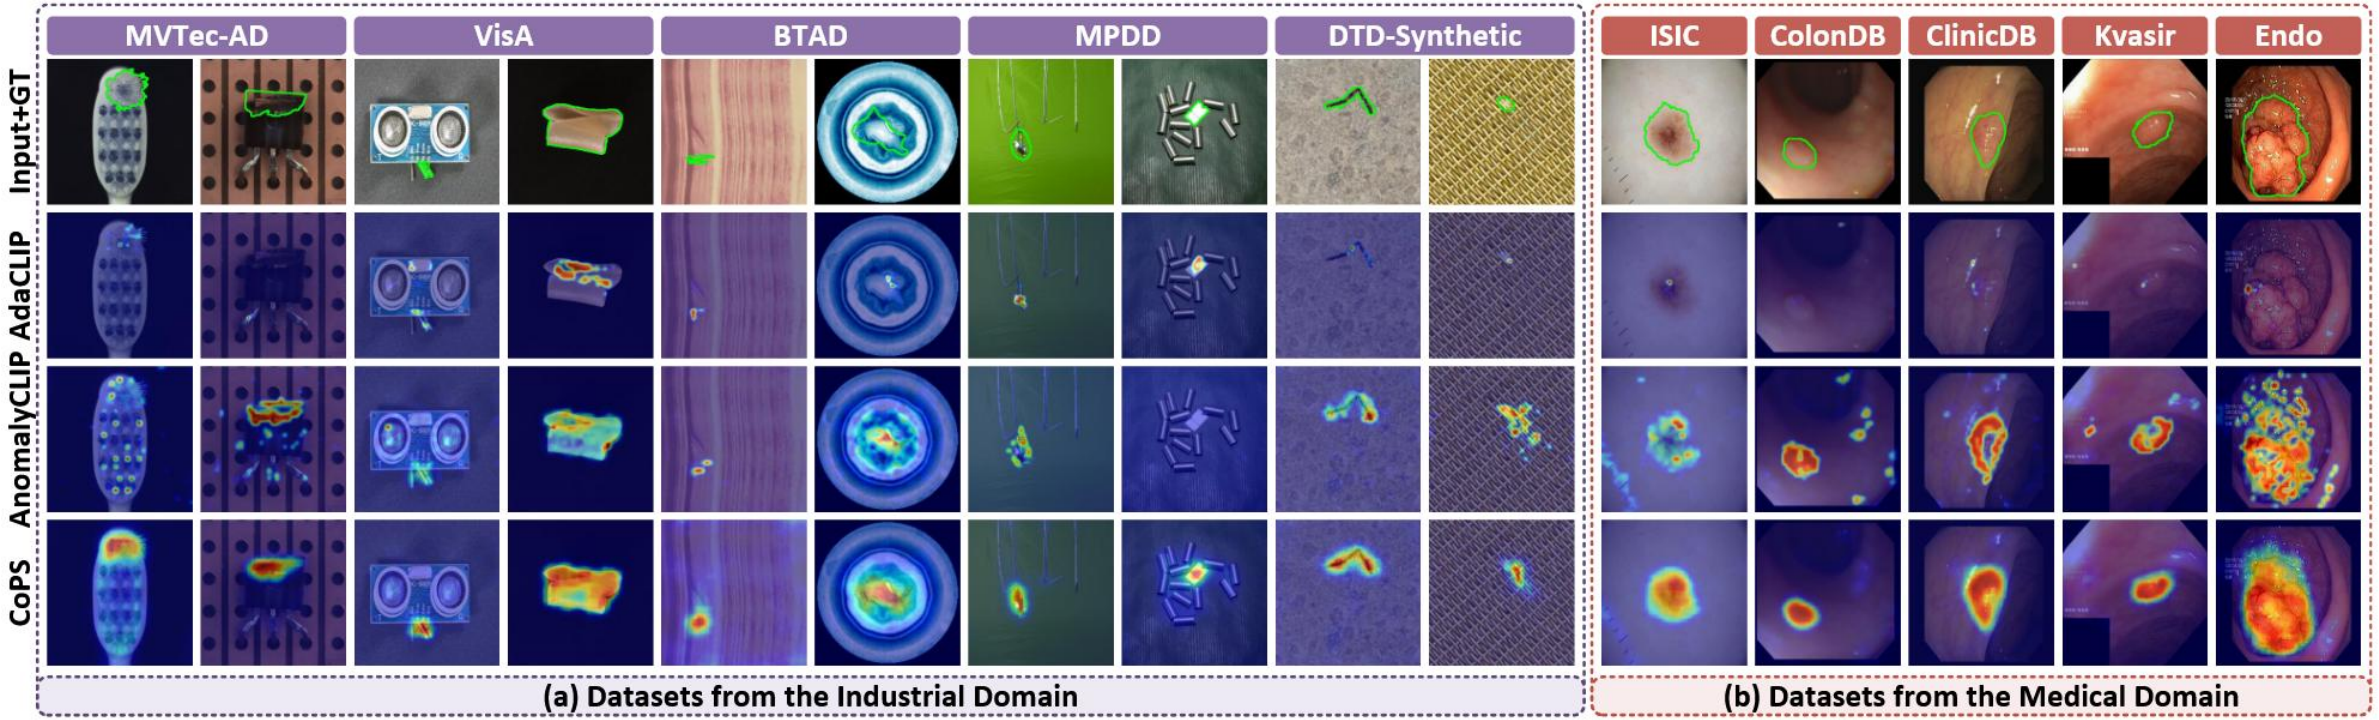



Figure 4. Qualitative comparison of CoPS against representative methods (AdaCLIP [4] and AnomalyCLIP [45]) across multiple datasets.

CoPS 与 AdaCLIP、AnomalyCLIP 在多个工业和医学数据集上进行可视化对比，CoPS 在工业图像上能精确框出缺陷区域，减少物体前景上的误报；医学图像上病变覆盖更完整，而过检现象明显少于 AnomalyCLIP。相比 AdaCLIP，CoPS 缓解了漏检；相比 AnomalyCLIP，抑制了正常区域的过度激活。

# 总结

## ➢ 总结

本文提出了CoPS，一种针对ZSAD的条件提示合成框架，CoPS通过显式视觉原型注入与隐式语义类别采样，解决了静态提示离散化和标签稀疏两大难题，配合空间感知的全局-局部对齐，在 13 个工业和医学数据集上取得了零样本异常检测的 SOTA 性能。

## ➢ 局限性

尽管CoPS在检测各种工业和医疗数据集的结构异常方面表现出强大的性能，但在处理需要高级语义推理的异常方面仍然有限。这种局限性源于现有框架缺乏对对象关系和功能语义的深入理解。

## ➢ 未来前景

未来工作将引入多模态大语言模型（MLLMs），提升对需要高层次语义推理的逻辑异常检测能力，以适应更复杂的实际场景。

# 谢 谢！