External Knowledge Injection for CLIP-Based Class-Incremental Learning
基于CLIP的类增量学习的外部知识注入

汇报人：李德志

2026/10/25

北京工業大學

目　　录



背景



相关工作



方法



实验

研究背景与动机

➢ CLIP模型的缺陷

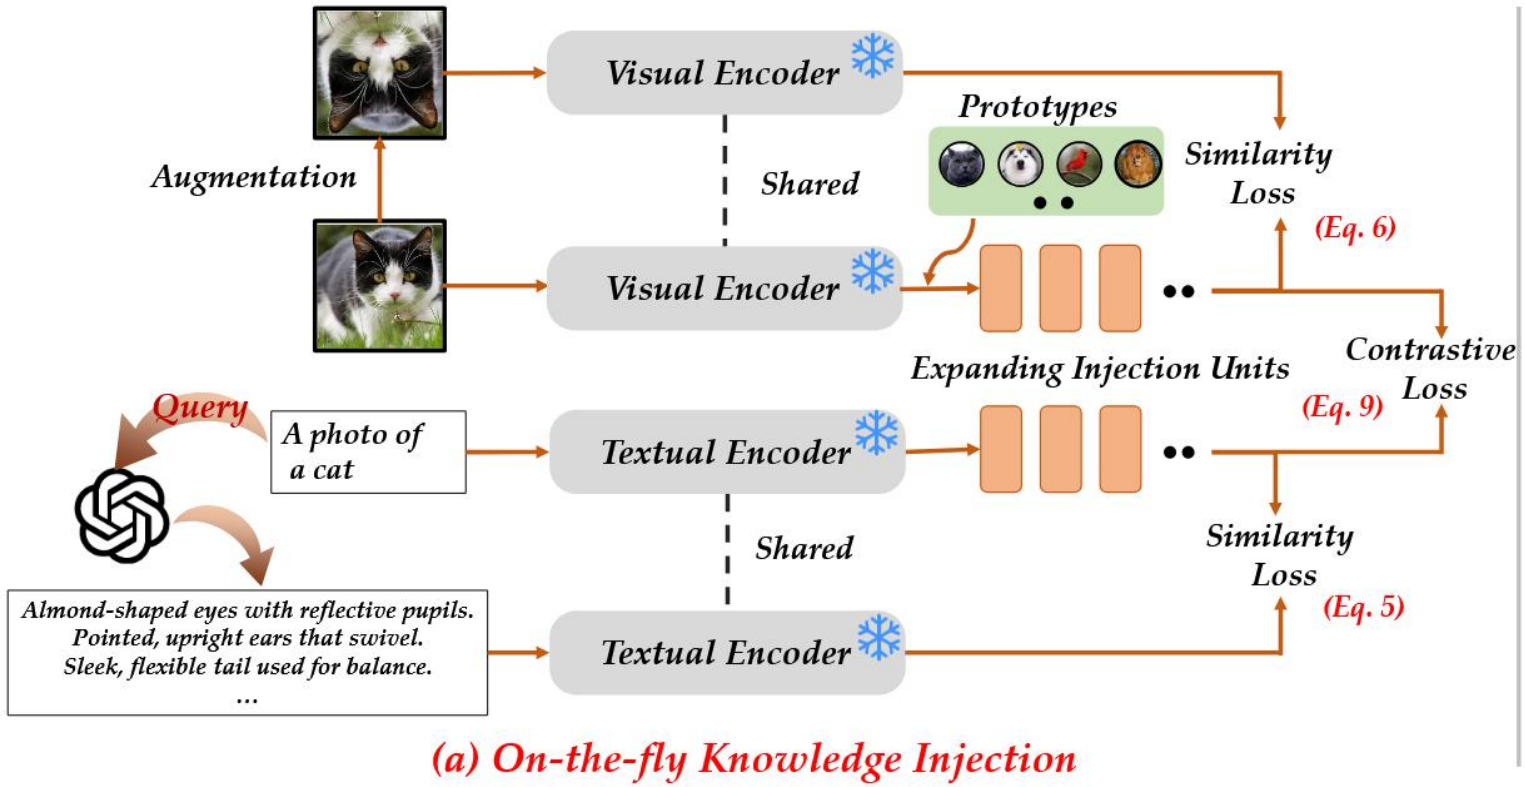
CLIP通过将图像与类别名称进行跨模态匹配来实现零样本识别，但仅依靠“a photo of a [CLASS]”这样的固定模板会丢失丰富的上下文信息（如“猫”可被分解为“胡须”“尾巴”“皮毛”等判别性特征）。

➢ CIL中面临的挑战

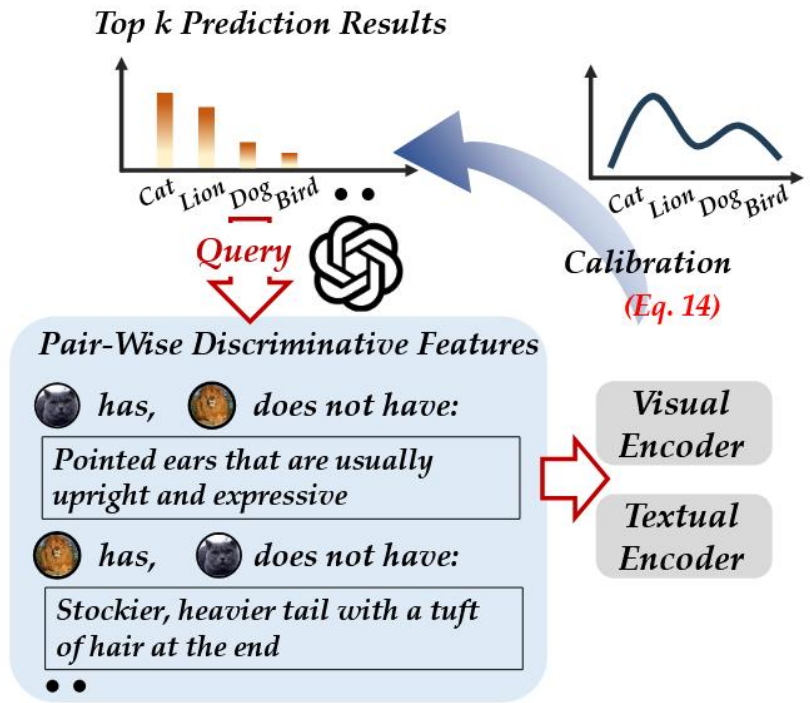
在增量学习过程中，模型不断更新，这些细粒度特征会被覆盖，导致遗忘加剧。现有方法多采用可学习的提示（prompts），但视觉提示难以分解类名中的精细概念，文本提示则容易对训练集过拟合。

因此，论文提出ENGINE方法，通过注入外部知识来增强模型对旧知识的记忆和对新类别的判别能力。

整体结构



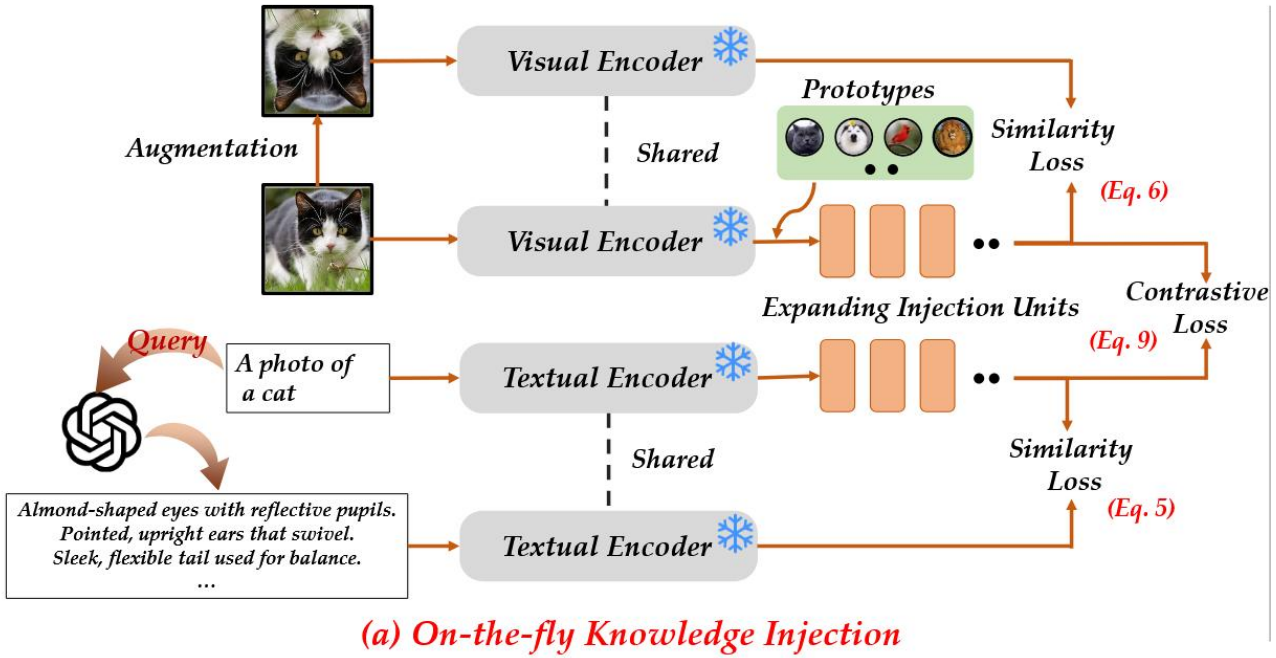
(a) On-the-fly Knowledge Injection



(b) Post-tuning Knowledge Injection

动态知识注入

- 文本知识注入：利用 GPT-4 为每个类别生成具有判别性的视觉特征描述，并通过相似度损失将这些细粒度知识注入线性注入单元。
- 视觉知识注入：通过数据增强丰富视觉特征，并注入对应的视觉注入单元。
- 防遗忘机制：为每个任务扩展新的注入单元并冻结旧单元，同时利用旧类别的视觉原型及高斯噪声进行重放，以防止对先前知识的遗忘。

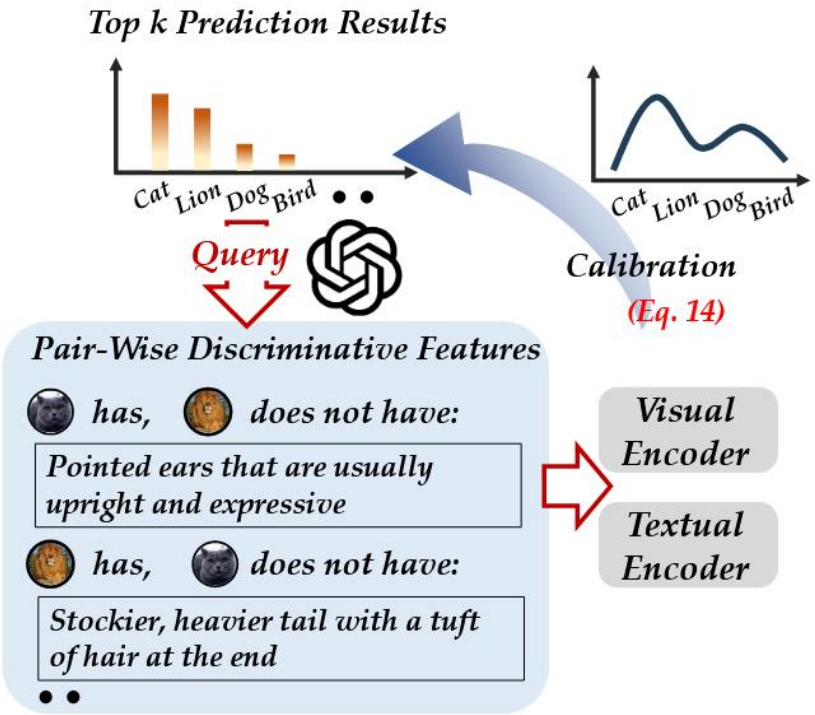


(a) On-the-fly Knowledge Injection

Q: What are unique visual features of $[\text{CLASS}]_i$ in a photo? Focus on the key visual features.
A: **1.** Long, thin tail that aids in balance. **2.** · · ·

后调优知识注入

- 候选集生成：对于一个查询图像，首先使用在线阶段训练好的模型 得到一个初步的预测分布，并选出Top-k个得分最高的类别 。
- 局部判别性特征生成：利用GPT-4为这个类别中的任意两类生成能区分它们的判别性描述 。
- 结果精炼：使用原始的零样本CLIP模型，计算图像 与这些成对判别性描述的匹配度，并对每个候选类的得分进行平均，得到后调优得分 ：
- 最终预测：最终的预测结果是初始预测和后调优得分的结合：



(b) Post-tuning Knowledge Injection

Q: What are unique visual features of $[\text{CLASS}]_i$ compared to $[\text{CLASS}]_j$ in a photo? Focus on their key visual differences.
A: $[\text{CLASS}]_i$: **1.** Long, thin tail that aids in balance $\cdots$ $[\text{CLASS}]_j$: **1.** Stockier, heavier tail with a tuft of hair at the end $\cdots$

实验

- **数据集：**九个具有领域偏移的基准数据集，包括CIFAR100、CUB200、ObjectNet、ImageNet-R、FGVCAircraft、StanfordCars、Food101、SUN397和UCF101。
- **数据划分：**采用'B-mInc-n'设置，其中m是初始任务的类别数，n是后续每个增量任务的类别数。例如，“B0 Inc10”表示从0个基类开始，每次增量学习10个新类。
- **评测指标：**A_B 是模型完成最后一个阶段后的性能，$\overline{A}$ 是模型在所有增量阶段上的平均性能。
- **对比基线：**与多种SOTA方法进行比较，包括：
  1. 基于预训练模型的CIL方法：L2P, DualPrompt, CODA-Prompt, SimpleCIL。
  2. 基于CLIP的CIL方法：CoOp, PROOF, RAPF。
  3. 标准的Finetune和零样本CLIP (ZS-CLIP) 作为基准。
  4. 一些需要样本回放的传统方法（如iCaRL）作为对比。

实验结果

- **总体性能：**
  - 在这些基准数据集上，ENGINE比当前的SOTA提高了3 %～10 %。
  - 对于基于视觉提示的方法，如L2P，DualPrompt和CODA - Prompt，由于无法利用文本信息，性能受到限制。
  - 对于文本提示调优方法,如CoOp，由于文本提示的遗忘而取得了较差的性能。
  - 对于其他基于CLIP的方法，如RAPF，ENGINE仍然有很大的改进。
- **结论：**ENGINE 能够更好地融合视觉与文本信息、缓解灾难性遗忘，从而在类增量学习中展现出更强的性能与稳定性。

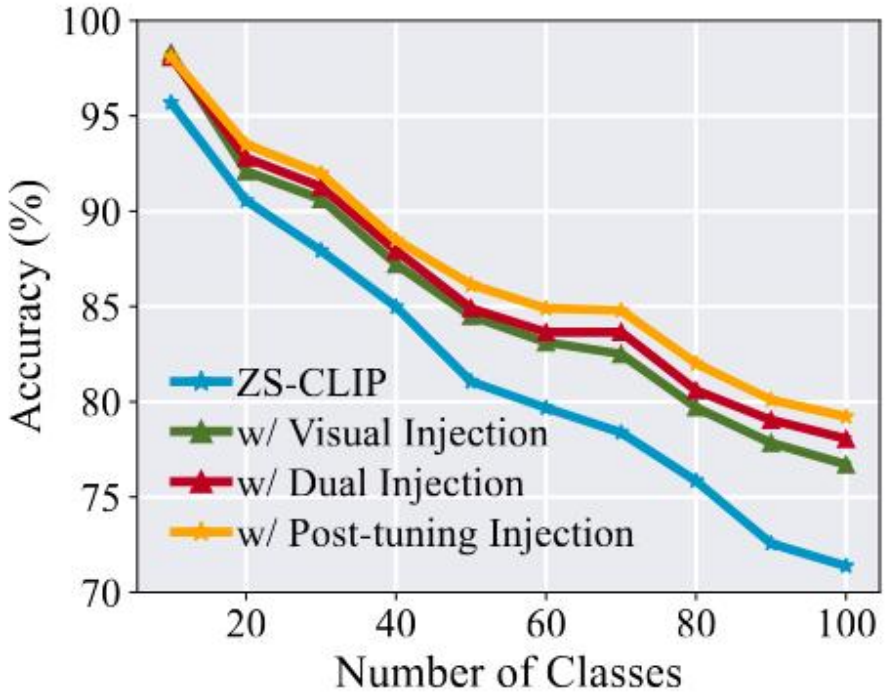
Table 1. Average and last performance comparison of different methods. The best performance is shown in bold. **All methods are initialized with the same pre-trained CLIP without exemplars for a fair comparison.**

Method	Aircraft				CIFAR100				Cars			
	B0 Inc10		B50 Inc10		B0 Inc10		B50 Inc10		B0 Inc10		B50 Inc10	
	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$
Finetune	3.16	0.96	1.72	1.05	7.84	4.44	5.30	2.46	3.14	1.10	1.54	1.13
CoOp [89]	14.54	7.14	13.05	7.77	47.00	24.24	41.23	24.12	36.46	21.65	37.40	20.87
SimpleCIL [85]	59.24	48.09	53.05	48.09	84.15	76.63	80.20	76.63	92.04	86.85	88.96	86.85
ZS-CLIP [50]	26.66	17.22	21.70	17.22	81.81	71.38	76.49	71.38	82.60	76.37	78.32	76.37
L2P [66]	47.19	28.29	44.07	32.13	82.74	73.03	81.14	73.61	76.63	61.82	76.37	65.64
DualPrompt [65]	44.30	25.83	46.07	33.57	81.63	72.44	80.12	72.57	76.26	62.94	76.88	67.55
CODA-Prompt [54]	45.98	27.69	45.14	32.28	82.43	73.43	78.69	71.58	80.21	66.47	75.06	64.19
RAPF [26]	50.38	23.61	40.47	25.44	86.14	78.04	82.17	77.93	82.89	62.85	75.87	63.19
ENGINE	**69.69**	**58.69**	**64.38**	**59.02**	**86.92**	**79.22**	**83.15**	**79.47**	**94.14**	**90.08**	**91.61**	**90.03**

Method	ImageNet-R				CUB				UCF			
	B0 Inc20		B100 Inc20		B0 Inc20		B100 Inc20		B0 Inc10		B50 Inc10	
	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$
Finetune	1.37	0.43	1.01	0.88	2.06	0.64	0.56	0.47	4.51	1.59	1.21	0.80
CoOp [89]	60.73	37.52	54.20	39.77	27.61	8.57	24.03	10.14	47.85	33.46	42.02	24.74
SimpleCIL [85]	81.06	74.48	76.84	74.48	83.81	77.52	79.75	77.52	90.44	85.68	88.12	85.68
ZS-CLIP [50]	83.37	77.17	79.57	77.17	74.38	63.06	67.96	63.06	75.50	67.64	71.44	67.64
L2P [66]	75.97	66.52	72.82	66.77	70.87	57.93	75.64	66.12	86.34	76.43	83.95	76.62
DualPrompt [65]	76.21	66.65	73.22	67.58	69.89	57.46	74.40	64.84	85.21	75.82	84.31	76.35
CODA-Prompt [54]	77.69	68.95	73.71	68.05	73.12	62.98	73.95	62.21	87.76	80.14	83.04	75.03
RAPF [26]	81.26	70.48	76.10	70.23	79.09	62.77	72.82	62.93	92.28	80.33	90.31	81.55
ENGINE	**86.22**	**80.37**	**83.63**	**80.98**	**86.65**	**80.20**	**82.59**	**79.30**	**94.35**	**90.03**	**92.51**	**89.58**

Method	SUN				Food				ObjectNet			
	B0 Inc30		B150 Inc30		B0 Inc10		B50 Inc10		B0 Inc20		B100 Inc20	
	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$	$\bar{\mathcal{A}}$	$\mathcal{A}_B$
Finetune	4.51	1.59	0.78	0.72	3.49	1.71	2.14	1.52	1.34	0.47	0.69	0.54
CoOp [89]	45.93	23.11	39.33	24.89	36.01	14.18	33.13	18.67	21.24	6.29	16.21	6.82
SimpleCIL [85]	82.13	75.58	78.62	75.58	87.89	81.65	84.73	81.65	52.06	40.13	45.11	40.13
ZS-CLIP [50]	79.42	72.11	74.95	72.11	87.86	81.92	84.75	81.92	38.43	26.43	31.12	26.43
L2P [66]	82.82	74.54	79.57	73.10	85.66	77.33	80.42	73.13	51.40	39.39	48.91	42.83
DualPrompt [65]	82.46	74.40	79.37	73.02	84.92	77.29	80.00	72.75	52.62	40.72	49.08	42.92
CODA-Prompt [54]	83.34	75.71	80.38	74.17	86.18	78.78	80.98	74.13	46.49	34.13	40.57	34.13
RAPF [26]	82.13	72.47	78.04	73.10	88.57	81.15	85.53	81.17	48.67	27.43	39.28	28.73
ENGINE	**85.04**	**78.54**	**81.57**	**78.45**	**89.81**	**83.89**	**86.89**	**83.94**	**59.11**	**45.19**	**51.32**	**44.99**

消融实验



(a) Ablation study

➢ **消融实验：**

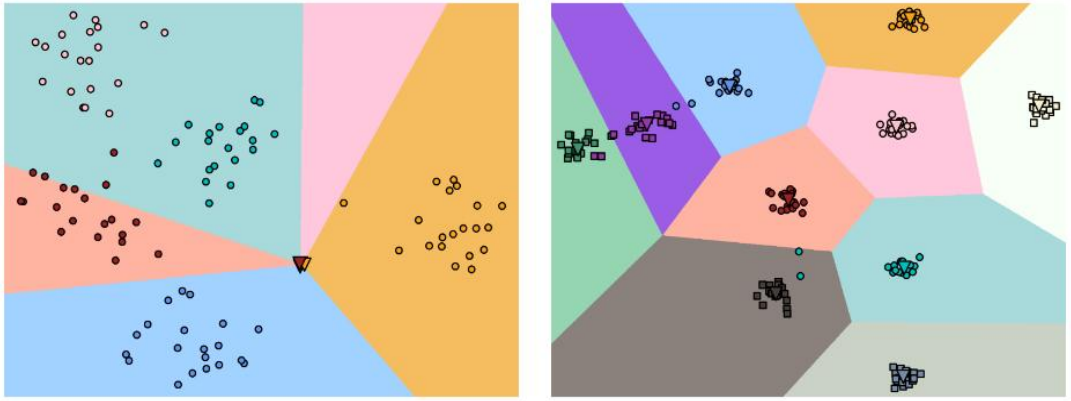
图a的消融实验清晰地展示了各个组件的贡献。从基线ZS-CLIP开始，依次加入“视觉注入”、“双分支注入（视觉+文本）”和“后调优注入”，模型的性能稳步提升。这证明了双分支设计以及后调优机制的必要性和有效性。

可视化分析

➢ 零样本CLIP和ENGINE的t-SNE可视化

经过 ENGINE 处理后：

- 各类别的图像特征聚类更加紧凑、分离更加清晰；
- 文本特征移动到相应图像特征簇的附近，实现视觉—文本对齐；
- 第一阶段的圆点类与第二阶段的方块类都得到清晰的决策区域；
- 旧类别在学习新类别后仍能保持良好的特征结构，未发生明显遗忘。



(a) ZS-CLIP, single stage (b) ENGINE, two stages

Figure 5. t-SNE [59] visualizations of zero-shot CLIP and ENGINE. ENGINE aligns the cross-modal features without forgetting. We represent the visual features of the first task with dots and classes of the second task with squares. The textual features are represented by triangles, and we utilize the shadow area to denote the decision boundary.

可视化分析

- ENGINE在注入外部知识并进行后调优前后，模型预测结果的变化

  - 知识注入可能暂时导致视觉特征与文本分类知识之间不完全匹配
  - 后调优可以重新校准跨模态特征和分类边界，使正确类别的预测排名上升，从而提升最终分类准确率。
  - 其他相似类别仍保持较高分数，也反映了图像在外观或语义上存在一定歧义。

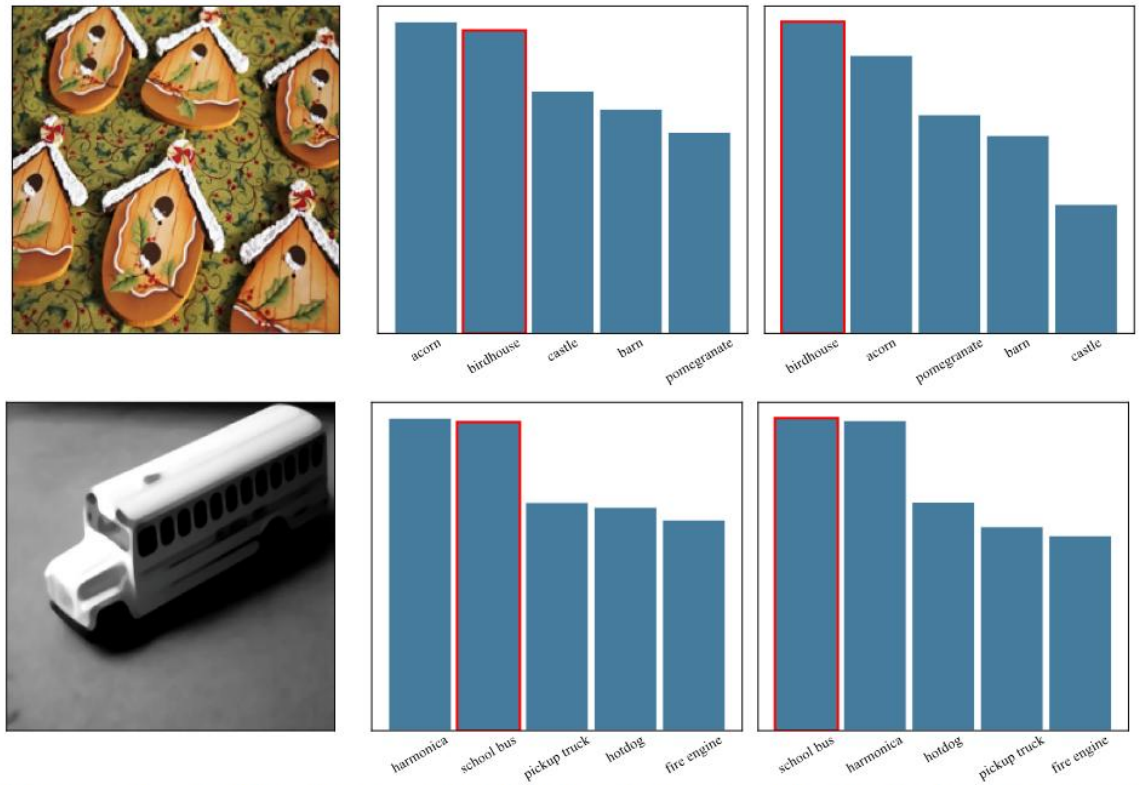


Figure 6. **Left:** Input. **Middle:** Top-5 predictions before post-tuning knowledge injection. **Right:** Top-5 predictions after post-tuning. More cases are shown in the supplementary.

总结

- **总结：**本文成功提出并验证了一种通过注入外部知识来增强CLIP模型类增量学习能力的新范式ENGINE。该方法极大地提升了CIL的性能，尤其是在处理细粒度或易混淆类别时。
- **局限性：**ENGINE方法依赖于GPT-4这类强大的LLM来提供专家知识，这在某些GPT-4无法泛化的特定领域或在无法访问LLM服务的场景下可能成为瓶颈。
- **未来工作：**首先，可以探索其他形式的外部知识，例如知识图谱，它们能提供更结构化的实体间关系信息。其次，可以研究如何降低对特定大型LLM的依赖，例如通过知识蒸馏将大型LLM的能力迁移到更小的专用模型中，或者探索无需外部API调用的知识生成方法。

谢 谢！