From GPS Points to Travel Patterns: Flexible and Semantic Trajectory Generation with LLMs

汇报人：段梦奥

2026年10月

轨迹生成：从隐私困境到方法局限

为什么需要轨迹生成?

- 城市轨迹是建模城市动态、支持智慧城市应用的核心数据
- 隐私保护限制了大规模高质量轨迹数据集的获取
- 轨迹生成通过合成真实数据来缓解隐私风险，是可行的替代方案

现有方法的三大局限

- 忽略宏观模式：直接在微观GPS点层面生成，缺乏对出行模式的显式建模，导致拥堵、加速等段级行为不真实
- 条件受限：多数方法仅利用起终点坐标作为条件，忽略出行距离、时间、道路等多重约束
- 固定长度：扩散模型受限于固定长度序列（如200个点），无法支持真实世界中的变长轨迹生成

核心思路： 不直接生成GPS点，而是**先层次化生成出行模式（Travel Patterns），再由模式生成GPS点**，借助大语言模型的强大生成能力实现灵活、语义化的轨迹生成。

HTP：层次化出行模式生成框架

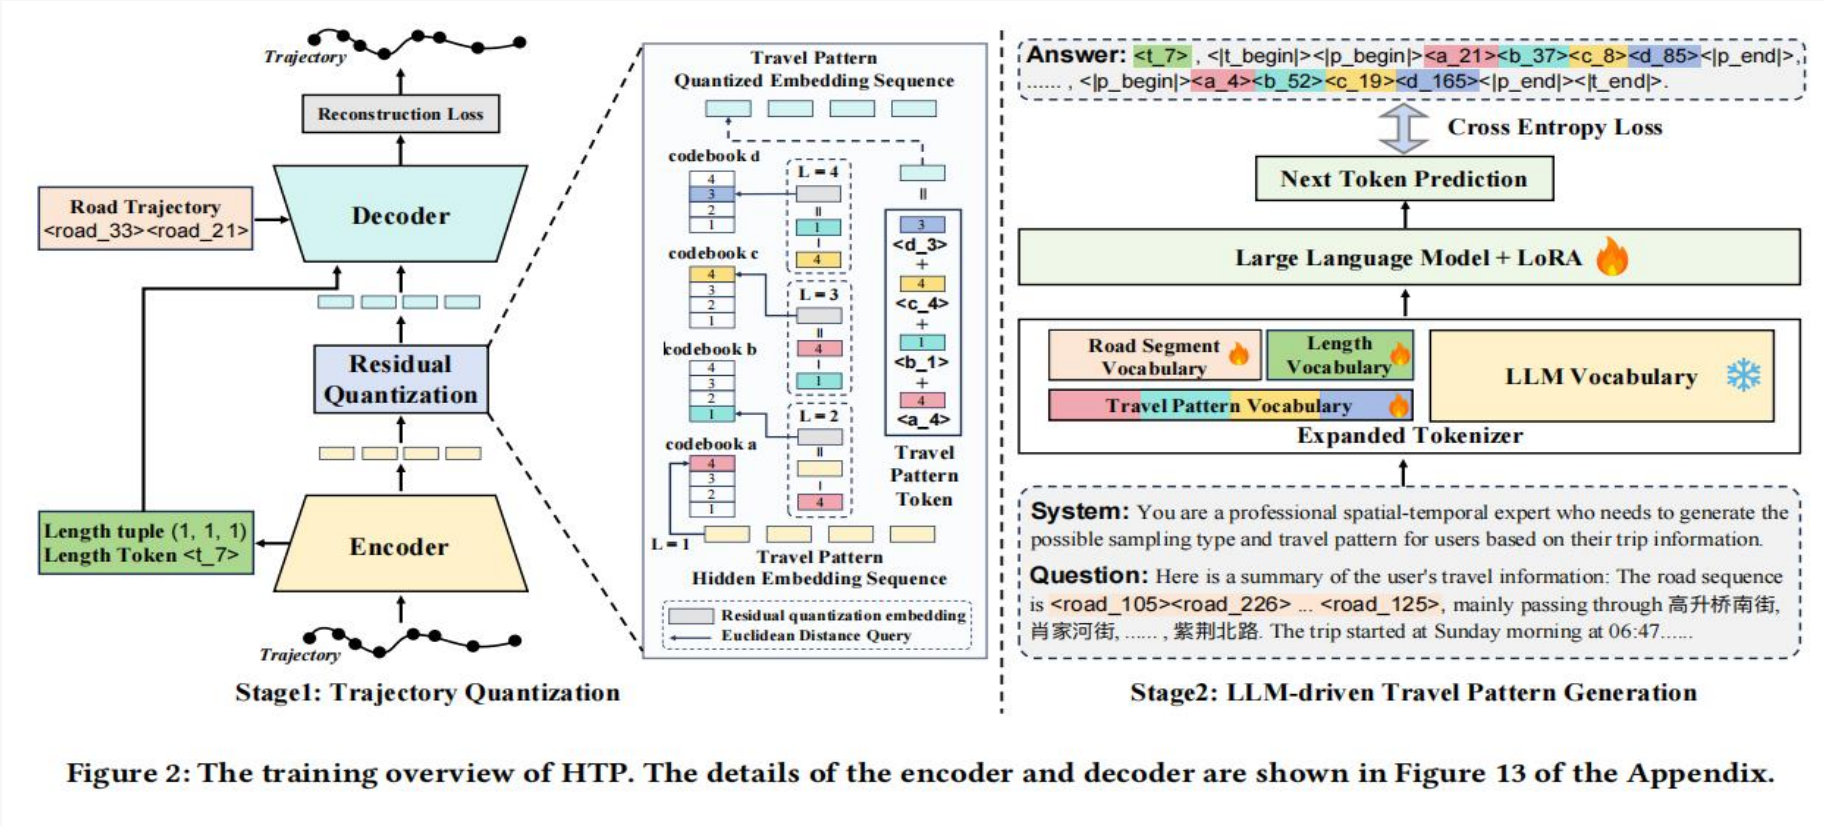


Figure 2: The training overview of HTP. The details of the encoder and decoder are shown in Figure 13 of the Appendix.

图：HTP 两阶段训练流程 —— Stage 1: 轨迹量化 (RQ-VAE) • Stage 2: LLM 驱动的出行模式生成

RQ-VAE：将GPS轨迹编码为出行模式Token

编码器设计

- CNN 与 Transformer 层交替使用，同时捕捉局部和全局移动特征
- 记录每步奇偶长度变化，解码器精准恢复原始序列长度

残差量化（Residual Quantization）

- 粗到细的多层码本：每层修正上一层的量化残差
- 4层量化，码本大小 {32, 64, 128, 256}
- 浅层编码粗粒度模式，深层捕捉细粒度特征

关键创新：相对重建损失（Relative Reconstruction Loss）

不在自由空间直接重建GPS坐标（精度极高，优化困难），而是将轨迹对齐到道路段上：
① **相对位置百分比损失**：预测每个点在道路段上的相对位置，捕捉点密度变化 ② **偏移损失**：建模GPS设备噪声导致的横向偏移

扩展LLM词表，实现多条件变长生成

扩展的Token词表

- **道路段 Token** <road_id>：描述途经的道路序列
- **长度 Token** <t_id>：编码下采样过程的奇偶长度变化（共8种）
- **出行模式 Token** <a_*><b_*><c_*><d_*>：对应RQ-VAE各量化层的码本
- 特殊 Token：<|t_begin|> <|t_end|> <|p_begin|> <|p_end|> 标记序列边界

训练与生成流程

- 使用 LoRA 高效微调LLM，对齐轨迹生成任务
- 输入：道路序列 + 出发时间 + 出行时间 + 距离等自然语言描述
- 输出：长度Token + 出行模式Token序列
- 生成的Token → 码本映射 → RQ-VAE解码器 → 最终GPS轨迹

效率优势： 直接用LLM生成GPS点约需 15n~20n 个token；HTP通过RQ-VAE压缩后，出行模式序列长度仅约 n/8，生成token数量减少近两个数量级，显著提升效率。

主实验：两个数据集上全面超越基线

数据集：成都出租车轨迹 · 波尔图出租车轨迹 | 指标：点级 / 网格级 / 道路级

方法	T-Dist↓	S-Dist↓	G-Den↑	G-Pat↑	R-Den↑	R-Pat↑	PR-Dist↓
DiffTraj	0.00052	0.00387	0.951	0.679	0.949	0.521	0.241
ControlTraj	0.00032	0.00920	0.973	0.752	0.965	0.553	0.152
Cardiff	0.00070	0.0240	0.943	0.542	0.941	0.390	0.217
HTP (ours)	0.00027	0.00069	0.996	0.844	0.997	0.941	0.030

关键结论： 在成都数据集上，HTP平均比最强基线提升 29.78% 的生成质量；尤其在段级模式（R-Pat）和道路级距离（PR-Dist）上提升显著（70%+），证明出行模式建模的有效性。

消融实验：各组件缺一不可

变体	T-Dist↓	G-Pat↑	R-Pat↑
w/o RQ-VAE	0.00932	0.732	0.667
w/o R-Loss	0.00244	0.098	0.151
w/o OOV	0.00178	0.752	0.691
w/o LLM	0.00051	0.740	0.913
HTP (full)	0.00027	0.844	0.941

消融结论

- 相对重建损失 影响最大，去掉后G-Pat从0.84暴跌到0.10
- RQ-VAE 去掉后T-Dist飙升34倍，证明量化压缩的关键作用
- 扩展词表(OOV) 带来约12%的G-Pat提升
- LLM 相比普通Transformer显著提升模式多样性

可视化对比： HTP生成的轨迹更清晰地贴合真实道路结构，空间分布更真实，运动模式更平滑，与真实出行行为高度相似；基线方法则容易产生扭曲形状、不真实绕路或散乱的点分布。此外，HTP能有效支持变长轨迹生成，并保持与真实数据一致的长度统计分布。

总结与思考

核心贡献

- 提出层次化生成范式：先生成出行模式，再生成GPS点
- 设计轨迹特定的RQ-VAE与相对重建损失
- 扩展LLM词表，实现多条件变长轨迹生成
- 两个数据集上平均提升 29.78% 生成质量

局限性与未来方向

- 引入LLM带来额外计算开销，可借助vLLM/SGLang加速
- 依赖道路匹配质量，离线路网场景受限
- 未来可探索：用户个性化、多智能体交互、城市场景理解

Thanks