Harnessing Vision-Language Models for Time Series Anomaly Detection

利用视觉-语言模型实现时间序列异常检测

汇报人：穆莹

研究背景

时间序列异常检测（TSAD）

点异常：数值突然大幅偏离（如尖峰）
上下文异常：数值本身不极端，但出现的时间或模式与历史趋势不符（如本该上升的曲线突然停滞）

TSAD 的应用价值
医疗健康：实时监测 ICU 患者生命体征，预警病情恶化。
金融风控：识别异常交易模式，防范欺诈与市场操纵。
工业监测：预测设备故障，实现预测性维护，避免停机损失。
航天器遥测：监控卫星 / 火箭参数，保障航天任务安全。

TSAD 的核心挑战
时间尺度多样：异常可能出现在秒级到小时级等不同时间粒度。
行为模式动态：系统行为随时间 / 环境变化，模型需具备适应性。
视觉 - 时间上下文理解缺失：传统模型难以像人类一样，通过观察图表形态并结合上下文，区分真实异常与良性波动。

现有方法的局限性

传统与深度学习TSAD方法
基于特定领域假设训练，仅能检测表面异常，缺乏上下文理解能力。（如ARIMA）、RNN/LSTM、Transformer、VAE、GAN等

基于大语言模型（LLM）的TSAD方法
将时序转为文本丢失视觉模式（如图形形状、趋势、周期性），如图(a)所示，上下文异常在文本中不明显，但在图中一目了然，token**成本高、检测精度低，易掩盖真实异常模式。**

直接使用视觉语言模型（VLM）的TSAD方法
存在 “分辨率 - 上下文矛盾”如图(b)：
长窗口图：保留全局上下文，但分辨率低，异常定位困难，易遗漏。
短窗口图：分辨率高，但上下文信息有限，token成本高。

一种新颖的两阶段时间序列异常检测（TSAD）框架，**VLM4TS**，旨在利用视觉语言模型（VLM）的能力，同时解决传统方法在精度、效率和上下文理解上的不足。

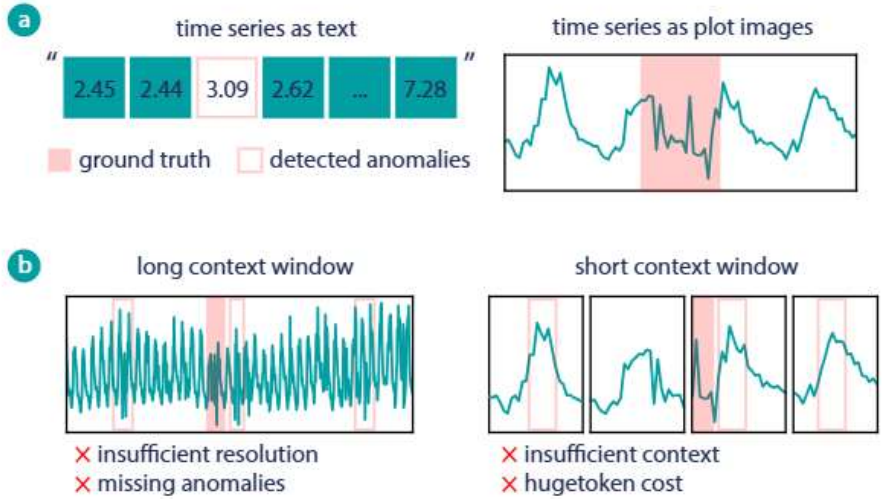

图2：(a) 将时间序列作为文本输入提供给大语言模型可能会掩盖真实的异常，并增加错误检测的概率，而将时间序列可视化为折线图则能使上下文异常（如扭曲）变得易于识别。
(b) 基于视觉语言模型的时间序列异常检测中的分辨率-上下文困境：全局图保留了长程上下文，但压缩了用于检测的细节（左图），而小窗口视图保持了高分辨率，但提供的上下文有限且会产生较高的令牌成本（右图）。

方法

- ✅ 高精度检测（尤其是上下文异常）
- ✅ 精确定位（异常边界清晰）
- ✅ 低成本（低token消耗、快速推理）
- ✅ 零样本泛化（无需领域训练）

↓

将异常检测拆解为"定位"与"验证"两个任务，分别交给轻量级视觉模型和重型VLM处理。

1.第一阶段（ViT4TS）：用**X光机快速扫描全身**，找出所有可疑的区域（高召回、快速、成本低）

2.第二阶段（VLM4TS）：由**专家医生仔细分析**这些可疑区域，结合病人的完整病史，最终确诊哪些是真正的病灶（高精度、全局理解）

ViT4TS 视觉筛选与异常定位

步骤 1：时序转视觉表征
一维时序→无冗余折线图（剔除坐标轴、图例，保留趋势），滑动窗口（窗口长度=224,步长=56）生成图像

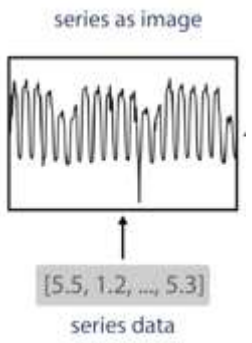

步骤 2：多尺度特征提取
采用 CLIP 视觉编码器，提取补丁级细粒度特征，多尺度池化捕捉「局部细粒度异常 + 全局广上下文异常」

步骤 3：跨补丁匹配评分
基于中位数参考计算余弦相异度，无真实正常样本也能实现异常评分

以所有窗口在相同位置上的中位数特征作为“正常参考”，通过跨补丁的余弦相似度匹配计算每个窗口每个补丁与参考的差异程度，差异越大说明该局部模式越稀有、越可能是异常，从而实现对每个窗口的异常评分

步骤 4：异常区间生成
多尺度评分融合→异常图→阈值筛选，输出高精度候选异常区间

输入输出

一维数值序列
↓
滑动窗口图像集
↓
多尺度patch特征图
↓
异常分数图
↓
候选异常区间

原图像 (224×224)
这是一张输入的图片，尺寸是 224 像素宽 × 224 像素高均匀地分割成许多个更小的正方形小块，也就是“补丁”。

具体分割
分割成 **14×14 个补丁**，每个补丁的大小是 **16×16 像素**。

特征提取
操作：对每个 16×16 的补丁进行分析，提取出它的“特征”。这个特征不是简单的像素值，而是一组能够描述这个补丁内容的数字（向量）。
结果：每个补丁被**转换成一个长度为 D 的特征向量**（D 是特征维度，比如 D=768）。因此，14×14 个补丁就形成了一个 **14×14×D** 的“特征图”。

多尺度池化 (Multi-scale Pooling)

尺度 1：14×14 (原始)
这是特征提取后的原始特征图，没有进行池化。相当于用最精细的放大镜观察，保留了所有细节。
尺度 2：13×13 (2×2 池化)
操作：使用一个 2×2 的 “池化窗口”，在 14×14 的特征图上滑动，每次滑动 1 个单位。
效果：对于每个 2×2 的区域，取平均值作为新的特征值。这样，原来的 14×14 特征图就被 “压缩” 成了 13×13 的特征图。
目的：降低特征图的分辨率，减少计算量，同时保留主要特征。这相当于用稍低倍数的放大镜观察，忽略一些细微末节，关注更主要的结构。
尺度 3：12×12 (3×3 池化)
操作：使用一个 3×3 的 “池化窗口”，在 14×14 的特征图上滑动。
效果：将特征图进一步压缩成 12×12 的大小。

多尺度池化模拟了"从全局到局部"的视觉认知过程。

步骤1：多尺度异常评分融合

尺度	网格大小	特点	适合检测的异常
k=1	14×14	高分辨率，对局部变化敏感	点异常、尖峰
k=2	13×13	中等粒度，聚合2×2区域	短时波动、局部模式
k=3	12×12	粗粒度，聚合3×3区域	趋势偏移、上下文异常

每个尺度的异常分数图网格大小不同（14,13,12），无法直接相加。

将所有尺度的异常分数图上采样到**最精细尺度（14×14）**

使用**调和平均（所有尺度都认为异常**时，融合分数才高）

对于k=2（13×13）：
使用**双线性插值**或**最近邻插值**将13×13扩展到14×14
新网格点(i,j)的值 = 原网格中最近4个点的加权平均
对于k=3（12×12）：
同样上采样到14×14

步骤2：2D异常图 → 1D异常分数曲线

每个窗口的14×14 patch网格，每个patch对应原图中16×16像素区域。而每个像素列对应一个时间点。

设窗口长度为 $L_w = 224$（像素/时间点），patch大小16：

每个patch覆盖16个连续时间点
14个patch覆盖全部224个时间点

映射关系：

窗口内第 c 列像素（时间点） → 对应第 $\lfloor c/16 \rfloor$ 个patch

对所有窗口重复以上映射，形成**二维异常图**　　**分位数降维，压缩为1D**

处理窗口重叠

由于滑动窗口有重叠（步长 $L_s = 56$，窗口长224），每个时间点可能被多个窗口覆盖：

每个窗口独立计算该时间点的异常分数
对同一时间点的多个分数，取**平均值**（或最大值，论文未明确，通常用平均）
最终得到平滑的异常分数曲线 $s(t), t = 1, \ldots, T$

步骤3：阈值筛选与区间提取

使用**高斯分布假设**对异常分数进行阈值化

使用三个阈值水平

对每个阈值，**二值化，提取连续区间，跨阈值合并：**两个区间间隔很小（例如间隔<5个时间点），可以合并为一个区间

论文使用三个阈值水平：
$\alpha = 0.1$：$z_{0.1} \approx 1.28$（较宽松，高召回）
$\alpha = 0.01$：$z_{0.01} \approx 2.33$（中等）
$\alpha = 0.001$：$z_{0.001} \approx 3.09$（严格，高精度）

1.多尺度融合：将k=1,2,3的异常分数图通过调和平均融合，只保留所有尺度都认为异常的区域，减少误报

2.2D→1D映射：将14个高度带的异常分数通过0.25分位数压缩成单一时间点分数，平衡敏感性和鲁棒性

3.重叠处理：对多个窗口覆盖的时间点取平均，得到平滑的异常分数曲线

4.阈值筛选：使用高斯阈值（μ+zσ）将连续异常分数转化为离散区间，生成候选异常区间

5.输出：候选异常区间 $\hat{\mathbf{A}}$，供第二阶段的VLM4TS验证和精细化

VLM4TS 异常验证与优化

1. 视觉输入

将**整条时间序列**（不是窗口）渲染成一张**完整的线图**
包含**清晰的坐标轴刻度**，让VLM能精确定位时间点
这张图展示了全局趋势、季节性、长期模式

2. 文本输入（精心设计的提示）

VLM接收一个结构化提示，包含：

1.候选列表：ViT4TS找出的所有可疑区间（用时间索引表示）

2.任务指令：

1. 确认那些真正偏离全局模式的区间
2. 排除那些与整体趋势一致的误报
3. 补充ViT4TS可能漏掉的异常

3.输出格式：JSON格式，包含：

1. interval_index：精修后的异常区间列表
2. confidence：置信度（1-3分）
3. abnormal_description：简短的自然语言解释

提示词

你的目标是：
- 删除那些看起来异常但与整体趋势一致的可疑窗口
- 添加那些被遗漏但破坏时间连续性的区间（尖峰、突变）
- 尽可能精确地使用x轴刻度确定边界
- 不要标记第一个片段（可能是切片导致的伪像）

VLM4TS 异常验证与优化

3. 最终输出

VLM返回JSON

系统丢弃置信度为1的区间

保留置信度2和3的区间作为最终检测结果

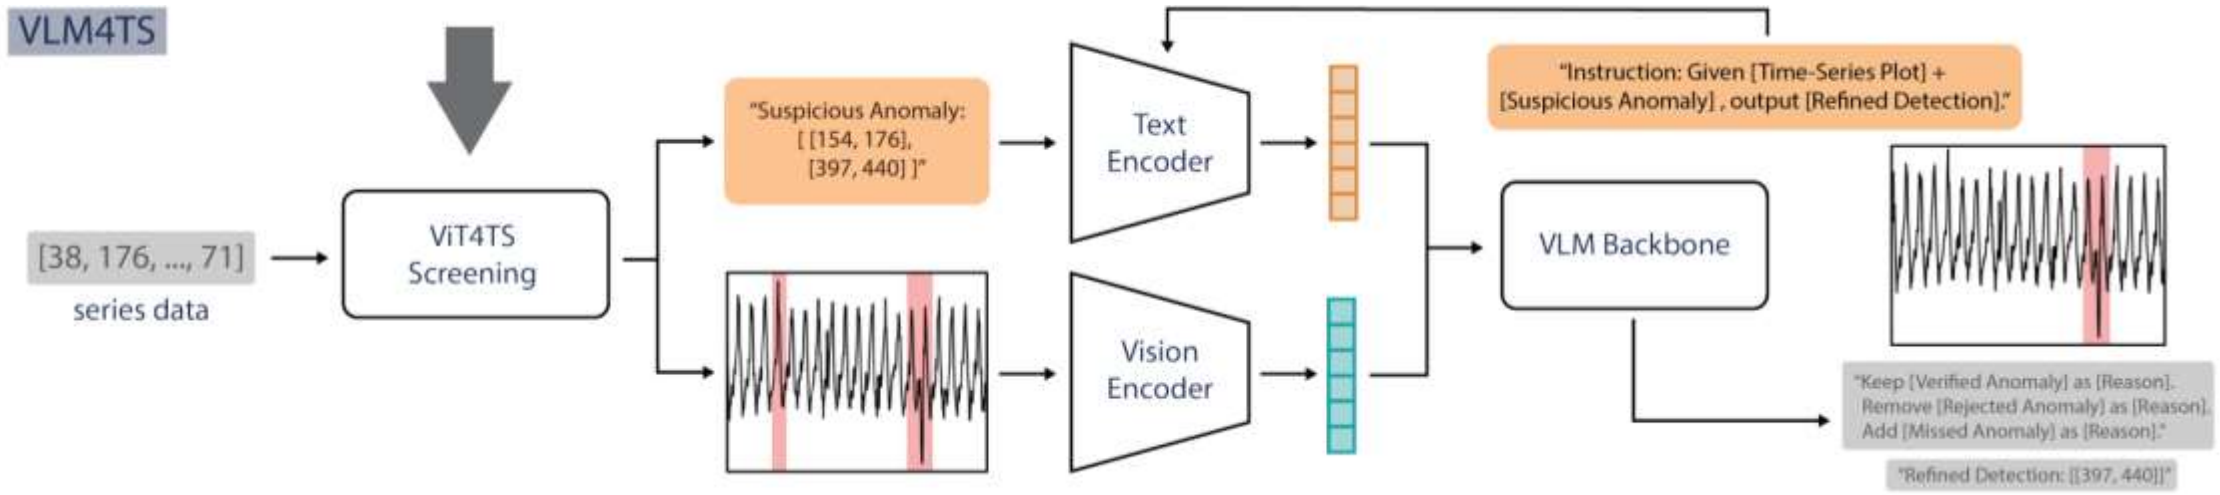

输入：ViT4TS 候选异常区间 + 完整时序带轴折线图（保留全局上下文）
核心操作：设计专属提示词引导 VLM 跨模态推理 —— 剔除假阳性、补充漏检异常、为区间分配 1-3 级置信度
输出：过滤低置信度区间，得到**最终精准异常检测结果**
核心优势：仅对候选区间推理，令牌使用量大幅降低；结合全局上下文，解决局部筛选的局限性

方法概述

作者提出一个两阶段框架，将异常检测任务分解为**局部定位**与**全局验证**：

1. ViT4TS（视觉筛选阶段）
将时间序列转为**二维线图**，使用预训练的视觉编码器（如CLIP）提取多尺度特征；

通过**跨窗口、跨补丁的对比匹配**，生成候选异常区间；

该阶段无需微调，零样本运行，具备高效、高召回的特点。

2. VLM4TS（验证与精修阶段）
将**整条时间序列的全局图像**与候选异常区间输入VLM（如GPT-4o）；

通过自然语言提示，要求模型：

- 确认或排除候选区间；
- 补充遗漏的异常；
- 输出置信度与自然语言解释；

该阶段仅对候选区间进行验证，极大减少token使用与计算成本。

ViT4TS：擅长**精确定位**，用**视觉模式匹配**快速找到异常候选

VLM4TS：擅长**全局推理**，用**语言理解+视觉上下文**做出最终判断

问题解决了吗？

分辨率-上下文困境

方法	窗口大小	分辨率	上下文	成本
传统VLM方法	小窗口	高	局部	高（多次调用）
传统VLM方法	大窗口	低	全局	低
ViT4TS+VLM4TS	第一阶段用小窗口+大窗口	高	全局	低（仅一次VLM调用）

零样本泛化

两个阶段都**不需要在目标数据集上训练：**

ViT4TS使用ImageNet预训练的视觉编码器

VLM4TS使用通用VLM（GPT-4o等）

这使得方法能跨领域泛化，无需重新训练

实验设置

实验数据集：11 个跨领域基准数据集（NAB/NASA/YAHOO），涵盖传感器、网络监控、航天器遥测等（标注真实 / 合成属性）
对比基线模型：6 类方法（统计 ARIMA、深度学习 LSTM-DT/TadGAN、时序预训练 UniTS/TimesFM、LLM-based SigLLM、VLM-based TAMA 等）
评价指标：核心**F1-max（最大 F1 值）**，辅助令牌使用量、推理耗时、精度 / 召回率

Category	Metric	NASA		YAHOO				NAB				
		MSL	SMAP	A1	A2	A3	A4	Art	AdEx	AWS	Traf	Tweets
Properties	Synthetic # signals	No	No	No	Yes	Yes	Yes	Yes	No	No	No	No
# Anomalies	Point (len = 1)	0	0	68	33	935	833	0	0	0	0	0
	Collective (len > 1)	36	67	110	167	4	2	6	11	30	14	33
# Data Points	Anomalous points	7766	54696	1669	466	943	837	2418	795	6312	1560	15651
	Total points	132046	562800	94866	142100	168000	168000	24192	7965	67644	15662	158511

Properties（该数据集是否为**合成信号**（Yes = 人工生成，No = 真实采集））
Anomalies：异常数量统计
Point (len=1)：点异常
Collective (len>1)：集体异常
Data Points：数据规模统计
Anomalous points：异常时间点总数（所有异常区间包含的时间点之和）
Total points：总时间点数量（整个数据集的长度）

Type	Method	NAB					NASA		YAHOO				
		Art	AWS	AdEx	Traf	Tweets	MSL	SMAP	A1	A2	A3	A4	$\mu \pm \sigma$
Trained From Scratch	ARIMA	0.387	0.263	0.500	0.344	0.179	0.585	0.750	0.650	0.771	0.502	0.336	0.479±0.187
	AER	0.338	0.244	0.518	0.404	0.178	0.553	0.753	0.618	0.866	**0.711**	**0.614**	0.527±0.207
	TadGAN	0.338	0.196	0.385	0.421	0.205	0.612	0.593	0.492	0.667	0.135	0.109	0.378±0.189
	LSTM-DT	0.368	0.273	0.444	0.451	0.190	0.615	0.724	0.639	0.877	0.704	0.534	0.529±0.200
	LSTM-AE	0.231	0.244	0.400	0.416	0.232	0.487	0.673	0.583	0.853	0.584	0.201	0.446±0.203
	ATrans	0.262	0.168	0.200	0.365	0.147	0.454	0.567	0.263	0.554	0.437	0.394	0.346±0.142
	VAE	0.000	0.248	0.345	0.323	0.237	0.515	0.695	0.557	0.845	0.524	0.189	0.407±0.234
Time-series Pretrained	UniTS	0.182	0.246	0.326	0.479	0.167	0.561	0.723	0.605	0.760	0.126	0.110	0.390±0.233
	TimesFM	0.234	0.243	0.400	0.467	0.198	0.564	0.686	0.554	0.694	0.120	0.107	0.388±0.209
	TimesFM2	0.255	0.233	0.364	0.386	0.171	0.556	0.676	0.594	0.692	0.202	0.181	0.392±0.194
Ours	**ViT4TS**	0.545	0.400	0.615	0.615	0.597	0.543	0.726	0.614	0.892	0.614	0.565	0.612±0.116
	VLM4TS	**0.714**	**0.488**	**0.727**	**0.632**	**0.686**	**0.619**	**0.773**	**0.733**	**0.901**	0.497	0.474	**0.659±0.127**

整体检测性能

核心结论 1：VLM4TS 在 11 个数据集中 9 个取得最优 F1-max，平均较次优基线（LSTM-DT）提升**24.6%**
核心结论 2：单阶段 ViT4TS 已表现优异，整体排名第二，验证视觉表征的有效性

Type	Method	NAB			NASA			YAHOO			μ		
		F1-max	Tokens	Time	F1-max	Tokens	Time	F1-max	Tokens	Time	F1-max	Tokens	Time
LLM-based	SIGLLM-D	0.353	11153	83.77	0.232	13157	89.50	0.393	21508	62.20	0.326	15273	78.49
	SigLLM-P_M	0.206	14191	613.28	0.157	45050	2107.96	0.276	45082	984.45	0.213	34774	1235.23
	SigLLM-P_G	0.162	25006	2258.78	0.080	78187	2614.87	0.143	83207	2852.52	0.128	62133	2575.39
VLM-based	TAMA	0.513	40009	110.47	0.631	31563	83.49	0.616	27324	68.99	0.587	32965	87.65
Ours	**VLM4TS**	**0.649**	**1219**	**16.71**	**0.696**	**1213**	**20.97**	**0.651**	**1204**	**6.36**	**0.665**	**1212**	**14.68**

核心结论 3：VLM4TS 显著优于 LLM/VLM 基线（较 TAMA 提升 13.3%，较 SigLLM 翻倍）

效率与任务特异性

效率结论：VLM4TS 令牌使用量较朴素 VLM/LLM 方法**平均降低 36 倍**，推理耗时与传统 TSAD 相当，ViT4TS 可 CPU 运行（适配大规模部署）
任务特异性：在**上下文异常为主的真实数据集（如 NAB）** 优势显著；在密集异常合成数据集（A3/A4）稍弱（因模型假设异常稀有）

消融实验与关键组件验证

Method	NAB	NASA	YAHOO
w/o patch-level embedding	0.519	0.578	0.541
w/o cross-patch comparison	0.504	0.613	0.514
w/o column-wise comparison	0.523	0.624	0.565
w/o multi-scale embedding	0.534	0.582	**0.677**
ViT4TS (ours)	**0.555**	**0.635**	0.671
w/o ViT4TS	0.539	0.517	0.292
VLM4TS (ours)	**0.649**	**0.696**	**0.651**

核心结论 1：
ViT4TS 的 3 大核心组件不可替代 —— 补丁级嵌入（-11.94%）、跨补丁匹配（-18.76%）、多尺度嵌入（-8.35%），移除后性能暴跌

核心结论 2：
两阶段设计是关键 —— 省略 ViT4TS 直接用 VLM4TS，F1 值大幅下降（尤其密集异常数据集）

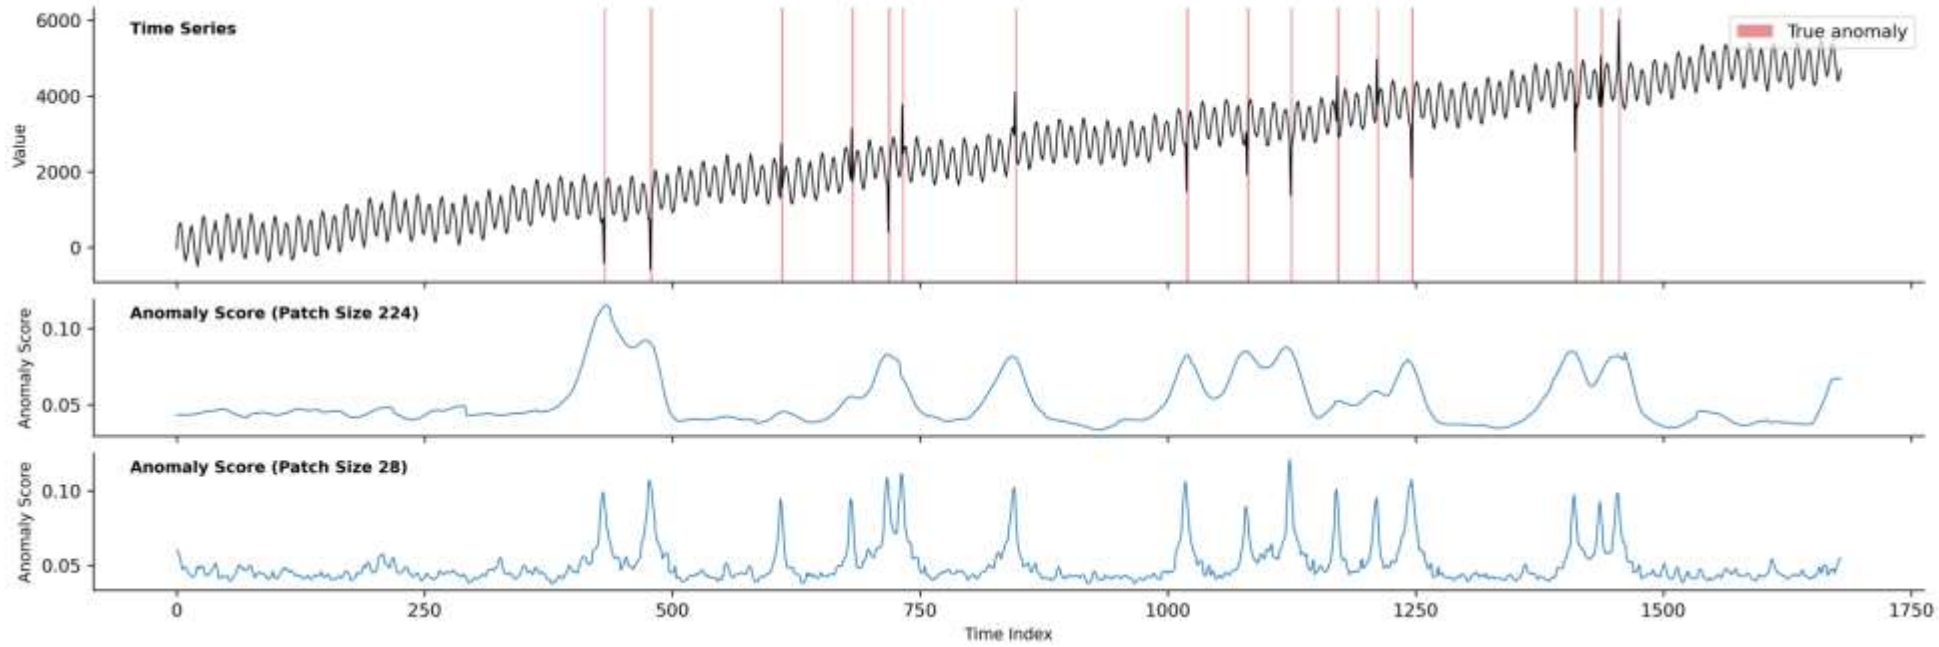

（Patch Size）对异常检测效果的影响对比

最上方：Time Series
黑色曲线：原始时间序列数据
红色竖线：真实异常点（Ground Truth Anomaly）
中间：Anomaly Score (Patch Size 224)
蓝色曲线：使用**大补丁（224 像素）** 提取特征后得到的异常分数
最下方：Anomaly Score (Patch Size 28)
蓝色曲线：使用**小补丁（28 像素）** 提取特征后得到的异常分数

大patch（224）适合捕捉长区间异常，小patch （28）能精准定位密集细粒度异常；ViT4TS 的多尺度设计融合两者优势，实现了对不同类型异常的全面检测。

研究贡献（3 点核心）
1.首次将一维 TSAD 转化为二维视觉理解问题，通过两阶段设计解决 VLM 的分辨率 - 上下文矛盾
2.提出 ViT4TS/VLM4TS 模块，实现零样本跨领域检测，兼顾定位精度与全局验证
3.在跨领域数据集上实现 SOTA 性能，令牌效率提升 36 倍，为 VLM 在 TSAD 的应用提供新范式

局限性
1.提示词策略较简单，时间推理能力有提升空间；
2. 主要聚焦单变量时序，多变量融合待深化；
3. 对密集异常的识别偏保守

未来工作
1.探索思维链 / 检索增强提示词；
2. 深化多变量时序跨通道融合；
3. 开发自适应补丁 / 窗口大小选择策略

谢谢