

Advancing Time Series Classification with Multimodal Language Modeling

基于多模态语言建模的时间序列分类推进

论文汇报

2026/06/28

I Introduction

研究背景、问题动机与核心目标

研究背景：时间序列分类的应用与范式

- **时间序列分类** (TSC) 广泛服务于疾病诊断、工业故障检测、人类行为识别等场景。
- 深度学习方法通常学习从**连续序列输入**到类别标签的映射。
- 主流方法遵循 **learning-to-classify** 范式，将目标类别编码为 one-hot 分布。
- 该范式有效但封闭：模型只学习“样本—类别”的判别关系，较少利用**标签文本**、世界知识和跨域共性。

典型任务

EEG 脑电信号、ECG 心电信号、HAR 人类行为识别、FD 工业故障检测、RWC 真实复杂场景

传统目标

输入时间序列 → 输出预定义类别

论文转向

把分类问题改写为多模态理解与文本生成问题

研究不足：one-hot 标签与跨域迁移的双重瓶颈

不足 1：标签相似性被抹平

one-hot 编码使所有类别彼此正交，无法表达 walking 与 jogging 之间的相似性，也无法利用标签语义辅助泛化。

不足 2：跨域可迁移模式难学

不同领域的时间序列长度、通道、类别体系不同，直接共享分类器参数很困难。


研究目标

- 提出 **InstructTime**，将时间序列分类重塑为 learning-to-generate 范式。
- 把局部时间序列片段与语言 **token** 看作**两种模态**，统一输入预训练语言模型。
- 用**文本标签生成**替代固定类别分类，增强类别语义表达和跨域泛化能力。

II Methods

InstructTime 的离散化、指令构造与训练流程

总体思路：把时间序列分类转化为多模态语言建模



- 离散时间序列 token 与任务 **instruction** 共同输入 PLM。
- 模型不再输出 one-hot 类别，而是生成对应的**标签文本**。
- **跨域预训练**让不同时间序列任务共享语言模型中的模式知识。

时间序列离散化：连续信号到离散 token

- 先将原始时间序列按 **patch** 切分，降低长序列直接建模难度。
- 每个 patch 经 **1D Conv Encoder** 映射为局部表示向量。
- VQ Networks 将连续向量映射到 **codebook** 中最近的离散 code。
- 离散 code 序列可被包装为 **<BET>** TS-Token **<EET>**，进入语言模型上下文。

关键收益

把不同长度、不同通道的序列变成可统一处理的符号序列。

模态桥接

时间序列 token 与文本 token 在 PLM 输入空间中对齐。

迁移基础

跨域参数共享不再依赖每个数据集独立分类头。

指令模板：让模型知道做什么任务、看什么上下文

Domain-specific Instruction

例如：你将收到 ECG 相关时间序列信号，请判断其诊断类别。

Contextual Features

可注入年龄、性别、传感器来源等结构化上下文。

Discrete TS Token


由 VQ 网络产生的离散时间序列 token。

模板组合后的多模态输入：

Instruction Text + Contextual Features + <BET> Time Series Tokens <EET>

- 文本指令提供**任务语义**，token 序列提供时间序列观测。
- 标签也以**文本形式**出现，使类别之间的语义关系能被语言模型利用。

网络结构：InstructTime 的三阶段框架



1. Representation

VQ网络生成离散时间序列 token

2. Alignment

Projector 对齐时间序列 token 与文本 embedding。

3. Generation

PLM 通过生成目标标签完成分类。

训练流程：预训练对齐，再监督微调分类

1. Auto-regressive Pre-training

跨域多任务序列中学习 next-token prediction，建立时间序列 token 与语言 token 的共享语义空间。

Representation Alignment

通过 projector 将离散时间序列表示映射到 PLM 可接收的 token embedding 空间。

2. Supervised Fine-tuning

构造多模态输入，训练模型生成目标类别文本。

- 预训练承担**模态对齐**职责，是后续泛化能力的基础。
- **监督微调**则把统一表征适配到具体分类任务。

III Experiment

实验设置、主结果与消融分析

实验设置

输入数据

论文在五个典型时间序列分类数据集上评估 InstructTime: EEG 脑电信号、ECG 心电信号、HAR 人类行为识别、FD 工业故障检测、RWC 真实复杂场景。这些数据集覆盖医疗、行为、工业和真实世界复杂序列，类别数从 2 类到 27 类不等，用来检验模型的跨领域泛化能力。

评价指标

实验主要报告 Accuracy 与 F1 Score。Accuracy 衡量整体分类正确率；F1 Score 同时考虑 precision 与 recall，更适合类别不均衡或多类别复杂场景。论文在每个数据集上同时比较这两个指标，以避免只看准确率带来的片面判断。

基线模型

比较对象覆盖多类时间序列建模范式：自注意力模型 TST、PatchTST、FormerTime；卷积模型 MCDLNN、TCN；高效特征方法 MiniROCKET；自监督方法 TimeMAE、TS-TCC；以及面向时间序列的语言模型适配方法 GPT4TS。

实验结果

Table 1: Classification results of all compared methods over five benchmark datasets.

Compared Models	EEG		ECG		HAR		FD		RWC	
	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score
Transformer	0.7940	0.5178	0.1821	0.3691	0.9148	0.9149	0.9451	0.9564	0.7158	0.7152
Patch Transformer	0.8076	0.5460	0.2465	0.3883	0.8704	0.8683	0.9390	0.9471	0.7552	0.7545
FormerTime	0.8356	0.5828	0.3712	0.5233	0.9199	0.9198	0.9732	0.9853	0.7803	0.7796
MDCNN	0.8102	0.5395	0.0929	0.1735	0.8873	0.8862	0.9396	0.9545	0.7762	0.7759
TCN	0.7525	0.3927	0.1014	0.1654	0.9002	0.8997	0.7962	0.7248	0.7113	0.7109
MiniROCKET	0.8318	0.5638	0.2689	0.3900	0.9173	0.9153	0.9412	0.9569	0.7569	0.7556
TimeMAE	0.8248	0.5865	0.2546	0.3834	0.9294	0.9284	0.9878	0.9904	0.7690	0.7664
TS-TCC	0.7291	0.4347	0.1778	0.3780	0.8832	0.8815	0.9296	0.9363	0.6979	0.6931
GPT-As-Classifier	0.7689	0.4929	0.2253	0.3557	0.8973	0.8963	0.9489	0.9598	0.7554	0.7553
InstructTime-Universal	0.8067	0.5007	0.3402	0.4820	0.8990	0.8944	0.9619	0.9656	0.7307	0.7299
InstructTime-Adapt	0.8452	0.6240	0.4121	0.5547	0.9298	0.9307	0.9901	0.9917	0.7599	0.7578

- **InstructTime**-Universal 和 InstructTime-Adapt 在多个数据集上优于传统深度模型与自监督模型。
- 提升不仅体现在 Accuracy，也体现在更敏感的 **F1 Score**。
- 结果说明将分类转化为**生成式**多模态理解任务具有有效性。

消融实验

Table 2: Results of our InstructTime model with and without auto-regressive pre-training across domains

Models	Settings	EEG		ECG		HAR		FD		RWC	
		Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score
InstructTime-Universal	w/o Cross-Domain	0.7854	0.4854	0.2554	0.3751	0.8341	0.8296	0.9092	0.9203	0.7270	0.7268
	w/ Cross-Domain	0.8067	0.5007	0.3402	0.4820	0.8990	0.8944	0.9619	0.9656	0.7307	0.7299
InstructTime-Adapt	w/o Cross-Domain	0.8283	0.5751	0.3740	0.5209	0.9019	0.9028	0.9813	0.9830	0.7482	0.7478
	w/ Cross-Domain	0.8452	0.6240	0.4121	0.5547	0.9298	0.9307	0.9901	0.9917	0.7599	0.7578

Table 4: Performance comparison of InstructTime-Adapt in terms of w/o or w/ auto-regressive pre-training stage.

Model Variants	EEG		ECG		HAR		FD		RWC	
	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score
w/o Pre-training	0.7854	0.4854	0.2554	0.3751	0.8341	0.8296	0.9092	0.9203	0.7270	0.7268
w/ Pre-training	0.8452	0.6240	0.4121	0.5547	0.9298	0.9307	0.9901	0.9917	0.7599	0.7578

Table 5: Effect of preserving textual information during auto-regressive training on InstructTime-Adapt.

Model Variants	EEG		ECG		HAR		FD		RWC	
	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score	Accuracy	F1 Score
w/o Text	0.7748	0.4641	0.1675	0.1779	0.8697	0.8676	0.8937	0.8984	0.7492	0.7489
w/ Text	0.8452	0.6240	0.4121	0.5547	0.9298	0.9307	0.9901	0.9917	0.7599	0.7578

- 去掉跨域/自回归预训练后，多个数据集的 Accuracy 与 F1 明显下降。
- 预训练并非附加技巧，而是完成时间序列 token 与语言 token 对齐的核心阶段。

迁移学习

Table 3: Transfer learning results of external two domain with pre-trained InstructTime-Adapt on five datasets.

Models	Epilepsy		AD	
	Accuracy	F1 Score	Accuracy	F1 Score
w/o Pre-training	0.8896	0.5558	0.8045	0.7199
w/ Pre-training	0.9596	0.9355	0.9237	0.9234

外部领域

Epilepsy 与 AD 两个未参与原始训练的任务。


核心观察

经过预训练后，模型在 Accuracy 与 F1 上均显著优于无预训练版本。

这支持论文的一个关键主张：**离散化 + 指令化 + PLM 预训练**，使时间序列分类具备跨领域迁移的基础。

深入分析

w/o textual prompt



w/ textual prompt



Figure 4: T-SNE embeddings of randomly sampled instance from five datasets.

文本提示增强聚类结构

t-SNE 显示加入 textual prompt 后，不同类别表示更集中、更可分。




Figure 6: Statics of used token frequency in terms of five datasets. Each heatmap corresponds to a dataset (EEG, ECG, HAR, RWC, and DEV), with color intensity indicating the frequency of token appearance.

离散 token 具有领域差异

不同数据集的 token frequency 热力图反映了可解释的模式使用差异。

IV Conclusion

研究结论、局限与未来方向

总结

核心贡献

首次系统尝试把时间序列分类重塑为 learning-to-generate 任务，用 PLM 完成多模态理解与标签文本生成。

方法价值

通过离散化、指令模板和自回归预训练，缓解 one-hot 标签语义缺失和跨域迁移困难。

实验结论

在 EEG、ECG、HAR、FD、RWC 等基准上取得稳定提升，预训练和文本信息均被验证有效。

局限与展望

上下文信息建模能力尚未充分验证；更大规模 PLM、更多真实场景和高效推理仍值得探索。

谢谢!
