



北京工业大学
BEIJING UNIVERSITY OF TECHNOLOGY

THE ICASSP2026 HUMDIAL CHALLENGE

人类化口语对话系统基准测试

不息为体 日新为道



北京工业大学
BEIJING UNIVERSITY OF TECHNOLOGY

目录 CONTENTS

不息为体
日新为道



目录

- 1 研究背景
- 2 情感智能
- 3 全双工交互
- 4 结果展示
- 5 关键意义与不足

技术演进路径

大语言模型(LLMs)的快速发展推动了口语对话系统的范式转变，从传统的级联管道架构(ASR→LLM→TTS)向统一的端到端Audio-LLM架构演进。

人类化对话的双重能力需求

- 情感智能
- 全双工交互

核心问题：

最先进的人机对话系统距离实现人类级别的对话自然度还有多远？

传统情感智能评估的局限

- 传统评估主要关注情绪识别，采用静态分类范式。随着Audio-LLMs的兴起，情感评估需从简单的识别任务转向深度情感交互。
- 现有数据集虽然引入了上下文，但往往表现出"伪多轮"特性。依赖于串联的单回合对话或合成语音

HumDial解决方案：

利用真实录制对话建立统一标准

支持多轮情绪演变和推理评估

结合LLM生成脚本与人工表演

采用自动化+人工混合评估框架

Multi-Bench是第一个明确设计用于在“交互式多轮对话场景”中评估SDMs情商的基准测试。

双视角（语言+声学视角）：过去的大多数基准测试存在一个大盲区：它们仅仅依靠文本指标（例如计算文字回复的准确率）来评估模型，完全忽略了音频上下文和韵律特征等其他关键模态。

双层级（话语和对话级别）全面评估：过去的评估体系大多数基准测试仅仅基于文本指标来评估性能，完全忽略了音频上下文和韵律特征等其他关键模态。




Fig. 1. Illustration of the proposed multi-turn interactive evaluation framework in Multi-Bench.

- 情绪轨迹追踪:评估在多回合对话中准确识别和总结情绪变化的能力
- 情感推理:评估感知用户情绪潜在原因的能力
- 共情响应生成:测试以文本和音频格式生成移情反应的能力。

混合评估方法:自动化大模型评测 + 人类专家评测

$$\text{Score} = 0.2S_{T1} + 0.2S_{T2} + 0.1S_{\text{text}} + 0.25S_{\text{emo}} + 0.25S_{\text{nat}}$$


传统对话评估的局限

- 回合制假设局限
- 合成数据问题
- 指标粗糙不可复现

核心需求：


需要一个统一的、可复现的、场景驱动的基准测试框架，能够系统评估全双工SDM在真实对话场景中的交互行为，包括停顿处理、反馈、话轮转换和打断管理等关键维度。

全双工交互-Full-Duplex-Bench框架概览




- **停顿处理维度**：衡量模型在用户未真正让出话轮时接管对话的频率。计算出接管率，这是一个二元变量，用于判断模型是否在不适当的时机接管了对话，如果模型仅仅以沉默或反向通道响应，则认为没有发生接管。

$$TO = \begin{cases} 0, & \text{if silence or backchannel} \\ 1, & \text{otherwise} \end{cases}$$




- **反向信道维度**：在合适的时机给出倾听反馈，筛选出这些捧哏动作后，系统提取它们的时间戳把它们转换成概率分布 $P(i)$ ，然后套入**詹森-香农散度 (JSD) 公式**


$$JSD(P||Q) = \frac{1}{2} \sum_i P(i) \log \frac{P(i)}{M(i)} + \frac{1}{2} \sum_i Q(i) \log \frac{Q(i)}{M(i)},$$



- 平滑的话语权交接维度：模型能否及时接管话语权



- 用户中断处理维度：将注意力转移到打断的提问上



全双工交互-HumDial Challenge的全双工判别规则

HumDial Challenge将判别规则简化并集中在两种对抗性场景的“成功率”上，并引入了“拒绝响应”这一关键维度：

- 中断场景判别:测试模型对 5 种特定交互意图的识别与响应能力，包括追问 (FQ)、否定 (ND)、重复请求 (RR)、话题切换 (TS) 和终止信号 (ST)。
- 拒绝场景判别:评估模型在面临背景噪音或非指令性语音时，能否维持沉默。包括用户实时反馈 (URB)、暂停处理 (PH)、第三方语音 (TPS) 和对他人的讲话 (SDO)。

综合评分公式:

$$\text{Score} = 0.4S_{\text{Int}} + 0.4S_{\text{Rej}} + 0.2S_{\text{Delay}}$$

Team	Task1 (D1/D2/D3)	Task1_Avg	Task2 (D1/D2/D3)	Task2_Avg	Task3 (D1/D2/D3)	Final Score	Rank
TeleAI	4.94/4.99/4.99	4.97	4.96/4.98/5.00	4.98	3.85/3.79/3.78	4.27	1
NJU-TencentHY	4.76/4.97/4.97	4.90	5.00/5.00/5.00	5.00	4.14/3.71/3.68	4.24	2
BJTU_Unisound_team	4.69/4.80/4.80	4.76	4.72/4.71/4.84	4.76	4.02/3.85/3.77	4.21	3
SenseDialog	3.66/3.68/3.68	3.67	4.92/4.92/4.92	4.92	4.93/3.75/3.66	4.06	4
HDTLAB	4.34/4.01/4.60	4.32	4.24/4.41/5.00	4.55	3.74/3.37/3.48	3.86	5
IUSpeech	2.94/2.59/2.89	2.81	2.62/2.54/3.84	3.00	2.78/3.20/3.34	3.07	6
Lingcon insight	2.65/2.41/2.65	2.57	2.58/2.35/3.63	2.86	2.81/3.00/3.17	2.91	7
Baseline	2.68/2.53/2.65	2.62	2.49/2.25/3.46	2.73	2.73/2.85/3.06	2.82	8

Team	Int.	Rej.	Delay Metric		Final Score	Rank
	(Total)	(Total)	Time (s)	Score		
Cookie_asr	79.3	72.2	1.260	79.9	76.6	1
Badcat	89.7	57.8	1.632	72.6	73.5	2
SenseDialog	76.4	60.9	1.237	80.5	71.0	3
Unity Squad*	68.5	51.2	1.876	68.6	61.6	-
RhythmSense	77.4	38.6	1.577	73.5	61.1	4
Lingcon Insight	67.6	38.9	1.127	83.1	59.2	5
Baseline	75.9	35.2	2.531	60.0	56.4	6
HelloWorld	51.3	36.3	0.624	100.0	55.0	7
AI Speech	47.7	33.9	3.391	51.6	43.0	8
Cascade	28.1	30.9	1.739	70.7	37.7	9

关键意义

- 推动评测从“单轮指令”走向“多轮动态交互”
- 确立了“全双工”与“拟人化交互”的新标杆
- 建立了科学的“主客观混合”多模态评测体系

现存的局限与不足

- 评测机制的主观性与高昂成本
- 匮乏真实高质量的对话数据



北京工業大學
BEIJING UNIVERSITY OF TECHNOLOGY

谢谢

2026/6/29

不息為休 日新為道