



北京工业大学
BEIJING UNIVERSITY OF TECHNOLOGY

多模态大模型发展汇报

不負為休 日新為道



北京工业大学

BEIJING UNIVERSITY OF TECHNOLOGY

目录 CONTENTS

目新
不為
為道
為休



1

ViT

2

CLIP

3

LLaVA

4

Tokenizer冲突

5

统一建模的三条技术路线

6

全模态统一

7


回顾与展望



BJUT

核心问题：在CNN主导的视觉领域，Transformer能否像处理文本一样高效处理图像？


1. **图像分块**：将输入图像分割成N个 patch
2. **线性投影**：每个patch通过线性投影映射到D维向量空间
3. **位置编码**：添加可学习的位置编码，保留空间位置信息
4. **类别token**：添加一个可学习的\([CLS]\) token用于分类
5. **Transformer编码器**：通过多层自注意力机制和前馈网络处理
6. **分类头**：用\([CLS]\) token的输出进行图像分类



ViT架构：将图像切割为Patch作为Token输入Transformer

核心问题：跨模态对齐如何打破视觉与语言的壁垒，让图像和文本在同一个高维语义空间中实现精准对齐？

1. 图像编码器：使用ViT提取图像特征
2. 文本编码器：使用Transformer提取文本特征
3. 特征对齐：通过对比学习损失函数，让匹配的图文对在特征空间中靠近，不匹配的远离
4. 零样本分类：将分类任务转换为图文匹配任务，实现零样本迁移




核心问题：实现图文理解之后如何让大语言模型突破纯文本限制，真正“看见”图片并进行自然的多模态对话？

1: MLP预训练，解决CLIP特征维度与LLM词嵌入维度不匹配的问题，实现让LLM能够读懂图片的意思

2: 指令微调，多模态对话能力的涌现，针对MLP和LLM层，学会看图 + 听指令，根据用户指令和图片信息来给出回答，这样就可以实现复杂的多轮对话

预训练好的CLIP ViT (看图) + 一个MLP投影层 (翻译) + 预训练好的LLM (说话)



LLaVA架构: CLIP ViT + MLP Connector + LLM

但这套范式也存在三个根本性局限：

局限	具体表现
缺乏细粒度理解	CLIP提取的是全局图像特征，难以进行细粒度的物体定位和检测
视觉编码器的限制	CLIP的视觉特征主要针对图文对齐任务，可能不适合所有视觉理解任务
只能理解，不能生成	图像只能作为输入，模型只能输出文本，无法生成或编辑图像

根本矛盾：理解与生成的Tokenizer冲突

图像处理主要有两种Tokenizer:


- VQ-VAE
- ViT

VQ-VAE处理步骤:


步骤1: **Encoder编码** (CNN提取特征): 通过多层卷积神经网络 (CNN) 逐步采样

步骤2: **量化**: 有一个预训练好的码本, 选择距离最近的那个码本向量的索引作为输出

步骤3: **Decoder解码**: 用离散索引 z 去码本中查找对应的实际向量




图像生成 Tokenizer: VQ-VAE



图像理解 Tokenizer: ViT

统一建模的三条技术路线（一）：统一Tokenizer

使用同一个VQVAE模型，来统一处理图像理解和图像生成两个任务，简化架构。



Chameleon 架构: VQVAE-LLaMA-2 (早期融合统一序列)

统一建模的三条技术路线（二）：双编码器


解耦策略：共享一个LLM Backbone，但理解和生成各用一个独立的编码器。

理解端：用CLIP ViT提取语义特征

生成端：用VQVAE提取像素特征

LLM：作为统一的自回归“大脑”，处理两种特征、共享推理能力

两个独立编码器意味着理解和生成的特征空间仍然是分离的，难以实现深度融合。模型结构也不够“原生”。



Janus双编码器架构：共享LLM + 解耦的CLIP ViT和VQVAE

统一建模的三条技术路线（三）：纯自回归统一

将所有模态（文本、图像、音频等）统一转换为离散token序列，使用纯自回归的方式进行建模。同时引入混合专家（MoE）机制，为不同模态分配专门的专家网络。



全模态统一：从“图文”到“全模态”

传统多模态

输入：图像 + 文字 → 输出：仅文字

全模态：

输入：图像 + 音频 + 视频 + 文字 → 输出：文字 + 语音 + 图像

全模态难点：

- 模态特性差异巨大
- 数据量差异巨大
- 实时性要求高

Qwen-Omni提出了Thinker-Talker架构，通过并行处理实现低延迟流式输出。

Thinker：负责理解和生成文字

Talker：负责将文字转为语音

两者并行工作，实现低延迟流式输出。

但是Qwen-Omni目前尚未将图像生成集成进主模型。


Ming-Omni: MoE + 模态特定路由器

同时支持图像生成和语音生成。

关键创新:

Multi-Router + AnyExperts: 它基于MoE架构，并引入了模态特定路由器。传统MoE给每个Token激活固定K个专家，但不同Token的重要度差异很大——Ming让模型自己决定每个Token需要激活多少专家，按需分配算力。

MingTok统一表征: 用连续表征做理解和生成效果最好——高维语义表征做自回归输入，低维潜在表征做自回归输出，同一套范式统一图像和语音处理。



Ming-Flash-Omni的MoE跨模态融合架构: Multi-Router + AnyExperts

未来方向：

1. 理解与生成的深度相互促进。
2. 视频理解-生成-编辑一体化。
3. 新一代多模态预训练范式。

阶段	核心突破	代表模型	能力边界
视觉Transformer化 (2020)	统一视觉与语言的 底层架构	ViT	图像分类
跨模态对齐 (2021)	图文嵌入空间统一	CLIP、SigLIP	图文检索、零样本分类
多模态理解 (2023-2024)	LLM获得视觉理解能力	LLaVA、Qwen-VL、InternVL、GPT-4V	图文问答、视觉推理
理解生成统一 (2024-2025)	同一模型同时理解和生成图像	Chameleon、Janus-Pro、BAGEL	图文理解+图像生成+编辑
全模态统一 (2025-)	音视图文全面覆盖	GPT-4o、Qwen-Omni、Mini-Omni、Gemini	全模态理解+全模态生成



北京工業大學
BEIJING UNIVERSITY OF TECHNOLOGY

谢谢

2026/6/29

不息為休 日新為道