



北京工业大学
BEIJING UNIVERSITY OF TECHNOLOGY

Traj-LLM: A New Exploration for Empowering Trajectory Prediction With Pre-Trained Large Language Models



01 轨迹预测：自动驾驶的核心基石

任务本质：基于道路参与者的历史运动行为，精准推断其未来轨迹，是连接“环境感知”与“决策规划”的关键技术桥梁，直接决定自动驾驶的安全性与乘坐舒适性。

核心挑战：交通参与者运动具有强随机性，且城市道路环境复杂多变，多智能体间的交互行为难以建模，导致高精度、长时域的轨迹预测成为行业难题。

02 现有深度学习方法的局限性

主流技术路径：多采用RNN、LSTM等循环神经网络捕捉时序依赖，或通过GCN等图卷积网络建模多智能体的空间交互关系。

关键瓶颈：此类模型缺乏对复杂交通场景的高层语义理解与常识认知，无法像人类驾驶员一样结合交通规则、场景意图进行全局推理，在非结构化场景下泛化性不足。

03 大语言模型（LLM）的机遇与核心设问

技术新机遇：大语言模型具备强大的语义理解、逻辑推理与世界知识储备能力，为解决场景认知难题提供了新范式。

待解核心问题：现有LLM在轨迹预测中的应用多依赖繁琐的显式提示工程（Prompt Engineering），能否绕过这一复杂环节，直接利用预训练LLM的原生能力赋能轨迹预测，实现更高效的场景理解与轨迹推理？

无需提示工程的LLM驱动轨迹预测框架

框架定位： Traj-LLM 是面向智能体轨迹预测的开创性方案，旨在突破传统范式，在无需显式人工提示工程的条件下，直接利用预训练大语言模型（LLM）的通用推理能力，实现对智能体未来轨迹的精准推断。

三大核心创新思路：

01 原生能力直驱： 摒弃繁琐的提示词设计工作，将轨迹序列与场景上下文转化为LLM可解析的输入格式，让模型自主挖掘并学习任务所需的高层次时空规律与场景知识。


02 类人认知建模： 引入车道感知概率学习机制，模拟人类驾驶员对目标车道的聚焦习惯，让预测逻辑更贴合真实的驾驶决策过程。

03 轻量化高效适配： 采用参数高效微调技术（如LoRA），在不显著增加计算开销的前提下，快速将通用大模型适配到轨迹预测任务，兼顾精度与部署效率。

核心目标： 把大语言模型的知识迁移、泛化推理能力注入轨迹预测领域，打造一套更通用、更灵活且易于适配不同场景的智能预测框架，为自动驾驶、机器人导航等领域提供全新的技术支撑。

Traj-LLM

针对自动驾驶场景下的轨迹预测难题，Traj-LLM 创新性地将大语言模型（LLM）引入轨迹预测任务，通过四大核心模块实现从原始感知数据到多模态未来轨迹的端到端建模，兼顾交互推理与场景约束的精准捕捉。



01 稀疏上下文联合编码

融合智能体运动特征与场景地图特征，将异构数据转化为LLM可理解的Token Embedding，为后续推理奠定统一表征基础。

02 高层交互建模

利用预训练LLM挖掘智能体间的复杂交互依赖，结合LoRA技术进行高效微调，轻量化实现对动态交互关系的深度捕捉。


03 车道感知概率学习

引入Mamba序列建模模块，模拟人类驾驶员的车道聚焦认知机制，精准估计智能体在各车道段的匹配概率与行驶倾向。

04 多模态拉普拉斯解码器


基于拉普拉斯分布建模轨迹的多模态特性，生成符合交通规则与场景约束的多样化未来轨迹，提升预测的鲁棒性。

日新月异
为道体



01 高效微调：LoRA 低秩适应
冻结预训练LLM权重，通过低秩矩阵分解近似权重更新量，避免全量重训，显著降低计算开销。

核心公式： $W = W_0 + B * A$
(仅优化低秩矩阵 B 和 A, W 保持冻结)



02 车道感知：Mamba 概率建模


利用Mamba的选择性状态空间特性捕捉时序依赖，计算智能体在各车道段的决策概率分布。

关键技术详解 (1): LoRA高效微调



在 Traj-LLM 中的核心应用

LoRA 技术被深度集成于模型的“高层交互建模”模块注意力层中。训练阶段，我们冻结预训练 LLM 的全部原始参数，仅对 LoRA 引入的少量低秩矩阵进行梯度更新，以此实现参数高效微调，显著降低了训练的计算资源消耗。



01 低秩分解原理

通过低秩分解来近似权重矩阵的更新量。将原本庞大的权重更新矩阵，拆解为两个低秩矩阵 $\mathbf{B} (d \times r)$ 与 $\mathbf{A} (r \times k)$ 的乘积，其中秩 r 远小于原矩阵维度，从而极大减少待训练的参数量。


02 前向传播机制

权重更新近似为 $\hat{\mathbf{W}} \approx \mathbf{W} + \mathbf{BA}$ 。在模型推理时，输出由两部分叠加而成：原始预训练模型的输出 $\mathbf{W} \cdot \mathbf{a}_j$ ，加上 LoRA 引入的低秩更新项 $\mathbf{BA} \cdot \mathbf{a}_j$ ，既保留通用知识，又适配特定任务。

03 训练策略与优势

训练时固定主干网络参数，仅优化低秩矩阵。初始化时 $\mathbf{B}$ 为零矩阵，确保初始不干扰模型； $\mathbf{A}$ 采用高斯分布。这种方式用极少的参数量，高效实现了从通用 LLM 到轨迹预测任务的知识迁移。

Mamba: Traj-LLM中模拟人类认知的车道注意力核心



图示解析: 展示了Mamba层的内部架构，通过选择性状态空间模型(SSM)实现对车道特征的动态筛选与精炼，是车道感知概率计算的核心单元。

01 核心作用：主动聚焦与特征对齐

模拟人类驾驶员的注意力机制，动态筛选环境中最相关的车道特征；将高层交互特征与车道拓扑信息深度融合，引导预测轨迹与潜在行驶车道精准对齐，解决复杂路口的多车道决策难题。

02 车道概率计算的四步闭环

①**输入构建**：拼接高层交互状态和车道特征得输入F；②**特征精炼**：F经 InstanceNorm后送入Mamba块提炼关键特征Q；③**向量映射**：残差连接+前馈网络输出车道学习向量S；④**概率输出**：MLP映射+Softmax归一化，生成车道段概率分布。

03 关键数学表达与优化目标

- 特征变换： $Q = \text{Mamba}(\text{InstanceNorm}(F))$ (时空特征的非线性提炼)
- 概率归一化： $p(i, t) = \exp(\text{MLP}(S_i)) / \sum \exp(\text{MLP}(S_j))$ (Softmax概率分布)
- 损失优化： $L_{\text{lane}} = \sum L_{\text{CE}}(p_t, \tilde{p}_t)$ (基于二元交叉熵的时序累积损失)

性能对比与可视化验证


01. 核心指标全面领先现有SOTA

在nuScenes公开数据集的对比实验中，Traj-LLM展现出显著优势：

- **K=5场景**：minFDE5 降至 2.46，MR5 低至 0.41，相比 GATraj (4.08) 与 AgentFormer (3.14)，轨迹终点预测误差大幅降低；
- **K=10场景**：minFDE10 达到 1.73，MR10 仅为 0.25，在多路径预测任务中兼顾了精度与覆盖率；
- 模型在 minADE、minFDE 及漏检率 MR 三项关键指标上实现了综合最优，证明了其对交通场景的深度理解能力。

02. 复杂动态场景的鲁棒性

面对路口交汇、车辆加塞、行人横穿等高密度交互场景，模型仍能稳定输出高精度轨迹，有效解决了传统方法在动态环境下的预测发散问题。



可视化结果解读：

图中绿色线条代表真实行驶轨迹，红色线条为 Traj-LLM 的预测轨迹。可见在多车并行、弯道转向等复杂场景下，预测轨迹与真实轨迹高度贴合，精准捕捉了车辆的行驶意图与路径变化趋势。

01 主要结论

- 1. LLM潜力释放：**预训练大语言模型无需显式提示工程，即可有效捕捉轨迹预测任务中的高层语义信息与复杂交互特征。
- 2. 认知机制模拟：**基于Mamba的车道感知概率学习机制，能够精准模拟人类驾驶员的车道聚焦、注意力分配与决策认知模式。
- 3. 性能突破SOTA：**在nuScenes公开数据集的评测中，Traj-LLM的ADE、FDE等关键预测指标全面超越现有主流轨迹预测模型。
- 4. 强泛化少样本：**即使仅使用50%的训练数据，模型仍能保持优越的预测性能，展现出极强的鲁棒性与跨场景泛化能力。



北京工业大学
BEIJING UNIVERSITY OF TECHNOLOGY

谢谢!

不息为体
日新为道