北京工業大學
BEIJING UNIVERSITY OF TECHNOLOGY

Recent Advances in Discrete Speech Tokens: A Review

离散语音Tokens的前沿进展综述

小焦為体 日新為道

北京工業大學
BEIJING UNIVERSITY OF TECHNOLOGY

目录
CONTENTS

目标为道 以体为

目录

1 研究背景与动机

2 离散表示学习基础

3 声学令牌

4 语义令牌

5 离散语音令牌的分析

6 挑战与未来方向

1.研究背景与动机

在大型语言模型时代，语音生成技术的快速发展已经建立了离散语音标记作为语音表示的基本范式。这些令牌具有离散、紧凑和简洁的特点，不仅有利于高效传输和存储，而且与语言建模框架具有固有的兼容性能够将语音无缝集成到以文本为主的LLM架构中。目前的研究将离散的语音令牌分为两大类:声学令牌和语义令牌。

- 声学令牌：旨在重构语音的波形细节，保留所有声音特性，包括说话人音色、韵律、情感和背景环境。
- 语义令牌：主要关注语音中的语言内容和意义，忽略说话人的音色、背景噪音等声学细节。

综述了概述各种类型的离散语音标记的概念、方法和特征，以及它们在口语理解、语音生成和口语对话模型中的应用。构建了当前离散语音令牌研究的综合分类，并仔细回顾了每个子类别中的代表性方法。

1.研究背景与动机

论文介绍了一种语音标记化的思路将两个研究方向联系起来。

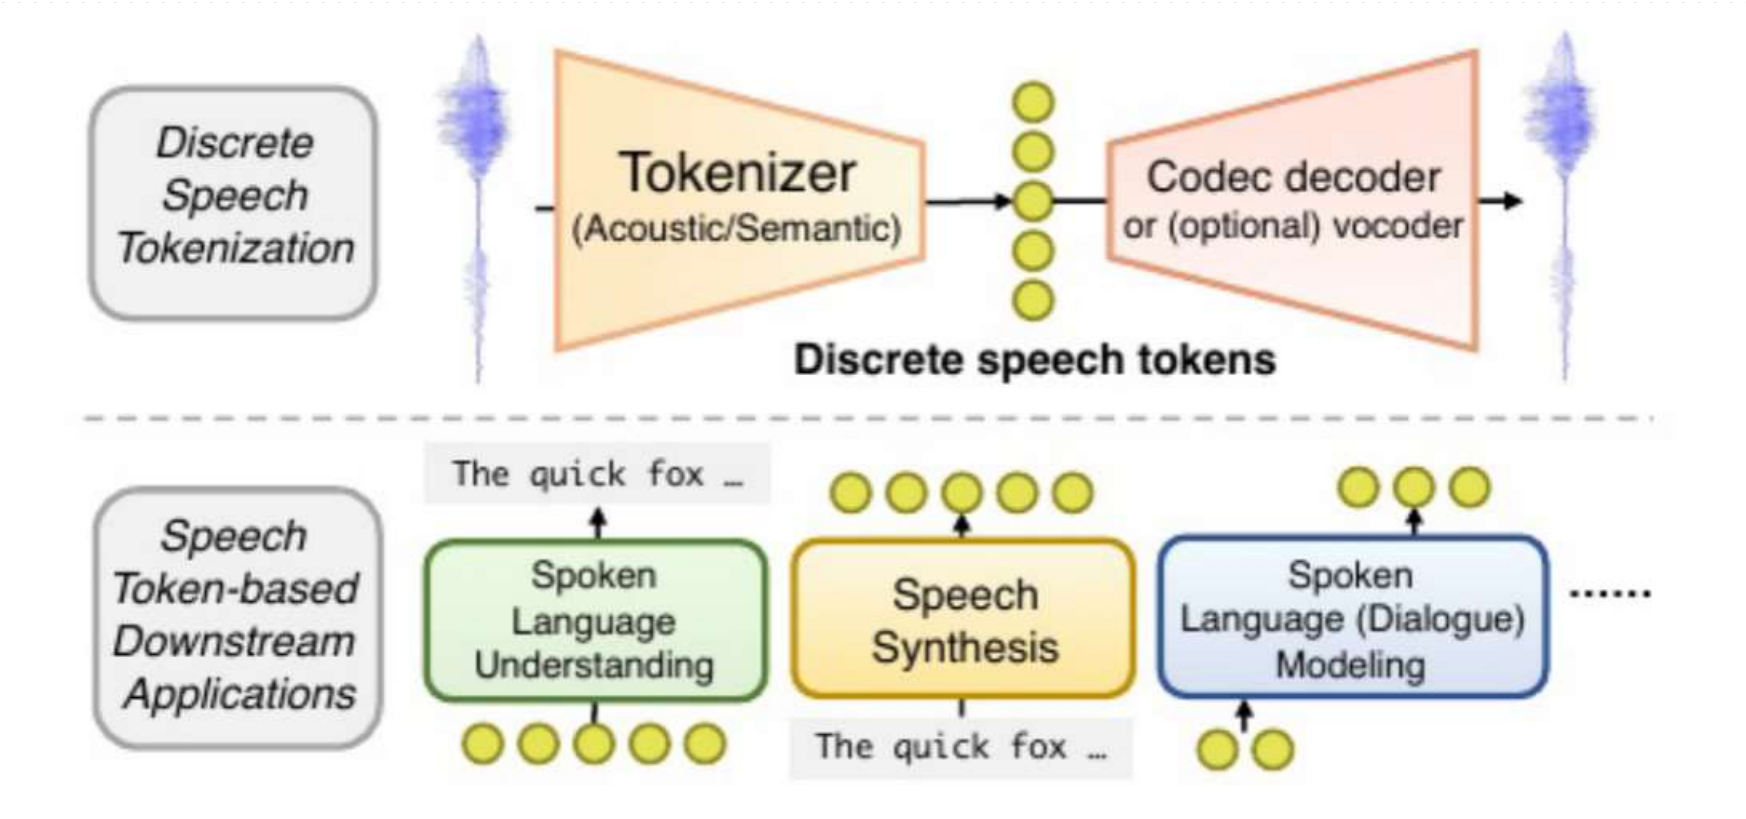

离散语音标记化过程和基于语音标记的下游应用示意图。

2.离散表示学习基础

- 量化方法：**离线聚类**与**矢量量化**

- 离线聚类：将语音特征分组，相似的归于一类。聚类通常是一个孤立的过程，因此不能与其他神经网络模块一起优化。

- 矢量量化(VQ)：使一个可学习的网络模块能够在产生离散表示时允许梯度通过。

2.离散表示学习基础

- 离线聚类

- k-means聚类，它的训练过程迭代地将每个数据样本分配到最近的质心，并移动聚类质心直到收敛，具有预定义的聚类数量。训练完成后，这些质心形成码本，新的数据可以量化为分区中最近质心的索引。

2.离散表示学习基础

■ 矢量量化（单模块）

- K-means VQ：与K-means聚类一样，K-means VQ方法找到最接近输入向量的代码向量，使用直通估计器 (STE) 传递梯度，辅助损失（Commitment loss, Codebook loss）来训练。

- Gumbel VQ：使用 Gumbel-Softmax 分布进行可微分采样，按概率选择最大 Logit 对应的索引。

- FSQ：在标量域进行量化，将每个维度的值映射到有限的整数范围。

2.离散表示学习基础

■ 矢量量化（多模块）

□ GVQ：将输入向量切分为多个子向量，分别独立进行量化

□ RVQ：串行级联量化。每一级量化器量化上一级的残差（误差）

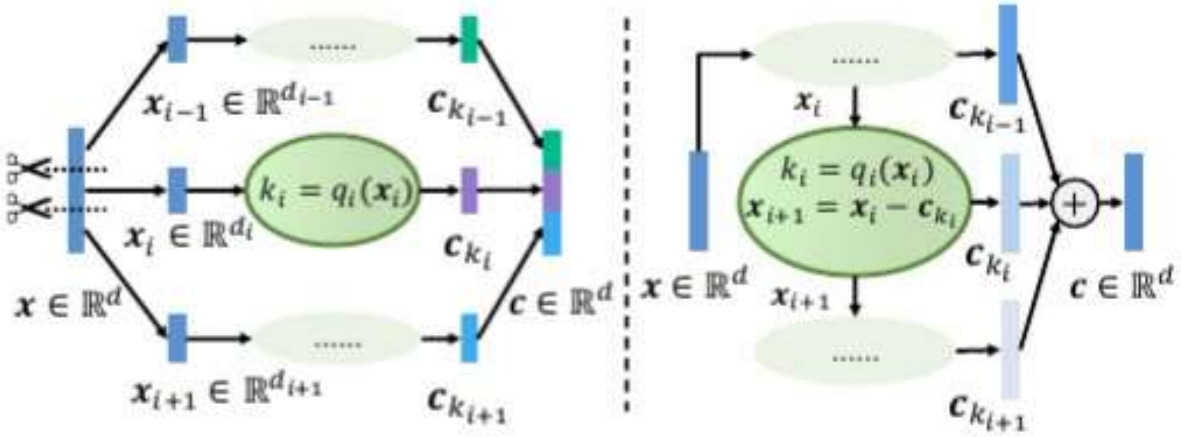

图3:GVQ(左)和RVQ(右)示意图。GVQ对输入向量的不同分区进行独立量化，而RVQ对残差进行顺序量化。

2.离散表示学习基础

离散语音常用量化方法	具体方法名称	核心原理简述
离线聚类	K-means	迭代地将数据样本分配给最近的质心，直到收敛。
矢量量化（单模块）	K-means VQ	寻找与输入向量最近的码本向量，使用直通估计器 (STE) 传递梯度 。
	Gumbel VQ	使用 Gumbel-Softmax 分布进行可微分采样，按概率选择最大 Logit 对应的索引 。
	Finite Scalar Quantization (FSQ)	在标量域进行量化，将每个维度的值映射到有限的整数范围 。
矢量量化（多模块）	Grouped VQ (GVQ)	将输入向量切分为多个子向量，分别独立进行量化 。
	Residual VQ (RVQ)	串行级联量化。每一级量化器量化上一级的残差（误差） 。

3.acoustic tokens -- 模型架构

■ Acoustic tokens来自神经网络音频Codec，核心目标是“低比特率下还原高质量语音”，主要有**VQ-GAN**和**扩散**两大模型。

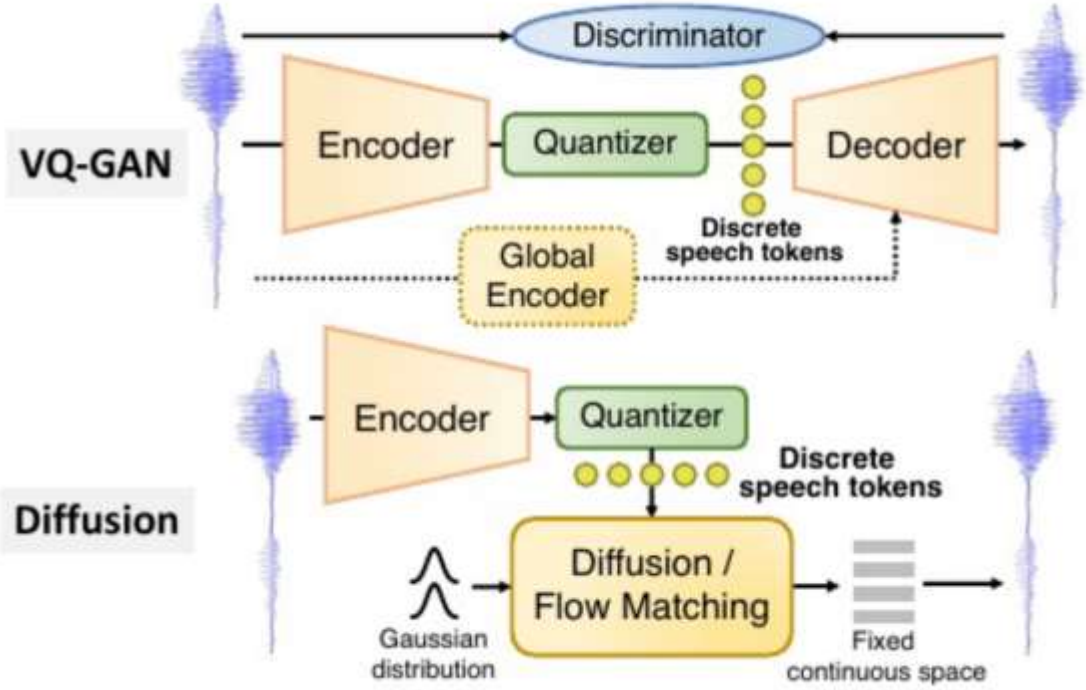

3.acoustic tokens -- 模型架构

VQ-GAN模型最具代表性三种生成器架构

- CNN-based：轻量，流式友好（固定感受野）。SoundStream的encoder/decoder纯由CNN构成，EnCodec在CNN基础上加了LSTM提取长时依赖；
- Transformer-based：缩放性好，大模型性能强。处理波形时先进行切块转换为向量，再输入Transformer进行处理，在流式场景下需要通过“因果注意力机制”来确保模型只看过去的信息，不看未来的信息。
- U-Net-based：多分辨率量化——在U-Net的不同层加VQ（浅层抓高频，深层抓低频），能灵活控重建粒度，但不同层的tokens关联性复杂，LLM难建模。

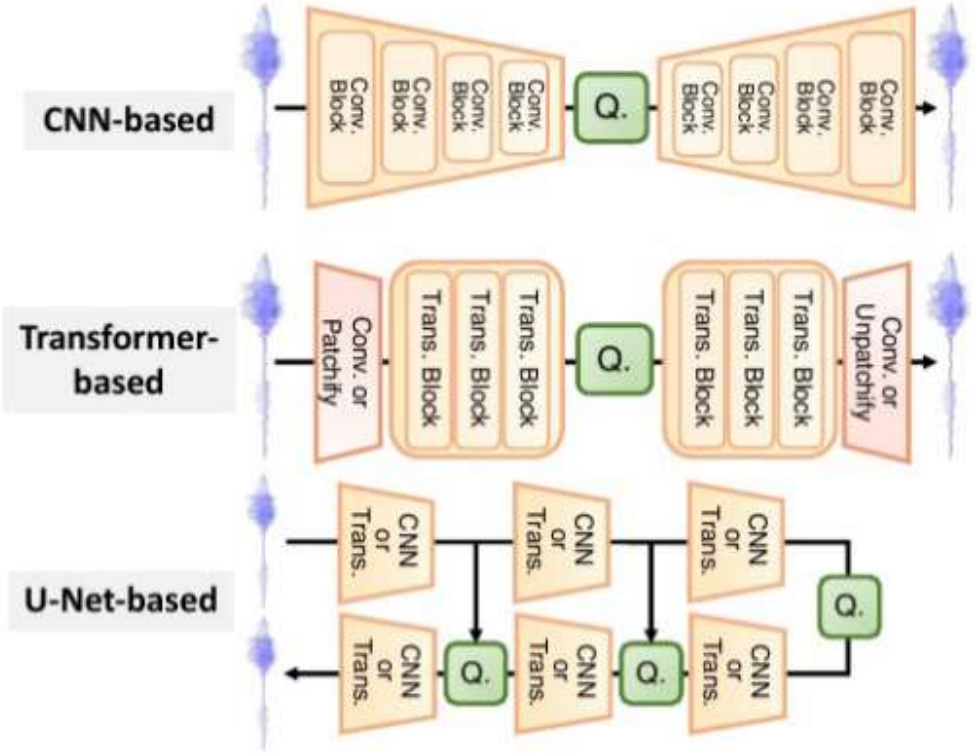

图5:基于vq - gan的声学令牌的主要生成器架构。“Conv.”、“Q.”和“Trans”。分别是convolution、quantizer和Transformer的缩写。

3.acoustic tokens -- 模型架构

扩散模型不需要GAN，训练更简单。不用鉴别器，靠“迭代去噪”生成语音——encoder输出tokens，decoder用tokens当条件，把高斯噪声一步步转成语音谱图，最后用vocoder转波形。
优点：训练目标简单（MSE损失），不用调GAN
缺点：推理慢（要100-1000步去噪），实时场景不友好。

架构对比

VQ-GAN更成熟，CNN快、Transformer准、U-Net灵活，但要调鉴别器；扩散不用对抗训练，但推理慢。
根据场景选择模型：实时用VQ-GAN（CNN），离线高质量用扩散。

3.acoustic tokens -- 通用声学令牌

声学令牌旨在以尽可能低的比特率实现更好的客观或感知质量。
常用方法如下：

- 先进的VQ方法和模型架构：基于SoundStream和EnCodec，深入研究了更多具有先进VQ方法、网络结构或优化策略的编解码器。

- 减少时间冗余:一些研究人员试图降低时变VQ码的冗余比特率，而不是像前面提到的编解码器那样通过VQ层捕获所有信息。

- 多分辨率和可变比特率编码:与其仅仅依赖于单分辨率令牌，其中所有量化器共享相同的时间频率，设计多分辨率编解码器，在编解码器中合并多个时间分辨率降低必要的比特率。

3.acoustic tokens -- 带有语义蒸馏的声学令牌

常规声学令牌太过于关注还原波形，导致它们把噪音、环境音、冗余信息全记录下来了。这使得令牌的信息密度太高，语义不清晰。所以提出了带有语义蒸馏的声学令牌，常用方法如下：

- 语义特征指导:利用 RVQ 的分层特性，让第一层令牌主要负责保留高质量语义信息，后面的层级负责保留声学信息。

- 固定语义码本:不再随机初始化码本，而是使用大语言模型已经训练好向量作为码本，让码本自身带有保又语义信息。

- 语义特征作为输入或输出:语义特征也可以与声学特征一起压缩。这就需要编码器和量化器构建一个共享的声学和语义空间，以平衡两个信息源。

3.acoustic tokens -- 解耦(Disentanglement)声学令牌

解耦声学令牌目标也是混合目标声学令牌，其将语音表示分解为独立的子空间，通常分为语义和声学两部分。主要有几下方法：

- 梯度反转层:使用对抗式训练将语音分解为语义和声学信息。判别器获取参数中的声学信息发回一个反馈信号。对抗式训练会反转信号，编码器收到反转信号后就会消除声色信息知道找不到声学信息为止，这样就只剩下语义信息了

- 扰动:它的核心逻辑叫做不变性。取一段原始语音，对它进行信号处理生成扰动版本，将两端音频同时放入内容编码器，保证语义令牌必须一致，内容编码器保留相同的部分，即纯净的语义信息，声学编码器则重构得到声学信息。

- 声源分离:基于信号处理的频域分离，声音的不同成分往往分布在不同的频率或信号子空间里，将原始波形通过转换成复数声谱图，强制划分频谱信息分流到不同的通道中。

3.acoustic tokens

常用acoustic tokens汇总

Acoustic Speech Tokens	Model Framework	Sampling Rate (kHz)	Quantization Method	Q	F (Hz)	V	Bitrate (kbps)
General-purpose acoustic tokens							
SoundStream [69]	VQ-GAN (C)	24	RVQ	max 24	75	1024	max 18.00
EnCodec [70]	VQ-GAN (C)	24	RVQ	max 32	75	1024	max 24.00
TF-Codec [55]	VQ-GAN (C)	16	GVQ	3-32	25	512 / 1024	0.68-8.00
Disen-TF-Codec [21]	VQ-GAN (C)	16	GVQ	2 / 6	25	256 / 1024	0.40 / 1.50
AudioDec [76]	VQ-VAE (C)+GAN	48	RVQ	8	160	1024	12.80
HiFi-Codec [39]	VQ-GAN (C)	16 / 24	GRVQ	4	50-100	1024	2.00-4.00
DAC [19]	VQ-GAN (C)	44.1	RVQ	9	86	1024	7.74
LaDiffCodec [17]	Diffusion	16	RVQ	3 / 6	50	1024	1.50 / 3.00
FreqCodec [71]	VQ-GAN (C)	16	RVQ	max 32	50	1024	max 16.00
TiCodec [22]	VQ-GAN (C)	24	RVQ, GVQ	1-4	75	1024	0.75-3.00
APCodec [82]	VQ-GAN (C)	48	RVQ	4	150	1024	6.00
SRCodec [280]	VQ-GAN (C)	16	GRVQ	2-8	50	512+1024	0.95-3.80
SQ-Codec [89]	VQ-GAN (C)	16	FSQ	1	50	19^{32}	8.00
Single-Codec [72]	VQ-GAN (T+C)	24	VQ	1	23	8192	0.30
ESC [75]	VQ-GAN (U)	16	GVQ	max 18	50	1024	max 9.00
CoFi-Codec [74]	VQ-GAN (U)	16	GVQ	3	8.33+25+50	16384	1.17
HILCodec [84]	VQ-GAN (C)	24	RVQ	2-12	75	1024	1.50-9.00
SuperCodec [85]	VQ-GAN (C)	16	RVQ	2-12	50	1024	1.00-6.00
SNAC [23]	VQ-GAN (C)	24	RVQ	3	12+23+47	4096	0.98
WavTokenizer [90]	VQ-GAN (C)	24	VQ	1	40 / 75	4096	0.48 / 0.90
BigCodec [91]	VQ-GAN (C)	16	VQ	1	80	8192	1.04
LFSC [281]	VQ-GAN (C)	22.05	FSQ	8	21.5	$8 \times 7 \times 6 \times 6$	1.89
NDVQ [88]	VQ-GAN (C)	24	RVQ	max 32	75	1024	max 24.00
VRVQ [24]	VQ-GAN (C)	44.1	RVQ	dynamic, max. 8	86	1024	0.26 + max 6.89
TS3-Codec [20]	VQ-GAN (T)	16	VQ	1	40 / 50	65536 / 131072	0.64-0.85
Stable-Codec [60]	VQ-GAN (T)	16	FSQ	1 / 2	25	5^6 / 6^6	0.40 / 0.70
FreeCodec [94]	VQ-GAN (C+T)	16	VQ	1+1	50+7	256	0.45
FocalCodec [282]	VQ-GAN (T+C)	16	FSQ	1	12.5 / 25 / 50	2^{13}	0.16 / 0.33 / 0.65
ALMTokenizer [283]	VQ-GAN (T)	24	RVQ	3	12.5	2048	0.41
TFC [172]	VQ-GAN (C)	24	RVQ	8	dynamic, 18.75-75	1024	1.50-6.00
CodecSlime [173]	VQ-GAN (C)	16	FSQ	1	dynamic, ≈40	$5^2 \times 3^6$	0.08 + (≈0.60)
Mixed-objective acoustic tokens: semantic distillation							
Siahkoohi et al. [100]	VQ-GAN (C)	16	RVQ	2+1 / 2+2 / 6	25+50	64	0.60 / 0.90 / 1.80
SpeechTokenizer [13]	VQ-GAN (C)	16	RVQ	8	50	1024	4.00
SemantiCodec [18]	Diffusion	16	VQ	2	12.5-50	8192+(4096-32768)	0.31-1.40
LLM-Codec [25]	VQ-GAN (C)	16	RVQ	3	8.33+16.67+33.33	3248+32000+32000	0.85
X-Codec [26]	VQ-GAN (C)	16	RVQ	max 8	50	1024	max 4.00
SoCodec [92]	VQ-GAN (C)	16	GVQ	1 / 4 / 8	25 / 8.3 / 4.2	16384	0.35 / 0.47
Mimi [14]	VQ-GAN (C+T)	24	RVQ	8	12.5	2048	1.10
X-Codec 2.0 [102]	VQ-GAN (C+T)	16	FSQ	1	50	4^8	0.80
BiCodec [93]	VQ-GAN (C)	16	VQ	1	50	8192	0.65
DualCodec [284]	VQ-GAN (C)	24	RVQ	3 / 6	12.5 / 25	(1024 / 16384)+(1024 / 4096)	0.75-0.93
XY-Tokenizer [104]	VQ-GAN (T)	16	RVQ	8	12.5	1024	1.00
TaDiCodec [279]	Diffusion	24	FSQ	1	6.25	2^{14}	0.0875
Mixed-objective acoustic tokens: disentanglement							
SSVC [27]	VQ-GAN (C)	24	RVQ	4	50	512	1.80
PromptCodec [285]	VQ-GAN (C)	24	GRVQ	1-4	75	1024	0.75-3.00
FACodec [28]	VQ-GAN (C)	16	RVQ	1+2+3	80	1024	4.80
LSCodec [29]	VQ-VAE (C+T)+GAN	24	VQ	1	25 / 50	1024 / 300	0.25 / 0.45
SD-Codec [30]	VQ-GAN (C)	16	RVQ	12	50	1024	6.00
DeCodec [31]	VQ-GAN (C)	16	RVQ	8+8	50	1024	8.00

4.semantic tokens

语义令牌指的是来自判别或自监督学习(SSL)模型的离散语音表示。语义令牌不追求重建，而是抓语音里的核心语义，适合语音识别(ASR)、翻译这些任务。主要用**SSL**和**判别模型**来实现。

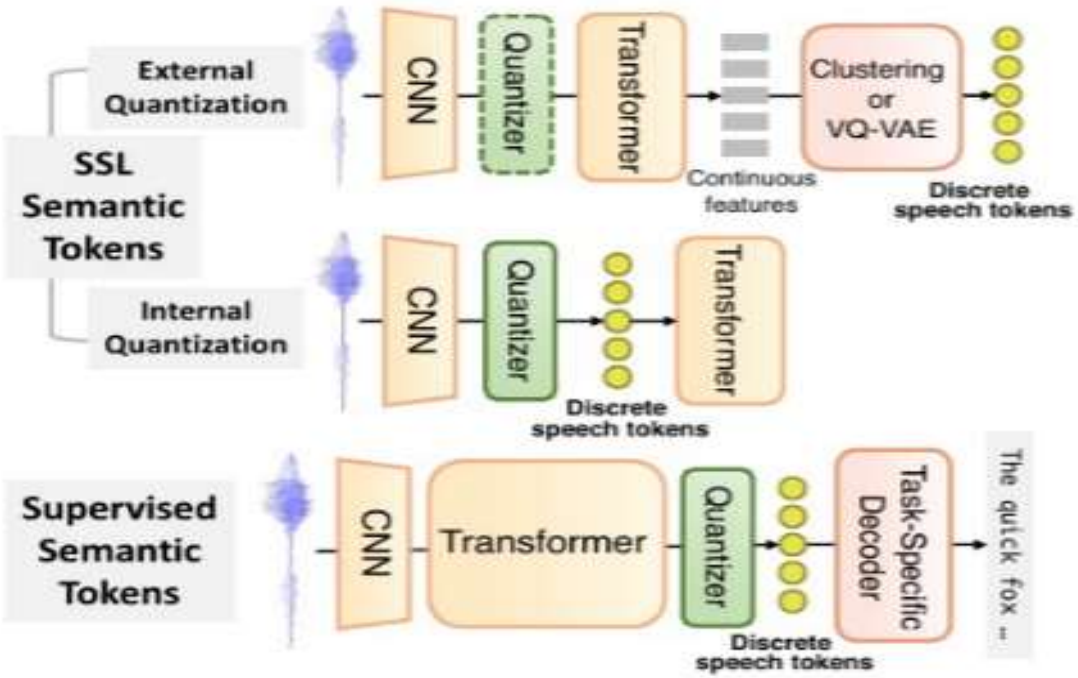

图7:不同类型语义标记的表示。虚线框表示模块是可选的。

4.semantic tokens -- SSL模型的语义令牌

SSL模型通过定义一个借口任务来启动学习过程，该任务使模型能够直接从数据本身学习有意义的表示。捕捉语音中的语言内容、音素和语义信息，同时尽可能去除说话人身份、背景噪音和录音质量等“无关”的声学细节。

两类生成方法：

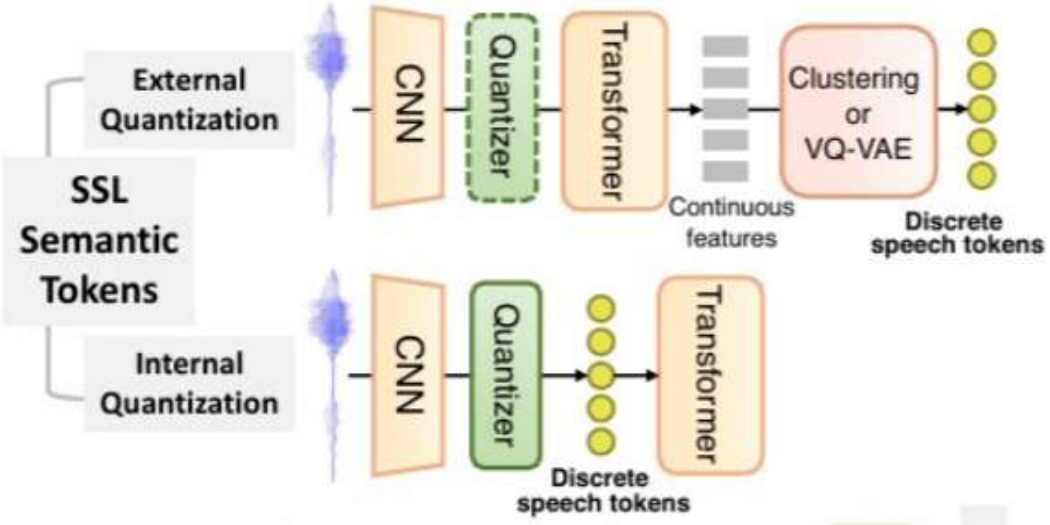

4.semantic tokens -- 来自监督模型的语义令牌

与无监督的 SSL 模型不同，这类方法通过有监督学习 (Supervised Learning) 直接训练模型来提取语义。最典型的任务就是 ASR（自动语音识别），给它一段录音（语音），强迫它准确地写出对应的文字（文本）。

4.semantic tokens -- 语音令牌编码器

前面的步骤是把声音压缩成了一串令牌，那么语音令牌编码器就是负责把这串令牌还原成可以听到的声音波形的组件。语义标记本质上不需要声码器。然而，当语义标记用于语音生成时，语音标记声码器就变得必要了。

文中提到了以下结合了声学提示的特定声码器模型：

- CTX-vec2wav提出了一种与位置无关的交叉注意机制，该机制可以有效地集成来自周围声学环境的音色信息，而无需进行预训练的扬声器嵌入。

- vec2wav 2.0引入了SSL音色特性和自适应激活来提高音色可控性，并报告了具有竞争力的VC性能。

5.离散语音令牌的分析

Token Type	Token Model (version)	Bitrate↓ (kbps)	Reconstruction				Voice Conversion			Semantic Modeling	
			WER↓	GPE↓	PESQ↑	STOI↑	WER↓	SECS↑	P.Corr↑	ASR WER↓	IC ACC↑
Continuous Baselines	Ground Truth Recording	-	1.16	0.00	4.50	1.000	-	-	-	-	-
	Mel + BigVGAN (100 band)	-	1.18	0.88	4.30	0.995	-	-	-	17.4	50.1
Acoustic (General-Purpose)	EnCodec ($Q = 8$)	6.00	1.53	1.33	2.83	0.946	-	-	-	19.4	34.8
	DAC (24kHz, $Q = 8$)	6.00	1.34	0.93	3.52	0.958	-	-	-	26.1	18.3
	TiCodec ($Q = 2$)	1.50	3.31	1.51	2.00	0.898	2.62	0.642	0.886	26.4	41.7
	SNAC (24kHz)	0.98	2.25	1.48	2.23	0.914	-	-	-	35.4	16.7
	WavTokenizer (Small, $F = 75$Hz)	0.90	2.45	1.63	2.47	0.925	-	-	-	37.2	15.5
	Stable-Codec (2 residual FSQ)	0.70	4.94	1.73	2.16	0.917	-	-	-	*NC*	14.0
Acoustic (Semantic Distillation)	SpeechTokenizer	4.00	1.47	1.20	2.60	0.930	-	-	-	19.3	57.3
	X-Codec (HuBERT LibriSpeech)	4.00	1.27	1.49	2.82	0.905	-	-	-	9.8	69.6
	Mimi	1.10	2.44	1.68	2.27	0.917	-	-	-	26.8	50.9
	LLM-Codec	0.85	6.25	1.86	1.82	0.879	-	-	-	*NC*	16.2
	SemantiCodec (F=25Hz, V=2^{13}+2^{15})	0.70	3.44	2.28	1.75	0.866	-	-	-	*NC*	26.8
Acoustic (Disentanglement)	FACodec (with *detail* codes)	4.80	1.37	1.02	2.91	0.954	1.57	0.773	0.583	14.6	51.1
	LSCodec ($F = 50$Hz)	0.45	3.33	2.42	1.77	0.688	4.04	0.852	0.697	25.3	49.8
Semantic (SSL)	vq-wav2vec (k-means)	1.80	2.81	2.73	1.49	0.795	3.27	0.857	0.718	16.9	58.7
	wav2vec 2.0 (Large, inner quantizer)	0.90	3.24	2.92	1.52	0.680	4.40	0.814	0.759	22.0	51.9
	wav2vec 2.0 (Large, L14+km2048)	0.55	2.51	9.57	1.20	0.630	2.81	0.880	0.492	5.8	69.5
	HuBERT (Large, L24+km2048)	0.55	1.86	15.65	1.17	0.625	1.97	0.876	0.375	6.1	67.2
	WavLM (Large, L24+km2048)	0.55	1.67	17.94	1.16	0.621	1.92	0.872	0.374	6.1	74.2
	ContentVec (L12+km2048)	0.55	2.09	18.88	1.15	0.613	2.21	0.869	0.348	5.5	72.0
Semantic (Supervised)	$\mathcal{S}^3$ Tokenizer ($F = 50$Hz)	0.60	2.12	4.25	1.37	0.673	2.52	0.868	0.687	17.5	67.2

6.挑战与未来方向

目前的离散语音令牌仍然表现出一定的局限性和挑战

- 难以生成极低码率令牌，目前的语音令牌帧率仍然远高于文本，导致长序列建模困难；但如果强行降低帧，又会导致语音质量和可懂度明显下降 。
- 流式能力与效率；实时应用要求模型必须是流式的，CNN 架构容易实现流式，但 SSL 模型依赖未来的信息，这使得由它们导出的语义令牌难以用于实时任务 。
- 可变帧率令牌研究不足，语音信息的密度是不均匀的，固定帧率会导致浪费。
- 声学令牌目前的解耦技术仍然不成熟
- 不同的应用对噪声的需求不同（有的需要还原背景音，有的需要去除）。目前尚不清楚各类令牌在不同信道和噪声环境下的表现 。

北京工業大學
BEIJING UNIVERSITY OF TECHNOLOGY

谢谢

2026/4/21

不負為体 日新為道