用于实时事件预测的动态异构图神经网络

汇报人: 韦浩文

时间: 2026-2-8

目录

01 背景

02 方法

03 实验

04 总结

1 背景

背景

4个典型网约车事件
预览（PreView）
叫车（Request）
取消订单（Cancel_Order）
完成订单（Finish_Order）

异构会话（h-session）
同一个交易中的一系列事件的集合

研究目标
预测PreView事件转化率——对PreView事件进行建模，预测用户点击Request的概率

研究意义
车辆调度...

影响用户点击Request的因素
显性（位置、时间...）——直接提取
隐性（等待意愿、支付意愿...）——考虑历史行为和周边环境——?

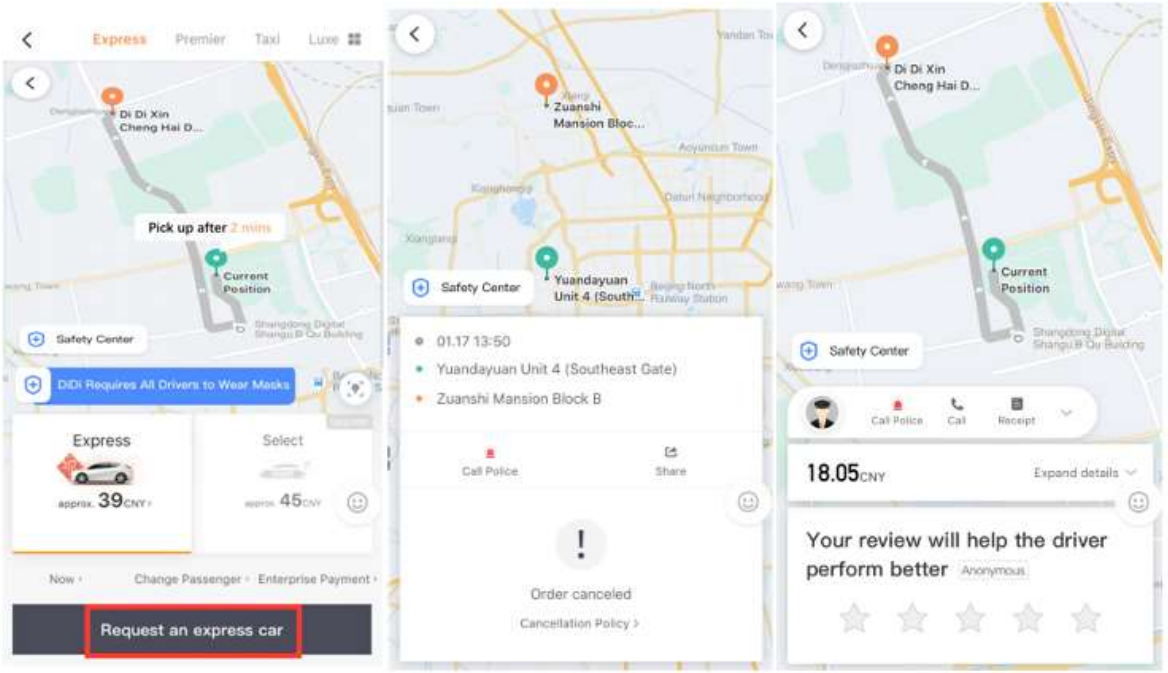

(a) PreView and Request (b) Cancel_Order (c) Finish_Order

2 方法

实时事件预测框架

构建动态异构图

↓

REGNN生成嵌入

↓

生成最终预测

构建动态异构图

$$G_{P_T} = HetG_{p,T} + HetG_{o,T} + HetG_{d,T}$$

$$P_T = (p, o, d, T)$$

乘客子图 $HetG_{p,T}$

历史行为

选乘客在时间T之前 N_p 个预览事件和它对应的叫车（如有）、完成订单（如有）、取消订单（如有）事件，作为目标预览事件的邻接节点，并添加相应类型的边。添加边时会先在同一个异构会话的事件之间添加边，然后将整个异构会话视为一个虚节点，添加乘客子图异构会话到目标预览事件之间的边。

出发地子图 $HetG_{o,T}$

选时间T之前x分钟内与目标预览事件具有相同出发地的预览事件，和它对应的叫车（如有）、完成订单（如有）、取消订单（如有）事件，作为目标预览事件的邻接节点，并添加相应类型的边。添加边时会先在同一个异构会话的事件之间添加边，然后将整个异构会话视为一个虚节点，添加出发地子图异构会话到目标预览事件之间的边。

周边环境

目的地子图 $HetG_{d,T}$

选时间T之前x分钟内目的地为目标预览事件出发地的预览事件，和它对应的叫车（如有）、完成订单（如有）、取消订单（如有）事件，作为目标预览事件的邻接节点，并添加相应类型的边。添加边时会先在同一个异构会话的事件之间添加边，然后将整个异构会话视为一个虚节点，添加目的地子图异构会话到目标预览事件之间的边。

REGNN生成嵌入——3层GAT

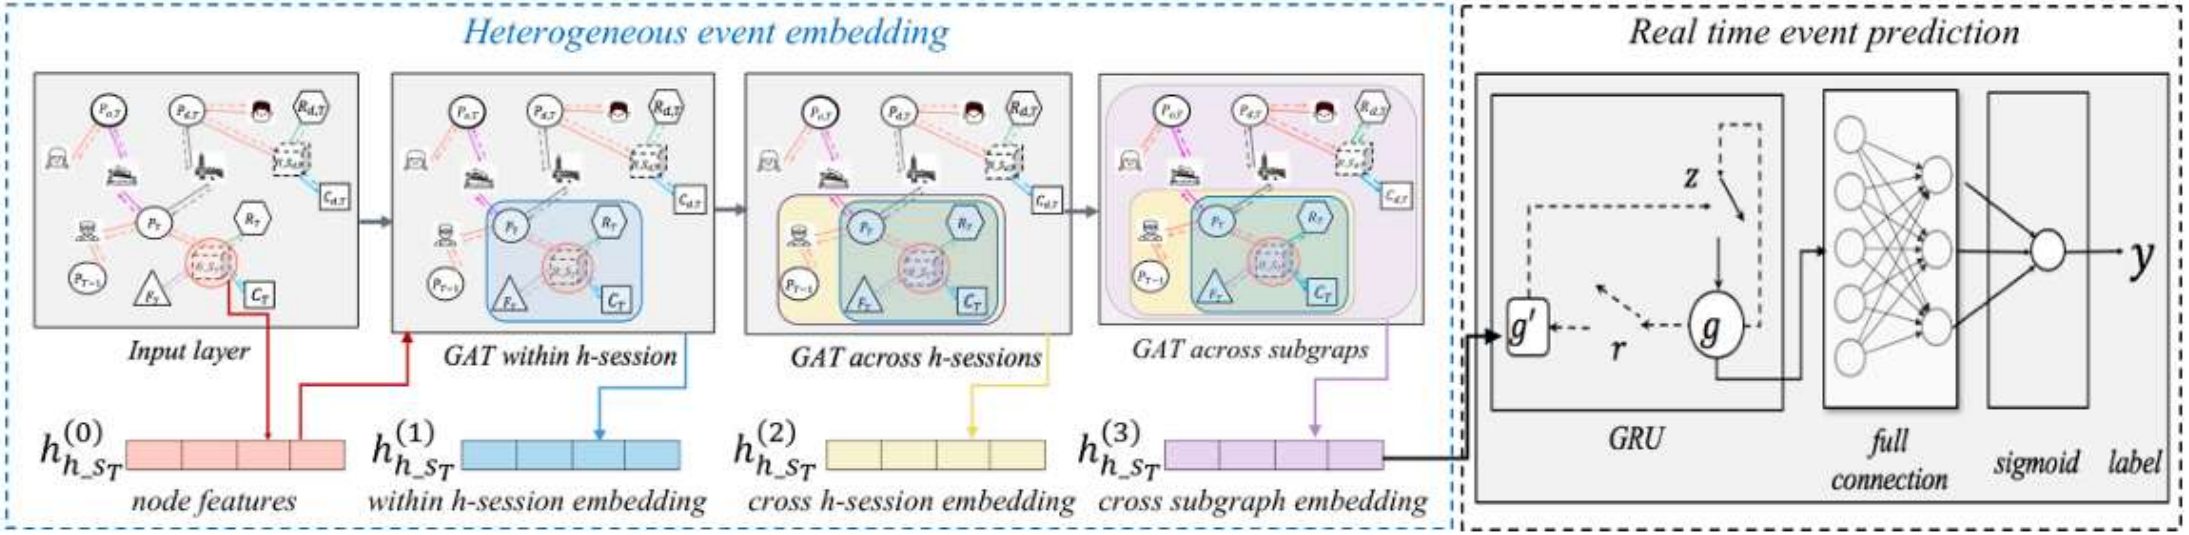

异构会话内的图注意力网络

输入： h-session内所有事件（P/R/F/C）的原始特征、h-session初始状态 $h^{(0)}_{h_s}$（通过P事件的原始特征初始化）

输出： 该h-session第一层嵌入 $h^{(1)}_{h_s}$

$$h^{(1)}_{h_s} = \oplus_{k=1}^{K} \sigma\Big(\sum_{i \in O_V} \alpha^{k}_{h_s,i} W^{k}_{i} f_i\Big)$$

$$\alpha^{k}_{h_s,i} = \frac{\sigma(W^{k} \cdot [W^{k}_{h} h^{(0)}_{h_s} \oplus W^{k}_{i} f_i])}{\sum_{j \in O_V} \sigma(W^{k} \cdot [W^{k}_{h} h^{(0)}_{h_s} \oplus W^{k}_{j} f_j])}$$

REGNN生成嵌入——3层GAT

跨异构会话的图注意力网络

输入： 同一个子图（乘客/出发地/目的地）内多个h-session的第一层嵌入 $h^{(1)}_{h_s}$ ，来自上一层

输出： 三个子图各自的跨会话聚合嵌入

$$h^{(2)}_{h_s_{T,p}} = GAT_p(h^{(1)}_{h_s_{T-t,p}}), \forall t, 0 <= t <= N_p$$

$$h^{(2)}_{h_s_{T,o}} = GAT_o(h^{(1)}_{h_s_{T-t,o}}), \forall t, 0 <= t <= N_o$$

$$h^{(2)}_{h_s_{T,d}} = GAT_d(h^{(1)}_{h_s_{T-t,d}}), \forall t, 0 <= t <= N_d$$

$$h^{(2)}_{h_s_{T,p}} = \oplus_{k=1}^{K_p} \sum_{t=0}^{N_p} \alpha^k_{t,T} W_l^{p,k} h^{(1)}_{h_s_{T-t,p}}$$

$$\alpha^k_{t,T} = \frac{\sigma(W^{p,k} \cdot [W_l^{p,k} h^{(1)}_{h_s_{T,p}} \oplus W_l^{p,k} h^{(1)}_{h_s_{T-t,p}}])}{\sum_{j=0}^{N_p} \sigma(W^{p,k} \cdot [W_l^{p,k} h^{(1)}_{h_s_{T,p}} \oplus W_l^{p,k} h^{(1)}_{h_s_{T-j,p}}])}$$

跨子图的图注意力网络

输入： 三个子图各自的跨会话聚合嵌入

输出： 当前预览事件的完整图嵌入

$$h^g_{P_T} = h^{(3)}_{h_s_T} = GAT_g(h^{(2)}_{h_s_{T,p}}, h^{(2)}_{h_s_{T,o}}, h^{(2)}_{h_s_{T,d}})$$

$$h^{(3)}_{h_s_T} = \oplus_{k=1}^{K_g} \sum_{i \in O_G} \alpha^k_{i,T} W_l^{g,k} h^{(2)}_{h_s_{T,i}}$$

$$\alpha^k_{i,T} = \frac{\sigma(W^{g,k} \cdot [W_l^{g,k} h^{(2)}_{h_s_{T,p}} \oplus W_l^{g,k} h^{(2)}_{h_s_{T,i}}])}{\sum_{j \in O_G} \sigma(W^{g,k} \cdot [W_l^{g,k} h^{(2)}_{h_s_{T,p}} \oplus W_l^{g,k} h^{(2)}_{h_s_{T,i}}])}$$

REGNN生成嵌入——GRU

GRU工作原理

$$z_T = \sigma(W_z \cdot E_T \oplus U_z \cdot h_{T-1})$$

$$r_T = \sigma(W_r \cdot E_T \oplus U_r \cdot h_{T-1})$$

$$\tilde{h_T} = tanh(W \cdot E_T \oplus U(r_T \circ h_{T-1}))$$

$$h_T = (1 - z_T) \circ h_{T-1} + z_T \circ \tilde{h_T}$$

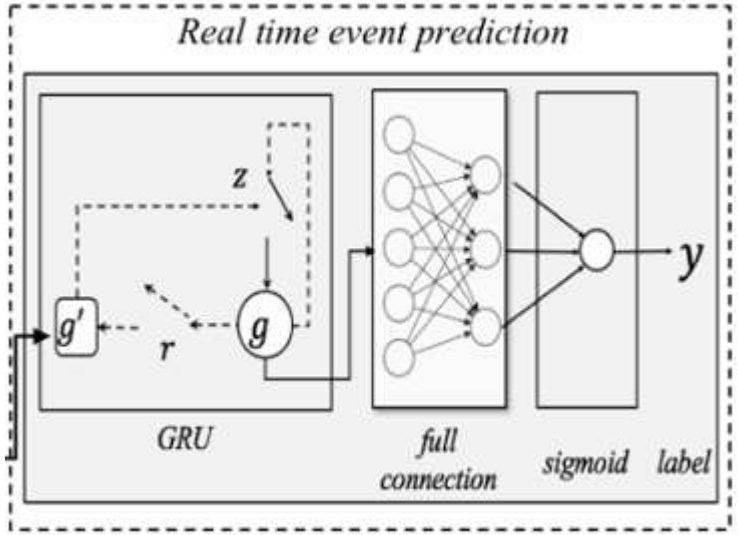

交叉熵损失+L2正则化

$$L = -\sum_{u \in U} \sum_{t=1}^{T} y_T^u log(\sigma(\theta \cdot h_T^u)) - (1 - y_T^u) log(1 - \sigma(\theta \cdot h_T^u)) + \lambda ||\theta||_2$$

3 实验

实验

数据集

滴滴真实日志，一周训练，下一周测试

评估指标

AUC——衡量模型区分正例和负例的能力

ACC——分类准确率，预测结果和真实标签一样的样本数占样本总数的比例

对比实验

REGNN vs DNN、DIN、DIEN、MIMN、SRGNN

DNN、DIN、DIEN、MIMN——点击率预测模型

SRGNN——同构图+GCN+GRU

消融实验

乘客子图作用最关键；

出发地子图比目的地子图能提供更多有效信息

Table 3: Performance Of Different Methods On Preview Event Prediction

Method	AUC(mean ± std)	ACC(mean ± std)
DNN	0.6854 ± 0.0008	0.7025 ± 0.0003
DIN	0.6817 ± 0.0001	0.7017 ± 0.0003
DIEN	0.6769 ± 0.0005	0.7027 ± 0.0003
MIMN	0.6895 ± 0.0002	0.7024 ± 0.0002
SRGNN	0.6901 ± 0.0008	0.7028 ± 0.0003
REGNN	**0.7684± 0.0006**	**0.7369± 0.0006**

Table 4: Influence Of Different Types Of Graphs On PreView Dataset

Model	AUC	Decrement
REGNN(with all subgraphs)	**0.7684**	-
REGNN(*w/o o subgraph*)	0.7599	0.0085
REGNN(*w/o d subgraph*)	0.7624	0.0060
REGNN(*w/o p subgraph*)	0.7098	**0.0586**

实验

参数实验

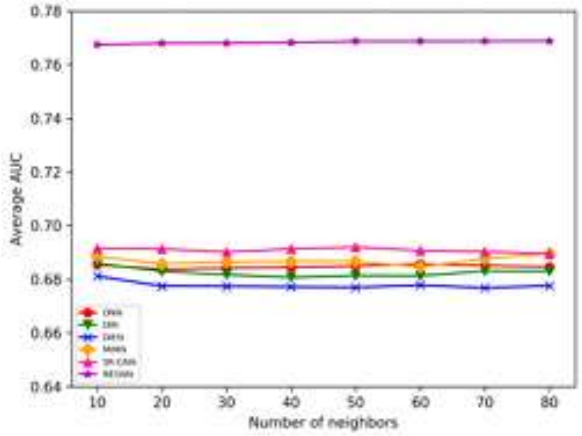

(a) Number of Neighbors

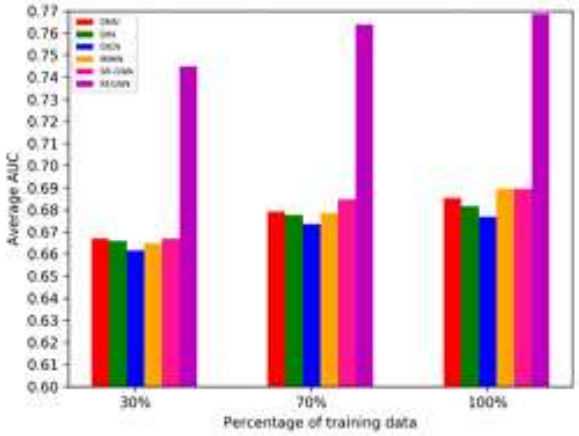

(b) Sample Rate

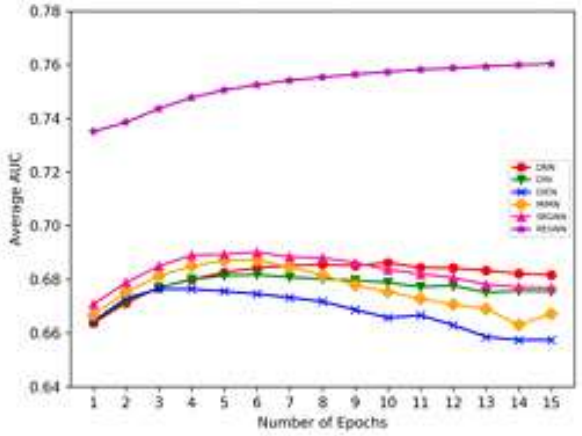

(c) Epoch Number

不同时序建模单元的有效性

Table 5: Results Of Different Modeling Units On PreView Dataset

Units	AUC	Units	AUC
GRU	**0.7684**	LSTM	0.7623
M-GRU	0.7657	LSTM+Attention	0.7585
Relu-GRU	0.7630	GAT	0.7584
GRU+Attention	0.7629	GCN	0.7566
M-Relu-GRU	0.7616	Pooling	0.7593

4 总结

总结

- **总结:**本文提出了一种通过构建动态异构图实现实时事件预测的新框架。通过由多层GAT+GRU组成的REGNN网络，从包含多种事件类型和复杂关系的异构图中聚合邻域信息，并进一步提取时序信息。离线和在线实验均表明，框架能显著提升实时事件预测的性能，目前框架已经部署到在线生产环境，每日处理数千万次事件预测请求。

TGSI、SATL

《 Towards Measuring and Modeling Geometric Structures in Time Series Forecasting via Image Modality 》

时间序列几何结构指数TGSI

形状感知时间损失SATL

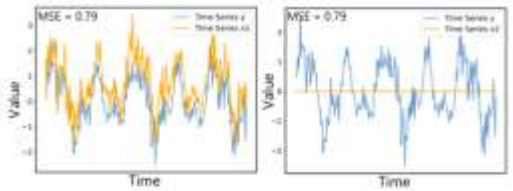

Figure 2: Comparison of time series y with x_1 (left) and x_2 (right). Both have MSE = 0.79, but x_1 shows a closer geometric resemblance to y.

MAE—— $\mathcal{L}_{MAE}(x,y) = \frac{1}{T}\sum_{t=1}^{T}|x(t)-y(t)|$

MSE—— $\mathcal{L}_{MSE}(x,y) = \frac{1}{T}\sum_{t=1}^{T}(x(t)-y(t))^2$

TGSI

1.时间序列转化成图像：归一化——映射——垂直扩展

2.公式定义：亮度组件*协方差组件

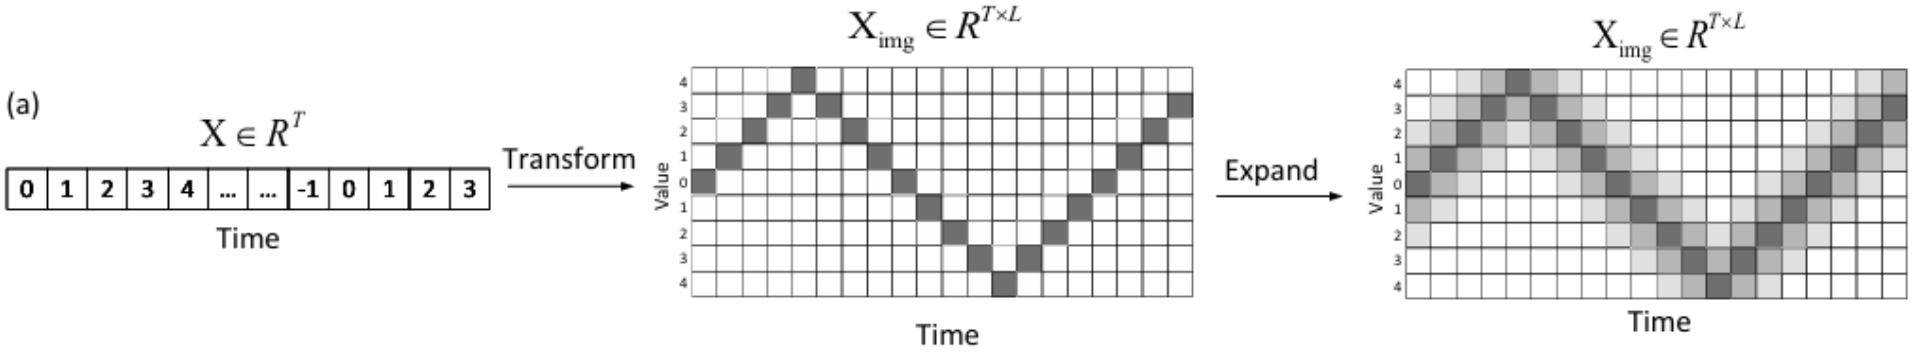

$$\mathrm{TGSI}(x,y) = l(x,y)\cdot s(x,y), \qquad l(x,y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2+\mu_y^2+C_1}, \qquad s(x,y) = \frac{\sigma_{xy}+C_2}{\sigma_x\sigma_y+C_2},$$

TGSI、SATL

SATL

$$\mathcal{L}_{\mathrm{SATL}}(x,y) = \alpha\mathcal{L}_{\mathrm{diff}}(x,y) + \beta\mathcal{L}_{\mathrm{freq}}(x,y) + \gamma\mathcal{L}_{\mathrm{perceptual}}(x,y)$$

一阶时间损失

$$\mathcal{L}_{\mathrm{diff}} = \frac{1}{(T-1)}\sum_{t=1}^{T-1}\left(\mathbf{diff}_x(t) - \mathbf{diff}_y(t)\right)^2.$$

$$\mathbf{diff}_x(t) = \mathbf{x}(t+1) - \mathbf{x}(t), \quad t = 1, 2, \ldots, T-1.$$

频域损失

$$\mathcal{L}_{\mathrm{freq}} = \frac{1}{\sqrt{T}}\left(\mathcal{L}_{\mathrm{dom}} + \mathcal{L}_{\mathrm{noise}}\right)$$

$$\mathcal{L}_{\mathrm{dom}} = \sum_{f\in\mathcal{F}_{\mathrm{dom}}}\left|\mathrm{FFT}(\mathbf{x})_f - \mathrm{FFT}(\mathbf{y})_f\right|.$$

$$\mathcal{L}_{\mathrm{noise}} = \sum_{f\notin\mathcal{F}_{\mathrm{dom}}}\left|\mathrm{FFT}(\mathbf{x})_f\right|.$$

TGSI、SATL

$$\mathcal{L}_{\text{total}}(x, y) = \mathcal{L}_{\text{SATL}}(x, y) + \delta \mathcal{L}_{\text{MSE}}(x, y)$$

感知特征损失

(b)

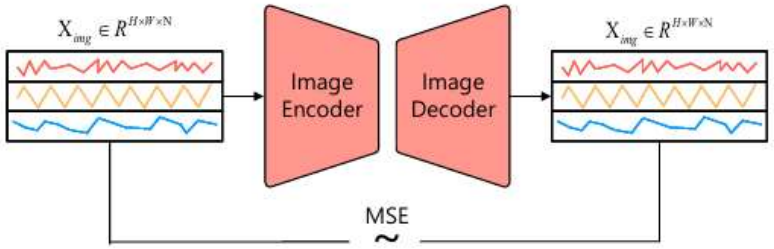

$$\mathcal{L}_{\text{ae}} = \|\text{img}(\mathbf{x}) - \hat{\text{img}}(\mathbf{x})\|_2^2.$$

(c)

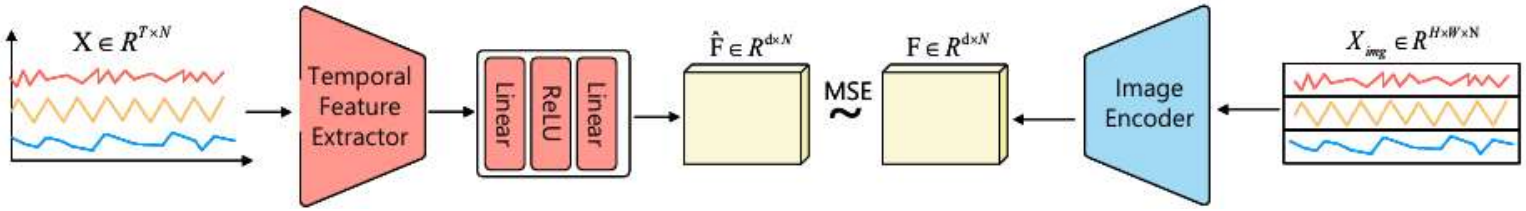

$$\mathbf{z}_{\text{time}} = f_{\text{time}}(\mathbf{x}),$$

$$\mathcal{L}_{\text{time}} = \|\mathbf{z}_{\text{time}} - f_{\text{enc}}(\text{img}(\mathbf{x}))\|_2^2.$$

(a)

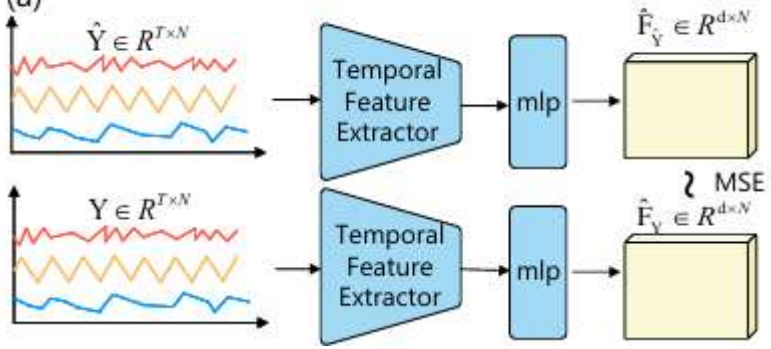

$$\mathcal{L}_{\text{perceptual}} = \frac{1}{d_z}\|\mathbf{z}_x - \mathbf{z}_y\|_2^2.$$

$$\mathbf{z}_x = f_{\text{time}}(\mathbf{x})$$

$$\mathbf{z}_y = f_{\text{time}}(\mathbf{y})$$

谢谢大家!

汇报人: 韦浩文

时间: 2026-2-8