



Node Role-Guided LLMs for Dynamic Graph Clusterin

汇报人: 韦浩文

时间: 2026-6-14



目

录

01 背景

02 方法

03 实验

04 总结



1

背景



背景

■ 什么是动态图聚类

结合动态图的拓扑结构和时序关联，识别社区结构并持续追踪其变化

■ 研究现状

- 基于神经网络的方法——两阶段，先学习节点特征，再聚类
- 基于矩阵分解的方法——联合优化学特征和聚类
- 基于LLM的方法
 - GNN作为预测器——LLM丰富节点特征
 - LLM作为预测器——将图的拓扑结构转换为文本提示词输入到LLM进行聚类推理

■ 局限

- 黑盒，无法对聚类过程给出语义层面的解释



背景

■ 挑战

LLM为用自然语言解释聚类结果提供了新方向，但想要生成真实可信的解释，面临3大挑战：

- 面向聚类的表征学习
- 结构-语义对齐
- 规范LLM推理过程

■ DyG-RoLLM

端到端可解释动态图聚类框架

- ✓ 正交子空间分解
- ✓ 5类角色原型+3层语义描述
- ✓ 思维链+GNN和LLM双向交互




2


方法



DyG-RoLLM



Cluster-aware Graph Encoding



输入图快照序列

GAT提取单个时间步下图快照的网络拓扑特征

GRU融合不同时间步的信息提取时序变化规律

对融合了空间+时间的最终节点嵌入做正交子空间分解，
分解为聚类子空间和角色子空间

➤ 理论依据：正交投影后的两个子空间是梯度隔离的，
训练互不干扰


➤ 聚类子空间：社区划分

➤ 角色子空间：角色学习+语义解释

聚类子空间：

输出——聚类概率分布矩阵

Interpretable Node-Roles Learning



角色子空间:

节点角色定义: 共5种角色, 分别是P1 (领导者——高中心性节点)、P2 (贡献者——连接数量中等的常驻节点)、P3 (游离者——处于社区边缘、连接关系较少的节点)、P4 (连接者——社区之间的桥梁节点)、P5 (新成员——近期刚加入网络的节点)

角色原型初始化: 人工构造每种角色的先验特征->MLP映射到角色子空间->得到5个角色原型

角色-嵌入对齐: 计算节点的角色子空间特征和5个角色原型的相似度->通过对比学习联合优化节点特征和角色原型->输出角色概率分布矩阵


角色-语义对齐: 依据模板函数从节点、社区、演化三个维度生成节点角色的结构化语义描述

- 社区特征: 所有节点角色概率逐维度累加求平均
- 演化模式: 6种, 分别是诞生、消亡、扩张、收缩、分裂、合并。计算相邻两个时间步的社区特征差值判断属于哪种演化模式
- 语义描述示例:

基于节点角色的描述

- 节点层面:** 节点 v_{23} 以领导者特征为主 (占比 70%), 同时兼具部分贡献者属性 (占比 20%)。该节点共有 45 条连接, 介数中心性为 0.82, 是网络中至关重要的核心枢纽。
- 社区层面:** 节点 v_{23} 隶属于 3 号社区 (共 89 名成员), 该社区整体角色构成为: 领导者占 15%、贡献者占 50%、游离者占 25%、连接者占 8%、新成员占 2%。作为这个层级化核心社群的主要领导者, v_{23} 与另外 12 名领导者协作, 维系整个社区的结构稳定性。
- 演化层面:** 在上一个时间周期内, 该社区呈现**规模扩张**趋势, 新成员流入比例达 18%, 同时核心领导层保持稳定。节点 v_{23} 的领导者属性占比从 55% 提升至 70%, 说明在社区扩张阶段, 其核心领导地位得到进一步巩固。

Hierarchical LLM Reasoning



输入：三层语义描述

LLM 5步思维链

- 1.角色-社区匹配度分析：评估单个节点的角色分布与各个社区整体角色构成的契合程度
- 2.角色供需平衡评估：分析全网不同社区之间的角色分布是否存在失衡问题
- 3.演化 - 角色匹配校验：将节点自身的角色变化轨迹，与所属社区的演化规律做匹配
- 4.结构可行性校验：结合节点真实连接关系，验证聚类分配是否符合网络拓扑规则
- 5.时序一致性评估：参考节点历史归属，评估跨时间步的群体迁移成本，保证结果时序平稳

输出：聚类概率分布矩阵

训练时——计算聚类子空间的输出和LLM的输出的一致率，筛选LLM输出的高置信度节点，定义一致性损失
GNN和LLM双向交互

推理时——最终聚类结果=0.7*聚类子空间输出的聚类结果+0.3*LLM输出的聚类结果、5步思维链生成的完整解释



3

实验



实验设置

■ 数据集

- 4个合成动态图数据集
- 6个真实场景动态图数据集

■ 基线模型

- 基于神经网络的方法: node2vec、RNNGCN、SepNE、ROLAND、TGC、DSCPCD
- 基于矩阵分解的方法: PisCES、DYNMOGA、NE2NMF、RTSC、RDMA、DyG-MF
- 基于大语言模型的方法: ComGPT、CommLLM

■ 评估指标

- NMI——归一化互信息，衡量两个概率分布之间的相似性
- NF1——归一化的F1分数

实验结果——性能评估

Table 2: Overall performances on dynamic graphs. Bold and Underline indicate the best and second-best performing methods. Symbol † indicates that DyG-RoLLM significantly surpassed all baselines with a p-value < 0.005. N/A means that it cannot be executed due to memory and running time constraints.

Methods	BD-30K		EC-30K		BD-100K		DR-100K		MS-100K		Wikipedia		Dublin		arXiv		SO		Flickr		Youtube		
	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	NMI	NF1	
NN-based	node2vec [16]	93.8	85.8	93.2	83.6	90.3	84.2	91.2	85.6	89.0	78.2	33.5	10.2	50.3	23.2	44.3	26.8	40.3	23.3	42.4	25.5	42.8	24.5
	RNNGCN [74]	96.6	84.5	95.9	85.1	90.8	84.9	92.1	84.3	91.2	80.9	40.3	22.5	52.2	31.6	45.4	26.2	40.8	23.8	48.5	30.2	47.6	32.3
	SepNE [35]	92.5	89.4	92.1	81.8	89.1	82.2	89.0	81.1	89.2	78.6	31.4	9.8	49.2	21.0	42.8	25.8	39.2	22.1	40.3	22.4	39.5	21.0
	ROLAND [76]	95.5	83.2	94.1	83.8	<u>92.8</u>	85.1	93.3	85.8	92.8	81.6	42.2	22.3	53.6	31.6	46.8	27.6	44.8	29.2	47.5	31.4	48.4	33.2
	TGC [39]	95.3	83.0	93.8	83.6	92.0	84.5	92.8	85.4	91.5	81.2	41.3	22.3	52.8	31.3	45.8	26.8	44.6	29.0	47.8	31.6	47.9	32.6
	DSCPCD [66]	89.2	69.8	88.9	70.3	81.2	65.8	79.6	63.5	81.0	64.4	28.2	7.3	32.4	11.9	31.8	10.9	34.4	18.6	34.3	18.2	32.6	15.9
MF-based	PisCES [36]	91.2	41.6	92.6	49.0	N/A	N/A	N/A	N/A	N/A	N/A	32.1	9.9	46.3	16.2	38.2	14.5	N/A	N/A	N/A	N/A	N/A	N/A
	DYNMOGA [14]	<u>98.1</u>	78.1	98.2	65.3	N/A	N/A	N/A	N/A	N/A	N/A	36.2	9.9	49.8	20.1	39.1	24.5	N/A	N/A	N/A	N/A	N/A	N/A
	NE2NMF [33]	97.1	76.1	97.5	63.1	N/A	N/A	N/A	N/A	N/A	N/A	34.1	8.2	47.9	18.9	38.2	22.9	N/A	N/A	N/A	N/A	N/A	N/A
	RTSC [77]	92.8	55.3	92.1	53.2	N/A	N/A	N/A	N/A	N/A	N/A	30.6	11.3	46.6	19.3	38.2	20.2	N/A	N/A	N/A	N/A	N/A	N/A
	RDMA [53]	95.3	69.8	94.8	85.5	N/A	N/A	N/A	N/A	N/A	N/A	33.8	10.2	47.2	18.6	41.6	25.2	N/A	N/A	N/A	N/A	N/A	N/A
	DyG-MF [28]	99.9	<u>90.2</u>	<u>99.2</u>	<u>90.9</u>	92.3	<u>86.8</u>	<u>94.3</u>	<u>86.5</u>	<u>94.4</u>	<u>83.2</u>	<u>50.4</u>	<u>25.8</u>	<u>56.1</u>	<u>33.7</u>	<u>51.8</u>	<u>30.2</u>	<u>45.5</u>	<u>29.6</u>	<u>52.3</u>	<u>33.6</u>	<u>51.8</u>	<u>34.5</u>
LLMs	ComGPT [49]	90.4	70.2	90.2	71.3	82.5	65.9	81.2	65.4	83.4	65.5	30.5	8.9	45.9	19.4	35.5	16.7	38.2	20.1	38.2	20.6	36.2	20.6
	CommLLM [17]	88.3	68.7	86.2	69.1	79.3	63.2	75.8	60.1	79.2	62.3	26.4	7.2	38.8	14.4	30.3	10.5	32.2	17.3	33.3	18.2	30.8	15.1
	DyG-RoLLM	99.9	90.4	99.4	91.7 [†]	94.3 [†]	90.9 [†]	96.2 [†]	88.6 [†]	95.4 [†]	84.8 [†]	51.6 [†]	26.7 [†]	57.6 [†]	35.2 [†]	53.3 [†]	32.1 [†]	47.6 [†]	30.9 [†]	54.2 [†]	34.8 [†]	52.7 [†]	35.3 [†]

Table2——聚类精度

Figure2——时序稳定性（A-B）

Figure2——无标签指标：模块度和电导上的表现（C）

模块度：衡量社区内部边的密集程度

电导：衡量不同社区之间的分割效果




Figure 2: Performance comparison of (A-B) varying time-stamps and (C) modularity and density of selected baselines.



实验结果——可解释性评估

定量指标评估

定义两个可解释性量化指标

- 角色一致性分数（RCS）——衡量节点角色随时间变化的稳定性，分值越接近 1，角色特征越稳定
- 解释保真度分数（EFS）——统计解释内容中符合真实图结构的表述占比，分值越高，解释越贴合客观事实

Table 3: Interpretability on real-world dynamic graphs.

Method	Wikipedia		Dublin		SO	
	RCS↑	EFS↑	RCS↑	EFS↑	RCS↑	EFS↑
ComGPT (+CoT)	0.69	0.58	0.64	0.55	0.71	0.60
CommLLM (+CoT)	0.62	0.51	0.58	0.47	0.65	0.53
DyG-RoLLM (w/o Role)	0.75	0.66	0.68	0.68	0.83	0.82
DyG-RoLLM (w/o CoT)	0.85	0.64	0.82	0.66	0.87	0.68
DyG-RoLLM	0.88	0.89	0.88	0.90	0.92	0.91

人工专家评估

邀请 3 名图挖掘领域专家，随机选取 50 条模型解释，采用 5 分制量表，从清晰度、逻辑合理性、信息完整性、可信度、落地指导性五个维度打分

Table 4: Human evaluation with average scores on 1-5 scale.

Method	Clarity	Soundness	Complete	Trust	Action
ComGPT (+CoT)	3.2	2.8	2.6	2.9	2.5
CommLLM (+CoT)	2.9	2.5	2.4	2.6	2.3
DyG-RoLLM (w/o Role)	3.5	3.3	3.1	3.4	3.2
DyG-RoLLM (w/o CoT)	3.8	3.6	3.4	3.7	3.5
DyG-RoLLM (full)	4.4	4.5	4.3	4.6	4.2

实验结果——其他补充实验




Figure 3: Efficiency comparison on large dynamic graphs.

Table 5: Ablation and strategy replacement of DyG-RoLLM.

	Methods	Wikipedia		arXiv	
		NMI↑	NF1↑	NMI↑	NF1↑
Remove	w/o Orthogonal Subspace	42.2	22.4	43.5	15.8
	w/o Clustering loss Eq.(6)	50.3	25.6	51.6	30.0
	w/o Temporal loss Eq.(7)	51.0	26.3	52.5	31.7
	w/o Contrastive loss Eq.(11)	50.6	25.7	51.7	30.1
	w/o Consistent loss Eq.(16)	50.0	25.1	51.2	29.7
	w/o Role-Guided Description	48.3	24.1	46.2	16.4
	w/o LLM Reasoning	47.2	23.8	45.1	16.0
Replace	Random Prompt Init	51.0	26.4	52.9	32.0
	GPT-3.5-turbo	50.3	25.9	52.0	31.4
	Claude-3.5	50.8	26.0	52.6	32.0
	Llama2-7B	50.1	25.8	51.9	31.2
	DyG-RoLLM (full)	51.6	26.7	53.3	32.1




Figure 4: Noise Attacks. NMI w.r.t. percentage of noisy edges.




Figure 5: Hyperparameter tuning results.



4

总结



总结



- **总结:** 针对现有的动态图聚类方法的局限性和可解释动态图聚类面临的挑战，论文提出了一个端到端的可解释动态图聚类框架DyG-RoLLM，它通过正交子空间分解同步学聚类规律和可解释性特征，通过5种角色定义+3层语义描述实现结构-语义对齐，通过5步思维链规范LLM推理过程，通过双向优化实现了GNN和LLM的优势互补。在合成及真实动态图数据集上的大量实验表明，该模型聚类效果、可解释性等均优于现有方法。





谢谢大家!

汇报人: 韦浩文

时间: 2026-6-14